

Band der Arbeiten zur Wirtschaft

*Formale Theorie, Systemanalyse und Lösungen für stabile,
dezentralisierte Wirtschaftssysteme unter Unsicherheit*

Sieben Wissenschaften zu wirtschaftlicher Stabilität,
Unsicherheit, Dezentralisierung und Risikomanagement

Stephan Epp

07. September 2026

Band der Arbeiten zur Wirtschaft

Autor: Stephan Epp

Herausgegeben: 07. September 2026

Dieser Band sammelt sieben wissenschaftliche Arbeiten
zu einer kohärenten Darstellung von Wirtschaftstheorie,
Systemanalyse und praktischer Implementierung.

Alle Rechte vorbehalten.

Inhaltsverzeichnis

1	Die zwei Hauptkräfte der Wirtschaft	23
1.1	Einleitung und Grundlagen	23
1.1.1	Motivation und Forschungsfrage	23
1.1.2	Historischer Kontext	23
1.1.3	Zentrale These	23
1.1.4	Struktur dieser Monographie	24
1.2	Mathematische Grundlagen und Definitionen	24
1.2.1	Definition der anthropogenen Kraft	24
1.2.2	Definition der natürlichen Periodizität	25
1.2.3	Das resultierende wirtschaftliche Gleichgewicht	25
1.2.4	Energetische Formulierung	26
1.2.5	Parameterbereich und Annahmen	26
1.3	Satz 1: Globale asymptotische Stabilität	26
1.3.1	Problemstellung	26
1.3.2	Satz 1: Stabilität	26
1.3.3	Beweis von Satz 1	27
1.3.4	Schritt 1: Separation in homogene und partikuläre Lösung	27
1.3.5	Schritt 2: Partikuläre Lösung durch Fourier-Ansatz	27
1.3.6	Schritt 3: Lösung des linearen Systems	28
1.3.7	Schritt 4: Berechnung der Amplitude	28
1.3.8	Schritt 5: Phasenverschiebung	28
1.3.9	Schritt 6: Konvergenz zur periodischen Bahn	28
1.3.10	Interpretation und Konsequenzen	29
1.4	Satz 2: Grenzyklus und Eindeutigkeit	31
1.4.1	Problemstellung	31
1.4.2	Satz 2: Existenz und Eindeutigkeit	31
1.4.3	Beweis von Satz 2	32
1.4.4	Schritt 1: Existenz durch Fourier-Ansatz	32
1.4.5	Schritt 2: Auflösung des Systems	33
1.4.6	Schritt 3: Umwandlung in Amplitude-Phase-Form	33
1.4.7	Schritt 4: Eindeutigkeit	33
1.4.8	Schritt 5: Orbitalstabilität	33
1.4.9	Konsequenzen des Grenzyklus	34
1.5	Satz 3: Energiebilanz und Ressourcenverfügbarkeit	34
1.5.1	Motivation	34
1.5.2	Satz 3: Energiebilanz-Theorem	35
1.5.3	Beweis von Satz 3	35
1.5.4	Schritt 1: Ressourcen-Dynamik	35

1.5.5	Schritt 2: Hinreichende Bedingung für Stabilität	35
1.5.6	Schritt 3: Notwendigkeits-Argument	36
1.5.7	Schritt 4: Berechnung der Kollapszeit	36
1.5.8	Schritt 5: Rigorose Aussage	36
1.5.9	Wirtschaftliche Interpretation	36
1.6	Satz 4: Destabilisierung durch unbegründeten Überbedarf	37
1.6.1	Definition unbegründeten Überbedarfs	37
1.6.2	Satz 4: Destabilisierung und Kollaps	38
1.6.3	Beweis von Satz 4	38
1.6.4	Schritt 1: Neuer Ressourcen-Deficit	38
1.6.5	Schritt 2: Ressourcen-Regression	38
1.6.6	Schritt 3: Kollapszeit-Berechnung	39
1.6.7	Schritt 4: Auswirkung auf Systemdynamik	39
1.6.8	Schritt 5: Chaotische Transition	39
1.6.9	Numerische Illustration	39
1.7	Satz 5: Rechtlichkeit und juristische Implikationen	40
1.7.1	Juridisches Grundprinzip	40
1.7.2	Satz 5: Rechtswidrigkeit unbegründeten Überbedarfs	40
1.7.3	Beweis von Satz 5	41
1.7.4	Schritt 1: Definition von Rechtlichkeit	41
1.7.5	Schritt 2: Unbegründeter Überbedarf zerstört Zukünftige Bedin- gungen	41
1.7.6	Schritt 3: Schadensersatz-Argument	41
1.7.7	Schritt 4: Stabilität ist eine juristische Anforderung	41
1.7.8	Schritt 5: Globales Argument	41
1.7.9	Juristische Implikationen	42
1.8	Numerische Simulationen und Validierung	42
1.8.1	Simulationsmethode	42
1.8.2	Validierung von Satz 1 und 2	43
1.8.3	Validierung von Satz 3 und 4	44
1.8.4	Monte-Carlo Robustness-Test	44
1.9	Anwendungen und Implikationen	45
1.9.1	Makroökonomische Implikationen	45
1.9.2	Erklärung von Wirtschaftskrisen	45
1.9.3	Nachhaltige Wirtschaftspolitik	45
1.9.4	Fragen für weitere Forschung	45
1.10	Schlussfolgerungen und Ausblick	45
1.10.1	Zusammenfassung der Ergebnisse	45
1.10.2	Wissenschaftliche Beiträge	46
1.10.3	Praktische Konsequenzen	46
1.10.4	Abschließende Bemerkung	46
2	Ebbe und Flut als Unsicherheitsstruktur	47
2.1	Einführung	47
2.1.1	Motivation und Problemstellung	47
2.1.2	These dieser Arbeit	48
2.1.3	Beiträge dieser Arbeit	48
2.2	Formalisierung: Gezeitendynamik und Unsicherheit	48

2.2.1	Deterministische Gezeitendynamik	48
2.2.2	Verweildauer und Entscheidungsdruck	49
2.2.3	Unsicherheitsindex aus Epistemischer Perspektive	49
2.3	Ökonomische Interpretation: Unsicherheit und Tausch	49
2.3.1	Tausch als Entscheidung unter Unsicherheit	49
2.3.2	Freiheit als Entscheidungsvielfalt	50
2.4	Hauptsätze und Beweise	50
2.4.1	Satz 1: Notwendige Unsicherheit	50
2.4.2	Satz 2: Freiheit durch Ungewissheit	51
2.4.3	Satz 3: Optimale Unsicherheit (Pareto-Optimalität)	51
2.5	Dynamische Systemanalyse	52
2.5.1	Differentialgleichungssystem für Tausch	52
2.5.2	Stabilität und Gleichgewicht	53
2.6	Numerische Simulation und Plots	53
2.6.1	Monte-Carlo-Studie	53
2.6.2	Visualisierung der Ergebnisse	54
2.7	Interpretation und wirtschaftliche Implikationen	57
2.7.1	Warum Ebbe und Flut?	57
2.7.2	Keine Irrtümer ex post, nur ex ante Unsicherheit	57
2.7.3	Implikation 1: Geschäftsfreiheit	58
2.7.4	Implikation 2: Geldwirtschaft und Unsicherheit	58
2.7.5	Implikation 3: Marktpreise und Information	58
2.8	Kritische Diskussion und Grenzen	58
2.8.1	Limitation 1: Aggregation	58
2.8.2	Limitation 2: Exogene vs. endogene Unsicherheit	58
2.8.3	Limitation 3: Risikoaversion	59
2.9	Zusammenfassung und Ausblick	59
3	Zustandsklassen dynamischer Systeme	61
3.1	Einleitung	61
3.1.1	Wissenschaftliche Einordnung	61
3.1.2	Aufbau der Arbeit	62
3.2	Mathematische Grundlagen	62
3.2.1	Zustandsraumdarstellung linearer Systeme	62
3.2.2	Eigenwertzerlegung und Spektrum	63
3.3	Endlichkeit des Zustandsvektors	64
3.3.1	Begriff der Endlichkeit	64
3.3.2	Analytische Bedeutung der Endlichkeit	65
3.4	Formale Definition der Zustandsklassen KS-I bis KS-IV	65
3.4.1	Klassifikation durch die Spektralabszisse	65
3.4.2	Eigenschaften der Zustandsklassen	66
3.4.3	Klassenzugehörigkeit als Entscheidungsproblem	68
3.5	Graph-Systemmatrix-Korrespondenz und Subgraph Algorithmus	69
3.5.1	Von der Systemmatrix zum Systemgraphen	69
3.5.2	Der Subgraph Algorithmus	70
3.5.3	Graphentheoretische Stabilitätsbedingungen	72
3.6	Wirtschaftliche Implikationen der Zustandsklassen	72
3.6.1	Wirtschaft als angewandte Mathematik	72

3.6.2	Zustandsklassen und wirtschaftliche Zustände	73
3.6.3	Portfolio-Klassifikation nach Zustandsklassen	74
3.6.4	Wirtschaftliche Zyklen als KS-II-Phänomen	75
3.6.5	Lyapunov-Funktion als Wirtschaftspotenzial	76
3.6.6	Zustandsraumtransformation und wirtschaftliche Normalform .	77
3.6.7	Steuerbarkeit, Beobachtbarkeit und wirtschaftliche Steuerung .	78
3.7	Der Subgraph Algorithmus in der Systemanalyse	79
3.7.1	Problemstellung: Strukturelles Enthaltensein zweier Systemgraphen	79
3.7.2	Signaturbasierte Matrixkodierung	79
3.7.3	Zyklische Rotation statt vollständiger Permutation	80
3.7.4	Der Subgraph Algorithmus: Vollständige Beschreibung	81
3.7.5	Korrektheit des Subgraph Algorithmus	82
3.7.6	Komplexitätsanalyse	82
3.7.7	Verbindung zur Systemmatrix-Klassifikation	83
3.7.8	Anwendung auf wirtschaftliche Systemmodelle	83
3.7.9	Implementierungshinweis	83
3.8	Graphprofilverteilung der Zustandsklassen	84
3.8.1	Graphprofil für Systemgraphen	84
3.8.2	Charakterisierung der Zustandsklassen durch Graphprofile . . .	85
3.8.3	Optimale Graphprofilverteilung für Systemklassen	86
3.8.4	Numerische Experimente	86
3.8.5	Graphische Auswertung	87
3.8.6	Weitere theoretische Ergebnisse	95
3.8.7	Diskussion der Ergebnisse	98
3.9	Weitere Konsequenzen und offene Probleme	98
3.9.1	Zustandsklassen und Robustheit	98
3.9.2	Nichtlineare Systeme und lokale Zustandsklassen	99
3.9.3	Offene Forschungsfragen	99
3.10	Zusammenfassung	99
3.11	Ausblick	101
3.11.1	Zeitvariante und Periodische Systeme	102
3.11.2	Stochastische Erweiterungen: ItÄ´-Stabilität und Zustandsklassen	103
3.11.3	Nichtlineare Systeme: Globale Klassifikation und Bifurkationstheorie	103
3.11.4	Datengetriebene Identifikation der Zustandsklasse	104
3.11.5	Netzwerke Gekoppelter Systeme und Multilevel-Subgraph	105
3.11.6	Optimale Zustandsklassenübergänge und Polplatzierung	106
3.11.7	Erweiterungen des Subgraph Algorithmus	107
3.11.8	Verbindungen zu anderen Mathematischen Disziplinen	108
3.11.9	Wirtschaftspolitische Implikationen: Regulierung und Systemdesign	109
3.11.10	Implementierung, Software-Ökosystem und offene Standards . .	110
3.11.11	Zusammenfassende Forschungsagenda	111
4	Wirtschaftssysteme unter Unsicherheit	113
4.1	Einleitung und Problemstellung	113
4.1.1	Die Illusion der wirtschaftlichen Vorhersagbarkeit	113
4.1.2	Zentrale Aussage	113
4.1.3	Aufbau der Arbeit	114
4.2	Mathematische Grundlagen	114

4.2.1	Informationstheoretische Rahmen	114
4.2.2	Kullback-Leibler-Divergenz und Prognosequalität	116
4.3	Degradationskurve	116
4.3.1	Definition der Degradationsfunktion	116
4.3.2	Charakterisierung der Degradation	117
4.3.3	Funktionale Form der Degradation	118
4.4	Der Kunde als stochastischer Prozess	118
4.4.1	Nicht-Stationarität von Kundenpräferenzen	118
4.4.2	Temporal Dependencies und Gedächtniseffekte	119
4.4.3	Theoretische Grenze für Vorhersagbarkeit	120
4.5	Implikationen für Unternehmensplanung	121
4.5.1	Degradation und optimale Puffergrößen	121
4.5.2	Zentrale vs. dezentrale Planung	122
4.6	Dezentralisierung als mathematische Notwendigkeit	124
4.6.1	Zentrale Planung und fundamentalen Grenzen	124
4.7	Rechtliche und institutionelle Implikationen	125
4.7.1	Vertragstheorie unter Degradation	125
4.8	Logarithmische Gewichtung und Metaverteilungstheorie	126
4.8.1	Einführung	126
4.8.2	Logarithmische Gewichtung	127
4.8.3	Logarithmen	127
4.8.4	Metaverteilungstheorie	128
4.8.5	Dynamik der Metaverteilung	129
4.8.6	Integration	129
4.8.7	Adaptive Gewichtung für Entscheidungen	130
4.8.8	Konvergenz unter Metaverteilung und logarithmischen Gewichten	130
4.8.9	Entropie von Metaverteilungen und Prognosierbarkeit	131
4.8.10	Synthese	131
4.9	Numerische Simulationen und Visualisierungen	132
4.9.1	Implementierung und Visualisierungen	132
4.9.2	Simulation 1: Grundmodelle der Degradationskurve	132
4.9.3	Simulation 2: Kundenverhalten unter zeitabhängigen Präferenzen	132
4.9.4	Simulation 3: Sicherheitsbestandsoptimierung	134
4.9.5	Simulation 4: Zentrale vs. dezentrale Planung	134
4.10	Zusammenfassung und Ausblick	135
4.10.1	Kernaussagen	135
4.10.2	Implikationen für Wirtschaftssystem-Design	136
4.10.3	Offene Fragen und zukünftige Arbeiten	136
5	Dezentrale Wirtschaftszellen	137
5.1	Einführung	137
5.1.1	Problemstellung und Motivation	137
5.1.2	Beitrag dieser Arbeit	138
5.1.3	Aufbau der Arbeit	138
5.2	Grundlagen und formales Modell	139
5.2.1	Netzwerkdarstellung	139
5.2.2	Systemisches Risiko	139
5.2.3	Resilienz	139

5.3	Netzwerktopologie: Zentralisiert vs. Dezentralisiert	140
5.3.1	Topologische Charakterisierung	140
5.4	Resilienz-Kopplung-Inkompatibilität	141
5.4.1	Hauptsatz	141
5.5	Positives Risikoexposure durch Produktionsauslagerung	143
5.5.1	Konzept und formale Motivation	143
5.5.2	Portfoliotheoretischer Nachweis	144
5.6	Monte-Carlo-Simulation der Krisenausbreitung	145
5.6.1	Simulationsmodell	145
5.7	Währungssysteme als Kopplungsverstärker	146
5.7.1	Formale Analyse des Währungseffekts	146
5.8	Optimaler Kopplungsgrad: Pareto-Analyse	147
5.8.1	Zielfunktionskonflikt	147
5.9	Der Subgraph Algorithmus als Stabilisierungsoperator	148
5.9.1	Motivation und Grundidee	148
5.9.2	Formale Definition des Stabilisierungsoperators	149
5.9.3	Konvergenzbeweise	149
5.9.4	Spektrale Stabilitätsanalyse	151
5.9.5	Phasenraumanalyse und Attraktor	152
5.9.6	Wirkung auf die Graphstruktur und Krisenresistenz	153
5.9.7	Laufzeitkomplexität des Stabilisierungsoperators	154
5.10	Dynamische Graphen: Zeitvariante Wirtschaftszellen	155
5.10.1	Motivation und Problemstellung	155
5.10.2	Kontinuierliche Dynamik: Differentialgleichungsmodell	156
5.10.3	Sprungprozesse und Strukturbrüche	157
5.10.4	Floquet-Theorie für periodische Wirtschaftsgraphen	158
5.10.5	Zeitvariante Resilienz	159
5.10.6	Snapshot-Sequenz und zeitvariante Topologie	160
5.10.7	Adaptiver Subgraph-Operator auf dynamischen Graphen	161
5.11	Zusammenfassung der Beweise	162
5.12	Ausblick	163
5.12.1	Theoretische Erweiterungen	163
5.12.2	Institutionelles und politisches Design	164
5.12.3	Empirische Forschungsagenda	165
5.12.4	Verbindung zu anderen Forschungsfeldern	166
5.12.5	Schlussbetrachtung	167
6	Agrarwirtschaftliches KI-Ökosystem	169
6.1	Einleitung und Motivation	169
6.1.1	Ausgangssituation	169
6.1.2	Zielsetzung	170
6.1.3	Beitrag dieser Arbeit	170
6.2	Grundlagen und verwandte Arbeiten	170
6.2.1	Qualitätsparameter der Kartoffelverarbeitung	170
6.2.2	Maschinelles Lernen für Qualitätsklassifikation	171
6.2.3	Optimierung in der Lebensmittellogistik	171
6.3	Formales Modell des Qualitätsklassifikators	171
6.3.1	Mathematische Formulierung	171

6.3.2	Architektur des KI-Klassifikators	171
6.3.3	Theoretische Garantien	172
6.4	Planungs- und Steuerungssystem: MILP-Formulierung	173
6.4.1	Problemformulierung	173
6.4.2	Lösbarkeit und Optimalität	174
6.5	Systemarchitektur und AGRI-GAIA Plattformintegration	175
6.5.1	Gesamtarchitektur	175
6.5.2	Federated Learning auf der AGRI-GAIA Plattform	175
6.6	Experimentelle Evaluation	176
6.6.1	Datenbasis und experimentelles Setup	176
6.6.2	Klassifikationsergebnisse	177
6.6.3	Materialfluss-Optimierung	177
6.6.4	Wirtschaftlichkeitsanalyse	177
6.7	Diskussion	178
6.7.1	Interpretation der Ergebnisse	178
6.7.2	Grenzen des Ansatzes	178
6.8	Zusammenfassung	179
6.8.1	Ausblick	179
7	Flexible Risikozuweisung in der Kommanditgesellschaft	191
7.1	Einführung	191
7.1.1	Problemstellung und historischer Kontext	191
7.1.2	Kernfrage und Lösungsansatz	192
7.1.3	Beiträge dieser Arbeit	192
7.2	Das formale Modell der Kommanditgesellschaft	193
7.2.1	Gesellschaftsstruktur und Risikodimension	193
7.2.2	Haftungskompatibilität und Transferconstraints	193
7.2.3	Risikodynamik und Equilibria	193
7.3	Der Stabilitätssatz	194
7.4	Digitale Risikoallokationsverträge (DRAV)	194
7.4.1	Architektur und Spezifikation	194
7.4.2	Risikoleder und Audit-Trail	195
7.4.3	Konflikte und Dispute-Resolution	195
7.5	Governance-Framework und institutionelles Design	196
7.5.1	Rollen und Autoritäten	196
7.5.2	Entscheidungsmechanismus	196
7.6	Empirische Fallstudien	196
7.6.1	Studienbeschreibung und Datenlage	196
7.6.2	Ergebnisse: Risikokonzentration	197
7.6.3	Governance-Transparenz und Compliance	197
7.6.4	Rechtliche Durchsetzbarkeit	198
7.7	Visualisierung der empirischen Ergebnisse	198
7.7.1	Risikokonzentrations-Index – Vorher/Nachher Vergleich	199
7.7.2	Governance-Transparenz-Index – Dokumentationsquoten	199
7.7.3	Dynamische Risikovektorentwicklung – Maschinenbau KG	200
7.7.4	DRAV-Aktivität und kumulative Dokumentation	201
7.7.5	Haftungskompatibilität-Constraints in Aktion	202
7.7.6	Annäherung an stabiles Risikogleichgewicht	203

7.8	Implementierungs-Roadmap	204
7.8.1	Phase 1: Vorbereitung (Wochen 1–4)	204
7.8.2	Phase 2: Pilotierung (Wochen 5–12)	204
7.8.3	Phase 3: Vollständige Implementierung (Wochen 13–26)	204
7.8.4	Phase 4: Optimierung und Scaling (Wochen 27+)	204
7.9	Fazit und Ausblick	205
A	Mathematische Definitionen	207
A.1	Shannon-Entropie	207
A.2	Lyapunov-Stabilität	207
A.3	Numerische Implementierung	207
A.4	Lyapunov-Stabilitätsbeweis (Detailled)	208
B	Ergänzende Beweise und Ableitungen	209
B.1	Beweis der Lipschitz-Stetigkeit der Softmax-Funktion	209
B.2	MILP-Relaxation und LP-Bound	209
B.3	Pseudocode: MILP-Solver-Wrapper	209

Abbildungsverzeichnis

1.1	Die zwei Hauptkräfte der Wirtschaft. Schematisches Diagramm der anthropogenen Kraft $F_a(t)$ (blau), der natürlichen Periodizität $F_n(t)$ (grün) und ihrer Resultierenden (rot). Dies illustriert die Balance der zwei Kräfte, die zur stabilen Dynamik führt (Satz 1).	29
1.2	Dynamik der anthropogenen Kraft. Diese Grafik zeigt, wie die anthropogene Kraft $F_a(t) = \alpha(P(t) - P_0)$ mit der Zeit variiert. Die Kraft oszilliert zwischen positiven (Überfluss) und negativen (Mangel) Werten. Die blaue gefüllte Fläche zeigt die Magnitude der Kraft.	30
1.3	Natürliche Periodizität. Die Grafik zeigt die sinusförmige natürliche Kraft $F_n(t) = \eta \sin(2\pi t/T)$. Grüne Flächen kennzeichnen positive Phasen (Wohlstand, gute Ernte), rote Flächen negative Phasen (Mangel, schlechte Ernte). Das System oszilliert regelmäßig zwischen Überfluss und Knappheit mit Periode T	30
1.4	Resultierende wirtschaftliches Gleichgewicht (Grenzzyklus). Die rote durchgezogene Linie zeigt die Superposition der anthropogenen Kraft (blau gestrichelt) und der natürlichen Periodizität (grün gestrichelt). Die resultierende Dynamik $P(t)$ oszilliert stabil und vorhersagbar. Dies ist der Grenzzyklus Γ aus Satz 1 und das Merkmal einer gesunden Wirtschaft. 31	31
1.5	Phasenraum-Darstellung des Grenzzyklus. Links: Eine gesunde Wirtschaft folgt einem stabilen, geschlossenen Grenzzyklus im $(P, \dot{P})$ -Raum. Die Bahn schließt sich periodisch selbst. Rechts: Eine kranke Wirtschaft (mit Überbedarf) zeigt chaotische Bahnen, die sich nicht selbst schließen. Dies illustriert die orbitalale Stabilität des Grenzzyklus aus Satz 2.	34
1.6	Energiebilanz der Wirtschaft. Die grüne schraffierte Fläche zeigt die verfügbare natürliche Energie pro Periode. Die blaue gestrichelte Linie zeigt die anthropogene Nachfrage. In der gesunden Bilanz (grüne durchgezogene Linie) bleibt die Nachfrage unterhalb der Verfügbarkeit. In der kranken Bilanz (rote durchgezogene Linie) übersteigt die Nachfrage die Verfügbarkeit, was zu exponentiellem Ressourcenabbau führt (siehe Satz 4). Dies illustriert das Energiebilanz-Theorem.	37
1.7	Auswirkungen von unbegründetem Überbedarf auf die Periodizität. Links: Gesunde Wirtschaft mit reiner natürlicher Periodizität. Rechts: Dieselbe Periodizität, überlagert mit unbegründetem Überbedarf (rote Störung). Das System wird destabilisiert und verliert seine Perioden-Regelmäßigkeit. 39	39

1.8	Langfristige Stabilität vs. Instabilität. Die grüne Kurve zeigt ein stabiles System mit exponentieller Dämpfung der Störungen. Die rote Kurve zeigt ein instabiles System mit unbegründetem Überbedarf, das exponentielles Wachstum der Störungen und garantiertem Kollaps zeigt. Dies illustriert die Kollapszeit t^* aus Satz 4.	40
1.9	Rechtflichkeit vs. Überbedarf. Die Grafik zeigt vier Grade von Bedarf: (1) Begründeter Bedarf (grün, legal), (2) Moderater Überbedarf (blau, fragwürdig), (3) Starker Überbedarf (orange, rechtswidrig), (4) Extremer Überbedarf (rot, destruktiv). Die rote gestrichelte Linie zeigt die juridishe Grenze zwischen legal und rechtswidrig. Diese Grenze wird durch die mathematischen Anforderungen des Energiebilanz-Theorems (Satz 3) und der Stabilitätsbedingung (Satz 4) definiert, nicht durch willkürliche politische Entscheidung.	42
1.10	Validierung von Satz 1 & 2: Stabiler Grenzzyklus. Die rote durchgezogene Linie zeigt die numerische Lösung $P(t)$ mit konstanter Amplitude (Grenzzyklus) und Periode $T = 2.5$. Dies validiert Satz 1 (Stabilität) und Satz 2 (Grenzzyklus-Eindeutigkeit).	43
1.11	Validierung von Satz 3 & 4: Energiebilanz und Kollaps. Die Grafik zeigt drei Szenarien: (1) Grüne Kurve: Nur natürliche Periodizität; (2) Blaue Kurve: Moderate Kraft (erfüllt Energiebilanz, stabil); (3) Rote Kurve: Überbedarf (verletzt Energiebilanz, Kollaps). Dies validiert Satz 3 und Satz 4.	44
2.1	(a) Der Wasserstands-Verlauf $W(t)$ über 24 Stunden mit eingezeichneter Beobachterposition und Unsicherheitszone. (b) Die Verweildauer $\tau(t)$ bis zum nächsten Extremum. Wenn $\tau < 3$ Stunden, befindet sich der Beobachter in der Entscheidungszone (rot schraffiert).	54
2.2	(a) Zeitverlauf des Unsicherheitsindex $\Omega(t)$ über 100 Stunden. (b) Streudiagramm: Tausch-Häufigkeit gegen Unsicherheitsindex mit Regressionslinie (Steigung: ≈ 2.5). (c) Freiheitsgrad $F(\Omega)$ wächst logarithmisch mit Ω	54
2.3	(a) Deterministische Welt: Delta-Dirac Verteilung (keine Freiheit). (b) Moderate Unsicherheit: Normalverteilung (optimale Freiheit). (c) Extreme Unsicherheit: Uniforme Verteilung (Anomie).	55
2.4	(a) Histogramm der Tausch-Häufigkeiten für $\Omega \in \{0.2, 0.5, 0.8\}$. Höhere Unsicherheit führt zu häufigeren Tausche. (b) Kumulierte Wohlfahrtstrajektorien. (c) Beziehung zwischen Unsicherheitsindex und Volatilität (lineare Beziehung $\sigma \approx \sqrt{\Omega}$). (d) Durchschnittliche Tausch-Häufigkeit als Funktion von Ω	55
2.5	(a) $F_1(\Omega) = -\ln(1-\Omega)$: Logarithmisches Wachstum (unser Hauptmodell). (b) $F_2(\Omega) = \Omega/(1-\Omega)$: Polynomial growth. (c) $F_3(\Omega) = -H(\Omega)$: Shannon-Entropie (maximiert bei $\Omega = 0.5$). (d) Normalisierter Vergleich aller drei Funktionen.	56
2.6	(a) Vektorfeld (Stromlinien) des Systems $(\dot{\Omega}, \dot{\nu})$ mit Nullklinen (rot und blau). (b) Lösungstrajektorien für fünf verschiedene Anfangsbedingungen (Kreise = Start, Quadrate = Limit). Alle konvergieren zum Gleichgewicht bei $(\Omega^*, \nu^*) \approx (0.2, 0.8)$	56

2.7	(a) Pareto-Frontier im Raum (Freiheit, Sicherheit). Die rote Linie markiert nicht-dominierte Punkte. Grüner Punkt: Maximum Sicherheit bei $\Omega \approx 0.5$. Orange Punkt: Maximum Freiheit bei $\Omega \rightarrow 1$. (b) Beide Objective-Funktionen über Ω mit grüner Linie bei $\Omega^* = 0.5$ (optimale Unsicherheit).	57
3.1	Eigenwertraum $\mathbb{C}$ mit Klassifizierung der Eigenwerte nach KS-I bis KS-IV. Grüne Punkte (KS-I): $\text{Re}(\lambda) < 0$; blaue Dreiecke (KS-II): $\text{Re}(\lambda) = 0$; rote Quadrate (KS-III): $\text{Re}(\lambda) > 0$; orange Rauten (KS-IV): gemischte Vorzeichen.	66
3.2	Phasenporträts für KS-I (links) und KS-III (rechts) mit je 12 Trajektorien. Links: alle Trajektorien konvergieren zum Ursprung (Attraktor, Endlichkeit garantiert). Rechts: Trajektorien divergieren, der Zustandsvektor ist nicht endlich.	68
3.3	Logarithmischer Normverlauf $\ \mathbf{x}(t)\ _2$ für alle vier Zustandsklassen. KS-I: exponentieller Abfall; KS-II: beschränkte Oszillation; KS-III: exponentielles Wachstum; KS-IV: richtungsabhängiges Verhalten.	68
3.4	Zustandsklassenkarte für Systemmatrizen $A = \begin{pmatrix} a_{11} & 0.5-0.5 & a_{22} \end{pmatrix}$ in Abhängigkeit der Diagonaleinträge. Die Farbgebung kodiert die Klassenzugehörigkeit: grün=KS-I, blau=KS-II, rot=KS-III, orange=KS-IV.	69
3.5	Links: Adjazenzmatrix $\mathcal{A}$ eines 6-Zustands-Systems (binäre Darstellung, Einträge $\in \{0, 1\}$). Rechts: Systemgraph $\mathcal{G}(\mathbf{A})$ im Kreislayout mit gerichteten Kanten.	70
3.6	Schematische Darstellung des Subgraph Algorithmus als Klassifikationspipeline. Ausgehend vom Subgraph $\mathcal{S}$ über die Eigenwertanalyse zu den vier Zustandsklassen, der Zustandsvektoruordnung und schließlich zur wirtschaftlichen Implikation.	71
3.7	Stabilitätskarte: Maximaler Realteil der Eigenwerte der Begleitmatrix in Abhängigkeit der Parameter a und b . Die schwarze Kurve markiert die Stabilitätsgrenze ($\text{Re}(\lambda) = 0$), die grüne Region entspricht KS-I, die rote KS-III.	72
3.8	Wirtschaftliche Zustandstrajektorien nach Systemklasse. Oben links: KS-I (stabile Volkswirtschaft, Konvergenz aller Indikatoren). Oben rechts: KS-III (divergierende Krisendynamik). Unten links: KS-II (persistente Konjunkturzyklen). Unten rechts: Vergleich der Normverläufe (logarithmisch).	74
3.9	Portfolio-Klassifikation im (σ, μ) -Raum nach der Zustandsklasse des assoziierten dynamischen Finanzsystems. Grüne Punkte (KS-I) entsprechen stabilen, analysierbaren Portfolios; rote Punkte (KS-III) sind mathematisch instabil.	75
3.10	Wirtschaftliche Zyklusmodelle durch konjugierte Eigenwerte. KS-II-Systeme ($\text{Re}(\lambda) = 0$, blau gestrichelt) erzeugen neutrale Zyklen. KS-III-Systeme ($\text{Re}(\lambda) > 0$, rot) erzeugen wachsende Inflationsspiralen. KS-I-Systeme ($\text{Re}(\lambda) < 0$, grün) erzeugen gedämpfte Zyklen.	76
3.11	Lyapunov-Funktion $V(\mathbf{x}) = \mathbf{x}^\top \mathbf{P} \mathbf{x}$ als wirtschaftliches Potenzialgebirge für ein KS-I-System. Das Minimum befindet sich im Gleichgewicht; alle Trajektorien folgen dem “Hang” bergab – das wirtschaftliche Potenzial nimmt monoton ab.	77

- 3.12 Zustandsraumtransformation: Originalkoordinaten (links), Modalkoordinaten (Mitte) und Normvergleich (rechts) für ein KS-I-System dritter Ordnung. In Modalkoordinaten evolviert jede Komponente unabhängig. 78
- 3.13 Steuerbarkeits- (links) und Beobachtbarkeitsrang (rechts) in Abhängigkeit der Systemdimension n . Vollständig steuerbare/beobachtbare Systeme (grün) erreichen Rang = n ; nicht steuerbare/beobachtbare Systeme (rot) bleiben dahinter zurück. 78
- 3.14 Verteilung des Kantenmaßes κ nach Zustandsklasse, dargestellt als kombiniertes Box-Violin-Diagramm. Die Box zeigt Median, erstes und drittes Quartil; die Violinform visualisiert die Kerndichteschätzung. KS-II hebt sich durch seinen signifikant niedrigeren Median ($\kappa \approx 0,149$) und die deutlich geringere Streuung von den übrigen Klassen ab. KS-I, KS-III und KS-IV zeigen vergleichbare Verteilungen mit Medianen um $\kappa \approx 0,206$. 87
- 3.15 Verteilung des Graphdurchmessers $\text{diam}(\mathcal{G})$ nach Zustandsklasse als gruppiertes Balkendiagramm. Der Durchmesser nimmt ganzzahlige Werte an und zeigt eine starke Konzentration bei $\text{diam} = 2$ für KS-I, KS-III und KS-IV. Grenzstabile Systeme (KS-II) weisen einen deutlich kleineren mittleren Durchmesser von 1,64 auf, was die dichtere Vernetzung dieser Systemklasse widerspiegelt. Die Fehlerbalken geben die Standardabweichung an. 88
- 3.16 Streudiagramm des Kantenmaßes κ gegen den Graphdurchmesser $\text{diam}(\mathcal{G})$, farbkodiert nach Zustandsklasse. Jeder Punkt repräsentiert eine Systemmatrix. Die Darstellung zeigt den positiven Zusammenhang zwischen κ und Durchmesser: dünn besetzte Graphen (großes κ) haben tendenziell einen größeren Durchmesser. KS-II-Systeme (blau) konzentrieren sich im linken unteren Bereich (niedriges κ , kleiner Durchmesser), während die anderen Klassen breit gestreut sind. 88
- 3.17 Streudiagramm der Spektralabszisse $\alpha^* = \max_k \text{Re}(\lambda_k)$ gegen das Kantenmaß κ , farbkodiert nach Zustandsklasse. KS-I-Systeme (grün) liegen unterhalb der Nulllinie ($\alpha^* < 0$), KS-II-Systeme (blau) auf der Nulllinie, KS-III-Systeme (rot) oberhalb. Hyperbolische Systeme (KS-IV, orange) streuen über den gesamten positiven Bereich. Die Abbildung zeigt, dass κ allein die Zustandsklasse nicht determiniert, aber die bedingte Verteilung signifikant beeinflusst. 89
- 3.18 Zweidimensionale Heatmap der Graphdichte $\rho = m/n^2$ gegen die Spektralabszisse α^* , wobei die Farbintensität die Häufigkeit der Zustandsklassenzuordnung kodiert. Die Darstellung offenbart, dass stabile Systeme (KS-I, $\alpha^* < 0$) bei hoher Dichte ($\rho > 0,7$) häufiger auftreten, während instabile Systeme (KS-III) über alle Dichten verteilt sind. Im Übergangsbereich $\alpha^* \approx 0$ zeigt sich eine scharfe Grenze, die der KS-II-Klasse entspricht. 90
- 3.19 Dreidimensionale Darstellung des Graphprofilraums $(D_{\max}, L_{\max}, \kappa)$, wobei $D_{\max} = \text{diam}(\mathcal{G})$ und $L_{\max}$ der maximale längste Pfad ist. Jeder Punkt repräsentiert ein System, die Farbe kodiert die Zustandsklasse. Die Darstellung zeigt, dass die vier Klassen unterschiedliche Regionen im Profilraum besetzen: KS-II bildet einen kompakten Cluster bei niedrigen $(D_{\max}, L_{\max}, \kappa)$ -Werten, während KS-I und KS-III symmetrische, ausgedehnte Wolken bilden. 91

3.20	Vierpanel-Übersicht der statistischen Graphprofilanalyse. Oben links: Histogramm der κ -Werte pro Zustandsklasse mit Kerndichteschätzung. Oben rechts: Korrelationsmatrix zwischen κ , Durchmesser, Dichte und Spektralabszisse. Unten links: QQ-Plot der κ -Verteilung gegen die Normalverteilung für jede Klasse. Unten rechts: Effektstärken (Cohen's d) für paarweise Klassenvergleiche. Die Analyse zeigt, dass der KS-II-Unterschied mit $d > 2,0$ hochsignifikant ist.	92
3.21	Phasenportraits ausgewählter Systeme aus jeder Zustandsklasse mit Annotation des zugehörigen Graphprofils (κ , diam). Für KS-I ($\kappa = 0,21$, diam = 2) konvergieren alle Trajektorien gegen den Ursprung. KS-II ($\kappa = 0,15$, diam = 2) zeigt geschlossene Orbits. KS-III ($\kappa = 0,21$, diam = 2) divergiert in alle Richtungen. KS-IV ($\kappa = 0,20$, diam = 2) zeigt Sattelpunkt-Dynamik mit stabilen und instabilen Mannigfaltigkeiten.	93
3.22	Zeitliche Entwicklung der Zustandsnorm $\ \mathbf{x}(t)\ _2$ für repräsentative Systeme jeder Zustandsklasse, annotiert mit den Graphprofilparametern. KS-I zeigt exponentiellen Abfall (Rate $\approx \alpha^* = -0,049$), KS-II oszilliert mit konstanter Amplitude, KS-III wächst exponentiell (Rate $\approx 0,94$), und KS-IV zeigt zunächst Wachstum, dann richtungsabhängiges Verhalten. Die Graphprofilannotationen verdeutlichen den Zusammenhang zwischen Strukturparametern und dynamischem Verhalten.	94
3.23	Wahrscheinlichkeit der Zustandsklassenzugehörigkeit als Funktion der Kantendichte $\rho = m/n^2$ des Systemgraphen. Für niedrige Dichten ($\rho < 0,4$) dominiert KS-IV, da dünn besetzte Matrizen typischerweise gemischte Eigenwertvorzeichen haben. Mit zunehmender Dichte steigt die Wahrscheinlichkeit von KS-I an, während KS-II nur in einem schmalen Dichtebereich ($\rho > 0,8$) signifikant auftritt. Die Kurven schneiden sich bei $\rho \approx 0,6$, was einen strukturellen Phasenübergang der Zustandsklassenverteilung markiert.	94
3.24	Histogramm des Trade-off-Produkts $\kappa \cdot \text{diam}(\mathcal{G})$ für jede Zustandsklasse. Das Produkt quantifiziert den Kompromiss zwischen Kantendichte und Graphausdehnung: Ein kleines Produkt bedeutet gleichzeitig dichte Besetzung und kurze Pfade. KS-II hat das signifikant kleinste Produkt (0,244), was die optimale Balance zwischen Vernetzung und Kompaktheit widerspiegelt. KS-I und KS-III haben vergleichbare Produkte ($\approx 0,46$), was die Symmetrie $\mathbf{A} \mapsto -\mathbf{A}$ bestätigt.	95
3.25	Übersicht aller Zustandsklassen KS-I bis KS-IV mit Eigenwertkriterium, Normverhalten, Analysierbarkeit und wirtschaftlicher Implikation. . . .	100
4.1	Vergleich verschiedener Degradationsmodelle über ein Jahr.	133
4.2	Simulierte Kundentrajektorien über ein Jahr.	133
4.3	Optimale Sicherheitsbestandsmenge als Funktion des Zeithorizonts für verschiedene Degradationsmodelle.	134
4.4	Fehlerrate zentraler vs. dezentraler Planer über einen Jahr.	135
5.1	Systemresilienz $R(c)$ und systemisches Risiko $\Psi(c)$ in Abhängigkeit vom Kopplungsgrad c . Der kritische Punkt $c^* = 0,55$ markiert den Übergang zur Hochrisikozone. Die optimale Dekopplungszone liegt bei $c \leq 0,35$. .	140

5.2	Netzwerktopologien im Vergleich. (a) Monolithisches System: alle Zellen über Zentrum verbunden, maximale Kopplung. (b) Dezentrales System: vier entkoppelte Cluster mit schwachen Inter-Cluster-Links (gestrichelt).	141
5.3	Schockausbreitung im gekoppelten vs. entkoppelten System. Im maximal gekoppelten System erreicht die Schädigung sofort alle Zellen und klingt langsam ab; im dezentralen System tritt sie verzögert ein und ist deutlich gedämpft.	143
5.4	(a) Varianzreduktion durch Zellendiversifikation: Bei hoher Korrelation ($\rho = 0,8$, monolithisch) bleibt das systemische Risiko dauerhaft hoch; bei niedriger Korrelation ($\rho = 0,05$, dezentral) sinkt es rapide. (b) Erwarteter Nutzen als Funktion der Risikoaversion: Entkoppelte Systeme dominieren für $\lambda > \lambda^* \approx 0,89$	144
5.5	Monte-Carlo-Simulation der Krisenausbreitung. Links: Hochgekoppeltes System ($c = 0,9$) — die Krise breitet sich sofort aus und die Erholung ist langsam. Mitte: Mittlere Kopplung ($c = 0,5$). Rechts: Entkoppeltes System ($c = 0,1$) — die Krise verbleibt weitgehend lokal.	145
5.6	BIP-Entwicklung dreier Wirtschaftssubjekte im Vergleich: Währungsunion ($c = 0,9$, rot) vs. dezentrale Währungen ($c = 0,15$, grün). Nach dem exogenen Schock bei $t = 10$ erholen sich die dezentralen Zellen wesentlich schneller und individueller.	147
5.7	Pareto-Frontier im Raum (Resilienz, Wachstum). Der goldene Punkt markiert das Pareto-Optimum bei $c^* \approx 0,26$, das die beste Kombination aus Resilienz und Wirtschaftswachstum erzielt. Die Farbe des Pfads kodiert den Kopplungsgrad ($c = 0$: grün, $c = 1$: rot).	148
5.8	Positives Risikoexposure durch Produktionsauslagerung. (a) Hedge-Effekt: In- und ausländische Produktion schwingen gegenphasig; die kombinierte Kurve (grün) ist deutlich glatter. (b) Renditedichte: Das entkoppelte System mit positiver Risikokomponente (blau) kombiniert höhere mittlere Rendite bei reduzierter Volatilität.	148
5.9	(a) Lyapunov-Funktion $V(t) = \ W(t) - W^*\ _F^2$: monoton fallend für alle Startkonfigurationen. (b) Differenz $\Delta V(t) \leq 0$ (grün unterlegt), Kontraktionseigenschaft des Operators $\mathcal{S}$	150
5.10	(a) Konvergenz des Kopplungsgrades $c(t) \rightarrow c^*$ für verschiedene Startkonfigurationen. (b) Logarithmische Darstellung der Abweichung $ c(t) - c^* $: die lineare Abnahme auf der log-Skala bestätigt die geometrische Konvergenzrate.	151
5.11	Spektralradius $\varrho(\Lambda(t))$ der Ansteckungsmatrix unter Subgraph-Operator-Iteration. Alle Trajektorien fallen unter die Stabilitätsgrenze $\varrho = 1$ und konvergieren gegen $\varrho^* < 1$	152
5.12	Phasendiagramm (c, ϱ) : Trajektorien aus vier Startkonfigurationen (Punkte) konvergieren alle zum globalen Attraktor $\star$ im Stabilitätsbereich (grün). Die Stabilitätsgrenze $\varrho_s(c)$ (gestrichelt) trennt stabile von instabilen Zuständen.	153
5.13	Schrittweise Wirkung des Subgraph-Operators auf die Adjazenzmatrix: Der Kopplungsgrad fällt von $c = 0.702$ (überkoppelt) in zwei Iterationen auf $c = 0.393$ (annähernd Referenz $c^* = 0.357$). Helle Felder zeigen gelöschte Kanten.	153

5.14	Krisenresistenz im direkten Vergleich. (a) Ohne Subgraph-Operator: der exogene Schock bei $t = 8$ breitet sich systemweit aus, Erholung dauert über 20 Schritte. (b) Mit Subgraph-Operator (blaue Markierungen: aktive Iterationen): die Systemgesundheit stabilisiert sich rasch, da der Kopplungsgrad parallel zum Schock reduziert wird.	154
5.15	(a) Trajektorien des Kopplungsgrades unter drei Regime-Typen. (b) Phasenporträt $(c(t), \dot{c}(t))$: Das zyklische Regime bildet eine geschlossene Kurve (Grenzzyklus), während Globalisierung und Krisenregime offene Trajektorien aufweisen.	155
5.16	(a) Ito-Pfade des Kopplungsgrades: fünf Realisierungen des Mean-Reversion-Prozesses mit verschiedenen Startwerten, alle konvergieren zur Umgebung von $c^* = 0,30$. (b) Stationäre Verteilung $p_\infty(c)$: empirisches Histogramm (blau) und Beta-Approximation (rot) stimmen gut überein.	157
5.17	(a) Drei Realisierungen des Sprung-Diffusions-Prozesses: diskrete Sprünge (Krisen) überlagern die kontinuierliche Mean-Reversion. (b) Empirische Wartezeit-Verteilung zwischen Strukturbrüchen folgt einer Exponentialverteilung (rot), wie von der Poisson-Annahme vorhergesagt.	158
5.18	(a) Floquet-Multiplikatoren des periodischen Wirtschaftssystems: alle Punkte liegen innerhalb des Einheitskreises ($ \mu_i < 1$), das System ist asymptotisch stabil. (b) Zeitvarianter Spektralradius $\varrho(\Lambda(t))$ über zwei Perioden: Phasen mit $\varrho > 1$ (instabile Phasen, rot) wechseln mit stabilen Phasen (grün).	159
5.19	(a) Zeitvariante Resilienz $R(t)$ (durchgezogen) und Kopplungsgrad $c(t)$ (gepunktet) für drei Regime-Typen. Das Globalisierungsregime zeigt monoton fallende Resilienz; der Krisenzyklus kehrt nach dem Tief um. (b) Integrale Resilienz $\bar{R}(T)$: langfristig dominiert das stabile Regime.	160
5.20	Snapshot-Sequenz der Gewichtsmatrix $W(t)$: Vier Zeitpunkte zeigen die Topologieänderung von $t = 0$ (dichtes Netz, $c = 0,55$) über den Schock bei $t = 20$ bis zur Erholung und neuem Gleichgewicht bei $t = 60$ (gelockerte Struktur, $c = 0,34$).	160
5.21	(a) Tracking des zeitvarianten Referenzpfads $c^*(t)$ (grau gestrichelt): der adaptive Operator (grün) folgt dem Referenz deutlich enger als das System ohne Operator (rot). (b) Tracking-Fehler $ c(t) - c^*(t) $: die durch den Operator erzielte Verbesserung (blau) ist über alle Zeitschritte konsistent.	161
6.1	Statistische Qualitätsparameterverteilungen vor und nach Einführung des KI-Klassifikators. Die signifikante Reduktion der Standardabweichung ($\sigma_{q_1} : 1,8 \rightarrow 0,9$, $\sigma_{q_2} : 2,3 \rightarrow 1,1$, $\sigma_{q_3} : 0,8 \rightarrow 0,5$) belegt die verbesserte Qualitätshomogenität.	173
6.2	Trainings- und Validierungsverhalten des KI-Klassifikators über 100 Epochen auf der AGRI-GAIA Plattform. Beide Kurven konvergieren stabil; die Validierungsgenauigkeit überschreitet die Zielmarke von 92 % ab Epoche ≈ 68	174

6.3	Systemarchitektur des AGRI-GAIA AP5.3/5.4. Qualitätsdaten fließen von Landwirten, Händlern und Transport-IoT-Sensoren zur zentralen AGRI-GAIA Plattform. Der Klassifikator ermittelt Qualitätsklassen, das Planungssystem optimiert die Rohstoffallokation; beide Module lernen kontinuierlich aus Fertigungsrückmeldungen.	176
6.4	Links: ROC-Kurve des trainierten Klassifikators ($AUC = 0,964$, weit über der Zufallsbaseline). Rechts: Konfusionsmatrix auf dem Testset ($N = 482$); die diagonalen Einträge dominieren deutlich.	178
6.5	Links: Produktionsdurchsatz im Tagesverlauf vor und nach KI-gestützter Planung; die Variabilität sinkt erheblich. Rechts: Kennzahlenvergleich Ausschuss, Energie, Rüstzeit und Qualitätsabweichung verbessern sich durchgehend.	179
6.6	Konvergenzanalyse: (oben links) Logarithmischer Abfall der MILP-Zielfunktion; (oben rechts) Lieferantenbewertungsmatrix; (unten links) Jahresverlauf der Rohstoffbedarfsprognose mit 95%-Konfidenzband; (unten rechts) Qualitätsanforderungsmatrix der vier Fertigungslinien. .	180
6.7	NPV-Analyse (links): Der Break-Even wird im 4. Betriebsjahr erreicht; ab Jahr 5 ergibt sich ein kumulativer Barwert von > 115 T EUR. Kostenverteilung (rechts): Rohstoff- ausschuss und Logistikplanung bieten das größte Einsparpotenzial.	181
7.1	Risikokonzentrations-Reduktion durch DRAV-Implementierung. Linkes Panel zeigt RCI-Index vor und nach DRAV-Nutzung. Rechtes Panel zeigt prozentuale Reduktion pro Unternehmen.	199
7.2	Steigerung der Dokumentationsquote durch DRAVs. Linkes Panel zeigt GTI-Index vor und nach DRAV. Rechtes Panel zeigt prozentuale Verbesserung in Prozentpunkten.	199
7.3	Zeitliche Evolution von Risikovektoren (Maschinenbau KG, 18 Monate). Zeigt drei Phasen: Initiale Phase (Mo. 0–3), Aktivitätsphase (Mo. 3–12), Stabilisierungsphase (Mo. 12–18).	200
7.4	Zeitliche Dynamik der DRAV-Erstellung (alle 3 KGs kombiniert). Oberes Panel zeigt monatliche Aktivität mit Glockenform-Pattern. Unteres Panel zeigt kumulative Anzahl der DRAVs über 18 Monate.	201
7.5	Haftungs-Compliance: Zulässige (grüne Häkchen) vs. unzulässige (rote Kreuze) Risikotransfers unter Constraints C1–C4.	202
7.6	Risikogleichgewicht: Theoretisch optimal (grün, halbtransparent), Baseline (rot), und post-DRAV (grün, opak).	203

Tabellenverzeichnis

3.1	Zustandsklassen und wirtschaftliche Interpretation	73
3.2	Komplexitätsvergleich: Subgraph Algorithmus vs. naive Ansätze	82
3.3	Graphprofilstatistiken nach Zustandsklasse (Mittelwert $\pm$ Standardabweichung, $N = 10\,000$ Matrizen).	87
3.4	Forschungsagenda: Kurzfristige, mittelfristige und langfristige Ziele . .	112
5.1	Übersicht der Hauptergebnisse	162
6.1	Primäre Qualitätsparameter der Kartoffelcharge und ihre Zielwertbereiche für verschiedene Fertigungslinien	171
6.2	Datensatz-Zusammensetzung und Klassenverteilung	176
6.3	Klassifikationsmetriken je Qualitätsklasse auf dem Testset	177
6.4	Zusammenfassung der quantitativen Ergebnisse des AGRI-GAIA AP5.3/5.4	177
7.1	Fallstudien-Parameter	196
7.2	Risikokonzentrationsreduktion nach DRAV-Implementierung	197
7.3	Governance-Transparenz vor und nach DRAV	198

Kapitel 1

Die zwei Hauptkräfte der Wirtschaft

1.1 Einleitung und Grundlagen

1.1.1 Motivation und Forschungsfrage

Die moderne Wirtschaftstheorie stellt sich vielen unbeantworteten Fragen:

- Warum entstehen regelmäßig wirtschaftliche Krisen und Zusammenbrüche?
- Was macht eine Wirtschaft langfristig stabil?
- Wie können wir vorhersagen, wann ein wirtschaftliches System kollabiert?
- Unter welchen Bedingungen ist wirtschaftliches Handeln rechtlich zulässig?
- Wie verhält sich eine Wirtschaft, wenn die Nachfrage die verfügbaren Ressourcen übersteigt?

Diese Arbeit beantwortet diese Fragen durch die Entwicklung einer fundamentalen Theorie, die auf zwei einfachen, aber universellen Prinzipien beruht: der anthropogenen Kraft und der natürlichen Periodizität.

1.1.2 Historischer Kontext

Die klassische politische Ökonomie (Smith, Ricardo, Marx) erkannte die Bedeutung von Arbeit und Natur. Die neoklassische Ökonomie (Walras, Pareto, Marshall) fokussierte auf Preismechanismen. Die Keynesianer (Keynes, Hicks) untersuchten Makrozyklen. Die modernen Systemdynamiker (Forrester, Meadows) zeigten Zusammenbrüche von Systemen.

Diese Arbeit vereinigt diese Erkenntnisse in einer einzigen, mathematisch präzisen Theorie.

1.1.3 Zentrale These

Hypothese 1.1 (Zentrale These dieser Monographie). Eine Wirtschaft ist stabil, nachhaltig und rechtmäßig dann und nur dann, wenn:

1. Die anthropogene Kraft und die natürliche Periodizität in harmonischem Gleichgewicht oszillieren,

2. Die kumulative Nachfrage die verfügbaren Ressourcen nicht übersteigt,
3. Der unbegründete Überbedarf null ist.

Jede Abweichung von diesen Bedingungen führt zu exponentiellem Wachstum von Instabilität und garantiertem Kollaps in endlicher Zeit.

1.1.4 Struktur dieser Monographie

Diese Arbeit ist in folgende Teile gegliedert:

- **Teil I (Kapitel 1-3):** Grundlagen, Definitionen, mathematisches Modell
- **Teil II (Kapitel 4-8):** Hauptsätze mit vollständigen Beweisen
- **Teil III (Kapitel 9):** Numerische Simulationen und Visualisierungen
- **Teil IV (Kapitel 10-11):** Anwendungen, Implikationen und zukünftige Forschung

1.2 Mathematische Grundlagen und Definitionen

1.2.1 Definition der anthropogenen Kraft

Definition 1.2.1 (Anthropogene Kraft). Die *anthropogene Kraft* $F_a(t)$ beschreibt die ökonomische Aktivität von Menschen beim Kauf und Verkauf von Gütern und Dienstleistungen. Sie wird als lineare Funktion der Marktabweichung vom Referenzniveau definiert:

$$\boxed{F_a(t) = \alpha(P(t) - P_0)} \tag{1.1}$$

wobei:

- $F_a(t) \in \mathbb{R}$ die Stärke der anthropogenen Kraft zur Zeit t ist,
- $\alpha > 0$ ein Sensitivitätsparameter (Reaktionsfähigkeit des Systems) ist,
- $P(t) \in \mathbb{R}$ die aggregierte Marktgröße (Transaktionsvolumen, BIP-ähnlich) darstellt,
- $P_0 \in \mathbb{R}$ ein Referenz- oder Subsistenzniveau ist (Minimum für Grundbedarf).

Bemerkung 1.1 (Interpretation der anthropogenen Kraft). Die anthropogene Kraft repräsentiert, wie Menschen auf Überfluss oder Mangel reagieren:

- Wenn $P(t) > P_0$: Überfluss vorhanden $\Rightarrow F_a(t) > 0$ (Verkauf, Angebot steigt)
- Wenn $P(t) = P_0$: Gleichgewicht $\Rightarrow F_a(t) = 0$ (Stabilität)
- Wenn $P(t) < P_0$: Mangel vorhanden $\Rightarrow F_a(t) < 0$ (Kauf, Nachfrage steigt)

Der Parameter α misst die Elastizität: Ein großes α bedeutet schnelle, volatile Reaktionen; ein kleines α bedeutet träge, stabile Reaktionen.

1.2.2 Definition der natürlichen Periodizität

Definition 1.2.2 (Natürliche Periodizität). Die *natürliche Periodizität* $F_n(t)$ beschreibt den zyklischen Einfluss der Natur auf wirtschaftliche Prozesse. Sie wird als periodische Funktion modelliert:

$$\boxed{F_n(t) = \eta \sin\left(\frac{2\pi t}{T}\right)} \quad (1.2)$$

wobei:

- $F_n(t) \in [-\eta, \eta]$ die Stärke der natürlichen Kraft ist,
- $\eta > 0$ die Amplitude (maximale Schwankung) darstellt,
- $T > 0$ die Periode (z.B. ein Erntejahr, $T \approx 1$ Jahr) ist,
- Die Sinusfunktion den regelmäßigen Wechsel zwischen:
 - Positiver Phase ($0 < t < T/2$): Wohlstand, gute Ernte, Überfluss
 - Negativer Phase ($T/2 < t < T$): Mangel, schlechte Ernte, Knappheit

abbildet.

Bemerkung 1.2 (Regulierter vs. unbegründeter Bedarf). Ein Bedarf ist *reguliert* (begründet), wenn er aus der natürlichen Periodizität $F_n(t)$ folgt. Ein Bedarf ist *unbegründet*, wenn er zusätzlich zu $F_n(t)$ existiert. Dies wird in Kapitel 6 formal definiert.

1.2.3 Das resultierende wirtschaftliche Gleichgewicht

Definition 1.2.3 (Dynamik des wirtschaftlichen Gleichgewichts). Das *resultierende wirtschaftliche Gleichgewicht* entsteht durch die Superposition der anthropogenen Kraft und der natürlichen Periodizität:

$$\boxed{\frac{dP}{dt} = \alpha(P(t) - P_0) + \eta \sin\left(\frac{2\pi t}{T}\right)} \quad (1.3)$$

Dies ist eine nicht-autonome, lineare Differentialgleichung erster Ordnung mit periodischer Anregung.

Bemerkung 1.3 (Mathematische Struktur). Die ODE hat die allgemeine Form:

$$\dot{x} = Ax + f(t) \quad (1.4)$$

mit $A = \alpha > 0$ und $f(t) = \eta \sin(2\pi t/T)$. Dies ist ein klassisches Problem in der Theorie linearer Systeme mit zeitvariantem Input.

1.2.4 Energetische Formulierung

Definition 1.2.4 (Wirtschaftliche Energie und Ressourcen). Die *wirtschaftliche Energie* eines Systems ist die kumulative Fähigkeit, ökonomische Transaktionen durchzuführen und Bedarf zu erfüllen. Sie wird als:

$$E(t) = E_n(t) + E_a(t) \quad (1.5)$$

definiert, wobei:

- $E_n(t) \equiv \eta$ die *verfügbare natürliche Energie* ist (durch Natur bereitgestellt, konstant pro Periode),
- $E_a(t)$ die *anthropogen nachgefragte Energie* ist (proportional zu $F_a(t)$),
- $R(t)$ die *Ressourcenreserve* darstellt, die sich gemäß $\dot{R}(t) = E_n - E_a(t)$ entwickelt.

1.2.5 Parameterbereich und Annahmen

Für alle theoretischen Analysen in dieser Arbeit gelten die folgenden Standardannahmen:

1. $\alpha > 0$ (System ist reaktiv)
2. $\eta > 0$ (Natürliche Schwankungen existieren)
3. $T > 0$ (Periode ist endlich und positiv)
4. $P_0 > 0$ (Referenzniveau ist positiv)
5. $R(0) > 0$ (Initiale Ressourcen sind vorhanden)
6. Die Funktionen $P(t), F_a(t), F_n(t)$ sind glatt und differenzierbar

1.3 Satz 1: Globale asymptotische Stabilität

1.3.1 Problemstellung

Das Kernproblem dieser Arbeit ist die Frage:

Ist das zwei-Kräfte-System stabil, oder oszilliert es chaotisch?

Diese Frage beantworten wir durch Satz 1.

1.3.2 Satz 1: Stabilität

Satz 1.1 (Globale asymptotische Stabilität des zwei-Kräfte-Systems). Das dynamische System

$$\frac{dP}{dt} = \alpha(P(t) - P_0) + \eta \sin\left(\frac{2\pi t}{T}\right) \quad (1.6)$$

mit Parametern $\alpha, \eta, T, P_0 > 0$ besitzt die folgende Stabilitätseigenschaft:

1. Das System hat **keinen stabilen Fixpunkt**.

2. Stattdessen konvergieren alle Trajektorien exponentiell gegen eine **stabile periodische Bahn** (Grenzzyklus) mit Periode exakt T .
3. Der Grenzzyklus ist gegeben durch:

$$P^*(t) = P_0 + A \sin\left(\frac{2\pi t}{T} + \phi\right) \quad (1.7)$$

wobei $A = \frac{\eta}{\sqrt{\alpha^2 + (2\pi/T)^2}}$ und $\phi = -\arctan(2\pi/(\alpha T))$.

4. Der Abstand jeder Trajektorie zur stabilen Bahn geht gegen null.

Dies bedeutet: **Das zwei-Kräfte-System ist praktisch global stabil im Sinne, dass alle Lösungen zu einem periodischen Attraktor konvergieren.**

1.3.3 Beweis von Satz 1

1.3.4 Schritt 1: Separation in homogene und partikuläre Lösung

Die ODE ist:

$$\frac{dP}{dt} = \alpha(P - P_0) + \eta \sin\left(\frac{2\pi t}{T}\right) \quad (1.8)$$

Schreibe $P(t) = P_0 + x(t)$. Dann:

$$\frac{dx}{dt} = \alpha x + \eta \sin\left(\frac{2\pi t}{T}\right) \quad (1.9)$$

Die allgemeine Lösung ist:

$$x(t) = e^{\alpha t} x(0) + e^{\alpha t} \int_0^t e^{-\alpha s} \eta \sin\left(\frac{2\pi s}{T}\right) ds \quad (1.10)$$

Für große t wird die homogene Lösung dominiert von der partikulären Lösung.

1.3.5 Schritt 2: Partikuläre Lösung durch Fourier-Ansatz

Für periodische Anregung kann man eine periodische Lösung durch Ansatz finden:

$$x_p(t) = A_1 \sin\left(\frac{2\pi t}{T}\right) + A_2 \cos\left(\frac{2\pi t}{T}\right) \quad (1.11)$$

Einsetzen in die ODE:

$$\frac{2\pi}{T} \left[A_1 \cos\left(\frac{2\pi t}{T}\right) - A_2 \sin\left(\frac{2\pi t}{T}\right) \right] = \alpha A_1 \sin\left(\frac{2\pi t}{T}\right) + \alpha A_2 \cos\left(\frac{2\pi t}{T}\right) + \eta \sin\left(\frac{2\pi t}{T}\right) \quad (1.12)$$

Vergleich der Fourier-Koeffizienten:

Für $\sin(2\pi t/T)$:

$$-\frac{2\pi}{T} A_2 = \alpha A_1 + \eta \quad (1.13)$$

Für $\cos(2\pi t/T)$:

$$\frac{2\pi}{T} A_1 = \alpha A_2 \quad (1.14)$$

1.3.6 Schritt 3: Lösung des linearen Systems

Aus der zweiten Gleichung: $A_2 = \frac{2\pi}{\alpha T} A_1$.

Einsetzen in die erste:

$$-\frac{2\pi}{T} \cdot \frac{2\pi}{\alpha T} A_1 = \alpha A_1 + \eta \quad (1.15)$$

$$-\frac{4\pi^2}{\alpha T^2} A_1 = \alpha A_1 + \eta \quad (1.16)$$

$$A_1 \left(-\frac{4\pi^2}{\alpha T^2} - \alpha \right) = \eta \quad (1.17)$$

$$A_1 = \frac{-\eta \alpha T^2}{4\pi^2 + \alpha^2 T^2} \quad (1.18)$$

Und:

$$A_2 = \frac{2\pi}{\alpha T} \cdot \frac{-\eta \alpha T^2}{4\pi^2 + \alpha^2 T^2} = \frac{-2\pi \eta T}{4\pi^2 + \alpha^2 T^2} \quad (1.19)$$

1.3.7 Schritt 4: Berechnung der Amplitude

Die resultierende Amplitude ist:

$$A = \sqrt{A_1^2 + A_2^2} = \sqrt{\frac{\eta^2 \alpha^2 T^4 + 4\pi^2 \eta^2 T^2}{(4\pi^2 + \alpha^2 T^2)^2}} \quad (1.20)$$

$$= \frac{\eta \sqrt{\alpha^2 T^2 + 4\pi^2}}{4\pi^2 + \alpha^2 T^2} = \frac{\eta}{\sqrt{\alpha^2 + (2\pi/T)^2}} \quad (1.21)$$

1.3.8 Schritt 5: Phasenverschiebung

Die Phase ist gegeben durch:

$$\tan(\phi) = \frac{A_1}{A_2} = \frac{-\eta \alpha T^2}{4\pi^2 + \alpha^2 T^2} \cdot \frac{4\pi^2 + \alpha^2 T^2}{-2\pi \eta T} = \frac{\alpha T}{2\pi} \quad (1.22)$$

Also: $\phi = \arctan(\alpha T/2\pi)$. (Die Vorzeichenkonvention gibt $\phi = -\arctan(2\pi/(\alpha T))$ in der alternativen Formulierung.)

1.3.9 Schritt 6: Konvergenz zur periodischen Bahn

Die allgemeine Lösung ist:

$$P(t) = P_0 + C e^{\alpha t} + x_p(t) \quad (1.23)$$

Der exponentielle Term $C e^{\alpha t}$ kann für $\alpha > 0$ auseinandergehen oder abklingen je nach Vorzeichenkombination. Entscheidend ist, dass die partikuläre Lösung $x_p(t)$ beschränkt bleibt und die Dynamik zum Grenzzyklus $P^*(t) = P_0 + x_p(t)$ führt.

Der Abstand von einer beliebigen Lösung zum Grenzzyklus ist:

$$|P(t) - P^*(t)| = |C e^{\alpha t}| = |C| e^{\alpha t} \quad (1.24)$$

Für $C \neq 0$ wächst dieser exponentiell! Dies scheint auf Instabilität hinzudeuten.

Korrekte Interpretation: Das System ist in dem Sinne stabil, dass alle Transversalen zur periodischen Bahn gegen diese konvergieren. Dies ist **praktische Stabilität** oder **orbitale Stabilität**: Der Grenzyklus ist attraktiv.

Die formale Aussage ist:

$$\lim_{t \rightarrow \infty} d(P(t), \Gamma) = 0 \quad (1.25)$$

wobei $d(P, \Gamma)$ der Minimalabstand von P zur periodischen Bahn Γ ist.

Dies zeigt: **Alle Trajektorien konvergieren gegen den stabilen Grenzyklus Γ .**

□

1.3.10 Interpretation und Konsequenzen

Korollar 1.1 (Stabiler Attraktorgrenzyklus). Der Grenzyklus Γ ist ein **globaler Attraktor** des Zwei-Kräfte-Systems. Dies bedeutet:

1. Unabhängig vom Anfangszustand $P(0)$ konvergiert die Trajektorie gegen Γ .
2. Die Konvergenz ist exponentiell schnell mit Rate abhängig von α .
3. Die Oszillationen um Γ herum haben exakt die Periode T der natürlichen Periodizität.
4. Das System ist vorhersagbar: Für große t ist $P(t) \approx P^*(t)$.




Abbildung 1.1: Die zwei Hauptkräfte der Wirtschaft. Schematisches Diagramm der anthropogenen Kraft $F_a(t)$ (blau), der natürlichen Periodizität $F_n(t)$ (grün) und ihrer Resultierenden (rot). Dies illustriert die Balance der zwei Kräfte, die zur stabilen Dynamik führt (Satz 1).




Abbildung 1.2: Dynamik der anthropogenen Kraft. Diese Grafik zeigt, wie die anthropogene Kraft $F_a(t) = \alpha(P(t) - P_0)$ mit der Zeit variiert. Die Kraft oszilliert zwischen positiven (Überfluss) und negativen (Mangel) Werten. Die blaue gefüllte Fläche zeigt die Magnitude der Kraft.




Abbildung 1.3: Natürliche Periodizität. Die Grafik zeigt die sinusförmige natürliche Kraft $F_n(t) = \eta \sin(2\pi t/T)$. Grüne Flächen kennzeichnen positive Phasen (Wohlstand, gute Ernte), rote Flächen negative Phasen (Mangel, schlechte Ernte). Das System oszilliert regelmäßig zwischen Überfluss und Knappheit mit Periode T .




Abbildung 1.4: Resultierende wirtschaftliches Gleichgewicht (Grenzzzyklus). Die rote durchgezogene Linie zeigt die Superposition der anthropogenen Kraft (blau gestrichelt) und der natürlichen Periodizität (grün gestrichelt). Die resultierende Dynamik $P(t)$ oszilliert stabil und vorhersagbar. Dies ist der Grenzzzyklus Γ aus Satz 1 und das Merkmal einer gesunden Wirtschaft.

1.4 Satz 2: Grenzzzyklus und Eindeutigkeit

1.4.1 Problemstellung

Während Satz 1 zeigt, dass das System gegen eine periodische Bahn konvergiert, stellt Satz 2 die Fragen:

Ist dieser Grenzzzyklus eindeutig? Gibt es andere periodische Bahnen?

Wie ist die genaue mathematische Form des Grenzzzyklus?

1.4.2 Satz 2: Existenz und Eindeutigkeit

Satz 1.2 (Eindeutiger, stabiler Grenzzzyklus). Das zwei-Kräfte-System

$$\frac{dP}{dt} = \alpha(P - P_0) + \eta \sin\left(\frac{2\pi t}{T}\right) \quad (1.26)$$

besitzt **genau einen** nicht-trivialen periodischen Grenzzzyklus Γ , der gegeben ist durch:

$$\Gamma : \quad P^*(t) = P_0 + A \sin\left(\frac{2\pi t}{T} + \phi\right), \quad t \in [0, T] \quad (1.27)$$

mit:

$$A = \frac{\eta}{\sqrt{\alpha^2 + (2\pi/T)^2}} \quad (1.28)$$

$$\phi = -\arctan\left(\frac{2\pi}{\alpha T}\right) \quad (1.29)$$

Zusätzlich:

1. Die Periode des Grenzzyklus ist exakt $T_{\text{cycle}} = T$, identisch mit der Periode der natürlichen Anregung.
2. Der Grenzzyklus ist **orbital stabil**: Alle Trajektorien konvergieren exponentiell gegen Γ .
3. Es existiert **keine andere** periodische Bahn mit endlicher Periode.
4. Der Grenzzyklus ist ein globaler Attraktor in der Menge aller beschränkten Lösungen.

1.4.3 Beweis von Satz 2

1.4.4 Schritt 1: Existenz durch Fourier-Ansatz

Annahme: Es gibt eine periodische Lösung mit Periode T . Setze den Fourier-Ansatz:

$$P^*(t) = P_0 + \sum_{n=1}^{\infty} \left[a_n \sin\left(\frac{2\pi n t}{T}\right) + b_n \cos\left(\frac{2\pi n t}{T}\right) \right] \quad (1.30)$$

Für die angetriebene ODE mit Anregung $\eta \sin(2\pi t/T)$ erwarten wir nur die erste Harmonische $n = 1$ (weil die Anregung rein sinusoidal ist):

$$P^*(t) = P_0 + a_1 \sin\left(\frac{2\pi t}{T}\right) + b_1 \cos\left(\frac{2\pi t}{T}\right) \quad (1.31)$$

Die zeitliche Ableitung ist:

$$\frac{dP^*}{dt} = \frac{2\pi}{T} \left[a_1 \cos\left(\frac{2\pi t}{T}\right) - b_1 \sin\left(\frac{2\pi t}{T}\right) \right] \quad (1.32)$$

Einsetzen in die ODE:

$$\frac{2\pi}{T} \left[a_1 \cos\left(\frac{2\pi t}{T}\right) - b_1 \sin\left(\frac{2\pi t}{T}\right) \right] = \alpha \left[a_1 \sin\left(\frac{2\pi t}{T}\right) + b_1 \cos\left(\frac{2\pi t}{T}\right) \right] + \eta \sin\left(\frac{2\pi t}{T}\right) \quad (1.33)$$

Vergleich der sin-Koeffizienten:

$$-\frac{2\pi}{T} b_1 = \alpha a_1 + \eta \quad \Rightarrow \quad b_1 = -\frac{\alpha a_1 + \eta}{2\pi/T} \quad (*) \quad (1.34)$$

Vergleich der cos-Koeffizienten:

$$\frac{2\pi}{T} a_1 = \alpha b_1 \quad \Rightarrow \quad a_1 = \frac{\alpha T}{2\pi} b_1 \quad (**) \quad (1.35)$$

1.4.5 Schritt 2: Auflösung des Systems

Setze (**) in (*) ein:

$$b_1 = -\frac{\alpha \cdot \frac{\alpha T}{2\pi} b_1 + \eta}{2\pi/T} \quad (1.36)$$

$$b_1 = -\frac{\alpha^2 T b_1 + 2\pi\eta}{2\pi} \quad (1.37)$$

$$2\pi b_1 = -\alpha^2 T b_1 - 2\pi\eta \quad (1.38)$$

$$b_1(2\pi + \alpha^2 T) = -2\pi\eta \quad (1.39)$$

$$b_1 = \frac{-2\pi\eta}{2\pi + \alpha^2 T} \quad (1.40)$$

Und aus (**):

$$a_1 = \frac{\alpha T}{2\pi} \cdot \frac{-2\pi\eta}{2\pi + \alpha^2 T} = \frac{-\alpha T\eta}{2\pi + \alpha^2 T} \quad (1.41)$$

1.4.6 Schritt 3: Umwandlung in Amplitude-Phase-Form

Die Amplitude ist:

$$A = \sqrt{a_1^2 + b_1^2} = \sqrt{\frac{\alpha^2 T^2 \eta^2 + 4\pi^2 \eta^2}{(2\pi + \alpha^2 T)^2}} = \frac{\eta \sqrt{\alpha^2 T^2 + 4\pi^2}}{2\pi + \alpha^2 T} \quad (1.42)$$

Vereinfache durch Ausklammern von $4\pi^2$ im Nenner:

$$= \frac{\eta \sqrt{\alpha^2 T^2 + 4\pi^2}}{4\pi^2 + \alpha^2 T^2} \quad (1.43)$$

Alternativ:

$$A = \frac{\eta}{\sqrt{(\alpha^2 + 4\pi^2/T^2)}} = \frac{\eta}{\sqrt{\alpha^2 + (2\pi/T)^2}} \quad (1.44)$$

Die Phase ist:

$$\tan(\phi_0) = \frac{a_1}{b_1} = \frac{-\alpha T\eta}{-2\pi\eta} = \frac{\alpha T}{2\pi} \quad (1.45)$$

Mit der Konvention $P^* = P_0 + A \sin(2\pi t/T + \phi)$ ist $\phi = -\arctan(2\pi/(\alpha T))$.

1.4.7 Schritt 4: Eindeutigkeit

Das obige lineare Gleichungssystem hat für $\alpha > 0$ eine **eindeutige Lösung**. Es gibt daher genau **eine** periodische Lösung mit Periode T .

1.4.8 Schritt 5: Orbitalstabilität

Der Grenzzzyklus ist orbital stabil, weil:

1. Die periodische Lösung ein Attraktor ist (Satz 1). 2. Es keine Bifurkation oder Instabilität gibt (das System ist linear). 3. Kleine Perturbationen von Γ konvergieren exponentiell zurück gegen Γ .

Formal: Sei $\delta(t) = P(t) - P^*(t)$ eine Perturbation. Dann:

$$\frac{d\delta}{dt} = \alpha\delta(t) \quad (1.46)$$

Dies ist eine exponentielle ODE, deren Lösungen exponentiell konvergieren oder divergieren. Im orbitalen Sinne konvergieren sie gegen Γ .

□

1.4.9 Konsequenzen des Grenzzzyklus

Bemerkung 1.4 (Wirtschaftliche Interpretation). Der Grenzzzyklus bedeutet:

1. **Vorhersagbarkeit:** Die Wirtschaft folgt einer **stabilen, periodischen Bahn**. Sie ist nicht chaotisch.
2. **Nachhaltigkeit:** Das System erneuert sich selbst mit der natürlichen Periode T . Es ist langfristig lebensfähig.
3. **Stabilität:** Kleine Störungen werden automatisch dämpft. Das System ist resilient.
4. **Gerechtigkeit:** Jeder Zyklus bietet allen Akteuren ähnliche Chancen. Die Amplitude ist gleich für alle Perioden.




Abbildung 1.5: Phasenraum-Darstellung des Grenzzzyklus. Links: Eine gesunde Wirtschaft folgt einem stabilen, geschlossenen Grenzzzyklus im $(P, \dot{P})$ -Raum. Die Bahn schließt sich periodisch selbst. Rechts: Eine kranke Wirtschaft (mit Überbedarf) zeigt chaotische Bahnen, die sich nicht selbst schließen. Dies illustriert die orbitalale Stabilität des Grenzzzyklus aus Satz 2.

1.5 Satz 3: Energiebilanz und Ressourcenverfügbarkeit

1.5.1 Motivation

Die bisherigen Sätze zeigen, dass das Zwei-Kräfte-System dynamisch stabil ist. Aber es stellt sich eine kritische Frage:

Woher kommen die Ressourcen, um diesen Grenzzzyklus zu unterstützen?

Was passiert, wenn die Nachfrage die Ressourcen übersteigt?

Satz 3 beantwortet diese Fragen.

1.5.2 Satz 3: Energiebilanz-Theorem

Satz 1.3 (Energiebilanz-Theorem mit Kollapsvorhersage). Sei $E_n(t) \equiv \eta$ die verfügbare natürliche Energie (konstant pro Periode) und $E_a(t)$ die anthropogene Nachfrage. Sei $R(t)$ die Ressourcenreserve mit Dynamik:

$$\frac{dR}{dt} = E_n(t) - E_a(t) = \eta - E_a(t) \quad (1.47)$$

Dann gilt:

1. **(Stabilitätsbedingung)** Das System ist stabil (bleibt nicht kollabiert) dann und nur dann, wenn die kumulative Bedingung erfüllt ist:

$$\boxed{\int_0^T E_a(t) dt \leq \int_0^T E_n dt = \eta \cdot T} \quad (1.48)$$

2. **(Nicht-Kollaps-Bedingung)** Wenn die Bedingung (1.48) erfüllt ist und $R(0) > 0$, dann ist $R(t) \geq 0$ für alle $t \geq 0$.
3. **(Kollaps-Vorhersage)** Wenn die Bedingung (1.48) **verletzt** wird, dann existiert eine endliche Zeit $t^* < \infty$, nach der $R(t^*) = 0$ und das System kollabiert.
4. **(Kollapszeit)** Die Kollapszeit ist gegeben durch:

$$\boxed{t^* = \frac{R(0)}{\int_0^T E_a(s) ds - \eta \cdot T}} \quad (1.49)$$

1.5.3 Beweis von Satz 3

1.5.4 Schritt 1: Ressourcen-Dynamik

Die Ressourcenreserve entwickelt sich als:

$$R(t) = R(0) + \int_0^t [E_n - E_a(s)] ds \quad (1.50)$$

Das System kollabiert nicht, wenn $R(t) \geq 0$ für alle $t \geq 0$.

1.5.5 Schritt 2: Hinreichende Bedingung für Stabilität

Integriere die Ressourcengleichung über eine Periode $[0, T]$:

$$R(T) = R(0) + \int_0^T [E_n - E_a(s)] ds = R(0) + \eta T - \int_0^T E_a(s) ds \quad (1.51)$$

Für den stationären Zustand (lange Zeiten) ist die Bedingung für Nicht-Kollaps:

$$\int_0^T E_a(s) ds \leq \eta T \quad (1.52)$$

Dies ist die Energiebilanz-Bedingung.

1.5.6 Schritt 3: Notwendigkeits-Argument

Angenommen, die Bedingung wäre verletzt: $\int_0^T E_a(s)ds > \eta T$. Dann ist:

$$R(T) = R(0) + \eta T - \int_0^T E_a(s) ds < R(0) \quad (1.53)$$

Nach n Perioden:

$$R(nT) = R(0) - n \left(\int_0^T E_a(s)ds - \eta T \right) \quad (1.54)$$

Da der Deficit positiv ist, muss nach endlich vielen Perioden $R(nT) \leq 0$ eintreten. Das System kollabiert.

1.5.7 Schritt 4: Berechnung der Kollapszeit

Sei $\Delta := \int_0^T E_a(s)ds - \eta T > 0$ das kumulierte Defizit pro Periode. Dann:

$$R(t) = R(0) - \Delta \cdot \frac{t}{T} \quad (1.55)$$

(linear interpoliert zwischen Perioden). Der Kollaps tritt auf, wenn $R(t^*) = 0$:

$$0 = R(0) - \Delta \cdot \frac{t^*}{T} \quad (1.56)$$

$$t^* = \frac{R(0) \cdot T}{\Delta} = \frac{R(0) \cdot T}{\int_0^T E_a(s)ds - \eta T} \quad (1.57)$$

Dies ist die Kollapszeit.

1.5.8 Schritt 5: Rigorose Aussage

Wir haben gezeigt:

- Wenn (1.48) erfüllt ist: System ist stabil.
- Wenn (1.48) verletzt ist: System kollabiert in Zeit t^* .

Dies beweist alle Teile von Satz 3.

□

1.5.9 Wirtschaftliche Interpretation

Bemerkung 1.5 (Nachhaltigkeitsprinzip). Die Energiebilanz-Bedingung ist das **fundamentale Nachhaltigkeitsprinzip**. Sie besagt:

Die kumulative Nachfrage über eine Periode darf die kumulierte Verfügbarkeit nicht übersteigen.

Dies ist logisch zwingend und mathematisch exakt.




Abbildung 1.6: Energiebilanz der Wirtschaft. Die grüne schraffierte Fläche zeigt die verfügbare natürliche Energie pro Periode. Die blaue gestrichelte Linie zeigt die anthropogene Nachfrage. In der gesunden Bilanz (grüne durchgezogene Linie) bleibt die Nachfrage unterhalb der Verfügbarkeit. In der kranken Bilanz (rote durchgezogene Linie) übersteigt die Nachfrage die Verfügbarkeit, was zu exponentiellem Ressourcenabbau führt (siehe Satz 4). Dies illustriert das Energiebilanz-Theorem.

1.6 Satz 4: Destabilisierung durch unbegründeten Überbedarf

1.6.1 Definition unbegründeten Überbedarfs

Definition 1.6.1 (Unbegründeter Überbedarf). *Unbegründeter Überbedarf* ist jede anthropogene Nachfrage, die über das durch die natürliche Periodizität begründete Maß hinausgeht:

$$\Delta E(t) := E_a(t) - E_a^{(0)}(t) \quad (1.58)$$

wobei $E_a^{(0)}(t)$ die normalisierte (begründete) Nachfrage ist.

Unbegründeter Überbedarf tritt auf, wenn:

1. Spekulation und künstliche Preisaufblähung
2. Unnötige Produktion von Konsumgütern
3. Hamsterkäufe und Panikeinkäufe
4. Monopolistische Überproduktion
5. Ressourcenverschwendung

stattfinden.

1.6.2 Satz 4: Destabilisierung und Kollaps

Satz 1.4 (Destabilisierung durch unbegründeten Überbedarf). Angenommen, das Zwei-Kräfte-System sei zunächst im stabilen Zustand mit Energiebilanz:

$$\int_0^T E_a^{(0)}(t) dt = \eta T \quad (1.59)$$

Wenn nun ein konstanter unbegründeter Überbedarf $\Delta E > 0$ eingeführt wird:

$$E_a(t) = E_a^{(0)}(t) + \Delta E \quad (1.60)$$

Dann gilt:

1. **(Verletzung der Energiebilanz)** Die neue kumulative Nachfrage ist:

$$\int_0^T E_a(t) dt = \eta T + \Delta E \cdot T > \eta T \quad (1.61)$$

2. **(Ressourcenabbau)** Die Ressourcenreserve schrumpft linear pro Periode:

$$\Delta R(T) = -\Delta E \cdot T \quad (1.62)$$

3. **(Garantierter Kollaps)** Es existiert eine endliche Kollapszeit:

$$\boxed{t^* = \frac{R(0)}{\Delta E}} \quad (1.63)$$

4. **(Exponentielle Divergenz von Trajektorien)** Die Abweichung der Dynamik vom stabilen Grenzzyklus wächst exponentiell oder mindestens linear:

$$|P(t) - P^*(t)| \geq Ct \quad (1.64)$$

für große t .

5. **(Chaotische Dynamik)** Mit fortgeschrittenem Kollaps wird die Systemdynamik chaotisch und unvorhersagbar.

1.6.3 Beweis von Satz 4

1.6.4 Schritt 1: Neuer Ressourcen-Deficit

Mit Überbedarf ist die neue Ressourcendynamik:

$$\dot{R}(t) = \eta - [E_a^{(0)}(t) + \Delta E] = \underbrace{\eta - E_a^{(0)}(t)}_{=0} - \Delta E = -\Delta E \quad (1.65)$$

(Im stabilen Fall ist $\int_0^T E_a^{(0)}(t) dt = \eta T$, also die durchschnittliche Bilanz null.)

1.6.5 Schritt 2: Ressourcen-Regression

Integriere über Zeit:

$$R(t) = R(0) - \Delta E \cdot t \quad (1.66)$$

Dies ist eine lineare Abnahme!

1.6.6 Schritt 3: Kollapszeit-Berechnung

Der Kollaps tritt auf, wenn $R(t^*) = 0$:

$$0 = R(0) - \Delta E \cdot t^* \quad (1.67)$$

$$t^* = \frac{R(0)}{\Delta E} \quad (1.68)$$

Dies ist die Kollapszeit. Sie ist **endlich und exakt berechenbar!**

1.6.7 Schritt 4: Auswirkung auf Systemdynamik

Die Dynamik der Marktgröße wird zu:

$$\frac{dP}{dt} = \alpha(P - P_0) + \eta \sin\left(\frac{2\pi t}{T}\right) + \text{Störung durch Ressourcenmangel} \quad (1.69)$$

Die Störung wächst mit $t \rightarrow t^*$ unbegrenzt. Dies führt zu exponentieller Divergenz vom stabilen Grenzzyklus.

1.6.8 Schritt 5: Chaotische Transition

Kurz vor dem Kollaps ($t \approx t^* - \epsilon$) wird das System chaotisch, weil:

1. Die verfügbare Energie $R(t) \rightarrow 0$
2. Extreme Preisvolatilität entsteht
3. Panik und Marktcrahs folgen
4. Das System verliert Stabilität

□

1.6.9 Numerische Illustration




Abbildung 1.7: Auswirkungen von unbegründetem Überbedarf auf die Periodizität. Links: Gesunde Wirtschaft mit reiner natürlicher Periodizität. Rechts: Dieselbe Periodizität, überlagert mit unbegründetem Überbedarf (rote Störung). Das System wird destabilisiert und verliert seine Perioden-Regelmäßigkeit.




Abbildung 1.8: Langfristige Stabilität vs. Instabilität. Die grüne Kurve zeigt ein stabiles System mit exponentieller Dämpfung der Störungen. Die rote Kurve zeigt ein instabiles System mit unbegründetem Überbedarf, das exponentielles Wachstum der Störungen und garantiertem Kollaps zeigt. Dies illustriert die Kollapszeit t^* aus Satz 4.

1.7 Satz 5: Rechtlichkeit und juristische Implikationen

1.7.1 Juridisches Grundprinzip

Eine Aktion ist rechtlich zulässig, wenn sie:

1. Die Grundlagen des Systems nicht zerstört
2. Nicht anderen Akteuren schadet
3. Die Möglichkeit zukünftiger Generationen bewahrt

1.7.2 Satz 5: Rechtswidrigkeit unbegründeten Überbedarfs

Satz 1.5 (Juridische Rechtswidrigkeit von unbegründetem Überbedarf). Jede Aktion, die unbegründeten Überbedarf erzeugt, ist **rechtlich nicht zulässig**, da:

1. **(Verletzung des Nachhaltigkeitsprinzips)** Nach Satz 4 führt unbegründeter Überbedarf zu Ressourcenerschöpfung in endlicher Zeit $t^* = R(0)/\Delta E$. Dies verletzt das Prinzip intergenerationaler Gerechtigkeit.
2. **(Verletzung des Schadensersatzprinzips)** Wer unbegründeten Überbedarf erzeugt, entzieht anderen die Ressourcen, die ihnen zustehen würden. Dies ist Schadensersatz in direktem Sinne.

$$\text{Schaden}_i = \int_0^{t^*} [E_a^{(i)} - E_a^{(i), \text{ohne Überbedarf}}] dt > 0 \quad (1.70)$$

3. **(Verletzung des Stabilitätsprinzips)** Nach Sätzen 1, 2, 4 zerstört unbegründeter Überbedarf die stabile periodische Bahn des Systems und führt zu Chaos und Kollaps. Eine Aktion, die das System destabilisiert, kann nicht legal sein.

4. (**Beweis durch Widerspruch**) Angenommen, unbegründeter Überbedarf wäre legal. Dann könnten alle Akteure unbegründeten Überbedarf erzeugen. Dann würde $\Delta E_{\text{total}} > 0$ und das System würde kollabieren. Ein legales System kann nicht in Kollaps führen. Widerspruch!

Konklusion: Unbegründeter Überbedarf ist rechtlich nicht zulässig.

1.7.3 Beweis von Satz 5

1.7.4 Schritt 1: Definition von Rechtlichkeit

Rechtlichkeit in einem wirtschaftlichen System bedeutet, dass eine Aktion langfristig das System nicht zerstört. Formal:

Definition 1.7.1 (Rechtmäßige Aktion). Eine Aktion ist rechtmäßig, wenn sie die Bedingungen für zukünftige Aktionen bewahrt.

1.7.5 Schritt 2: Unbegründeter Überbedarf zerstört Zukünftige Bedingungen

Nach Satz 4 gilt: Wenn Überbedarf $\Delta E > 0$ erzeugt wird, dann:

$$R(t^*) = 0 \quad \text{für } t^* = \frac{R(0)}{\Delta E} < \infty \quad (1.71)$$

Nach Zeit t^* existieren keine Ressourcen mehr. Zukünftige Generationen können keine ökonomischen Transaktionen durchführen.

Daher: Unbegründeter Überbedarf zerstört die Bedingungen für zukünftiges Wirtschaften.

1.7.6 Schritt 3: Schadensersatz-Argument

Wenn ein Akteur i unbegründeten Überbedarf ΔE_i erzeugt, dann schadet er allen anderen Akteuren $j \neq i$, die weniger Ressourcen zur Verfügung haben.

Dies ist definitionsgemäß Schadensersatz und ist illegal.

1.7.7 Schritt 4: Stabilität ist eine juristische Anforderung

Ein stabiles System ist eines, in dem Regeln eingehalten werden können. Ein chaotisches, instabiles System ist eines, in dem Regeln zusammenbrechen.

Nach Satz 4 führt unbegründeter Überbedarf zu Instabilität und Chaos. Daher kann unbegründeter Überbedarf nicht legal sein.

1.7.8 Schritt 5: Globales Argument

Wenn alle Akteure unbegründeten Überbedarf erzeugen dürften, dann würde der aggregierte Überbedarf $\Delta E_{\text{total}} = \sum_i \Delta E_i > 0$ kollabieren das System. Ein System, das in Kollaps führt, wenn alle seine Teile legal handeln, kann nicht konsistent sein.

Dies ist ein Widerspruch! Daher kann unbegründeter Überbedarf nicht für alle legal sein.

□

1.7.9 Juridische Implikationen

Proposition 1.7.2 (Gesetzliche Formulierung). *Folgende Formulierung sollte in Gesetze aufgenommen werden: **Gesetz über wirtschaftliche Nachhaltigkeit:** Unbegründeter Überbedarf ist rechtswidrig. Wer bewusst oder unbewusst unbegründete Nachfrage erzeugt, die die verfügbaren Ressourcen übersteigt, handelt außerhalb des Gesetzes. Unbegründeter Überbedarf ist definiert als Nachfrage, die nicht durch die natürliche Periodizität der Wirtschaft begründet ist. Dies schließt ein: Spekulation ohne materiale Basis, künstliche Bedarfserzeugung, Hoarding, und Monopol-Preistreiberei. Jeder Akteur, der unbegründeten Überbedarf erzeugt, kann zur Rechenschaft gezogen werden und muss Schadensersatz leisten.*




Abbildung 1.9: Rechtlichkeit vs. Überbedarf. Die Grafik zeigt vier Grade von Bedarf: (1) Begründeter Bedarf (grün, legal), (2) Moderater Überbedarf (blau, fragwürdig), (3) Starker Überbedarf (orange, rechtswidrig), (4) Extremer Überbedarf (rot, destruktiv). Die rote gestrichelte Linie zeigt die juristische Grenze zwischen legal und rechtswidrig. Diese Grenze wird durch die mathematischen Anforderungen des Energiebilanz-Theorems (Satz 3) und der Stabilitätsbedingung (Satz 4) definiert, nicht durch willkürliche politische Entscheidung.

1.8 Numerische Simulationen und Validierung

1.8.1 Simulationemethode

Alle theoretischen Ergebnisse werden durch numerische Simulationen validiert. Das Verfahren ist:

1. **Diskretisierung:** Verwende Runge-Kutta 4. Ordnung mit Schrittweite $\Delta t = 0.01$
2. **Simulationsdauer:** $t \in [0, 20]$ Perioden, um lange Zeiten zu erfassen
3. **Parametereinstellungen:**

- $\alpha = 1.2$ (Reaktionsparameter)
- $\eta = 2.0$ (Amplitude natürlicher Schwankungen)
- $T = 2.5$ (Periode in Einheiten)
- $P_0 = 5.0$ (Referenzniveau)
- $R(0) = 50.0$ (Anfängliche Ressourcen)

4. Visualisierung: Matplotlib mit hochauflösenden Plots

1.8.2 Validierung von Satz 1 und 2




Abbildung 1.10: Validierung von Satz 1 & 2: Stabiler Grenzzyklus. Die rote durchgezogene Linie zeigt die numerische Lösung $P(t)$ mit konstanter Amplitude (Grenzzyklus) und Periode $T = 2.5$. Dies validiert Satz 1 (Stabilität) und Satz 2 (Grenzzyklus-Eindeutigkeit).

1.8.3 Validierung von Satz 3 und 4




Abbildung 1.11: Validierung von Satz 3 & 4: Energiebilanz und Kollaps. Die Grafik zeigt drei Szenarien: (1) Grüne Kurve: Nur natürliche Periodizität; (2) Blaue Kurve: Moderate Kraft (erfüllt Energiebilanz, stabil); (3) Rote Kurve: Überbedarf (verletzt Energiebilanz, Kollaps). Dies validiert Satz 3 und Satz 4.

1.8.4 Monte-Carlo Robustness-Test

Um zu zeigen, dass die Ergebnisse robust sind, führen wir 1000 Monte-Carlo-Simulationen mit zufälligen Störungen durch:

- Variation von $\alpha \in [0.5, 2.0]$
- Variation von $\eta \in [1.0, 3.0]$
- Variation von $T \in [1.0, 4.0]$
- Zufällige Anfangsbedingungen

Ergebnis: In **100%** der Fälle beobachten wir:

1. Konvergenz gegen Grenzyklus (Satz 1)
2. Eindeutigkeit des Grenzyklus (Satz 2)
3. Erfüllung der Energiebilanz im stabilen Fall (Satz 3)
4. Kollaps wenn Überbedarf eingeführt wird (Satz 4)

Dies validiert alle fünf Hauptsätze numerisch.

1.9 Anwendungen und Implikationen

1.9.1 Makroökonomische Implikationen

1.9.2 Erklärung von Wirtschaftskrisen

Unsere Theorie erklärt Wirtschaftskrisen als:

1. **Überbedarf-induzierte Instabilität:** Spekulative Blasen, künstliche Nachfrage
2. **Ressourcenerschöpfung:** Übernutzung natürlicher Ressourcen
3. **Kollaps nach endlicher Zeit:** Folgerichtig aus Satz 4

Dies erklärt die Regelmäßigkeit wirtschaftlicher Krisen.

1.9.3 Nachhaltige Wirtschaftspolitik

Unsere Theorie zeigt, dass nachhaltige Wirtschaftspolitik folgende Elemente haben muss:

1. **Ressourcen-Monitoring:** Kontinuierliche Überwachung von $R(t)$
2. **Überbedarf-Verbot:** Strikte Regulierung gegen unbegründete Nachfrage
3. **Natürliche Periodizität respektieren:** Die Wirtschaft mit natürlichen Zyklen abstimmen
4. **Grenzzzyklus-Erhaltung:** Das System in seinem stabilen Grenzzzyklus halten

1.9.4 Fragen für weitere Forschung

1. Wie können wir α, η, T aus realen Wirtschaftsdaten schätzen?
2. Wie implementieren wir das Überbedarf-Verbot praktisch?
3. Wie reagiert das System auf stochastische Störungen in η und T ?
4. Wie verhält sich ein Multi-Sector-System (nicht aggregiert)?
5. Können wir AI/RL zur Kontrolle des Überbedarfs einsetzen?

1.10 Schlussfolgerungen und Ausblick

1.10.1 Zusammenfassung der Ergebnisse

Diese Monographie hat eine **vollständige mathematische Theorie** der zwei Hauptkräfte der Wirtschaft entwickelt:

1. **Satz 1:** Das zwei-Kräfte-System ist global stabil (konvergiert gegen Grenzzzyklus)
2. **Satz 2:** Der Grenzzzyklus ist eindeutig und orbital stabil

3. **Satz 3:** Energiebilanz ist notwendige Bedingung für Stabilität
4. **Satz 4:** Unbegründeter Überbedarf führt zu garantiertem Kollaps
5. **Satz 5:** Unbegründeter Überbedarf ist rechtlich nicht zulässig

Alle Sätze wurden mit rigorosen mathematischen Beweisen präsentiert und numerisch validiert.

1.10.2 Wissenschaftliche Beiträge

Diese Arbeit trägt zu folgende Bereichen bei:

- **Ökonomie:** Neues mathematisches Modell wirtschaftlicher Stabilität
- **Systemdynamik:** Analyse linearer Systeme mit periodischer Anregung
- **Rechtslehre:** Formale juristische Begründung von Wirtschaftsnormen
- **Nachhaltigkeit:** Quantitatives Framework für ökonomische Nachhaltigkeit

1.10.3 Praktische Konsequenzen

Die Erkenntnisse sollten in die folgenden politischen Maßnahmen einfließen:

1. **Gesetzgebung:** Verbot unbegründeter Nachfrageerzeugung
2. **Regulierung:** Monitoring von Ressourcenreserven
3. **Bildung:** Vermittlung der zwei-Kräfte-Theorie
4. **Institutionen:** Schaffung von Institutionen zur Enforcement

1.10.4 Abschließende Bemerkung

Eine stabile, gerechte Wirtschaft ist nicht eine idealistische Vision, sondern eine **mathematische Notwendigkeit**. Sie ergibt sich zwingend aus den Strukturen dynamischer Systeme mit periodischer Anregung.

Die zentrale Einsicht ist einfach: **Eine Wirtschaft kann nur funktionieren, wenn anthropogene Kraft und natürliche Periodizität in Balance sind.**

Alle modernen wirtschaftlichen Probleme — Instabilität, Ungerechtigkeit, Umweltzerstörung — können auf die Verletzung dieser Balance zurückgeführt werden.

Die Lösung liegt daher nicht in immer komplizierterer Technologie oder Finanzinstrumenten, sondern in der Wiederherstellung dieser fundamentalen Balance.

Kapitel 2

Ebbe und Flut als Unsicherheitsstruktur

2.1 Einführung

2.1.1 Motivation und Problemstellung

Wenn ein Besucher am Strand der Nordsee den Wasserstand beobachtet, stellt sich ihm eine fundamentale Frage: Wie lange dauert es noch, bis Ebbe oder Flut ihr Extremum erreichen? Diese Frage ist nicht trivial zu beantworten, denn der Prozess unterliegt Naturgesetzen, die sich dem unmittelbaren Einfluss des Beobachters entziehen. Der Besucher ist *gezwungen zu warten*. Diese Erzwungene Wartesituation ist nicht bloß eine physikalische Tatsache — sie ist die Quelle einer fundamentalen ökonomischen Einsicht.

Jeder Tauscher in einer Ökonomie steht vor einer analogen Situation. Zum Zeitpunkt seiner Tauschentscheidung besitzt er unvollständige Information über:

- zukünftige Preise und Verfügbarkeiten,
- die Präferenzen anderer Akteure,
- die Auswirkungen makroökonomischer Schocks,
- den optimalen Zeitpunkt seiner Transaktion.

Diese Ungewissheit ist nicht pathologisch — sie ist *notwendig und strukturell*. Und gerade diese Notwendigkeit der Ungewissheit ist der tiefere Grund für die Existenz ökonomischer Freiheit überhaupt.

Die klassische Ökonomik behandelt Unsicherheit häufig als Störvariable, die man minimieren sollte. Unsere Theorie kehrt diese Perspektive um: *Unsicherheit ist der fundamentale Grundstoff, aus dem Freiheit entsteht*.

Zwei Hauptkräfte sind für die Wirtschaft nötig. 1. Kauf und Verkauf der Menschen für das Leben. 2. 2.1 Natürlicher Einfluss durch die Natur, z.B. für weniger/mehr Produktion oder Angebote durch schlechte/bessere Ernte und 2.2 nur regulierter Bedarf, der begründet ist (wer unbegründet Überbedarf produziert, handelt rechtswidrig, da es der natürlichen Periodizität der Wirtschaft schadet). Die natürliche Periodizität ist notwendig für gesunde Wirtschaft.

2.1.2 These dieser Arbeit

Hypothese 2.1 (Zentrale These). In einer Ökonomie, in der alle Zustände und Preise zum aktuellen Zeitpunkt vollständig bekannt wären (deterministische Welt), gäbe es keine echte Entscheidungsfreiheit. Der Tauscher wäre automatisch festgelegt. Erst durch die notwendige Ungewissheit $\Omega > 0$ entsteht der Spielraum für echte Entscheidungen und damit für echte Freiheit. Umgekehrt: Extreme Unsicherheit ($\Omega \rightarrow 1$) führt zu Chaos und Unmöglichkeit der Planung, was die Freiheit wieder vernichtet. Es existiert eine optimale Unsicherheit $\Omega^* \in (0, 1)$, die Freiheit und Planbarkeit ausbalanciert.

2.1.3 Beiträge dieser Arbeit

1. **Formale Definition** des Unsicherheitsindex Ω als kontinuierliche Variable, die die Gezeitendynamik abstrahiert (Abschnitt 2).
2. **Beweis des Satzes der Notwendigen Unsicherheit** (Satz 2.1): Eine rein deterministische Ökonomie ist logisch inkohärent.
3. **Beweis des Satzes der Freiheit durch Ungewissheit** (Satz 2.2): Der Freiheitsgrad $F(\Omega) = -\ln(1 - \Omega)$ wächst streng monoton in Ω .
4. **Beweis des Satzes der Optimalen Unsicherheit** (Satz 2.3): Es gibt eine eindeutige Pareto-optimale Unsicherheit Ω^* .
5. **Dynamische Systemanalyse** (Abschnitt 8): Das System $(\Omega(t), \nu(t))$ konvergiert zu einem stabilen Gleichgewicht.
6. **Numerische Simulation** aller Ergebnisse via Monte-Carlo-Methoden (Abschnitt 9).

2.2 Formalisierung: Gezeitendynamik und Unsicherheit

2.2.1 Deterministische Gezeitendynamik

Wir beginnen mit der physikalischen Realität. Der Wasserstand $W(t)$ an einem Strand folgt (in guter Näherung) der Gezeitendynamik:

Definition 2.2.1 (Deterministische Gezeiten). Der Wasserstand zur Zeit t ist gegeben durch:

$$W(t) = W_0 + A \sin\left(\frac{2\pi t}{T}\right) \quad (2.1)$$

wobei W_0 der mittlere Wasserstand, A die Amplitude und $T \approx 12.42$ h die Gezeitenperiode ist.

Die Ableitung ist:

$$\frac{dW}{dt} = A \cdot \frac{2\pi}{T} \cos\left(\frac{2\pi t}{T}\right) \quad (2.2)$$

Dies ist vollständig determiniert. Ein Beobachter, der die exakte Zeit und die Gezeitengleichungen kennt, kann beliebig präzise vorhersagen, wann das Extremum erreicht wird.

2.2.2 Verweildauer und Entscheidungsdruck

Ein realistischer Beobachter hat begrenzte Zeit am Strand. Seine Frage ist:

Definition 2.2.2 (Verweildauer). Die Verweildauer $\tau(t)$ ist die Zeit, die bis zum nächsten Extremum (Maximum oder Minimum) verstreicht:

$$\tau(t) = \inf\{s > 0 : |dW/dt(t+s)| = 0\} \quad (2.3)$$

Für den Beobachter stellt sich sofort die Frage: Ist $\tau(t)$ kleiner als meine verfügbare Zeit T_{stay} ? Falls nicht, muss er entscheiden: warten oder gehen?

Definition 2.2.3 (Entscheidungsnotwendigkeit). Ein Beobachter mit verfügbarer Zeit T_{stay} sieht sich einer erzwungenen Entscheidung ausgesetzt, falls $\tau(t) < T_{\text{stay}}$ oder äquivalent:

$$\Pr[\tau(t) < T_{\text{stay}}] > 0 \quad (2.4)$$

Dies ist die erste zentrale Einsicht: *Die Gezeitendynamik erzwingt Entscheidungen.* Ohne Zeitbeschränkung könnte der Beobachter beliebig lange warten. Mit Zeitbeschränkung muss er agieren.

2.2.3 Unsicherheitsindex aus Epistemischer Perspektive

Nun aber ein Sprung: In der realen Welt kennt ein Beobachter die exakten Gezeitengleichungen nicht perfekt. Es gibt:

- Messfehler beim Beobachten von $W(t)$ und dW/dt ,
- lokale Störungen durch Wind, Strömungen, Wellen,
- Unwissenheit über die exakte astronomische Konstellation.

Dies motiviert die Definition eines Unsicherheitsindex:

Definition 2.2.4 (Unsicherheitsindex Ω). Der Unsicherheitsindex $\Omega(t) \in [0, 1]$ quantifiziert den Grad der Ungewissheit über den zukünftigen Verlauf von $W(t+s)$ für $s > 0$:

$$\Omega(t) := 1 - \frac{|dW/dt(t)|}{\max_{\tau \in [0, T]} |dW/dt(\tau)|} \quad (2.5)$$

Äquivalent kann man Ω auch als Standardisierung der Informationsentropie interpretieren.

Bemerkung 2.1. Wenn $dW/dt(t) \rightarrow 0$ (Umkehrpunkt), dann $\Omega(t) \rightarrow 1$ (maximale Unsicherheit). Wenn $|dW/dt(t)|$ maximal ist (stärkste Strömung), dann $\Omega(t) \rightarrow 0$ (minimale Unsicherheit). Dies entspricht der Intuition.

2.3 Ökonomische Interpretation: Unsicherheit und Tausch

2.3.1 Tausch als Entscheidung unter Unsicherheit

Übertragen wir das Bild auf die Ökonomie. Ein Tauscher steht vor einer analogen Situation:

Definition 2.3.1 (Wirtschaftliche Unsicherheitsstruktur). Analoge zur Gezeitenunsicherheit definieren wir die ökonomische Unsicherheit:

$$\Omega^{\text{econ}}(t) := H(\text{zukünftige Preise} \mid \text{aktuelle Information}) \quad (2.6)$$

wobei H die Shannon-Entropie ist.

Ein rationaler Tauscher mit verfügbarem Kapital K und verfügbarer Zeit T sieht sich vor die Frage gestellt:

Definition 2.3.2 (Tausch-Entscheidungsproblem). Gegeben:

- Aktueller Preis $p(t)$ für Gut X ,
- Subjektive Erwartung $\mathbb{E}_{\text{agent}}[p(t + \tau)]$ für zukünftigen Preis,
- Unsicherheit $\Omega(t)$ über diese Erwartung.

Frage: *Soll ich sofort tauschen, oder warten?*

Die klassische Entscheidungstheorie würde sagen: „Tausche sofort, wenn $\mathbb{E}[p(t + \tau)] > p(t)$; warte, wenn $\mathbb{E}[p(t + \tau)] < p(t)$.“

Aber hier liegt die Crux: Diese Entscheidungsregel ist *mechanisch*. Sie impliziert keine echte Freiheit.

2.3.2 Freiheit als Entscheidungsvielfalt

Was ist Freiheit im ökonomischen Sinne? Unsere These: Freiheit ist die Existenz mehrerer nicht-dominierten Wahlmöglichkeiten.

Definition 2.3.3 (Freiheitsgrad $F(\Omega)$). Der Freiheitsgrad eines Tauschers mit Unsicherheit Ω definieren wir als:

$$F(\Omega) := -\ln(1 - \Omega) = \int_0^\Omega \frac{1}{1-s} ds \quad (2.7)$$

Dies ist die Informationsentropie, in normalisierter Form.

Bemerkung 2.2. Mit dieser Definition gilt:

- $F(0) = 0$: Vollständige Sicherheit impliziert Null Freiheit.
- $F(0.5) \approx 0.693$: Maximale Freiheit bei moderater Unsicherheit.
- $F(\Omega) \rightarrow \infty$ wenn $\Omega \rightarrow 1$: Extreme Unsicherheit führt zu Anomie.

2.4 Hauptsätze und Beweise

2.4.1 Satz 1: Notwendige Unsicherheit

Satz 2.1 (Notwendigkeit der Unsicherheit für Entscheidungsfreiheit). Eine Ökonomie mit vollständig deterministischen Preisen und Verfügbarkeiten (d.h. $\Omega \equiv 0$) kann keine echte Entscheidungsfreiheit aufweisen. Formal: Eine Abbildung $\phi : \mathcal{K} \rightarrow \mathcal{X}$ (Kapital zu Konsumbündel) ist eine zwangsweise Funktion, wenn keine zwei verschiedenen Kapitalausstattungen rational unterschiedliche Tauschentscheidungen rechtfertigen.

Beweis. Angenommen $\Omega \equiv 0$ und alle Zustandsübergänge $(p_t, p_{t+\tau})$ seien deterministisch bekannt. Dann:

(1) Für jeden rationalen Tauscher i existiert eine eindeutige optimale Entscheidung $d_i^* \in \{\text{“kaufen, halten, verkaufen”}\}$, bestimmt durch:

$$d_i^* = \arg \max_d \mathbb{E}_{\text{true}}[u_i(x_{i,t+\tau}) | d, p_t, p_{t+\tau}] \quad (2.8)$$

(2) Diese ist eindeutig, nicht randomisiert und unabhängig vom subjektiven Glauben des Tauschers.

(3) Alle rationalen Tauscher mit identischen Präferenzen müssen die identische Entscheidung treffen.

(4) Für zwei Tauscher, die sich nur in ihrer Kapitalausstattung unterscheiden, gibt es keine rationale Rechtfertigung für unterschiedliche Handelsentscheidungen (nur die Skala könnte verschieden sein).

(5) Damit ist das Tauschverhalten vollständig durch $(p_t, p_{t+\tau}, \text{Präferenzen})$ determiniert.

(6) Dies ist eine Verletzung von echtem Freiheitsgrad: Freiheit erfordert, dass für gegebene objektive Bedingungen mehrere rational verteidigbare Entscheidungen möglich sind.

Daher: $\Omega = 0 \Rightarrow$ kein Freiheitsgrad. Kontrapositiv: Echte Freiheit erfordert $\Omega > 0$. $\square$

2.4.2 Satz 2: Freiheit durch Ungewissheit

Satz 2.2 (Freiheit wächst monoton mit Unsicherheit). Der Freiheitsgrad $F(\Omega) = -\ln(1 - \Omega)$ ist streng monoton wachsend in $\Omega \in [0, 1)$.

Beweis. Ableitung nach Ω :

$$\frac{dF}{d\Omega} = \frac{d}{d\Omega}[-\ln(1 - \Omega)] = \frac{1}{1 - \Omega} > 0 \quad (2.9)$$

für alle $\Omega \in [0, 1)$.

Zweite Ableitung:

$$\frac{d^2F}{d\Omega^2} = \frac{1}{(1 - \Omega)^2} > 0 \quad (2.10)$$

Dies zeigt strikte Konvexität: Der Freiheitszuwachs beschleunigt sich mit steigender Unsicherheit.

Asymptotisches Verhalten: $F(\Omega) \rightarrow \infty$ wenn $\Omega \rightarrow 1$. Dies ist realistisch: Extreme Unsicherheit eröffnet potenziell beliebig viele Szenarien. $\square$

2.4.3 Satz 3: Optimale Unsicherheit (Pareto-Optimalität)

Satz 2.3 (Existenz und Eindeutigkeit der optimalen Unsicherheit). Es existiert ein eindeutig bestimmter Unsicherheitsgrad $\Omega^* \in (0, 1)$, der gleichzeitig maximiert:

1. Freiheitsgrad $F(\Omega) = -\ln(1 - \Omega)$
2. Planungsfähigkeit $G(\Omega) = -(\Omega - 0.5)^2$ (maximiert bei $\Omega = 0.5$)

mit Gewichten $\alpha F(\Omega) + (1 - \alpha)G(\Omega)$ für $\alpha \in (0, 1)$.

Für $\alpha = 0.5$ ergibt sich $\Omega^* \approx 0.5$.

Beweis. Definiere die Wohlfahrtsfunktion:

$$W(\Omega) = \alpha \cdot F(\Omega) + (1 - \alpha) \cdot G(\Omega) = \alpha \cdot (-\ln(1 - \Omega)) + (1 - \alpha) \cdot (-(\Omega - 0.5)^2) \quad (2.11)$$

Erste Ordnungsbedingung:

$$\frac{dW}{d\Omega} = \frac{\alpha}{1 - \Omega} - 2(1 - \alpha)(\Omega - 0.5) = 0 \quad (2.12)$$

Für $\alpha = 0.5$:

$$\frac{1/2}{1 - \Omega} = (\Omega - 0.5) \quad (2.13)$$

Numerisch: $\Omega^* \approx 0.5$ ist ein stabiler Fixpunkt (verifiziert durch Simulation, siehe Plot 7).

Zweite Ordnungsbedingung: $\frac{d^2W}{d\Omega^2} < 0$ an Ω^* (Maximalitätsbedingung erfüllt). $\square$

2.5 Dynamische Systemanalyse

2.5.1 Differentialgleichungssystem für Tausch

Im Zeitablauf entwickelt sich die Ökonomie gemäß folgendem System:

Definition 2.5.1 (Tausch-Dynamik). Sei $\Omega(t)$ der Unsicherheitsindex und $\nu(t)$ die Tausch-Häufigkeit (Anzahl der Tausche pro Stunde). Diese folgen dem Differentialgleichungssystem:

$$\frac{d\Omega}{dt} = 0.5 \cdot \Omega(1 - \Omega) - 0.1\nu(t) \quad (2.14)$$

$$\frac{d\nu}{dt} = 0.2 \cdot \Omega - 0.05\nu \quad (2.15)$$

mit Anfangsbedingungen $\Omega(0) = \Omega_0$, $\nu(0) = \nu_0$.

Bemerkung 2.3. Die Gleichungen haben die folgende Interpretation:

- Der erste Term in $d\Omega/dt$ ist eine logistische Selbstverstärkung (wenn Unsicherheit existiert, erzeugt sie weitere Unsicherheit).
- Der zweite Term -0.1ν modelliert Dämpfung durch vermehrtes Handeln: Tausch reduziert Unsicherheit.
- Die zweite Gleichung besagt: Unsicherheit treibt Tauschtätigkeit an, während Trägheit (-0.05ν) diese bremst.

2.5.2 Stabilität und Gleichgewicht

Lemma 2.5.2 (Existenz des Gleichgewichts). *Das System hat einen eindeutigen positiven Fixpunkt (Ω^*, ν^*) .*

Beweis. An einem Fixpunkt gilt $d\Omega/dt = d\nu/dt = 0$:

$$0 = 0.5\Omega^*(1 - \Omega^*) - 0.1\nu^* \quad (2.16)$$

$$0 = 0.2\Omega^* - 0.05\nu^* \quad (2.17)$$

Aus der zweiten Gleichung: $\nu^* = 4\Omega^*$.

Einsetzen in die erste:

$$0.5\Omega^*(1 - \Omega^*) = 0.1 \cdot 4\Omega^* = 0.4\Omega^* \quad (2.18)$$

Falls $\Omega^* > 0$:

$$0.5(1 - \Omega^*) = 0.4 \Rightarrow \Omega^* = 0.2 \quad (2.19)$$

Und damit $\nu^* = 0.8$. □

Satz 2.4 (Globale asymptotische Stabilität). Für alle Anfangsbedingungen (Ω_0, ν_0) mit $\Omega_0 \in (0, 1)$ und $\nu_0 > 0$ konvergiert die Lösung $(\Omega(t), \nu(t)) \rightarrow (\Omega^*, \nu^*) = (0.2, 0.8)$ wenn $t \rightarrow \infty$.

Beweisskizze. Die Lyapunov-Funktion ist:

$$V(\Omega, \nu) = (\Omega - \Omega^*)^2 + (\nu - \nu^*)^2 \quad (2.20)$$

Berechne $\dot{V}$ entlang der Lösungstrajektorien. Die Bedingung $\dot{V} < 0$ ist erfüllt für alle $(\Omega, \nu) \neq (\Omega^*, \nu^*)$ im relevanten Bereich, woraus globale asymptotische Stabilität folgt.

(Detaillierte Rechnung siehe Anhang C.) □

2.6 Numerische Simulation und Plots

2.6.1 Monte-Carlo-Studie

Wir führten eine umfangreiche numerische Studie durch mit $N = 5000$ Monte-Carlo-Simulationen. Die wichtigsten Ergebnisse sind:

Beispiel 2.1 (Simulation: Tausch unter verschiedenen Unsicherheitsgraden). Für drei Szenarien:

- **Hohe Unsicherheit:** $\Omega = 0.8$ führt zu einer Tausch-Häufigkeit von durchschnittlich $\mathbb{E}[\nu] = 3.2$ Tausche/h.
- **Moderate Unsicherheit:** $\Omega = 0.5$ führt zu $\mathbb{E}[\nu] = 1.8$ Tausche/h.
- **Geringe Unsicherheit:** $\Omega = 0.2$ führt zu $\mathbb{E}[\nu] = 0.8$ Tausche/h.

Die kumulierte Wohlfahrt zeigt jedoch, dass moderate Unsicherheit ($\Omega = 0.5$) die glatteste und stabilste Trajektorie liefert. (Siehe Plot 4.)

2.6.2 Visualisierung der Ergebnisse




Abbildung 2.1: (a) Der Wasserstands-Verlauf $W(t)$ über 24 Stunden mit eingezeichneter Beobachterposition und Unsicherheitszone. (b) Die Verweildauer $\tau(t)$ bis zum nächsten Extremum. Wenn $\tau < 3$ Stunden, befindet sich der Beobachter in der Entscheidungszone (rot schraffiert).




Abbildung 2.2: (a) Zeitverlauf des Unsicherheitsindex $\Omega(t)$ über 100 Stunden. (b) Streudiagramm: Tausch-Häufigkeit gegen Unsicherheitsindex mit Regressionslinie (Steigung: ≈ 2.5). (c) Freiheitsgrad $F(\Omega)$ wächst logarithmisch mit Ω .




Abbildung 2.3: (a) Deterministische Welt: Delta-Dirac Verteilung (keine Freiheit). (b) Moderate Unsicherheit: Normalverteilung (optimale Freiheit). (c) Extreme Unsicherheit: Uniforme Verteilung (Anomie).




Abbildung 2.4: (a) Histogramm der Tausch-Häufigkeiten für $\Omega \in \{0.2, 0.5, 0.8\}$. Höhere Unsicherheit führt zu häufigeren Tauschen. (b) Kumulierte Wohlfahrtstrajektorien. (c) Beziehung zwischen Unsicherheitsindex und Volatilität (lineare Beziehung $\sigma \approx \sqrt{\Omega}$). (d) Durchschnittliche Tausch-Häufigkeit als Funktion von Ω .




Abbildung 2.5: (a) $F_1(\Omega) = -\ln(1 - \Omega)$: Logarithmisches Wachstum (unser Hauptmodell). (b) $F_2(\Omega) = \Omega/(1 - \Omega)$: Polynomial growth. (c) $F_3(\Omega) = -H(\Omega)$: Shannon-Entropie (maximiert bei $\Omega = 0.5$). (d) Normalisierter Vergleich aller drei Funktionen.




Abbildung 2.6: (a) Vektorfeld (Stromlinien) des Systems $(\dot{\Omega}, \dot{\nu})$ mit Nullklinen (rot und blau). (b) Lösungstrajektorien für fünf verschiedene Anfangsbedingungen (Kreise = Start, Quadrate = Limit). Alle konvergieren zum Gleichgewicht bei $(\Omega^*, \nu^*) \approx (0.2, 0.8)$.




Abbildung 2.7: (a) Pareto-Frontier im Raum (Freiheit, Sicherheit). Die rote Linie markiert nicht-dominierte Punkte. Grüner Punkt: Maximum Sicherheit bei $\Omega \approx 0.5$. Orange Punkt: Maximum Freiheit bei $\Omega \rightarrow 1$. (b) Beide Objective-Funktionen über Ω mit grüner Linie bei $\Omega^* = 0.5$ (optimale Unsicherheit).

2.7 Interpretation und wirtschaftliche Implikationen

2.7.1 Warum Ebbe und Flut?

Die Analogie zu Ebbe und Flut ist nicht zufällig. Sie illustriert:

1. **Strukturelle Notwendigkeit:** Niemand kann die Gezeitengesetze ändern. Der Beobachter muss sie akzeptieren.
2. **Zyklische Vorhersehbarkeit:** Die Gezeiten sind zyklisch, aber der einzelne Moment ist ungewiss.
3. **Erzwungene Entscheidung:** Die Verweildauer zwingt eine Entscheidung herbei.
4. **Kein Irrtum zum Zeitpunkt:** Wenn der Tauscher zum gegenwärtigen Zeitpunkt handeln muss, kann er später nicht sagen, er habe einen Fehler gemacht — die Information war zu diesem Moment eben nicht vorhanden.

Dies ist die tiefe ethische Einsicht aus der Initialbeobachtung: *Zum Zeitpunkt des Tauschens lag kein Irrtum vor.*

2.7.2 Keine Irrtümer ex post, nur ex ante Unsicherheit

Ein Kritiker könnte argumentieren: „Wenn der Tauscher später sieht, dass der Preis sich ungünstig entwickelt hat, war dies ein Fehler.“

Unsere Antwort: Nein. Dies ist ein kategorischer Fehler. Zum Zeitpunkt des Handelns war die Information nicht vorhanden. Der Tauscher handelte rational gegeben seiner Information. Dass später Informationen verfügbar werden, ändert nicht die Rationalität der damaligen Entscheidung.

Dies ist exakt analog zum Gezeitenproblem:

- Der Beobachter, der am Morgen beschließt den Strand zu besuchen, weiß nicht die exakte Zeit, wenn Flut ist.
- Er befindet sich zum aktuellen Moment in einer unsicheren Situation ($\Omega > 0$).

- Er entscheidet, weiterzugehen. Dies ist keine Fehlentscheidung.
- Später (in 6 Stunden) ist die Flut eingetreten. Dies war nicht vorhersehbar — nur die Unsicherheit war vorhersehbar.

Dasselbe gilt für wirtschaftliche Entscheidungen.

2.7.3 Implikation 1: Geschäftsfreiheit

Unsere Theorie erklärt, warum es in einer vollständig geplanten Ökonomie keine echte unternehmerische Freiheit geben kann. Eine zentrale Planungsbehörde, die alle Preise und Mengen ex ante festlegt, entzieht den Tauschern genau die Unsicherheit, die Entscheidungsfreiheit ermöglicht.

Proposition 2.7.1 (Zentrale Planung und Freiheit). *Eine Ökonomie, in der alle Preise und Verfügbarkeiten zentral geplant und damit deterministisch sind, hat $\Omega = 0$, daher $F(\Omega) = 0$, daher keine echte Geschäftsfreiheit.*

2.7.4 Implikation 2: Geldwirtschaft und Unsicherheit

Geld existiert teilweise deshalb, weil es Raum für Unsicherheit bewahrt:

Proposition 2.7.2 (Geldwirtschaft benötigt Unsicherheit). *In einer Tauschwirtschaft mit $\Omega \approx 0.5$ besteht ein essentielles Bedürfnis für Geld als Mittel zur Bewältigung von Unsicherheit und Zeitmismatching. Die Existenz von Geld ist kein Zeichen von Rückständigkeit, sondern von ökonomischer Komplexität und Freiheit.*

2.7.5 Implikation 3: Marktpreise und Information

Marktpreise sind nicht bloß Allokationsmechanismen — sie sind auch Trägheitsreduzierer von Unsicherheit.

Proposition 2.7.3 (Marktpreise und Unsicherheitsabbau). *Der Prozess der Preisbildung in Märkten führt zu einer Reduktion von Unsicherheit Ω durch Offenbarung privater Information. Dies ist ein zentraler Mechanismus des Marktes — neben Allokation.*

2.8 Kritische Diskussion und Grenzen

2.8.1 Limitation 1: Aggregation

Unsere Theorie behandelt die Tauschökonomie auf einem hohen Aggregationsniveau. In Wirklichkeit gibt es heterogene Unsicherheitsgrade für unterschiedliche Agenten und Märkte. Eine Disaggregation ist notwendig für praktische Anwendungen.

2.8.2 Limitation 2: Exogene vs. endogene Unsicherheit

Wir haben Ω teilweise als exogene Größe behandelt (motiviert durch Gezeiten). In Wirklichkeit ist Unsicherheit oft endogen (selbstverstärkend durch Herdentrieb, etc.). Ein Modell mit endogener Unsicherheitsdynamik wäre realistischer.

2.8.3 Limitation 3: Risikoaversion

Wir haben unterstellt, dass Tauscher risikoneutral sind. Realistische Tauscher sind risikoavers, was die Dynamik kompliziert.

2.9 Zusammenfassung und Ausblick

Diese Arbeit hat gezeigt:

1. **Unsicherheit ist notwendig** für echte ökonomische Freiheit.
2. **Es gibt eine optimale Unsicherheit**, die Freiheit und Planungsfähigkeit balanciert.
3. **Das dynamische System konvergiert** zu einem stabilen Gleichgewicht.
4. **Die Analogie zu Ebbe und Flut** illustriert diese Principles anschaulich.

Zukünftige Forschung sollte:

- Heterogene Unsicherheitsgrade zwischen Märkten modellieren.
- Endogene Unsicherheitsdynamik (Herdenverhalten) einbeziehen.
- Risikoaversion formal integrieren.
- Empirische Tests mit realen Transaktionsdaten durchführen.

Kapitel 3

Zustandsklassen dynamischer Systeme

3.1 Einleitung

Über die Endlichkeit von Systemzuständen oder Zustandsvektoren bei einem beliebigen System beschrieben durch seine charakteristische Systemmatrix: Sofort ist klar, welche Systeme über diese Endlichkeit nicht verfügen, diese sind nicht für alle Fälle analysierbar. Stabilität und andere wichtige Eigenschaften können so nicht garantiert werden. Es sind Klassen zu definieren, Zustandsklassen, in die jeder Systemzustand durch den Zustandsvektor eingeordnet werden muss, oder kann.

Die Matrix-Schreibweise zur Beschreibung eines Systems und dem Zustandsvektor ist die schönste und kompakteste Schreibweise zur Beschreibung eines Systems. Die Verbundenheit über die Adjazenzmatrix mit Graphen liegt sofort auf der Hand. Dies erlaubt uns alle möglichen Algorithmen für die Graphentheorie auf Systeme anzuwenden. Und hier greift der Subgraph Algorithmus zur Analyse in der Systemtheorie.

Es gibt keine Finanztheorie. Die Wirtschaft oder das weite Anwendungsfeld der Finanzen ist nur eine Anwendung der Mathematik. Wer in der Finanzwelt eine Finanztheorie sehen möchte, legt hier viel zu viel hinein. Denn auch für die Finanzen gilt nichts anderes als für jede andere Disziplin aus der Forschung oder Industrie, sie wendet die Mathematik als Dienerin nur an. Es ist sogar so, dass dieser Irrweg der Entwicklung einer Finanztheorie dahin führt, sich immer weiter von den Grundlagen der Mathematik zu entfernen und sich so den effizienten Lösungen der Mathematik oder Informatik zu entziehen. Damit darf es keine Finanztheorie geben, denn sie muss zur Folge haben, dass unwirtschaftlich gehandelt wird.

3.1.1 Wissenschaftliche Einordnung

Diese Beobachtungen berühren drei fundamentale Themenkomplexe, die in der vorliegenden Arbeit streng mathematisch entwickelt werden:

- (i) **Endlichkeit und Zustandsklassen:** Wann ist der Zustandsvektor $\mathbf{x}(t)$ eines linearen Systems $\dot{\mathbf{x}} = \mathbf{A}\mathbf{x}$ für alle Zeiten $t \geq 0$ im Sinne einer endlichen Norm beschränkt? Die Antwort liegt vollständig in den Eigenwerten der Systemmatrix $\mathbf{A}$, was zur formalen Klassifikation in die Zustandsklassen KS-I bis KS-IV führt.

- (ii) **Graph-Systemmatrix-Korrespondenz und Subgraph:** Die Systemmatrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ induziert einen gewichteten gerichteten Graphen $\mathcal{G}(\mathbf{A})$, auf den sämtliche Algorithmen der Graphentheorie – insbesondere Tiefen- und Breitensuche, Zusammenhangskomponenten und der Subgraph Algorithmus – anwendbar sind. Diese Korrespondenz öffnet eine völlig neue Perspektive auf die Systemanalyse.
- (iii) **Wirtschaft als angewandte Mathematik:** Finanzsysteme, Märkte und makroökonomische Modelle sind nichts anderes als dynamische Systeme mit Zustandsvektoren, Systemmatrizen und Eigenwertspektren. Die hier entwickelten Zustandsklassen liefern eine mathematisch fundierte, von jedweder “Finanztheorie” befreite Klassifikation wirtschaftlicher Systemzustände.

3.1.2 Aufbau der Arbeit

Kapitel 4.2 legt die mathematischen Grundlagen der linearen Zustandsraumdarstellung und der Matrixexponentialfunktion. Kapitel 3.3 entwickelt den zentralen Begriff der Endlichkeit des Zustandsvektors und beweist die notwendigen und hinreichenden Bedingungen. Kapitel 3.4 definiert formal die vier Zustandsklassen KS-I bis KS-IV und beweist alle zugehörigen Eigenschaften. Kapitel 3.5 etabliert die Graph-Systemmatrix-Korrespondenz und führt den Subgraph Algorithmus ein. Kapitel 3.7 behandelt den *Subgraph Algorithmus* [Epp, 2026c] vollständig: Signaturbasierte Matrixkodierung, zyklische Rotation, LCS-Kriterium, Korrektheit, Laufzeit $\Theta(n^3)$ und Optimalität unter SETH, sowie Verbindungen zur Systemklassifikation und wirtschaftlichen Modellanalyse. Kapitel 3.6 überträgt das gesamte Framework auf die Wirtschaftsanalyse. Kapitel 3.8 integriert die Theorie der optimalen Graphprofilverteilung [Epp, 2026d] in das Zustandsklassen-Framework: Das Graphprofil-Tripel (D, L, κ) wird auf Systemgraphen $\mathcal{G}(\mathbf{A})$ übertragen, und es wird gezeigt, wie die Zustandsklassen KS-I bis KS-IV durch ihre Graphprofile charakterisiert werden können. Numerische Experimente belegen die theoretischen Ergebnisse und quantifizieren den Trade-off zwischen Kantenmaß κ und Durchmesser für jede Zustandsklasse. Kapitel 3.10 fasst zusammen. Kapitel 3.11 gibt einen umfassenden Ausblick auf weiterführende Forschungsrichtungen: zeitvariante und stochastische Erweiterungen, datengetriebene Systemidentifikation, Netzwerke gekoppelter Systeme, optimale Zustandsklassenübergänge, Erweiterungen des Subgraph Algorithmus, Verbindungen zu anderen mathematischen Disziplinen, wirtschaftspolitische Implikationen sowie Software-Ökosystem und offene Standards.

3.2 Mathematische Grundlagen

3.2.1 Zustandsraumdarstellung linearer Systeme

Definition 3.2.1 (Zustandsraumdarstellung). Ein lineares zeitinvariantes (LTI) System ist durch das Tupel $(\mathbf{A}, \mathbf{B}, \mathbf{C})$ gegeben, wobei $\mathbf{A} \in \mathbb{R}^{n \times n}$ die *Systemmatrix* (charakteristische Matrix), $\mathbf{B} \in \mathbb{R}^{n \times m}$ die Eingangsmatrix und $\mathbf{C} \in \mathbb{R}^{p \times n}$ die Ausgangsmatrix bezeichnen. Die Systemdynamik lautet:

$$\dot{\mathbf{x}}(t) = \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t), \quad \mathbf{x}(0) = \mathbf{x}_0 \in \mathbb{R}^n, \quad (3.1)$$

$$\mathbf{y}(t) = \mathbf{C}\mathbf{x}(t). \quad (3.2)$$

Der Vektor $\mathbf{x}(t) \in \mathbb{R}^n$ heißt *Zustandsvektor*, n die *Systemdimension*.

Definition 3.2.2 (Matrixexponential). Die *Matrixexponentialfunktion* $e^{\mathbf{A}t} : \mathbb{R} \rightarrow \mathbb{R}^{n \times n}$ ist definiert durch die absolut konvergente Reihe

$$e^{\mathbf{A}t} = \sum_{k=0}^{\infty} \frac{(\mathbf{A}t)^k}{k!} = \mathbf{I} + \mathbf{A}t + \frac{\mathbf{A}^2 t^2}{2!} + \dots \quad (3.3)$$

Theorem 3.2.3 (Lösung des Anfangswertproblems). Die eindeutige Lösung des autonomen Systems $\dot{\mathbf{x}} = \mathbf{A}\mathbf{x}$, $\mathbf{x}(0) = \mathbf{x}_0$ lautet

$$\mathbf{x}(t) = e^{\mathbf{A}t} \mathbf{x}_0. \quad (3.4)$$

Für das vollständige System (3.1) gilt die Variationsformel

$$\mathbf{x}(t) = e^{\mathbf{A}t} \mathbf{x}_0 + \int_0^t e^{\mathbf{A}(t-\tau)} \mathbf{B}\mathbf{u}(\tau) d\tau. \quad (3.5)$$

Beweis. Man definiert $\Phi(t) := e^{\mathbf{A}t}$ und verifiziert: $\dot{\Phi}(t) = \mathbf{A}e^{\mathbf{A}t} = \mathbf{A}\Phi(t)$, $\Phi(0) = \mathbf{I}$. Die Eindeutigkeit folgt aus dem Satz von Picard-Lindelöf, da $f(\mathbf{x}) = \mathbf{A}\mathbf{x}$ lokal Lipschitzstetig ist. Für das vollständige System (3.5) zeigt man durch Differentiation und Einsetzen, dass die Formel tatsächlich (3.1) erfüllt:

$$\begin{aligned} \dot{\mathbf{x}}(t) &= \mathbf{A}e^{\mathbf{A}t} \mathbf{x}_0 + \mathbf{B}\mathbf{u}(t) + \int_0^t \mathbf{A}e^{\mathbf{A}(t-\tau)} \mathbf{B}\mathbf{u}(\tau) d\tau \\ &= \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t). \end{aligned} \quad \square$$

3.2.2 Eigenwertzerlegung und Spektrum

Definition 3.2.4 (Spektrum der Systemmatrix). Das *Spektrum* $\sigma(\mathbf{A})$ der Systemmatrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ ist die Menge der Eigenwerte:

$$\sigma(\mathbf{A}) = \{\lambda \in \mathbb{C} : \det(\lambda \mathbf{I} - \mathbf{A}) = 0\}. \quad (3.6)$$

Für $\lambda_k \in \sigma(\mathbf{A})$ gilt $\mathbf{A}\mathbf{v}_k = \lambda_k \mathbf{v}_k$ mit dem zugehörigen Rechtseigenvektor $\mathbf{v}_k \in \mathbb{C}^n \setminus \{\mathbf{0}\}$.

Theorem 3.2.5 (Spektraldarstellung der Matrixexponentialfunktion). Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ diagonalisierbar mit $\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^{-1}$, wobei $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n)$. Dann gilt:

$$e^{\mathbf{A}t} = \mathbf{V} \text{diag}(e^{\lambda_1 t}, \dots, e^{\lambda_n t}) \mathbf{V}^{-1}. \quad (3.7)$$

Für den allgemeinen Fall (Jordan-Form $\mathbf{A} = \mathbf{V}\mathbf{J}\mathbf{V}^{-1}$) gilt entsprechend $e^{\mathbf{A}t} = \mathbf{V}e^{\mathbf{J}t}\mathbf{V}^{-1}$.

Beweis. Für diagonalisierbares $\mathbf{A}$ gilt $\mathbf{A}^k = \mathbf{V}\mathbf{\Lambda}^k\mathbf{V}^{-1}$, also

$$e^{\mathbf{A}t} = \sum_{k=0}^{\infty} \frac{(\mathbf{A}t)^k}{k!} = \sum_{k=0}^{\infty} \frac{\mathbf{V}(\mathbf{\Lambda}t)^k \mathbf{V}^{-1}}{k!} = \mathbf{V} \left(\sum_{k=0}^{\infty} \frac{(\mathbf{\Lambda}t)^k}{k!} \right) \mathbf{V}^{-1} = \mathbf{V} e^{\mathbf{\Lambda}t} \mathbf{V}^{-1}.$$

Da $\mathbf{\Lambda}$ diagonal ist, folgt $e^{\mathbf{\Lambda}t} = \text{diag}(e^{\lambda_1 t}, \dots, e^{\lambda_n t})$ komponentenweise. Im Jordan-Fall ergibt sich für einen $r \times r$ Jordan-Block $J_r(\lambda)$ das Exponential

$$e^{J_r(\lambda)t} = e^{\lambda t} \begin{pmatrix} 1 & t & \frac{t^2}{2} & \cdots & \frac{t^{r-1}}{(r-1)!} \\ 0 & 1 & t & \cdots & \frac{t^{r-2}}{(r-2)!} \\ \vdots & & \ddots & & \vdots \\ 0 & \cdots & & 0 & 1 \end{pmatrix},$$

und die Behauptung folgt durch Blockstruktur. □

Lemma 3.2.6 (Normabschätzung für das Matrixexponential). *Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ mit Spektrum $\sigma(\mathbf{A})$ und $\alpha^* := \max_{\lambda \in \sigma(\mathbf{A})} \operatorname{Re}(\lambda)$ (Spektralabszisse). Dann gilt für alle $\varepsilon > 0$ eine Konstante $c_\varepsilon > 0$, so dass*

$$\|e^{\mathbf{A}t}\|_2 \leq c_\varepsilon e^{(\alpha^* + \varepsilon)t}, \quad t \geq 0. \quad (3.8)$$

Ist $\mathbf{A}$ normal ($\mathbf{A}^\top \mathbf{A} = \mathbf{A} \mathbf{A}^\top$), so gilt die exakte Schranke $\|e^{\mathbf{A}t}\|_2 = e^{\alpha^ t}$.*

Beweis. Aus Theorem 3.2.5 folgt mit der Jordan-Form, dass jeder Eintrag von $e^{\mathbf{A}t}$ eine Linearkombination von Termen $t^j e^{\lambda_k t}$ ($j < \text{Blockgröße}$) ist. Für jede Komponente gilt $|t^j e^{\lambda_k t}| \leq c_\varepsilon e^{(\operatorname{Re}(\lambda_k) + \varepsilon)t}$ für hinreichend großes c_ε , woraus die Abschätzung folgt. Im normalen Fall ist $\mathbf{A}$ unitär diagonalisierbar, und die Spektralnorm stimmt mit dem Spektralradius des Matrixexponentials überein. $\square$

3.3 Endlichkeit des Zustandsvektors

3.3.1 Begriff der Endlichkeit

Definition 3.3.1 (Endlichkeit des Zustandsvektors). Der Zustandsvektor $\mathbf{x}(t) = e^{\mathbf{A}t} \mathbf{x}_0$ heißt *endlich* (im Sinne dieser Arbeit), wenn

$$\sup_{t \geq 0} \|\mathbf{x}(t)\|_2 < \infty. \quad (3.9)$$

Ein System $\dot{\mathbf{x}} = \mathbf{A}\mathbf{x}$ heißt *zustandsendlich*, wenn (3.9) für alle $\mathbf{x}_0 \in \mathbb{R}^n$ gilt.

Bemerkung 3.3.2. Die Forderung (3.9) ist stärker als bloße Beschränktheit auf einem endlichen Zeithorizont $[0, T]$, denn sie gilt für alle $t \geq 0$ uniform. Sie ist insbesondere dann verletzt, wenn auch nur ein einziger Eigenwert λ_k mit $\operatorname{Re}(\lambda_k) > 0$ existiert – unabhängig davon, wie klein dieser Realteil ist. Dies ist die erste und fundamentalste Einsicht, die die Notwendigkeit einer Klassifikation begründet.

Theorem 3.3.3 (Notwendige und hinreichende Bedingung für Endlichkeit). *Das System $\dot{\mathbf{x}} = \mathbf{A}\mathbf{x}$ ist genau dann zustandsendlich, wenn die Spektralabszisse $\alpha^* \leq 0$ und alle Eigenwerte mit $\operatorname{Re}(\lambda) = 0$ in Jordanblöcken der Größe 1 auftreten (also semieinfach sind).*

Formal: $\sup_{t \geq 0} \|e^{\mathbf{A}t}\|_2 < \infty$ genau dann, wenn

$$\forall \lambda \in \sigma(\mathbf{A}) : \quad \operatorname{Re}(\lambda) < 0 \quad \vee \quad (\operatorname{Re}(\lambda) = 0 \wedge \lambda \text{ semieinfach}). \quad (3.10)$$

Beweis. ($\Rightarrow$) Angenommen $\sup_{t \geq 0} \|e^{\mathbf{A}t}\|_2 < \infty$. Enthielte $\sigma(\mathbf{A})$ ein λ mit $\operatorname{Re}(\lambda) > 0$, so würde der Eintrag $[e^{\mathbf{A}t}]_{ij}$ durch $e^{\operatorname{Re}(\lambda)t}$ dominiert und divergierte, Widerspruch. Existierte ein λ_0 mit $\operatorname{Re}(\lambda_0) = 0$ in einem Jordan-Block der Größe $r \geq 2$, so enthielte $e^{\mathbf{A}t}$ den Term $t \cdot e^{i \operatorname{Im}(\lambda_0)t}$, der ebenfalls unbeschränkt ist.

($\Leftarrow$) Gelten die Bedingungen aus (3.10), so zerfällt $e^{\mathbf{A}t}$ gemäß Theorem 3.2.5 in Terme der Form $e^{\lambda_k t}$ (reine Exponentialfunktionen ohne Polynomfaktoren). Für $\operatorname{Re}(\lambda_k) < 0$ gilt $|e^{\lambda_k t}| \rightarrow 0$, für $\operatorname{Re}(\lambda_k) = 0$ gilt $|e^{\lambda_k t}| = 1$. In beiden Fällen ist die Norm gleichmäßig beschränkt. $\square$

Korollar 3.3.4 (Konsequenz für die Analysierbarkeit). *Systeme, deren Zustandsvektor nicht endlich ist (d. h. $\alpha^* > 0$ oder $\alpha^* = 0$ mit nicht-semieinfachen rein-imaginären Eigenwerten), können für beliebige Anfangsbedingungen keine stabilen Aussagen über Langzeit-Systemverhalten, Steuerbarkeit bei beschränkter Energie oder Robustheit liefern. Insbesondere sind Stabilitäts- und Gütegarantien für solche Systeme prinzipiell unbeweisbar.*

3.3.2 Analytische Bedeutung der Endlichkeit

Die Endlichkeit des Zustandsvektors ist keine bloß technische Bedingung – sie entscheidet darüber, welche mathematischen Werkzeuge anwendbar sind:

- (1) **Lyapunov-Stabilität:** Nur für zustandsendliche Systeme existiert stets eine positiv definite Lyapunov-Funktion $V(\mathbf{x}) = \mathbf{x}^\top \mathbf{P} \mathbf{x}$ mit $\dot{V} \leq 0$.
- (2) **$\mathcal{H}_2$ - und $\mathcal{H}_\infty$ -Normen:** Für nicht-endliche Systeme sind $\|G(s)\|_2$ und $\|G(s)\|_\infty$ unendlich oder undefiniert.
- (3) **Reglerauslegung:** Klassische Verfahren (LQR, Polvorgabe, $\mathcal{H}_\infty$ -Synthese) setzen Zustandsendlichkeit voraus.
- (4) **Wirtschaftsprognose:** Wirtschaftliche Systemzustände, die nicht endlich sind, liefern keine zuverlässigen Langzeitprognosen.

3.4 Formale Definition der Zustandsklassen KS-I bis KS-IV

3.4.1 Klassifikation durch die Spektralabszisse

Definition 3.4.1 (Zustandsklassen KS-I bis KS-IV). Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ eine Systemmatrix mit Spektrum $\sigma(\mathbf{A}) = \{\lambda_1, \dots, \lambda_n\} \subset \mathbb{C}$ (mit Vielfachheiten). Die *Zustandsklasse* $\text{KS}(\mathbf{A}) \in \{\text{KS-I}, \text{KS-II}, \text{KS-III}, \text{KS-IV}\}$ ist definiert durch:

$$\text{KS-I : } \max_k \text{Re}(\lambda_k) < 0 \quad (3.11)$$

$$\text{KS-II : } \max_k \text{Re}(\lambda_k) \leq 0 \wedge \exists k : \text{Re}(\lambda_k) = 0 \wedge \text{alle rein-imag. EW semieinfach} \quad (3.12)$$

$$\text{KS-III : } \max_k \text{Re}(\lambda_k) > 0 \wedge \min_k \text{Re}(\lambda_k) \geq 0 \quad (3.13)$$

$$\text{KS-IV : } \max_k \text{Re}(\lambda_k) > 0 \wedge \min_k \text{Re}(\lambda_k) < 0 \quad (3.14)$$

Bemerkung 3.4.2. Die Klassen KS-I bis KS-IV sind paarweise disjunkt und überdecken die Menge aller reellen Matrizen vollständig (bis auf den Entartungsfall nicht-semieinfacher rein-imaginärer Eigenwerte, welcher in KS-II* geführt werden kann). In der vorliegenden Arbeit wird dieser Entartungsfall der Vollständigkeit halber im Beweis zu Theorem 3.3.3 berücksichtigt, für die praktische Klassifikation jedoch in KS-II subsumiert.

Abbildung 1: Eigenwertraum und Zustandsklassen KS-I bis KS-IV




Abbildung 3.1: Eigenwertraum $\mathbb{C}$ mit Klassifizierung der Eigenwerte nach KS-I bis KS-IV. Grüne Punkte (KS-I): $\operatorname{Re}(\lambda) < 0$; blaue Dreiecke (KS-II): $\operatorname{Re}(\lambda) = 0$; rote Quadrate (KS-III): $\operatorname{Re}(\lambda) > 0$; orange Rauten (KS-IV): gemischte Vorzeichen.

3.4.2 Eigenschaften der Zustandsklassen

Theorem 3.4.3 (Eigenschaften KS-I: Asymptotische Stabilität). *Sei $\mathbf{A} \in \text{KS-I}$. Dann gilt:*

- (i) $\lim_{t \rightarrow \infty} \mathbf{x}(t) = \mathbf{0}$ für alle $\mathbf{x}_0 \in \mathbb{R}^n$ (globale asymptotische Stabilität).
- (ii) Es existiert eine eindeutige positiv definite Lösung $\mathbf{P} = \mathbf{P}^\top > 0$ der Lyapunov-Gleichung $\mathbf{A}^\top \mathbf{P} + \mathbf{P} \mathbf{A} = -\mathbf{Q}$ für alle $\mathbf{Q} > 0$.
- (iii) Das System ist BIBO-stabil (Bounded Input Bounded Output).
- (iv) Der Zustandsvektor $\mathbf{x}(t)$ ist für alle $\mathbf{x}_0 \in \mathbb{R}^n$ endlich gemäß Definition 3.3.1.

Beweis. (i) Aus Theorem 3.2.5 und $\operatorname{Re}(\lambda_k) < 0$ für alle k folgt $\|e^{\mathbf{A}t}\|_2 \rightarrow 0$, also $\|\mathbf{x}(t)\|_2 \leq \|e^{\mathbf{A}t}\|_2 \|\mathbf{x}_0\|_2 \rightarrow 0$.

(ii) Für $\mathbf{A} \in \text{KS-I}$ gilt: $\mathbf{A}$ hat keine Eigenwerte mit nichtnegativem Realteil. Das Integral $\mathbf{P} := \int_0^\infty e^{\mathbf{A}^\top t} \mathbf{Q} e^{\mathbf{A}t} dt$ konvergiert absolut (da der Integrand wie $e^{2\alpha^* t} \|\mathbf{Q}\|_2$ abklingt mit $\alpha^* < 0$). Man verifiziert $\mathbf{A}^\top \mathbf{P} + \mathbf{P} \mathbf{A} = -\mathbf{Q}$ durch direkte Differentiation:

$$\begin{aligned} \mathbf{A}^\top \mathbf{P} + \mathbf{P} \mathbf{A} &= \int_0^\infty (\mathbf{A}^\top e^{\mathbf{A}^\top t} \mathbf{Q} e^{\mathbf{A}t} + e^{\mathbf{A}^\top t} \mathbf{Q} e^{\mathbf{A}t} \mathbf{A}) dt \\ &= \int_0^\infty \frac{d}{dt} (e^{\mathbf{A}^\top t} \mathbf{Q} e^{\mathbf{A}t}) dt = [e^{\mathbf{A}^\top t} \mathbf{Q} e^{\mathbf{A}t}]_0^\infty = 0 - \mathbf{Q} = -\mathbf{Q}. \end{aligned}$$

Positiv Definitheit: für $\mathbf{z} \neq \mathbf{0}$ gilt $\mathbf{z}^\top \mathbf{P} \mathbf{z} = \int_0^\infty \|\mathbf{Q}^{1/2} e^{\mathbf{A}t} \mathbf{z}\|^2 dt > 0$.

(iii) Mit Eigenschaft (i) und der Variationsformel (3.5) gilt für beschränkte Eingabe $\|\mathbf{u}(t)\| \leq M < \infty$: $\|\mathbf{y}(t)\| \leq \|\mathbf{C}\| \|e^{\mathbf{A}t}\| \|\mathbf{x}_0\| + \|\mathbf{C}\| \|\mathbf{B}\| M \int_0^t \|e^{\mathbf{A}(t-\tau)}\| d\tau$, wobei das Integral konvergiert.

(iv) Folgt unmittelbar aus (i). $\square$

Theorem 3.4.4 (Eigenschaften KS-II: Grenzstabilität). *Sei $\mathbf{A} \in \text{KS-II}$. Dann gilt:*

(i) *Der Zustandsvektor ist endlich: $\sup_{t \geq 0} \|\mathbf{x}(t)\|_2 \leq c \|\mathbf{x}_0\|_2$ für eine Konstante $c > 0$.*

(ii) *Die rein imaginären Eigenwerte erzeugen persistente Oszillationen.*

(iii) *Asymptotische Stabilität ist nicht garantiert; $\mathbf{x}(t)$ konvergiert im Allgemeinen nicht gegen $\mathbf{0}$.*

(iv) *Das System ist Lyapunov-stabil, aber nicht asymptotisch stabil.*

Beweis. (i) Da alle Eigenwerte semieinfach sind (keine Jordan-Blöcke der Größe > 1) und $\text{Re}(\lambda_k) \leq 0$, hat $e^{\mathbf{A}t}$ die Form $\mathbf{V} \text{diag}(e^{\lambda_k t}) \mathbf{V}^{-1}$ mit $|e^{\lambda_k t}| \leq 1$ für alle k (da $\text{Re}(\lambda_k) \leq 0$). Damit $\|e^{\mathbf{A}t}\|_2 \leq \|\mathbf{V}\|_2 \|\mathbf{V}^{-1}\|_2 =: c < \infty$.

(ii) Für $\lambda_k = i\omega$ mit $\omega \neq 0$ gilt $e^{\lambda_k t} = \cos(\omega t) + i \sin(\omega t)$, was persistente Schwingungen erzeugt.

(iii) Wegen $|e^{i\omega t}| = 1$ gilt $\|\mathbf{x}(t)\| \not\rightarrow 0$.

(iv) Lyapunov-Stabilität folgt aus der Beschränktheit; asymptotische Stabilität erfordert $\text{Re}(\lambda_k) < 0$ für alle k , was per Annahme ausgeschlossen ist. $\square$

Theorem 3.4.5 (Eigenschaften KS-III: Instabilität). *Sei $\mathbf{A} \in \text{KS-III}$ mit $\alpha^* = \max_k \text{Re}(\lambda_k) > 0$. Dann gilt:*

(i) *$\|\mathbf{x}(t)\|_2 \rightarrow \infty$ für generische Anfangsbedingungen $\mathbf{x}_0 \notin E^s$ (instabiler Unterraum ist nicht-trivial).*

(ii) *Der Zustandsvektor ist **nicht** endlich.*

(iii) *Stabilitäts- und Robustheitseigenschaften können nicht garantiert werden.*

(iv) *Der Spektralradius des Übergangsoperators $e^{\mathbf{A}t}$ wächst unbeschränkt.*

Beweis. Sei $\lambda^* = \alpha^* + i\beta^*$ mit $\alpha^* > 0$ ein Eigenwert mit maximalem Realteil und $\mathbf{v}^*$ der zugehörige Eigenvektor. Für $\mathbf{x}_0 = \text{Re}(\mathbf{v}^*)$ gilt:

$$\mathbf{x}(t) = e^{\alpha^* t} (\cos(\beta^* t) \text{Re}(\mathbf{v}^*) - \sin(\beta^* t) \text{Im}(\mathbf{v}^*))$$

mit $\|\mathbf{x}(t)\| = e^{\alpha^* t} \|\mathbf{v}^*\| \rightarrow \infty$. Die Endlichkeitsbedingung (3.9) ist verletzt; Aussagen über das Langzeitverhalten sind daher prinzipiell nicht garantierbar. $\square$

Theorem 3.4.6 (Eigenschaften KS-IV: Hyperbolisches System). *Sei $\mathbf{A} \in \text{KS-IV}$ mit sowohl positiven als auch negativen Realteilen im Spektrum. Dann existiert eine direkte Zerlegung des Zustandsraums:*

$$\mathbb{R}^n = E^s \oplus E^u, \quad (3.15)$$

wobei E^s der stabile Unterraum ($\text{Re}(\lambda) < 0$) und E^u der instabile Unterraum ($\text{Re}(\lambda) > 0$) sind. Für Trajektorien mit $\mathbf{x}_0 \in E^s$ gilt Endlichkeit; für $\mathbf{x}_0 \notin E^s$ gilt $\|\mathbf{x}(t)\| \rightarrow \infty$.

Beweis. Die Zerlegung (3.15) folgt aus der Spektralprojektion: $P_s := \frac{1}{2\pi i} \oint_{\Gamma_s} (\lambda \mathbf{I} - \mathbf{A})^{-1} d\lambda$, wobei Γ_s eine Kurve ist, die $\sigma(\mathbf{A}) \cap \{\operatorname{Re}(\lambda) < 0\}$ umschließt. Dann gilt $E^s = \operatorname{Bild}(P_s)$, $E^u = \ker(P_s)$, und die Eigenschaften folgen aus den Theoremen 3.4.3 und 3.4.5 angewendet auf die jeweiligen Unterräume. $\square$

Abbildung 2: Phasenporträts - Klassen KS-I und KS-III




Abbildung 3.2: Phasenporträts für KS-I (links) und KS-III (rechts) mit je 12 Trajektorien. Links: alle Trajektorien konvergieren zum Ursprung (Attraktor, Endlichkeit garantiert). Rechts: Trajektorien divergieren, der Zustandsvektor ist nicht endlich.




Abbildung 3.3: Logarithmischer Normverlauf $\|\mathbf{x}(t)\|_2$ für alle vier Zustandsklassen. KS-I: exponentieller Abfall; KS-II: beschränkte Oszillation; KS-III: exponentielles Wachstum; KS-IV: richtungsabhängiges Verhalten.

3.4.3 Klassenzugehörigkeit als Entscheidungsproblem

Proposition 3.4.7 (Algorithmus zur Klassenzugehörigkeit). *Gegeben $\mathbf{A} \in \mathbb{R}^{n \times n}$. Die Klassenzugehörigkeit $\operatorname{KS}(\mathbf{A})$ kann in polynomialer Zeit $O(n^3)$ bestimmt werden:*

- S1.** Berechne $\sigma(\mathbf{A})$ via QR-Algorithmus in $O(n^3)$.
- S2.** Berechne $\alpha^* := \max_k \operatorname{Re}(\lambda_k)$.
- S3.** Falls $\alpha^* < 0$: Ausgabe KS-I.
- S4.** Falls $\alpha^* = 0$: Prüfe Semieinfachheit der rein-imaginären EW. Falls semieinfach: Ausgabe KS-II. Sonst: Ausgabe KS-II* (entartet).
- S5.** Falls $\alpha^* > 0$ und $\min_k \operatorname{Re}(\lambda_k) \geq 0$: Ausgabe KS-III.
- S6.** Falls $\alpha^* > 0$ und $\min_k \operatorname{Re}(\lambda_k) < 0$: Ausgabe KS-IV.




Abbildung 3.4: Zustandsklassenkarte für Systemmatrizen $\mathbf{A} = \begin{pmatrix} a_{11} & 0.5 \\ -0.5 & a_{22} \end{pmatrix}$ in Abhängigkeit der Diagonaleinträge. Die Farbgebung kodiert die Klassenzugehörigkeit: grün=KS-I, blau=KS-II, rot=KS-III, orange=KS-IV.

3.5 Graph-Systemmatrix-Korrespondenz und Subgraph Algorithmus

3.5.1 Von der Systemmatrix zum Systemgraphen

Definition 3.5.1 (Systemgraph). Sei $\mathbf{A} = (a_{ij}) \in \mathbb{R}^{n \times n}$ eine Systemmatrix. Der zugehörige *Systemgraph* ist der gewichtete gerichtete Graph

$$\mathcal{G}(\mathbf{A}) = (V, E, w), \quad (3.16)$$

mit Knotenmengen $V = \{x_1, \dots, x_n\}$ (den Zustandsvariablen), Kantenmenge $E = \{(x_i, x_j) : a_{ji} \neq 0\}$ und Gewichtsfunktion $w(x_i, x_j) = a_{ji}$.

Bemerkung 3.5.2. Der Systemgraph $\mathcal{G}(\mathbf{A})$ entspricht dem Signalflussgrafen des Systems. Die Adjazenzmatrix $\mathcal{A}(\mathcal{G}(\mathbf{A}))$ stimmt – nach geeigneter Binärisierung ($a_{ij} \neq 0 \mapsto 1$) – mit der Struktur von $\mathbf{A}$ überein. Dies ist die fundamentale Korrespondenz, die alle graphentheoretischen Methoden auf Systemmatrizen anwendbar macht.

Theorem 3.5.3 (Graphentheoretische Charakterisierung von Steuerbarkeit). *Das System $(\mathbf{A}, \mathbf{B})$ ist steuerbar genau dann, wenn für jeden Knoten $x_i \in V$ ein gerichteter Pfad von mindestens einem Eingangsknoten (Knoten mit Eintrag in $\mathbf{B}$) zu x_i im Systemgraphen $\mathcal{G}(\mathbf{A})$ existiert.*

Beweis. Dies ist eine bekannte Aussage der strukturellen Steuerbarkeit [Lin, 1974]. Die Steuerbarkeitsmatrix $\mathcal{C} = [\mathbf{B}, \mathbf{A}\mathbf{B}, \dots, \mathbf{A}^{n-1}\mathbf{B}]$ hat vollen Rang genau dann, wenn kein Eigenvektor von $\mathbf{A}^\top$ im Orthogonalkomplement des Spaltenraums von $\mathbf{B}$ liegt, was äquivalent zur Pfadbedingung im Graphen ist. $\square$

Abbildung 4: Adjazenzmatrix und Systemgraph




Abbildung 3.5: Links: Adjazenzmatrix $\mathcal{A}$ eines 6-Zustands-Systems (binäre Darstellung, Einträge $\in \{0, 1\}$). Rechts: Systemgraph $\mathcal{G}(\mathcal{A})$ im Kreislayout mit gerichteten Kanten.

3.5.2 Der Subgraph Algorithmus

Der *Subgraph Algorithmus* (kurz: SA) ist ein graphenbasiertes Verfahren zur vollständigen Analyse eines dynamischen Systems. Er verbindet die algebraische Eigenwertanalyse mit der topologischen Struktur des Systemgraphen.

Definition 3.5.4 (Subgraph). Sei $\mathcal{G}(\mathbf{A})$ der Systemgraph eines n -dimensionalen Systems. Der *Subgraph* $\mathcal{S}(\mathbf{A})$ ist ein annotierter, hierarchischer Metagraph:

$$\mathcal{S}(\mathbf{A}) = (\mathcal{G}(\mathbf{A}), \sigma(\mathbf{A}), \text{KS}(\mathbf{A}), \mathcal{C}_1, \dots, \mathcal{C}_r), \quad (3.17)$$

wobei $\mathcal{C}_1, \dots, \mathcal{C}_r$ die starken Zusammenhangskomponenten (strongly connected components, SCC) von $\mathcal{G}(\mathbf{A})$ bezeichnen.

Algorithm 1 Subgraph Algorithmus (SA) für Systemanalyse**Require:** Systemmatrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ **Ensure:** Subgraph $\mathcal{S}(\mathbf{A})$, Zustandsklasse $\text{KS}(\mathbf{A})$, Stabilitätsaussagen

- 1: **Graphkonstruktion:** Bilde $\mathcal{G}(\mathbf{A})$ gemäß Definition 3.5.1
- 2: **SCC-Zerlegung:** Berechne SCCs via Kosarajus Algorithmus in $O(n + |E|)$
- 3: **Spektralanalyse:** Berechne $\sigma(\mathbf{A})$ via QR-Iteration in $O(n^3)$
- 4: **Klassenbestimmung:** Bestimme $\text{KS}(\mathbf{A})$ gemäß Proposition 3.4.7
- 5: **Lyapunov-Analyse** (falls $\text{KS}(\mathbf{A}) = \text{KS-I}$):
- 6: Löse $\mathbf{A}^\top \mathbf{P} + \mathbf{P} \mathbf{A} = -\mathbf{I}$ via Bartels-Stewart-Algorithmus
- 7: **Steuerbarkeit:** Prüfe Pfadbedingung in $\mathcal{G}(\mathbf{A})$ (Theorem 3.5.3)
- 8: **Blockdiagonalisierung:** Zerlege $\mathcal{G}(\mathbf{A})$ in SCC-DAG
- 9: **Ausgabe:** Subgraph $\mathcal{S}(\mathbf{A})$ mit vollständiger Annotation

Abbildung 5: Subgraph Algorithmus - Klassifikationspipeline




Abbildung 3.6: Schematische Darstellung des Subgraph Algorithmus als Klassifikationspipeline. Ausgehend vom Subgraph $\mathcal{S}$ über die Eigenwertanalyse zu den vier Zustandsklassen, der Zustandsvektorzuzuordnung und schließlich zur wirtschaftlichen Implikation.

Theorem 3.5.5 (Korrektheit des Subgraph Algorithmus). *Der Subgraph Algorithmus (Algorithm 2) gibt die korrekte Zustandsklasse $\text{KS}(\mathbf{A})$ aus und identifiziert alle stabilen, grenzstabilen und instabilen Subsysteme korrekt. Die Gesamtkomplexität beträgt $O(n^3)$.*

Beweis. Die Korrektheit der Klassenbestimmung folgt aus Proposition 3.4.7. Die Korrektheit der SCC-Zerlegung ist eine bekannte Eigenschaft von Kosarajus Algorithmus [Kosaraju, 1978]. Die Bartels-Stewart-Methode löst die Lyapunov-Gleichung exakt in $O(n^3)$. Da alle Teilschritte $O(n^3)$ sind (der QR-Algorithmus dominiert), ergibt sich $O(n^3)$ insgesamt. $\square$

3.5.3 Graphentheoretische Stabilitätsbedingungen

Proposition 3.5.6 (SCC-basiertes Stabilitätskriterium). *Sei $\mathbf{A}$ blockuntere Dreiecksgestalt entsprechend der SCC-Zerlegung: $\mathbf{A} = \text{blockdiag}(\mathbf{A}_1, \dots, \mathbf{A}_r) + (\text{off-diagonal})$. Das Gesamtsystem gehört genau dann zu KS-I, wenn alle Diagonalblöcke $\mathbf{A}_k$ zu KS-I gehören.*

Beweis. $\sigma(\mathbf{A}) = \bigcup_{k=1}^r \sigma(\mathbf{A}_k)$ für die Block-Dreiecksstruktur (da die off-diagonalen Blöcke die Eigenwerte nicht ändern). Damit gilt $\alpha^*(\mathbf{A}) = \max_k \alpha^*(\mathbf{A}_k) < 0$ genau dann, wenn $\alpha^*(\mathbf{A}_k) < 0$ für alle k . $\square$




Abbildung 3.7: Stabilitätskarte: Maximaler Realteil der Eigenwerte der Begleitmatrix in Abhängigkeit der Parameter a und b . Die schwarze Kurve markiert die Stabilitätsgrenze ($\text{Re}(\lambda) = 0$), die grüne Region entspricht KS-I, die rote KS-III.

3.6 Wirtschaftliche Implikationen der Zustandsklassen

3.6.1 Wirtschaft als angewandte Mathematik

Die einleitende Beobachtung, dass es keine eigenständige “Finanztheorie” geben kann, lässt sich nun präzise mathematisch formulieren:

Theorem 3.6.1 (Mathematische Reduktion der Finanzwirtschaft). *Jedes makroökonomische Gleichgewichtsmodell, jedes Portfoliooptimierungsproblem und jede Zinsdynamiktheorie ist isomorph zu einem linearen oder nichtlinearen dynamischen System mit Zustandsvektor $\mathbf{x}(t) \in \mathbb{R}^n$ und Systemmatrix $\mathbf{A}$. Insbesondere sind alle qualitativen Stabilitätsaussagen über Wirtschaftssysteme vollständig durch $\text{KS}(\mathbf{A})$ bestimmt.*

Beweis. Man betrachte das allgemeine makroökonomische Dynamiksystem:

$$\dot{\mathbf{x}}(t) = F(\mathbf{x}(t), \mathbf{u}(t), t), \quad (3.18)$$

wobei $\mathbf{x} = (Y, \pi, r, D, C, \dots)^\top$ den Zustandsvektor (BIP-Index, Inflationsrate, Zinssatz, Schuldenquote, Konsum, ...) bezeichnet. Die Linearisierung um einen Gleichgewichtspunkt $\mathbf{x}^*$ liefert: $\dot{\tilde{\mathbf{x}}} = \mathbf{A}\tilde{\mathbf{x}} + O(\|\tilde{\mathbf{x}}\|^2)$, wobei $\mathbf{A} = \partial F / \partial \mathbf{x}|_{\mathbf{x}^*}$ die Jacobi-Matrix (= Systemmatrix) ist. Damit sind lokale Stabilitätseigenschaften des Wirtschaftssystems vollständig durch $\text{KS}(\mathbf{A})$ bestimmt. Eine eigenständige "Finanztheorie" jenseits dieser Reduktion auf lineare Systemanalyse enthält mathematisch gesehen keine zusätzliche Erklärungskraft. $\square$

Korollar 3.6.2 (Unwirtschaftlichkeit nicht-mathematischer Finanzmodelle). *Finanzmodelle, die nicht auf der mathematischen Systemtheorie beruhen, können die Zustandsklasse des betrachteten Wirtschaftssystems nicht korrekt identifizieren. Sie liefern damit keine Stabilitätsgarantien und führen per Theorem 3.4.5 für KS-III-Systeme zu unbeschränkten Zustandsabweichungen – d. h. zu wirtschaftlichen Divergenzen (Blasen, Hyperinflation, Schuldenkrisen).*

3.6.2 Zustandsklassen und wirtschaftliche Zustände

Die folgende Tabelle fasst die wirtschaftliche Interpretation jeder Zustandsklasse zusammen:

Tabelle 3.1: Zustandsklassen und wirtschaftliche Interpretation

Klasse	Eigenwertbedingung	Wirtschaftliche Interpretation	Implikation
KS-I	$\text{Re}(\lambda_k) < 0$, alle k	Stabiles Wachstum, Konvergenz	Investierbar
KS-II	$\max_k \text{Re}(\lambda_k) = 0$	Konjunkturzyklen, Zinspolitik	Beobachten
KS-III	$\max_k \text{Re}(\lambda_k) > 0$, alle	Blasen, Hyperinflation, Krisen	Risikowarnung
KS-IV	Gemischte Vorzeichen	Strukturelle Ungleichgewichte	Umstrukturierung

Beispiel 3.6.3 (IS-LM-Modell als KS-I-System). Das klassische IS-LM-Modell nach Hicks (1937) beschreibt die Volkswirtschaft durch das Gleichungssystem:

$$\begin{pmatrix} \dot{Y} \\ \dot{r} \end{pmatrix} = \underbrace{\begin{pmatrix} -\frac{1-c+m}{\alpha} & \frac{b}{\alpha} \\ \frac{k}{\beta} & -\frac{h}{\beta} \end{pmatrix}}_{\mathbf{A}_{\text{ISLM}}} \begin{pmatrix} Y - Y^* \\ r - r^* \end{pmatrix}, \quad (3.19)$$

wobei Y das Einkommen, r den Zinssatz, c die Konsumquote, m die Importquote, b, h die Zinselastizitäten der Investition bzw. Geldnachfrage, und α, β Anpassungsgeschwindigkeiten bezeichnen. Für typische Parameterwerte gilt $\text{tr}(\mathbf{A}_{\text{ISLM}}) < 0$ und $\det(\mathbf{A}_{\text{ISLM}}) > 0$, woraus $\text{Re}(\lambda_{1,2}) < 0$ folgt: das IS-LM-System ist KS-I.

Beispiel 3.6.4 (Schuldendynamik als KS-III-System). Die lineare Schuldendynamik lautet:

$$\dot{D} = r \cdot D - s, \quad (3.20)$$

wobei D die Schuldenquote, r der reale Zinssatz und s der Primärüberschuss ist. Die skalare Systemmatrix ist $A = r$. Für $r > 0$ (was in Zeiten hoher Zinsen gilt) ist das System KS-III: die Schuldenquote wächst exponentiell, falls $s < r \cdot D$. Dies ist die mathematisch präzise Beschreibung einer Staatsschuldenkrise.

Abbildung 6: Wirtschaftliche Zustandstrajektorien nach Systemklasse




Abbildung 3.8: Wirtschaftliche Zustandstrajektorien nach Systemklasse. Oben links: KS-I (stabile Volkswirtschaft, Konvergenz aller Indikatoren). Oben rechts: KS-III (divergierende Krisendynamik). Unten links: KS-II (persistente Konjunkturzyklen). Unten rechts: Vergleich der Normverläufe (logarithmisch).

3.6.3 Portfolio-Klassifikation nach Zustandsklassen

Definition 3.6.5 (Finanzsystem-Zustandsvektor). Für ein Portfolio oder einen Markt wird der Zustandsvektor definiert als

$$\mathbf{x}_{\text{fin}}(t) = (\mu(t), \sigma(t), \rho_{12}(t), \dots)^\top, \quad (3.21)$$

wobei μ die erwartete Rendite, σ die Volatilität und ρ_{ij} Korrelationskoeffizienten zwischen Vermögenswerten bezeichnen. Die assoziierte Systemmatrix $\mathbf{A}_{\text{fin}}$ ergibt sich aus der Linearisierung der Marktdynamikgleichungen.

Proposition 3.6.6 (Klassifikation des Risikos). *Ein Portfolio mit assoziiertem KS-I-System hat mathematisch garantierte Wertstabilität im Sinne der Zustandsendlichkeit. Ein KS-III-Portfolio ist per Theorem 3.4.5 nicht stabil analysierbar – klassische Value-at-Risk- oder Sharpe-Ratio-Metriken verlieren ihre Gültigkeit.*




Abbildung 3.9: Portfolio-Klassifikation im (σ, μ) -Raum nach der Zustandsklasse des assoziierten dynamischen Finanzsystems. Grüne Punkte (KS-I) entsprechen stabilen, analysierbaren Portfolios; rote Punkte (KS-III) sind mathematisch instabil.

3.6.4 Wirtschaftliche Zyklen als KS-II-Phänomen

Theorem 3.6.7 (Konjunkturzyklen als KS-II-Trajektorien). *Sei $\mathbf{A} \in \text{KS-II}$ mit einem Paar konjugierter rein-imaginärer Eigenwerte $\lambda_{1,2} = \pm i\omega$, $\omega > 0$. Dann ist die Lösung $\mathbf{x}(t)$ periodisch mit Periode $T = 2\pi/\omega$:*

$$\mathbf{x}(t + T) = \mathbf{x}(t) \quad \forall t \geq 0. \quad (3.22)$$

Beweis. Aus Theorem 3.4.4 gilt $\mathbf{x}(t) = \mathbf{V} \text{diag}(e^{\lambda_k t}) \mathbf{V}^{-1} \mathbf{x}_0$. Für $\lambda_k = \pm i\omega$: $e^{i\omega(t+T)} = e^{i\omega t} e^{i\omega T} = e^{i\omega t} \cdot 1$, da $\omega T = 2\pi$. Damit gilt $e^{\mathbf{A}(t+T)} = e^{\mathbf{A}t}$ und (3.22) folgt. $\square$




Abbildung 3.10: Wirtschaftliche Zyklusmodelle durch konjugierte Eigenwerte. KS-II-Systeme ($\text{Re}(\lambda) = 0$, blau gestrichelt) erzeugen neutrale Zyklen. KS-III-Systeme ($\text{Re}(\lambda) > 0$, rot) erzeugen wachsende Inflationsspiralen. KS-I-Systeme ($\text{Re}(\lambda) < 0$, grün) erzeugen gedämpfte Zyklen.

3.6.5 Lyapunov-Funktion als Wirtschaftspotenzial

Theorem 3.6.8 (Wirtschaftliches Lyapunov-Potenzial). *Für ein KS-I-Wirtschaftssystem definiert $V(\mathbf{x}) = \mathbf{x}^\top \mathbf{P} \mathbf{x}$ (mit $\mathbf{P} > 0$ aus Theorem 3.4.3 (ii)) ein wirtschaftliches Potenzial, das folgende Eigenschaften hat:*

(i) $V(\mathbf{x}^*) = 0$ (minimales Potenzial im Gleichgewicht $\mathbf{x}^*$),

(ii) $V(\mathbf{x}) > 0$ für $\mathbf{x} \neq \mathbf{x}^*$ (jede Abweichung erhöht das Potenzial),

(iii) $\dot{V}(\mathbf{x}(t)) < 0$ entlang Trajektorien (das Potenzial nimmt monoton ab).

Beweis. (i) und (ii) folgen aus $\mathbf{P} > 0$. Für (iii): $\dot{V} = \dot{\mathbf{x}}^\top \mathbf{P} \mathbf{x} + \mathbf{x}^\top \mathbf{P} \dot{\mathbf{x}} = \mathbf{x}^\top (\mathbf{A}^\top \mathbf{P} + \mathbf{P} \mathbf{A}) \mathbf{x} = -\mathbf{x}^\top \mathbf{Q} \mathbf{x} < 0$ für $\mathbf{x} \neq \mathbf{0}$ (da $\mathbf{Q} > 0$). $\square$

Abbildung 8: Lyapunov-Funktion $V(\mathbf{x}) = \mathbf{x}^\top \mathbf{P} \mathbf{x}$
für KS-I-System (positiv definit, $\dot{V} < 0$)




Abbildung 3.11: Lyapunov-Funktion $V(\mathbf{x}) = \mathbf{x}^\top \mathbf{P} \mathbf{x}$ als wirtschaftliches Potenzialgebirge für ein KS-I-System. Das Minimum befindet sich im Gleichgewicht; alle Trajektorien folgen dem “Hang” bergab – das wirtschaftliche Potenzial nimmt monoton ab.

3.6.6 Zustandsraumtransformation und wirtschaftliche Normalform

Definition 3.6.9 (Wirtschaftliche Modalkoordinaten). Sei $\mathbf{A}$ die Systemmatrix eines Wirtschaftsmodells mit Eigenzerlegung $\mathbf{A} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^{-1}$. Die *wirtschaftlichen Modalkoordinaten* sind

$$\mathbf{z}(t) = \mathbf{V}^{-1} \mathbf{x}(t), \quad (3.23)$$

wobei jede Komponente $z_k(t) = e^{\lambda_k t} z_k(0)$ unabhängig nach der Eigenwertdynamik evolviert.

Bemerkung 3.6.10. In Modalkoordinaten entkoppelt das Wirtschaftssystem vollständig in n unabhängige skalare Dynamiken, von denen jede einzeln nach ihrer Zustandsklasse bewertet werden kann. Instabile Modalkomponenten ($\text{Re}(\lambda_k) > 0$) identifizieren präzise die wirtschaftlichen “Risikofaktoren” des Systems.

Abbildung 12: Zustandsraumtransformation - Original- und Modalkoordinaten




Abbildung 3.12: Zustandsraumtransformation: Originalkoordinaten (links), Modalkoordinaten (Mitte) und Normvergleich (rechts) für ein KS-I-System dritter Ordnung. In Modalkoordinaten evolviert jede Komponente unabhängig.

3.6.7 Steuerbarkeit, Beobachtbarkeit und wirtschaftliche Steuerung

Theorem 3.6.11 (Wirtschaftliche Steuerbarkeit). *Ein Wirtschaftssystem $(\mathbf{A}, \mathbf{B})$ ist steuerbar genau dann, wenn für jede Zielkonfiguration $\mathbf{x}_f \in \mathbb{R}^n$ und jeden Zeithorizont $T > 0$ eine Steuerpolitik $\mathbf{u} : [0, T] \rightarrow \mathbb{R}^m$ (z. B. Zinssatz, Staatsausgaben, Transferzahlungen) existiert, die das System von $\mathbf{x}_0$ nach $\mathbf{x}_f$ überführt.*

Beweis. Standardergebnis der linearen Systemtheorie: Das System ist steuerbar genau dann, wenn die Steuerbarkeitsmatrix $\mathbf{C} = [\mathbf{B}, \mathbf{AB}, \mathbf{A}^2\mathbf{B}, \dots, \mathbf{A}^{n-1}\mathbf{B}]$ vollen Rang n hat (Kalman-Rang-Bedingung, [Kalman, 1960]). Die Steuerpolitik ergibt sich dann explizit durch Minimierung der Eingabenorm über die Grammatrix $\mathbf{W}_c(T) = \int_0^T e^{\mathbf{A}t} \mathbf{B} \mathbf{B}^\top e^{\mathbf{A}^\top t} dt$. $\square$

Abbildung 10: Steuer- und Beobachtbarkeitsanalyse nach Systemklasse




Abbildung 3.13: Steuerbarkeits- (links) und Beobachtbarkeitsrang (rechts) in Abhängigkeit der Systemdimension n . Vollständig steuerbare/beobachtbare Systeme (grün) erreichen Rang = n ; nicht steuerbare/beobachtbare Systeme (rot) bleiben dahinter zurück.

3.7 Der Subgraph Algorithmus in der Systemanalyse

Der in Kapitel 3.5 eingeführte Systemgraph $\mathcal{G}(\mathbf{A})$ ermöglicht die Anwendung graphentheoretischer Algorithmen auf dynamische Systeme. Ein zentrales Problem dabei ist der *Subgraph-Vergleich*: Gegeben zwei Systemmatrizen $\mathbf{A}$ und $\mathbf{B}$, ist das durch $\mathbf{A}$ beschriebene System strukturell im durch $\mathbf{B}$ beschriebenen System enthalten? Der *Subgraph Algorithmus* [Epp, 2026c] löst dieses Problem effizient in $O(n^3)$ durch eine neuartige Kombination aus Signaturhashing und zyklischer Rotation.

3.7.1 Problemstellung: Strukturelles Enthaltensein zweier Systemgraphen

Definition 3.7.1 (Strukturelle Subgraph-Relation). Seien $\mathcal{G}(\mathbf{A})$ und $\mathcal{G}(\mathbf{B})$ die Systemgraphen zweier LTI-Systeme mit n Zustandsvariablen. Die *strukturelle Subgraph-Relation* $\mathcal{G}(\mathbf{A}) \subseteq \mathcal{G}(\mathbf{B})$ ist definiert durch:

$$\mathcal{G}(\mathbf{A}) \subseteq \mathcal{G}(\mathbf{B}) \iff \forall (i, j) : A_{ij} \neq 0 \Rightarrow B_{ij} \neq 0. \quad (3.24)$$

Das heisst, jede Kopplung (Kante) im System $\mathbf{A}$ existiert auch im System $\mathbf{B}$; $\mathbf{B}$ enthält mindestens alle Kopplungen von $\mathbf{A}$ und möglicherweise weitere.

Bemerkung 3.7.2. In der Systemtheorie entspricht $\mathcal{G}(\mathbf{A}) \subseteq \mathcal{G}(\mathbf{B})$ der Aussage, dass das System $\mathbf{A}$ eine *strukturelle Vereinfachung* (ein Subsystem) von $\mathbf{B}$ ist. Gilt $\mathcal{G}(\mathbf{A}) \subseteq \mathcal{G}(\mathbf{B})$ und $\mathcal{G}(\mathbf{B}) \subseteq \mathcal{G}(\mathbf{A})$, so sind beide Systeme strukturell isomorph. Der Subgraph Algorithmus beantwortet damit automatisch die Frage, welches von zwei Systemmodellen mehr Kopplungsinformation trägt – eine fundamentale Frage der Modellreduktion und Systemidentifikation.

Das Ergebnis des Subgraph Algorithmus [Epp, 2026c] ist ein Vierfeldentscheid:

- (i) $\mathcal{G}(\mathbf{B}) \supseteq \mathcal{G}(\mathbf{A})$: Verwerfe $\mathbf{A}$, behalte $\mathbf{B}$ ($\mathbf{B}$ trägt mehr Kopplungsinformation).
- (ii) $\mathcal{G}(\mathbf{A}) \supseteq \mathcal{G}(\mathbf{B})$: Behalte $\mathbf{A}$, verwerfe $\mathbf{B}$.
- (iii) $\mathcal{G}(\mathbf{A}) = \mathcal{G}(\mathbf{B})$: Beliebiges Modell behalten.
- (iv) Keine Enthaltensein-Beziehung: Beide Modelle behalten.

3.7.2 Signaturbasierte Matrixkodierung

Das Kernprinzip des Subgraph Algorithmus [Epp, 2026c] besteht darin, jede Spalte der Adjazenzmatrix durch eine injektive Signaturfunktion auf eine ganze Zahl abzubilden. Dies reduziert den Vergleich zweier $n \times n$ Matrizen auf den Vergleich zweier n -dimensionaler Vektoren.

Definition 3.7.3 (Spaltensignatur). Sei $A \in \{0, 1\}^{n \times n}$ eine Adjazenzmatrix mit Spaltenvektor $\mathbf{a}_j = (A_{0j}, A_{1j}, \dots, A_{(n-1)j})^\top$. Die *Spaltensignatur* der j -ten Spalte ist:

$$\sigma_j(A) := \underbrace{\sum_{i=0}^{n-1} A_{ij} \cdot 2^i}_{\text{Zeilenkomponente}} + \underbrace{j \cdot 2^n}_{\text{Spaltengewichtung}}. \quad (3.25)$$

Das *Signaturarray* von A ist $\boldsymbol{\sigma}(A) := (\sigma_0(A), \sigma_1(A), \dots, \sigma_{n-1}(A))^\top \in \mathbb{N}^n$.

Beispiel 3.7.4 (Signaturberechnung). Für $n = 4$ und die Adjazenzmatrix

$$A = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

ergibt sich: $\sigma_0 = 0$; $\sigma_1 = 2^0 + 1 \cdot 16 = 17$; $\sigma_2 = 2^1 + 2 \cdot 16 = 34$; $\sigma_3 = 2^2 + 3 \cdot 16 = 52$.
Signaturarray: $\sigma(A) = (0, 17, 34, 52)$.

Lemma 3.7.5 (Injektivität der Signaturfunktion, nach [Epp, 2026c]). *Die Signaturfunktion $\sigma_j : \{0, 1\}^n \times \{0, \dots, n-1\} \rightarrow \mathbb{N}$ ist injektiv: verschiedene $(j, \mathbf{a}_j)$ -Paare erhalten verschiedene Signaturen.*

Beweis. Die Abbildung $\mathbf{a} \mapsto \sum_i a_i 2^i$ ist bijektiv von $\{0, 1\}^n$ nach $\{0, \dots, 2^n - 1\}$; verschiedene Spaltenvektoren erhalten verschiedene Zeilenkomponenten $R(\mathbf{a}_j) \in [0, 2^n - 1]$. Da $j \cdot 2^n$ für verschiedene j disjunkte Intervalle $[j \cdot 2^n, (j+1) \cdot 2^n - 1]$ erzeugt und $R(\mathbf{a}_j) < 2^n$, sind alle Signaturen $\sigma_j = R(\mathbf{a}_j) + j \cdot 2^n$ paarweise verschieden. $\square$

3.7.3 Zyklische Rotation statt vollständiger Permutation

Das klassische Subgraph-Isomorphismusproblem ist NP-vollständig, da es alle $n!$ Permutationen prüfen muss. Der Subgraph Algorithmus [Epp, 2026c] umgeht diese kombinatorische Explosion durch Beschränkung auf *zyklische* Rotationen.

Definition 3.7.6 (Zyklische Spaltenrotation). Die zyklische Spaltenrotation um k Positionen einer Matrix $B \in \{0, 1\}^{n \times n}$ ist $\text{rot}_k(B)$ mit

$$\left[\text{rot}_k(B) \right]_{ij} := B_{i, (j+k) \bmod n}. \quad (3.26)$$

Beispiel 3.7.7 (Zyklische Rotationen für $n = 4$). Für das Signaturarray $\sigma = [\sigma_0, \sigma_1, \sigma_2, \sigma_3]$ ergeben sich genau 4 zyklische Rotationen statt $4! = 24$ Permutationen:

$$k = 0 : [\sigma_0, \sigma_1, \sigma_2, \sigma_3], \quad k = 1 : [\sigma_1, \sigma_2, \sigma_3, \sigma_0], \quad k = 2 : [\sigma_2, \sigma_3, \sigma_0, \sigma_1], \quad k = 3 : [\sigma_3, \sigma_0, \sigma_1, \sigma_2].$$

Proposition 3.7.8 (Korrektheit der zyklischen Einschränkung). *Die Beschränkung auf zyklische Rotationen ist systemtheoretisch korrekt, wenn die sequentielle Ordnung der Zustandsvariablen durch die Modellierung festgelegt ist (z. B. Zustandsvariablen in einer Signalverarbeitungskette oder einem Ringschaltkreis). Die Gruppe $\mathbb{Z}_n$ der zyklischen Rotationen deckt alle n möglichen Startpositionen der Knotennummerierung vollständig ab.*

3.7.4 Der Subgraph Algorithmus: Vollständige Beschreibung

Algorithm 2 Subgraph Algorithmus [Epp, 2026c]

Require: Adjazenzmatrizen $A, B \in \{0, 1\}^{n \times n}$

Ensure: Entscheidung: keep_A, keep_B, keep_either, keep_both

```

1: Phase 1 – Signaturberechnung  $\sigma^A$ :  $\sigma_j^A \leftarrow \sum_{i=0}^{n-1} A_{ij} 2^i + j \cdot 2^n$  für  $j = 0, \dots, n-1$ 
2: Phase 2 – Signaturberechnung  $\sigma^B$ :  $\sigma_j^B \leftarrow \sum_{i=0}^{n-1} B_{ij} 2^i + j \cdot 2^n$  für  $j = 0, \dots, n-1$ 
3: Phase 3 – Zeilenkomponenten:  $\rho_j^A \leftarrow \sigma_j^A \bmod 2^n$ ;  $\rho_j^B \leftarrow \sigma_j^B \bmod 2^n$ 
4:  $AinB \leftarrow \text{FALSE}$ 
5: for  $k = 0$  to  $n - 1$  do
6:    $\rho_k^B \leftarrow$  Rotation von  $\rho^B$  um  $k$  Positionen
7:   if  $\text{LCS}(\rho^A, \rho_k^B) \geq 2$  then
8:      $AinB \leftarrow \text{TRUE}$ ; break
9:   end if
10: end for
11:  $BinA \leftarrow \text{FALSE}$ 
12: for  $k = 0$  to  $n - 1$  do
13:    $\rho_k^A \leftarrow$  Rotation von  $\rho^A$  um  $k$  Positionen
14:   if  $\text{LCS}(\rho^B, \rho_k^A) \geq 2$  then
15:      $BinA \leftarrow \text{TRUE}$ ; break
16:   end if
17: end for
18: if  $AinB$  and  $BinA$  then return keep_either
19: else if  $AinB$  then return keep_B
20: else if  $BinA$  then return keep_A
21: else return keep_both
22: end if

```

3.7.4.1 Longest Common Subsequence als Subgraph-Kriterium

Theorem 3.7.9 (Subgraph-Kriterium via LCS, nach [Epp, 2026c]). *Seien ρ^A und ρ_k^B die Zeilenkomponenten-Signaturvektoren von A und der k -ten Rotation von B . Dann gilt:*

$$\mathcal{G}(A) \subseteq \text{rot}_k(\mathcal{G}(B)) \iff \text{LCS}(\rho^A, \rho_k^B) \geq 2. \quad (3.27)$$

Beweis. Eine Subgraph-Beziehung erfordert mindestens zwei durch eine Kante verbundene Knoten aus $\mathcal{G}(A)$, die ihre Verbindungsstruktur in $\mathcal{G}(B)$ wiederfinden. Eine Kante $v_i \rightarrow v_j$ ($A_{ij} = 1$) wird in der Signatur durch den Term 2^i in ρ_j^A kodiert. Stimmt ρ_j^A mit dem entsprechenden Eintrag der rotierten Signatursequenz von B überein, existiert die Kante auch in der Rotation von $\mathcal{G}(B)$. Eine LCS-Länge ≥ 2 bezeugt mindestens zwei übereinstimmende Spaltenstrukturen – damit eine zusammenhängende Subgraph-Struktur. Die Injektivität (Lemma 3.7.5) schliesst Fehlerkennungen aus. $\square$

Die LCS zweier Sequenzen $X = [x_1, \dots, x_m]$ und $Y = [y_1, \dots, y_n]$ wird durch das klassische DP-Schema in $O(mn)$ berechnet:

$$\text{dp}[i][j] = \begin{cases} 0 & i = 0 \text{ oder } j = 0, \\ \text{dp}[i-1][j-1] + 1 & x_i = y_j, \\ \max(\text{dp}[i-1][j], \text{dp}[i][j-1]) & x_i \neq y_j. \end{cases} \quad (3.28)$$

3.7.5 Korrektheit des Subgraph Algorithmus

Theorem 3.7.10 (Korrektheit, nach [Epp, 2026c]). *Der Subgraph Algorithmus (Algorithmus 2) entscheidet korrekt, ob eine zyklische Subgraph-Beziehung zwischen $\mathcal{G}(A)$ und $\mathcal{G}(B)$ existiert.*

Beweis. (i) **Vollständigkeit:** Existiert Rotation k^* mit $\mathcal{G}(A) \subseteq \text{rot}_{k^*}(\mathcal{G}(B))$, so wird für $k = k^*$ nach Theorem 3.7.9 die LCS-Bedingung erfüllt und $\text{AinB} = \text{TRUE}$ gesetzt.

(ii) **Keine Falschpositive:** Die Injektivität der Signaturfunktion (Lemma 3.7.5) garantiert: $\rho_j^A = \rho_{j'}^B$ nur wenn $\mathbf{a}_j = \mathbf{b}_{j'}$. Eine LCS-Übereinstimmung der Länge ≥ 2 zeigt daher tatsächlich strukturelle Übereinstimmung an.

(iii) **Entscheidungsvollständigkeit:** Die vier Ausgaben decken die vier logischen Möglichkeiten der Relationen $A \subseteq B$, $B \subseteq A$, beides oder keines vollständig und disjunkt ab. $\square$

3.7.6 Komplexitätsanalyse

Theorem 3.7.11 (Laufzeit des Subgraph Algorithmus, nach [Epp, 2026c]). *Der Subgraph Algorithmus hat Worst-Case-Laufzeit $\Theta(n^3)$ und Speicherbedarf $O(n^2)$.*

Beweis. **Phasen 1&2:** Je n Spalten mit je n Einträgen: $O(n^2)$ pro Phase. **Phase 3:** n Modulo-Operationen: $O(n)$. **Phasen 4&5:** Je n Rotationen, pro Rotation LCS in $O(n^2)$: $O(n^3)$ pro Phase. Gesamtlaufzeit: $O(n^2 + n^2 + n + n^3) = O(n^3)$.

Untere Schranke $\Omega(n^3)$: Aus Lemma 1–4 in [Epp, 2026c]: alle n^2 Einträge müssen gelesen werden ($\Omega(n^2)$); alle n Rotationen müssen geprüft werden; pro Rotation ist LCS unter SETH $\Omega(n^{2-\varepsilon})$; die n LCS-Berechnungen sind unabhängig. Zusammen: $\Omega(n^{3-\varepsilon})$ für beliebiges $\varepsilon > 0$, also $\Theta(n^3)$.

Speicher: $O(n^2)$ für Matrizen und wiederverwendete LCS-DP-Tabelle. $\square$

Theorem 3.7.12 (Optimalität unter SETH, nach [Epp, 2026c]). *Unter der Strong Exponential Time Hypothesis (SETH) kann das zyklische Subgraph-Problem nicht in $O(n^{3-\varepsilon})$ für beliebiges $\varepsilon > 0$ gelöst werden. Der Subgraph Algorithmus ist daher asymptotisch optimal.*

Beweisstruktur nach [Epp, 2026c]. Vier Lemmata in [Epp, 2026c] etablieren die untere Schranke: (1) *Eingabe-Leseschranke* $\Omega(n^2)$: Weglassen eines Matrixeintrags erlaubt Konstruktion einer Gegeninstanz mit falscher Ausgabe. (2) *Notwendigkeit aller Rotationen*: Für jede übersprungene Rotation k^* existiert eine Instanz, bei der nur k^* eine Subgraph-Beziehung liefert. (3) *LCS-Schranke* $\Omega(n^{2-\varepsilon})$ unter SETH: nach Abboud, Backurs, Vassilevska Williams (FOCS 2015). (4) *Unabhängigkeit der Rotationen*: Die n LCS-Berechnungen können nicht mit Gesamtaufwand $o(n \cdot T_{\text{LCS}}(n))$ durchgeführt werden. Zusammen: $T_{\text{ges}}(n) \geq \Omega(n^{3-\varepsilon})$. $\square$

Tabelle 3.2: Komplexitätsvergleich: Subgraph Algorithmus vs. naive Ansätze

Verfahren	Zeitkomplexität	Speicher	Optimal?
Naive Permutation	$O(n! \cdot n^2)$	$O(n^2)$	Nein
Backtracking (VF2)	$O(n!)$ (Worst Case)	$O(n^2)$	Nein
Subgraph Algorithmus	$\Theta(n^3)$	$O(n^2)$	Ja (unter SETH)

3.7.7 Verbindung zur Systemmatrix-Klassifikation

Proposition 3.7.13 (Subgraph-Relation und Stabilitäts-erbe). *Sei $\mathcal{G}(\mathbf{A}) \subseteq \mathcal{G}(\mathbf{B})$. Ist $\mathbf{B} \in \text{KS-I}$ und ist die Zusatzkopplungsmatrix $\Delta := \mathbf{B} - \mathbf{A}$ (komponentenweise ≥ 0) stabilisierend, so gilt $\mathbf{A} \in \text{KS-I}$.*

Beweis. Strukturell gilt $\mathbf{A} = \mathbf{B} - \Delta$ mit $\Delta \geq 0$ komponentenweise. Enthält Δ nur ausserdiagonale Dämpfungsterme (d. h. $\Delta_{ij} \geq 0$ stabilisiert die Kopplung), so gilt $\alpha^*(\mathbf{A}) \leq \alpha^*(\mathbf{B}) < 0$, also $\mathbf{A} \in \text{KS-I}$. $\square$

Proposition 3.7.14 (Modellreduktion durch Subgraph-Enthalten). *Liefert der Subgraph Algorithmus [Epp, 2026c] das Ergebnis `keep_B`, so kann das Modell $\mathbf{A}$ für Zwecke der strukturellen Analyse ohne Kopplungsinformationsverlust durch $\mathbf{B}$ ersetzt werden: Steuerbarkeits-, Beobachtbarkeits- und Pfadbedingungen bleiben für $\mathbf{B}$ mindestens ebenso erfüllt.*

Beweis. Aus $A_{ij} \neq 0 \Rightarrow B_{ij} \neq 0$ folgt, dass jeder Pfad in $\mathcal{G}(\mathbf{A})$ auch in $\mathcal{G}(\mathbf{B})$ existiert. Nach Theorem 3.5.3 ist daher jede durch Pfade garantierte Steuerbarkeit in $\mathbf{A}$ auch in $\mathbf{B}$ gegeben. $\square$

3.7.8 Anwendung auf wirtschaftliche Systemmodelle

Beispiel 3.7.15 (Vergleich zweier makroökonomischer Modelle). Betrachte zwei Systemmatrizen für eine 3-dimensionale Volkswirtschaft (BIP Y , Inflation π , Zins r):

$$\mathbf{A}_1 = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}, \quad \mathbf{A}_2 = \begin{pmatrix} 0 & 1 & 1 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}.$$

Der Subgraph Algorithmus liefert $\mathcal{G}(\mathbf{A}_1) \subseteq \mathcal{G}(\mathbf{A}_2)$ (`keep_B`): $\mathbf{A}_2$ enthält zusätzlich die direkte BIP-Zins-Kopplung. Ist $\mathbf{A}_2 \in \text{KS-I}$, so ist nach Proposition 3.7.13 auch $\mathbf{A}_1$ stabil – die Zinspolitik wirkt nicht destabilisierend.

Beispiel 3.7.16 (Deduplizierung konkurrierender Finanzmodelle). Gegeben k Systemmodelle $\mathbf{A}_1, \dots, \mathbf{A}_k$ für dieselbe Volkswirtschaft. Der Subgraph Algorithmus vergleicht paarweise alle $\binom{k}{2}$ Paare in je $O(n^3)$. Modelle, die als Subgraphen anderer enthalten sind, werden als redundant identifiziert. Das Ergebnis ist eine Menge *maximaler* Modelle: eine informationstheoretisch nicht-redundante Modellbibliothek.

3.7.9 Implementierungshinweis

Der Subgraph Algorithmus ist quelloffen verfügbar unter:

<https://github.com/hjstephan86/science>

Die Implementierung [Epp, 2026c] verwendet NumPy für effiziente Matrixoperationen und ist für Adjazenzmatrizen bis $n \approx 5000$ praktisch einsetzbar. Für sehr grosse sparse Graphen bietet die Adjazenzzustanddarstellung eine Speicheroptimierung auf $O(n + m)$.

Kernaussagen: Subgraph Algorithmus

- (i) Laufzeit $\Theta(n^3)$, asymptotisch optimal unter SETH [Epp, 2026c].
- (ii) Injektive Signaturfunktion garantiert fehlerfreie Strukturerkennung.

- (iii) n zyklische Rotationen statt $n!$ Permutationen: von superexponentiell zu kubisch.
- (iv) Subgraph-Relation $\mathcal{G}(\mathbf{A}) \subseteq \mathcal{G}(\mathbf{B})$ vermittelt Stabilitätseigenschaften, Steuerbarkeit und Modellreduktion.
- (v) Anwendung in der Wirtschaftsanalyse: struktureller Modellvergleich und Deduplizierung von Systemmodellbibliotheken.

3.8 Graphprofilverteilung der Zustandsklassen

Die vorhergehenden Kapitel haben gezeigt, dass die Systemmatrix $\mathbf{A}$ einen gerichteten Graphen $\mathcal{G}(\mathbf{A})$ induziert, dessen Struktur die Zustandsklasse vollständig bestimmt. In der Begleitarbeit [Epp, 2026d] wurde die Theorie der *optimalen Graphprofilverteilung* entwickelt, die jeden Graphen durch ein Tripel (D, L, κ) beschreibt – bestehend aus der kürzesten-Pfad-Matrix D , der längsten-Pfad-Matrix L und dem Kantenmaß $\kappa := |V|/|E|$. Das vorliegende Kapitel überträgt diese Theorie auf die Systemgraphen $\mathcal{G}(\mathbf{A})$ der Zustandsklassen KS-I bis KS-IV und zeigt, dass jede Zustandsklasse ein charakteristisches Graphprofil besitzt. Die theoretischen Ergebnisse werden durch umfangreiche numerische Experimente an 10 000 zufällig generierten Systemmatrizen validiert.

3.8.1 Graphprofil für Systemgraphen

Definition 3.8.1 (Systemgraph). Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ eine Systemmatrix. Der *Systemgraph* $\mathcal{G}(\mathbf{A}) = (V, E)$ ist der gewichtete, gerichtete Graph mit Knotenmenge $V = \{1, \dots, n\}$ und Kantenmenge $E = \{(i, j) : a_{ij} \neq 0\}$, wobei jede Kante (i, j) das Gewicht $|a_{ij}|$ trägt.

Definition 3.8.2 (Graphprofil eines Systemgraphen). Sei $\mathcal{G}(\mathbf{A}) = (V, E)$ ein Systemgraph mit $|V| = n$ und $|E| = m$. Das *Graphprofil* von $\mathcal{G}(\mathbf{A})$ ist das Tripel $\mathcal{P}(\mathbf{A}) := (D, L, \kappa)$, wobei:

- (i) $D = (d_{ij}) \in \mathbb{R}^{n \times n}$ die *kürzeste-Pfad-Matrix* mit $d_{ij} := \min_{\pi \in \Pi(i, j)} |\pi|$ ist, wobei $\Pi(i, j)$ die Menge aller Pfade von i nach j und $|\pi|$ die Pfadlänge (Anzahl der Kanten) bezeichnen. Falls kein Pfad existiert, setze $d_{ij} := \infty$.
- (ii) $L = (\ell_{ij}) \in \mathbb{R}^{n \times n}$ die *längste-Pfad-Matrix* mit $\ell_{ij} := \max_{\pi \in \Pi_s(i, j)} |\pi|$ ist, wobei $\Pi_s(i, j)$ die Menge aller *einfachen* Pfade von i nach j bezeichnet. Falls kein Pfad existiert, setze $\ell_{ij} := 0$.
- (iii) $\kappa := n/m \in (0, \infty)$ das *Kantenmaß* ist, welches das Verhältnis von Knoten- zu Kantenanzahl misst.

Der *Durchmesser* des Graphen ist $\text{diam}(\mathcal{G}) := \max_{i, j: d_{ij} < \infty} d_{ij}$.

Bemerkung 3.8.3. Das Kantenmaß κ ist die Inverse des durchschnittlichen Ausgangsgrads. Für einen vollständigen Graphen gilt $\kappa = 1/(n-1)$, für einen Pfadgraphen $\kappa = n/(n-1) \approx 1$. Dünn besetzte Systemmatrizen haben große κ -Werte, dicht besetzte kleine.

3.8.2 Charakterisierung der Zustandsklassen durch Graphprofile

Theorem 3.8.4 (Charakterisierung der Zustandsklassen durch Graphprofile). *Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ mit Systemgraph $\mathcal{G}(\mathbf{A})$ und Graphprofil $\mathcal{P}(\mathbf{A}) = (D, L, \kappa)$. Sei $\alpha^* := \max_k \operatorname{Re}(\lambda_k(\mathbf{A}))$ die Spektralabszisse. Dann gelten folgende notwendige Bedingungen:*

- (i) **KS-I** ($\alpha^* < 0$): *Es existiert eine obere Schranke $\kappa \leq \kappa_I(n)$, die nur von der Dimension n abhängt. Insbesondere erfordert asymptotische Stabilität eine hinreichende Kantendichte, und es gilt $\operatorname{diam}(\mathcal{G}) \geq 2$ für $n \geq 3$.*
- (ii) **KS-II** ($\alpha^* = 0$, semieinfach): *Grenzstabile Systeme weisen das kleinste mittlere Kantenmaß auf: $\mathbb{E}[\kappa_{II}] < \mathbb{E}[\kappa_k]$ für $k \in \{I, III, IV\}$. Die Graphen sind dichter vernetzt und haben einen kleineren Durchmesser.*
- (iii) **KS-III** ($\alpha^* > 0$, alle $\operatorname{Re}(\lambda_k) > 0$): *Das Kantenmaß κ_{III} ist statistisch nicht unterscheidbar von κ_I . Die Graphstrukturen stabiler und vollständig instabiler Systeme sind im Profil symmetrisch.*
- (iv) **KS-IV** (gemischte Vorzeichen): *Die Profile hyperbolischer Systeme liegen im Mittel zwischen KS-I und KS-III, mit vergleichbarer Varianz.*

Beweis. (i) Sei $\mathbf{A} \in \text{KS-I}$ mit $\operatorname{Re}(\lambda_k) < 0$ für alle k . Die Hurwitz-Bedingungen erfordern, dass die Hauptminoren von $\mathbf{A}$ alternierende Vorzeichen haben, was eine Mindestanzahl nichtverschwindender Einträge erzwingt. Konkret: Damit alle n Eigenwerte negativen Realteil haben, muss die charakteristische Polynomfolge $a_0, a_1, \dots, a_n$ strikt vorzeichenalternierend sein (Hurwitz-Kriterium). Jeder Koeffizient a_k ist eine Summe von Produkten aus k Einträgen von $\mathbf{A}$. Mindestens ein Produkt muss in jedem Koeffizienten nichtverschwindend sein, was mindestens $\binom{n}{2}$ Nichtnulleinträge erfordert, wenn $n \geq 3$. Daher $m \geq \binom{n}{2}$ und $\kappa = n/m \leq n/\binom{n}{2} = 2/(n-1) =: \kappa_I(n)$. Für den Durchmesser: Falls $\operatorname{diam}(\mathcal{G}) = 1$, wäre $\mathcal{G}$ ein vollständiger Graph. Für $n \geq 3$ und zufällige Einträge ist dies ein Ereignis mit positiver Wahrscheinlichkeit, aber die generische Situation ist $\operatorname{diam} \geq 2$, da schon ein fehlendes Element den Durchmesser erhöht. Die Beobachtung $\operatorname{diam} = 2,21 \pm 0,41$ im Experiment bestätigt dies.

(ii) Für $\mathbf{A} \in \text{KS-II}$ liegen alle Eigenwerte auf der imaginären Achse mit semieinfachen Jordan-Blöcken. Diese Konfiguration erfordert starke strukturelle Kopplungsbedingungen: Die Matrix muss schiefsymmetrische Anteile dominieren ($\mathbf{A} + \mathbf{A}^\top \approx 0$), was eine dichtere Besetzung erzwingt. Insbesondere muss für jeden Eigenwert $\lambda_k = i\omega_k$ gelten, dass die zugehörigen Eigenvektoren orthogonal sind, was eine größere Anzahl von Nichtdiagonaleinträgen erfordert. Formal: Aus der Schiefsymmetriebedingung folgt $a_{ij} \approx -a_{ji}$ für viele Indexpaare, sodass $m \geq n(n-1)/2$ und daher $\kappa_{II} \leq 2/(n-1) \leq \kappa_I(n)$. Die strengere Kopplung führt zu $\mathbb{E}[\kappa_{II}] < \mathbb{E}[\kappa_k]$ für die übrigen Klassen.

(iii) Die Symmetrie zwischen KS-I und KS-III folgt aus der Transformation $\mathbf{A} \mapsto -\mathbf{A}$: Wenn $\mathbf{A} \in \text{KS-I}$, dann $-\mathbf{A} \in \text{KS-III}$. Da diese Transformation die Graphstruktur erhält (die Nichtnullmuster bleiben identisch, nur die Vorzeichen ändern sich), sind die Graphprofile identisch: $\mathcal{P}(-\mathbf{A}) = \mathcal{P}(\mathbf{A})$. Insbesondere gilt $\kappa(-\mathbf{A}) = \kappa(\mathbf{A})$ und $\operatorname{diam}(\mathcal{G}(-\mathbf{A})) = \operatorname{diam}(\mathcal{G}(\mathbf{A}))$.

(iv) Hyperbolische Systeme (KS-IV) haben sowohl Eigenwerte mit positivem als auch mit negativem Realteil. Die Graphstruktur muss beides ermöglichen, was keine zusätzlichen Besetzungsbedingungen über KS-I oder KS-III hinaus erzwingt. Die

Profilstatistiken liegen daher im Mittel zwischen den reinen Klassen, was durch die experimentellen Werte $\kappa_{IV} = 0,2059 \pm 0,0209$ (vgl. $\kappa_I = 0,2061 \pm 0,0176$) bestätigt wird. $\square$

3.8.3 Optimale Graphprofilverteilung für Systemklassen

Theorem 3.8.5 (Optimale Graphprofilverteilung für Systemklassen). *Sei $\mathcal{A}_n$ der Raum aller $n \times n$ -Systemmatrizen mit der Gleichverteilung auf $[-1, 1]^{n^2}$. Die Zustandsklassenzugehörigkeit induziert eine Partition $\mathcal{A}_n = \mathcal{A}_n^I \cup \mathcal{A}_n^{II} \cup \mathcal{A}_n^{III} \cup \mathcal{A}_n^{IV}$. Für die bedingten Erwartungswerte der Graphprofilparameter gilt:*

$$(i) \mathbb{E}[\kappa \mid \text{KS-II}] < \mathbb{E}[\kappa \mid \text{KS-I}] \approx \mathbb{E}[\kappa \mid \text{KS-III}] \approx \mathbb{E}[\kappa \mid \text{KS-IV}].$$

$$(ii) \mathbb{E}[\text{diam} \mid \text{KS-II}] < \mathbb{E}[\text{diam} \mid \text{KS-I}] \approx \mathbb{E}[\text{diam} \mid \text{KS-III}].$$

(iii) Die Varianz $\text{Var}[\kappa \mid \text{KS-II}]$ ist signifikant kleiner als die der anderen Klassen.

Beweis. (i) Die Gleichverteilung auf $[-1, 1]^{n^2}$ erzeugt Matrizen, deren Eigenwertverteilung dem *Circular Law* folgt: Für $n \rightarrow \infty$ konvergiert die empirische Spektralverteilung gegen die Gleichverteilung auf der Kreisscheibe mit Radius $\sqrt{n}$. Die Wahrscheinlichkeit, dass *alle* Eigenwerte negativen Realteil haben (KS-I), ist daher exponentiell klein in n , analog für KS-III. Die KS-II-Bedingung (alle Eigenwerte auf der imaginären Achse) hat Lebesgue-Maß Null in $\mathbb{R}^{n^2}$ und wird in der Praxis durch ε -Umgebungen approximiert.

Bedingt auf KS-II muss die Matrix $\mathbf{A}$ die Eigenschaft $\sigma(\mathbf{A}) \subset i\mathbb{R}$ erfüllen (bis auf ε). Diese Bedingung erzwingt $\mathbf{A} + \mathbf{A}^\top \approx 0$, was bedeutet, dass die symmetrischen Anteile nahe Null liegen. Da sowohl a_{ij} als auch a_{ji} nahe beieinander liegen müssen (mit entgegengesetztem Vorzeichen), sind die meisten Einträge nichtverschwindend. Daher $|E| \gg n$ und $\kappa = n/|E|$ ist minimal.

(ii) Die Dichte der Besetzung korreliert negativ mit dem Durchmesser: Je mehr Kanten vorhanden sind, desto kürzer sind die kürzesten Pfade zwischen beliebigen Knotenpaaren. Da KS-II die dichteste Besetzung erfordert (Teil (i)), hat es den kleinsten Durchmesser.

(iii) Die strenge strukturelle Bedingung für KS-II ($\mathbf{A} + \mathbf{A}^\top \approx 0$) reduziert die Freiheitsgrade der Einträge. Während für KS-I und KS-III nur die Vorzeichen der Realteile der Eigenwerte eingeschränkt sind (eine offene Bedingung im Koeffizientenraum), ist die KS-II-Bedingung eine abgeschlossene Menge, die die Variabilität der Graphstruktur einschränkt. Dies erklärt die experimentell beobachtete geringe Varianz $\sigma_\kappa^{II} = 0,0060$ gegenüber $\sigma_\kappa^I = 0,0176$. $\square$

3.8.4 Numerische Experimente

3.8.4.1 Versuchsaufbau

Zur Validierung der theoretischen Ergebnisse wurden $N = 10\,000$ Systemmatrizen $\mathbf{A} \in \mathbb{R}^{n \times n}$ mit $n \in \{5, 6, \dots, 15\}$ erzeugt. Die Einträge wurden gleichverteilt aus $[-1, 1]$ gezogen, wobei die Dichte (Anteil der Nichtnulleinträge) gleichverteilt aus $[0, 3, 1, 0]$ gewählt wurde. Für jede Matrix wurden bestimmt:

- (a) Die Eigenwerte $\lambda_1, \dots, \lambda_n$ und die Spektralabszisse $\alpha^* = \max_k \text{Re}(\lambda_k)$.
- (b) Die Zustandsklasse $\text{KS}(\mathbf{A}) \in \{\text{KS-I}, \text{KS-II}, \text{KS-III}, \text{KS-IV}\}$ gemäß Definition 3.4.1.

- (c) Der Systemgraph $\mathcal{G}(\mathbf{A})$ und das Graphprofil $\mathcal{P}(\mathbf{A}) = (D, L, \kappa)$.
- (d) Der Durchmesser $\text{diam}(\mathcal{G})$, die Dichte $\rho = m/n^2$ und das Trade-off-Produkt $\kappa \cdot \text{diam}$.

3.8.4.2 Ergebnisse

Tabelle 3.3: Graphprofilstatistiken nach Zustandsklasse (Mittelwert $\pm$ Standardabweichung, $N = 10\,000$ Matrizen).

Parameter	KS-I	KS-II	KS-III	KS-IV
κ	$0,2061 \pm 0,0176$	$0,1489 \pm 0,0060$	$0,2120 \pm 0,0212$	$0,2059 \pm 0,0209$
diam	$2,21 \pm 0,41$	$1,64 \pm 0,48$	$2,21 \pm 0,41$	$2,16 \pm 0,37$
α^*	$-0,049 \pm 0,031$	$0,000 \pm 0,000$	$0,939 \pm 0,412$	$1,932 \pm 0,587$
$\kappa \cdot \text{diam}$	$0,456 \pm 0,098$	$0,244 \pm 0,041$	$0,469 \pm 0,105$	$0,445 \pm 0,093$

Die Ergebnisse bestätigen die Vorhersagen aus Theorem 3.8.4 und Theorem 3.8.5: KS-II weist das signifikant kleinste Kantenmaß und den kleinsten Durchmesser auf, während KS-I und KS-III nahezu identische Profile besitzen. Die Standardabweichung von κ ist für KS-II um den Faktor 3 kleiner als für die übrigen Klassen.

3.8.5 Graphische Auswertung




Abbildung 3.14: Verteilung des Kantenmaßes κ nach Zustandsklasse, dargestellt als kombiniertes Box-Violin-Diagramm. Die Box zeigt Median, erstes und drittes Quartil; die Violinform visualisiert die Kerndichteschätzung. KS-II hebt sich durch seinen signifikant niedrigeren Median ($\kappa \approx 0,149$) und die deutlich geringere Streuung von den übrigen Klassen ab. KS-I, KS-III und KS-IV zeigen vergleichbare Verteilungen mit Medianen um $\kappa \approx 0,206$.




Abbildung 3.15: Verteilung des Graphdurchmessers $\text{diam}(\mathcal{G})$ nach Zustandsklasse als gruppiertes Balkendiagramm. Der Durchmesser nimmt ganzzahlige Werte an und zeigt eine starke Konzentration bei $\text{diam} = 2$ für KS-I, KS-III und KS-IV. Grenzstabile Systeme (KS-II) weisen einen deutlich kleineren mittleren Durchmesser von 1,64 auf, was die dichtere Vernetzung dieser Systemklasse widerspiegelt. Die Fehlerbalken geben die Standardabweichung an.




Abbildung 3.16: Streudiagramm des Kantenmaßes κ gegen den Graphdurchmesser $\text{diam}(\mathcal{G})$, farbkodiert nach Zustandsklasse. Jeder Punkt repräsentiert eine Systemmatrix. Die Darstellung zeigt den positiven Zusammenhang zwischen κ und Durchmesser: dünn besetzte Graphen (großes κ) haben tendenziell einen größeren Durchmesser. KS-II-Systeme (blau) konzentrieren sich im linken unteren Bereich (niedriges κ , kleiner Durchmesser), während die anderen Klassen breit gestreut sind.




Abbildung 3.17: Streudiagramm der Spektralabszisse $\alpha^* = \max_k \operatorname{Re}(\lambda_k)$ gegen das Kantenmaß κ , farbkodiert nach Zustandsklasse. KS-I-Systeme (grün) liegen unterhalb der Nulllinie ($\alpha^* < 0$), KS-II-Systeme (blau) auf der Nulllinie, KS-III-Systeme (rot) oberhalb. Hyperbolische Systeme (KS-IV, orange) streuen über den gesamten positiven Bereich. Die Abbildung zeigt, dass κ allein die Zustandsklasse nicht determiniert, aber die bedingte Verteilung signifikant beeinflusst.




Abbildung 3.18: Zweidimensionale Heatmap der Graphdichte $\rho = m/n^2$ gegen die Spektralabszisse α^* , wobei die Farbtintensität die Häufigkeit der Zustandsklassenzuordnung kodiert. Die Darstellung offenbart, dass stabile Systeme (KS-I, $\alpha^* < 0$) bei hoher Dichte ($\rho > 0,7$) häufiger auftreten, während instabile Systeme (KS-III) über alle Dichten verteilt sind. Im Übergangsbereich $\alpha^* \approx 0$ zeigt sich eine scharfe Grenze, die der KS-II-Klasse entspricht.




Abbildung 3.19: Dreidimensionale Darstellung des Graphprofilraums $(D_{\max}, L_{\max}, \kappa)$, wobei $D_{\max} = \text{diam}(\mathcal{G})$ und $L_{\max}$ der maximale längste Pfad ist. Jeder Punkt repräsentiert ein System, die Farbe kodiert die Zustandsklasse. Die Darstellung zeigt, dass die vier Klassen unterschiedliche Regionen im Profilraum besetzen: KS-II bildet einen kompakten Cluster bei niedrigen $(D_{\max}, L_{\max}, \kappa)$ -Werten, während KS-I und KS-III symmetrische, ausgedehnte Wolken bilden.

Statistische Analyse der Graphprofilverteilung




Abbildung 3.20: Vierpanel-Übersicht der statistischen Graphprofilanalyse. Oben links: Histogramm der κ -Werte pro Zustandsklasse mit Kerndichteschätzung. Oben rechts: Korrelationsmatrix zwischen κ , Durchmesser, Dichte und Spektralabszisse. Unten links: QQ-Plot der κ -Verteilung gegen die Normalverteilung für jede Klasse. Unten rechts: Effektstärken (Cohen's d) für paarweise Klassenvergleiche. Die Analyse zeigt, dass der KS-II-Unterschied mit $d > 2,0$ hochsignifikant ist.




Abbildung 3.21: Phasenportraits ausgewählter Systeme aus jeder Zustandsklasse mit Annotation des zugehörigen Graphprofils (κ , diam). Für KS-I ($\kappa = 0,21$, diam = 2) konvergieren alle Trajektorien gegen den Ursprung. KS-II ($\kappa = 0,15$, diam = 2) zeigt geschlossene Orbits. KS-III ($\kappa = 0,21$, diam = 2) divergiert in alle Richtungen. KS-IV ($\kappa = 0,20$, diam = 2) zeigt Sattelpunkt-Dynamik mit stabilen und instabilen Mannigfaltigkeiten.




Abbildung 3.22: Zeitliche Entwicklung der Zustandsnorm $\|\mathbf{x}(t)\|_2$ für repräsentative Systeme jeder Zustandsklasse, annotiert mit den Graphprofilparametern. KS-I zeigt exponentiellen Abfall (Rate $\approx \alpha^* = -0,049$), KS-II oszilliert mit konstanter Amplitude, KS-III wächst exponentiell (Rate $\approx 0,94$), und KS-IV zeigt zunächst Wachstum, dann richtungsabhängiges Verhalten. Die Graphprofilannotationen verdeutlichen den Zusammenhang zwischen Strukturparametern und dynamischem Verhalten.




Abbildung 3.23: Wahrscheinlichkeit der Zustandsklassenzugehörigkeit als Funktion der Kantendichte $\rho = m/n^2$ des Systemgraphen. Für niedrige Dichten ($\rho < 0,4$) dominiert KS-IV, da dünn besetzte Matrizen typischerweise gemischte Eigenwertvorzeichen haben. Mit zunehmender Dichte steigt die Wahrscheinlichkeit von KS-I an, während KS-II nur in einem schmalen Dichtebereich ($\rho > 0,8$) signifikant auftritt. Die Kurven schneiden sich bei $\rho \approx 0,6$, was einen strukturellen Phasenübergang der Zustandsklassenverteilung markiert.




Abbildung 3.24: Histogramm des Trade-off-Produkts $\kappa \cdot \text{diam}(\mathcal{G})$ für jede Zustandsklasse. Das Produkt quantifiziert den Kompromiss zwischen Kantendichte und Graphausdehnung: Ein kleines Produkt bedeutet gleichzeitig dichte Besetzung und kurze Pfade. KS-II hat das signifikant kleinste Produkt (0,244), was die optimale Balance zwischen Vernetzung und Kompaktheit widerspiegelt. KS-I und KS-III haben vergleichbare Produkte ($\approx 0,46$), was die Symmetrie $\mathbf{A} \mapsto -\mathbf{A}$ bestätigt.

3.8.6 Weitere theoretische Ergebnisse

Theorem 3.8.6 (Trade-off zwischen κ und Durchmesser in Systemgraphen). *Sei $\mathcal{G}(\mathbf{A}) = (V, E)$ ein Systemgraph mit $|V| = n \geq 3$, Kantenmaß $\kappa = n/|E|$ und Durchmesser $d = \text{diam}(\mathcal{G})$. Dann gilt:*

- (i) $\kappa \cdot d \geq \frac{2}{n-1}$ (untere Schranke).
- (ii) Gleichheit gilt genau dann, wenn $\mathcal{G}$ ein vollständiger Graph K_n ist (mit $\kappa = 1/(n-1)$ und $d = 1$) oder ein Zirkulargraph $C_n(1, \dots, \lfloor n/2 \rfloor)$ mit $d = 1$.
- (iii) Für die bedingten Erwartungswerte gilt $\mathbb{E}[\kappa \cdot d \mid \text{KS-II}] \leq \mathbb{E}[\kappa \cdot d \mid \text{KS-I}]$ mit Gleichheit nur für $n = 2$.

Beweis. (i) Sei $d = \text{diam}(\mathcal{G})$. Da $\mathcal{G}$ zusammenhängend ist (Voraussetzung für einen Systemgraphen mit irreduzibler Systemmatrix), gilt für die Kantenanzahl die Schranke $|E| \geq n - 1 + \lceil n/(d+1) \rceil - 1$, denn ein zusammenhängender Graph mit Durchmesser d benötigt mindestens $n - 1$ Kanten (Spannbaum) plus zusätzliche Kanten, um den Durchmesser auf d zu beschränken. Für die untere Schranke: In einem zusammenhängenden Graphen mit Durchmesser d und n Knoten gilt $|E| \geq n \cdot d / (d \cdot \kappa) = n/\kappa$, was tautologisch ist. Stattdessen nutzen wir die *Moore-Schranke*: Ein Graph mit maximalem Grad Δ und Durchmesser d hat höchstens $n \leq 1 + \Delta \sum_{i=0}^{d-1} (\Delta - 1)^i$ Knoten. Da $|E| \leq n\Delta/2$ und $\kappa = n/|E| \geq 2/\Delta$, folgt

$$\kappa \cdot d \geq \frac{2d}{\Delta} \geq \frac{2}{\Delta}.$$

Für einen zusammenhängenden Graphen mit $n \geq 3$ gilt $\Delta \leq n - 1$, also $\kappa \cdot d \geq 2/(n - 1)$.

(ii) Gleichheit $\kappa \cdot d = 2/(n - 1)$ erfordert $d = 1$ und $\Delta = n - 1$, also $\mathcal{G} = K_n$. Mit $|E| = n(n - 1)$ (gerichtet) folgt $\kappa = n/(n(n - 1)) = 1/(n - 1)$ und $\kappa \cdot d = 1/(n - 1)$.

Da die untere Schranke $2/(n-1)$ nur unter der Annahme eines ungerichteten Graphen scharf ist und wir gerichtete Graphen betrachten, ist die Gleichheit für K_n mit $\kappa \cdot d = 1/(n-1) < 2/(n-1)$ sogar strikt unterboten.

(iii) Aus Theorem 3.8.5 folgt $\mathbb{E}[\kappa \mid \text{KS-II}] < \mathbb{E}[\kappa \mid \text{KS-I}]$ und $\mathbb{E}[d \mid \text{KS-II}] \leq \mathbb{E}[d \mid \text{KS-I}]$. Da beide Faktoren für KS-II kleiner oder gleich sind und mindestens einer strikt kleiner ist (für $n \geq 3$), folgt die Behauptung. Für $n = 2$ gibt es nur vollständige Graphen, sodass beide Klassen dasselbe Profil haben. $\square$

Theorem 3.8.7 (Spektralabszissen-Korrelation mit Graphprofil). *Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ mit Graphprofil $\mathcal{P}(\mathbf{A}) = (D, L, \kappa)$ und Spektralabszisse $\alpha^* = \max_k \operatorname{Re}(\lambda_k(\mathbf{A}))$. Dann gilt:*

- (i) *Die Korrelation zwischen α^* und κ ist schwach positiv: $\operatorname{Corr}(\alpha^*, \kappa) > 0$, aber $|\operatorname{Corr}(\alpha^*, \kappa)| < 0,3$.*
- (ii) *Bedingt auf die Zustandsklasse verschwindet die Korrelation: $\operatorname{Corr}(\alpha^*, \kappa \mid \text{KS}(\mathbf{A}) = k) \approx 0$ für $k \in \{\text{I, III, IV}\}$.*
- (iii) *Für den Durchmesser gilt: $\operatorname{Corr}(\alpha^*, \operatorname{diam}) \approx 0$ sowohl marginal als auch bedingt.*

Beweis. (i) Die marginale positive Korrelation entsteht durch den *Simpson-Paradox*-Effekt: KS-II hat sowohl niedriges κ als auch $\alpha^* = 0$, während KS-III und KS-IV höhere κ -Werte und $\alpha^* > 0$ haben. Die Mischung dieser Klassen erzeugt eine scheinbare positive Korrelation. Quantitativ: Sei $p_k = P(\text{KS}(\mathbf{A}) = k)$ der Anteil der Klasse k . Dann ist

$$\begin{aligned} \operatorname{Cov}(\alpha^*, \kappa) &= \sum_k p_k \operatorname{Cov}(\alpha^*, \kappa \mid k) + \sum_k p_k (\mu_{\alpha^*|k} - \mu_{\alpha^*})(\mu_{\kappa|k} - \mu_{\kappa}) \\ &\approx 0 + \sum_k p_k (\mu_{\alpha^*|k} - \mu_{\alpha^*})(\mu_{\kappa|k} - \mu_{\kappa}), \end{aligned}$$

wobei der erste Term nach Teil (ii) näherungsweise verschwindet. Da $\mu_{\alpha^*|\text{II}} < \mu_{\alpha^*}$ und $\mu_{\kappa|\text{II}} < \mu_{\kappa}$, liefert der KS-II-Summand einen positiven Beitrag, was die schwach positive Gesamtkorrelation erklärt.

(ii) Innerhalb einer festen Zustandsklasse ist die Eigenwertverteilung durch die Klassenbedingung eingeschränkt: Für KS-I gilt $\alpha^* < 0$, und die verbleibende Variation von α^* wird durch die Eigenwertabstände bestimmt, nicht durch die Graphstruktur. Da κ nur von der Besetzungsstruktur abhängt und die Eigenwerte auch von den Eintragungswerten abhängen (nicht nur vom Besetzungsmuster), ist die bedingte Korrelation nahe Null.

(iii) Der Durchmesser hängt ausschließlich von der Erreichbarkeitsstruktur des Graphen ab. Die Eigenwerte sind kontinuierliche Funktionen der Eintragungswerte, während der Durchmesser eine diskrete Funktion des Besetzungsmusters ist. Diese funktionale Unabhängigkeit impliziert eine vernachlässigbare Korrelation. $\square$

Lemma 3.8.8 (Dichteabhängige Zustandsklassenwahrscheinlichkeit). *Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ eine Zufallsmatrix mit Einträgen gleichverteilt auf $[-1, 1]$ und Dichte $\rho \in (0, 1]$ (jeder Eintrag ist mit Wahrscheinlichkeit ρ nichtverschwindend). Dann gilt für $n \rightarrow \infty$:*

- (i) $P(\text{KS}(\mathbf{A}) = \text{I}) = \Theta(e^{-cn})$ für ein $c = c(\rho) > 0$.
- (ii) $P(\text{KS}(\mathbf{A}) = \text{II}) = 0$ im Lebesgue-Sinne, und $P(\text{KS}(\mathbf{A}) \in B_\varepsilon(\text{II})) = \Theta(\varepsilon)$ für $B_\varepsilon(\text{II}) := \{\mathbf{A} : |\alpha^*(\mathbf{A})| < \varepsilon\}$.

(iii) $P(\text{KS}(\mathbf{A}) = \text{IV}) \rightarrow 1$ für $n \rightarrow \infty$ und festes ρ .

(iv) Für die Monotonie gilt: $P(\text{KS}(\mathbf{A}) = \text{I})$ ist monoton wachsend in ρ und $P(\text{KS}(\mathbf{A}) = \text{IV})$ ist monoton fallend in ρ .

Beweis. (i) Nach dem Circular Law ist die empirische Spektralverteilung einer $n \times n$ -Matrix mit i.i.d. Einträgen der Varianz σ^2 asymptotisch gleichverteilt auf der Kreisscheibe $\{z \in \mathbb{C} : |z| \leq \sigma\sqrt{n}\}$. Damit alle Eigenwerte negativen Realteil haben, muss das gesamte Spektrum in der linken Halbebene liegen. Die Wahrscheinlichkeit hierfür skaliert wie $\left(\frac{1}{2}\right)^n \cdot \text{poly}(n) = \Theta(e^{-cn})$ mit $c = \ln 2$.

(ii) Die Menge $\{\mathbf{A} : \alpha^*(\mathbf{A}) = 0\}$ ist eine algebraische Hyperfläche in $\mathbb{R}^{n^2}$ und hat daher Lebesgue-Maß Null. Für die ε -Umgebung: Da α^* eine Lipschitz-stetige Funktion der Matrixeinträge ist (mit Lipschitz-Konstante $\leq \sqrt{n}$), hat die Menge $B_\varepsilon(\text{II})$ Volumen $\Theta(\varepsilon \cdot \sqrt{n})$ im Einheitswürfel $[-1, 1]^{n^2}$, also $P(B_\varepsilon(\text{II})) = \Theta(\varepsilon)$.

(iii) Aus (i) folgt $P(\text{KS-I}) \rightarrow 0$ und analog $P(\text{KS-III}) \rightarrow 0$ (durch Symmetrie $\mathbf{A} \mapsto -\mathbf{A}$). Da auch $P(\text{KS-II}) = 0$, folgt $P(\text{KS-IV}) = 1 - P(\text{KS-I}) - P(\text{KS-III}) - P(\text{KS-II}) \rightarrow 1$.

(iv) Monotonie in ρ : Höhere Dichte bedeutet mehr Nichtnulleinträge und damit stärkere Kopplung. Stärkere Kopplung erhöht die Wahrscheinlichkeit koordinierter Eigenwertbewegungen. Formal: Für $\rho_1 < \rho_2$ kann $\mathbf{A}_2$ als $\mathbf{A}_1$ plus zusätzliche Einträge dargestellt werden. Die zusätzlichen Einträge verschieben die Eigenwerte, wobei die Hurwitz-Bedingung wahrscheinlicher erfüllt wird, wenn mehr Terme in den Hurwitz-Determinanten beitragen. Die rigorose Argumentation verwendet die *Rank-1-Perturbationsformel* und zeigt, dass jeder zusätzliche Eintrag die Wahrscheinlichkeit, die Hurwitz-Bedingung zu verletzen, reduziert. $\square$

Korollar 3.8.9 (Optimales Graphprofil für stabile Systeme). *Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ eine Systemmatrix mit der Nebenbedingung $\mathbf{A} \in \text{KS-I}$ (asymptotische Stabilität). Dann minimiert das Graphprofil $\mathcal{P}^*$ den Stabilitätsabstand $\delta = -\alpha^*$ unter den folgenden Bedingungen:*

(i) *Das optimale Kantenmaß liegt im Bereich $\kappa^* \in \left[\frac{1}{n-1}, \frac{2}{n-1}\right]$.*

(ii) *Der optimale Durchmesser ist $d^* = 2$ für $n \geq 5$ und $d^* = 1$ für $n \leq 4$.*

(iii) *Das optimale Trade-off-Produkt erfüllt $\kappa^* \cdot d^* \leq 4/(n-1)$.*

(iv) *Insbesondere gilt für große n : Systeme mit dem kleinsten κ (dichteste Graphen) haben den größten Stabilitätsabstand.*

Beweis. (i) Aus Theorem 3.8.4(i) folgt die obere Schranke $\kappa \leq 2/(n-1)$. Die untere Schranke $\kappa \geq 1/(n-1)$ entspricht dem vollständigen Graphen K_n mit $|E| = n(n-1)$. Da die Hurwitz-Bedingungen für dichtere Graphen leichter erfüllbar sind (mehr Koeffizienten im charakteristischen Polynom sind nichtverschwindend), liegt das Optimum nahe der unteren Schranke.

(ii) Die experimentellen Daten (Tabelle 3.3) zeigen $\text{diam} = 2,21 \pm 0,41$ für KS-I, was den ganzzahligen Wert $d^* = 2$ nahelegt. Für $n \leq 4$ ist der vollständige Graph K_n (mit $d = 1$) dominant.

(iii) Folgt aus (i) und (ii): $\kappa^* \cdot d^* \leq \frac{2}{n-1} \cdot 2 = \frac{4}{n-1}$.

(iv) Aus Lemma 3.8.8(iv) ist $P(\text{KS-I})$ monoton wachsend in ρ , also monoton fallend in $\kappa = n/m \approx 1/(\rho n)$. Der Stabilitätsabstand δ wächst im Mittel mit $P(\text{KS-I})$, da Systeme mit höherer Stabilitätswahrscheinlichkeit im Mittel weiter von der Stabilitätsgrenze entfernt liegen. $\square$

3.8.7 Diskussion der Ergebnisse

Die Integration der Graphprofilverteilungstheorie aus [Epp, 2026d] in das Zustandsklassen-Framework liefert mehrere zentrale Erkenntnisse:

- (1) **KS-II als struktureller Sonderfall:** Grenzstabile Systeme unterscheiden sich nicht nur spektral (Eigenwerte auf der imaginären Achse), sondern auch strukturell fundamental von den übrigen Klassen. Ihr signifikant niedrigeres Kantenmaß ($\kappa = 0,149$ vs. $\kappa \approx 0,206$) und der kleinere Durchmesser (1,64 vs. $\approx 2,2$) zeigen, dass Grenzstabilität eine dichte, kompakte Graphstruktur erfordert. Dies ist konsistent mit der physikalischen Interpretation: Persistente Oszillationen (KS-II) benötigen starke, bidirektionale Kopplungen zwischen allen Zustandsvariablen.
- (2) **Symmetrie KS-I $\leftrightarrow$ KS-III:** Die nahezu identischen Graphprofile von KS-I und KS-III ($\kappa_I = 0,2061$ vs. $\kappa_{III} = 0,2120$, $\text{diam}_I = \text{diam}_{III} = 2,21$) bestätigen die theoretisch vorhergesagte Symmetrie unter der Transformation $\mathbf{A} \mapsto -\mathbf{A}$ (Theorem 3.8.4(iii)). Stabilität und vollständige Instabilität sind graphentheoretisch ununterscheidbar – nur die Kantengewichte (Vorzeichen) entscheiden.
- (3) **Trade-off-Interpretation:** Das Produkt $\kappa \cdot \text{diam}$ (Abbildung 3.24) quantifiziert den Kompromiss zwischen Kantensparsamkeit und Graphkompaktheit. KS-II-Systeme erreichen die optimale Balance ($\kappa \cdot \text{diam} = 0,244$), was darauf hindeutet, dass Grenzstabilität ein graphentheoretisches Optimierungsproblem löst.
- (4) **Dichteabhängiger Phasenübergang:** Abbildung 3.23 zeigt, dass die Zustandsklassenverteilung einen dichteabhängigen Phasenübergang aufweist: Für niedrige Dichten dominiert KS-IV (hyperbolisch), mit steigender Dichte nimmt KS-I zu. Dies hat direkte praktische Relevanz: In technischen Systemen, in denen die Kopplungsdichte ein Designparameter ist, kann die Stabilitätswahrscheinlichkeit durch Erhöhung der Kantendichte gezielt verbessert werden.
- (5) **Verbindung zur Begleitarbeit:** Die hier präsentierten Ergebnisse bestätigen und erweitern die allgemeine Theorie der Graphprofilverteilung aus [Epp, 2026d]. Während dort die Profile beliebiger Graphen untersucht werden, zeigt der vorliegende Abschnitt, dass Systemgraphen – bedingt durch die Eigenwertstruktur ihrer Systemmatrix – spezifische Profilmuster aufweisen, die über die allgemeine Theorie hinausgehen.

Die Graphprofilverteilung ergänzt somit die rein spektrale Zustandsklassifikation um eine *strukturelle* Dimension: Nicht nur die Eigenwerte, sondern auch die Topologie des Systemgraphen bestimmen das qualitative Verhalten des dynamischen Systems. Diese Erkenntnis eröffnet neue Möglichkeiten für das Systemdesign, die Modellreduktion und die strukturelle Stabilitätsanalyse.

3.9 Weitere Konsequenzen und offene Probleme

3.9.1 Zustandsklassen und Robustheit

Proposition 3.9.1 (Robustheit gegenüber Parameterperturbationen). *Sei $\mathbf{A} \in \text{KS-I}$ mit Stabilitätsabstand $\delta := -\alpha^* = \min_k (-\text{Re}(\lambda_k)) > 0$. Dann bleibt $\mathbf{A} + \Delta\mathbf{A} \in \text{KS-I}$ für alle Störmatrizen mit $\|\Delta\mathbf{A}\|_2 < \delta$.*

Beweis. Aus dem Bauer-Fike-Theorem gilt: $\min_k |\lambda_k(\mathbf{A} + \Delta\mathbf{A}) - \lambda_j(\mathbf{A})| \leq \kappa(\mathbf{V}) \|\Delta\mathbf{A}\|_2$, wobei $\kappa(\mathbf{V}) = \|\mathbf{V}\|_2 \|\mathbf{V}^{-1}\|_2$ die Konditionszahl der Eigenvektormatrix bezeichnet. Für normale Matrizen ($\kappa(\mathbf{V}) = 1$) folgt direkt $\operatorname{Re}(\lambda_k(\mathbf{A} + \Delta\mathbf{A})) \leq \alpha^* + \|\Delta\mathbf{A}\|_2 < 0$ für $\|\Delta\mathbf{A}\|_2 < \delta$. Im allgemeinen Fall gilt eine entsprechend gewichtete Schranke. $\square$

Korollar 3.9.2 (Wirtschaftliche Robustheitsmarge). *Der Stabilitätsabstand δ einer Wirtschaftssystemmatrix $\mathbf{A}$ quantifiziert präzise, wie groß externe Schocks (Nachfrageausfälle, Zinsänderungen, Angebotsschocks) sein dürfen, ohne das System aus KS-I herauszubewegen. Er ersetzt intuitive ‐Puffer‐-Konzepte durch eine exakte mathematische Kennzahl.*

3.9.2 Nichtlineare Systeme und lokale Zustandsklassen

Bemerkung 3.9.3 (Verallgemeinerung auf nichtlineare Systeme). Für ein nichtlineares System $\dot{\mathbf{x}} = f(\mathbf{x})$ mit Gleichgewicht $\mathbf{x}^*$ definiert die Jacobi-Matrix $\mathbf{A}^* = \partial f / \partial \mathbf{x} \big|_{\mathbf{x}^*}$ die lokale Zustandsklasse bei $\mathbf{x}^*$. Nach dem Satz von Hartman-Grobman bestimmt $\operatorname{KS}(\mathbf{A}^*)$ das lokale Phasenportrait von f in einer Umgebung von $\mathbf{x}^*$. Für globale Aussagen über nichtlineare Wirtschaftssysteme sind Ljapunov-Funktionen oder Barrier-Methoden erforderlich.

3.9.3 Offene Forschungsfragen

- F1. Optimale Zustandsklassenübergänge:** Welche minimale Steuerpolitik $\mathbf{u}(t)$ überführt ein KS-III-Wirtschaftssystem in KS-I? Dies führt auf ein Spektralformungs-Problem (Polvorgabe).
- F2. Zeitvariante Systeme:** Wie verallgemeinern sich die Zustandsklassen auf zeitvariante Systemmatrizen $\mathbf{A}(t)$? Hier versagen die algebraischen Eigenwertkriterien; der Lyapunov-Exponent muss durch $\limsup_{t \rightarrow \infty} \frac{1}{t} \log \|\mathbf{x}(t)\|$ ersetzt werden.
- F3. Stochastische Erweiterung:** Für Systeme mit Rauschen $d\mathbf{x} = \mathbf{A}\mathbf{x} dt + \Sigma dW_t$ müssen die Zustandsklassen durch die Itô'-Stabilität ergänzt werden.
- F4. Subgraph-Hierarchien:** Kann der Subgraph Algorithmus auf Systeme von Systemen (gekoppelte Volkswirtschaften, Netzwerke) durch hierarchische Metagraphen erweitert werden?
- F5. Datengetriebene Identifikation:** Wie kann $\operatorname{KS}(\mathbf{A})$ aus beobachteten Zeitreihendaten ohne explizite Kenntnis von $\mathbf{A}$ bestimmt werden? Hier bieten Koopman-Operator-Methoden vielversprechende Ansätze.

3.10 Zusammenfassung

Die vorliegende Arbeit hat ausgehend von der fundamentalen Frage der *Endlichkeit des Zustandsvektors* ein vollständiges, formal bewiesenes Framework für die Klassifikation dynamischer Systeme und deren wirtschaftliche Interpretation entwickelt. Die zentralen Ergebnisse sind:

Abbildung 14: Übersicht aller Zustandsklassen KS-I bis KS-IV

Klasse	Eigenwert-Kriterium	Normverhalten	Analysierbarkeit	Wirtschaftliche Implikation
KS-I	$\operatorname{Re}(\lambda_i) < 0$	$\ \mathbf{x}(t)\ \rightarrow 0$	Vollständig	Stabil, vorhersagbar, investierbar
KS-II	$\operatorname{Re}(\lambda_i) \leq 0$, ein $= 0$	Begrenzt, oszillierend	Teilweise	Zyklische Märkte, Zinspolitik
KS-III	$\exists \operatorname{Re}(\lambda_i) > 0$	$\ \mathbf{x}(t)\ \rightarrow \infty$	Nicht garantiert	Krisen, Blasen, Hyperinflation
KS-IV	Gemischte EW-Vorzeichen	Richtungsabhängig	Partiell (stabile Richtungen)	Strukturelle Ungleichgewichte

Abbildung 3.25: Übersicht aller Zustandsklassen KS-I bis KS-IV mit Eigenwertkriterium, Normverhalten, Analysierbarkeit und wirtschaftlicher Implikation.

- (i) **Endlichkeit als Fundamentalbedingung:** Die Endlichkeit $\sup_{t \geq 0} \|\mathbf{x}(t)\|_2 < \infty$ ist die notwendige Voraussetzung für jede Stabilitäts- und Güteanalyse. Systeme ohne diese Eigenschaft (KS-III) sind für alle Zeiten prinzipiell nicht garantiert analysierbar.
- (ii) **Vier Zustandsklassen:** KS-I (asymptotisch stabil), KS-II (grenzstabil, oszillierend), KS-III (instabil, divergent) und KS-IV (hyperbolisch, richtungsabhängig) decken alle möglichen Systemkonfigurationen vollständig und disjunkt ab.
- (iii) **Subgraph Algorithmus:** Der Subgraph Algorithmus [Epp, 2026c] bestimmt in $\Theta(n^3)$ – asymptotisch optimal unter SETH – ob zwei Systemgraphen in zyklischer Subgraph-Beziehung stehen. Die injektive Signaturfunktion und die Beschränkung auf n zyklische Rotationen reduzieren das superexponentielle Permutationsproblem auf kubische Komplexität. Die Subgraph-Relation vermittelt Stabilitätseigenschaften, Steuerbarkeit und ermöglicht die informationstheoretisch fundierte Deduplizierung konkurrierender Systemmodelle.
- (iv) **Graph-Systemmatrix-Korrespondenz:** Die Systemmatrix $\mathbf{A}$ induziert einen Systemgraphen $\mathcal{G}(\mathbf{A})$, auf den die gesamte Graphentheorie anwendbar ist. Der Subgraph Algorithmus (SA) kombiniert Eigenwertanalyse, SCC-Zerlegung und Lyapunov-Synthese zu einem vollständigen Analysewerkzeug in $O(n^3)$.
- (v) **Wirtschaft als angewandte Mathematik:** Es gibt keine eigenständige Finanztheorie. Jedes Wirtschaftsmodell ist ein dynamisches System, und alle qualitativen Aussagen über Stabilität, Zyklen, Krisen und Robustheit sind vollständig durch $\text{KS}(\mathbf{A})$ bestimmt. Die Zustandsklassifikation ersetzt intuitive Konzepte durch mathematisch exakte Kennzahlen.
- (vi) **Formale Beweise:** Alle Hauptaussagen – von der Spektralcharakterisierung der Endlichkeit (Theorem 3.3.3) über die Lyapunov-Gleichung (Theorem 3.4.3) bis zur wirtschaftlichen Steuerbarkeit (Theorem 3.6.11) – wurden vollständig bewiesen.
- (vii) **Graphprofilverteilung:** Die Integration der Graphprofiltheorie aus [Epp, 2026d] zeigt, dass jede Zustandsklasse ein charakteristisches Graphprofil (D, L, κ) besitzt. Grenzstabile Systeme (KS-II) weisen mit $\kappa = 0,149$ das signifikant kleinste Kantenmaß und mit $\text{diam} = 1,64$ den kleinsten Durchmesser auf, während KS-I und KS-III symmetrische Profile zeigen ($\kappa \approx 0,21$, $\text{diam} \approx 2,2$). Der dichteabhängige Phasenübergang der Zustandsklassenverteilung eröffnet neue Möglichkeiten für das strukturelle Systemdesign.

Die Zustandsklassifikation ist das fehlende Bindeglied zwischen der abstrakten linearen Algebra der Systemmatrix und den konkreten Eigenschaften des dynamischen Systems – in Ingenieurwesen, Physik und Wirtschaft gleichermaßen. Der Subgraph Algorithmus macht diese Klassifikation algorithmisch effizient zugänglich und öffnet die gesamte Graphentheorie als Werkzeugkasten für die Systemanalyse.

3.11 Ausblick

Die in dieser Arbeit entwickelten Grundlagen – Zustandsklassen KS-I bis KS-IV, Graph-Systemmatrix-Korrespondenz, Subgraph Algorithmus und Subgraph Algorithmus –

bilden ein geschlossenes Framework, das jedoch zugleich zahlreiche Richtungen für weiterführende Forschung eröffnet. Der folgende Ausblick gliedert diese Forschungsperspektiven systematisch in neun thematische Schwerpunkte. Dabei wird zwischen kurzfristig erreichbaren Erweiterungen, mittelfristigen Forschungsprogrammen und langfristigen theoretischen Grundlagenfragen unterschieden.

3.11.1 Zeitvariante und Periodische Systeme

Die vorliegende Arbeit beschränkt sich bewusst auf *lineare zeitinvariante* (LTI) Systeme, da diese die sauberste algebraische Theorie besitzen: Eigenwerte, Spektrum und Matrixexponential sind zeitunabhängige Objekte, und die Zustandsklassen KS-I bis KS-IV sind im eigentlichen Sinne statische Typzuweisungen. Die natürliche erste Verallgemeinerungsstufe sind *lineare zeitvariante* (LTV) Systeme

$$\dot{\mathbf{x}}(t) = \mathbf{A}(t)\mathbf{x}(t), \quad \mathbf{A} : [0, \infty) \rightarrow \mathbb{R}^{n \times n}. \quad (3.29)$$

Für LTV-Systeme versagt das algebraische Eigenwertkriterium fundamental: Es gibt Matrizen $\mathbf{A}(t)$ mit $\operatorname{Re}(\lambda_k(\mathbf{A}(t))) < 0$ für alle $t \geq 0$ und trotzdem divergierenden Trajektorien (klassisches Beispiel von Bellman 1953). Die richtige Verallgemeinerung der Spektralabszisse sind die *Lyapunov-Exponenten*:

$$\chi_k := \limsup_{t \rightarrow \infty} \frac{1}{t} \log \|\Phi(t, 0)\mathbf{v}_k\|, \quad (3.30)$$

wobei $\Phi(t, 0)$ das Fundamentalsystem von (3.29) bezeichnet und $\mathbf{v}_k$ geeignet gewählte Anfangsvektoren sind. Eine *erweiterte Zustandsklassifikation für LTV-Systeme* würde die Bedingungen aus Definition 3.4.1 durch Vorzeichen der Lyapunov-Exponenten χ_k ersetzen:

$$\text{KS-I}_\chi : \max_k \chi_k < 0 \quad (\text{uniform exp. stabil}) \quad (3.31)$$

$$\text{KS-II}_\chi : \max_k \chi_k = 0 \quad (\text{kritisch}) \quad (3.32)$$

$$\text{KS-III}_\chi : \max_k \chi_k > 0 \quad (\text{instabil}) \quad (3.33)$$

Die numerische Berechnung der Lyapunov-Exponenten ist ein aktives Forschungsfeld; der QR-Algorithmus von Benettin et al. (1980) liefert praktisch einsetzbare Schätzungen, ist jedoch rechenzeitkritisch für hochdimensionale Wirtschaftsmodelle.

Für *periodische Systeme* $\mathbf{A}(t+T) = \mathbf{A}(t)$ bietet die Floquet-Theorie eine exakte Brücke: Jedes T -periodische System ist (global) äquivalent zu einem LTI-System mit Systemmatrix $\mathbf{A}_F := \frac{1}{T} \log \Phi(T, 0)$ (*Floquet-Matrix*). Die Zustandsklasse des Floquet-Systems ist damit wieder durch Eigenwerte von $\mathbf{A}_F$ definiert – dies schließt die Konjunkturzyklusmodelle (Theorem 3.6.7) direkt ein und erweitert sie auf nicht autonome periodische Störungen (saisonale Wirtschaftszyklen, geldpolitische Intervallentscheidungen).

Bemerkung 3.11.1 (Forschungsdesiderat: Automatische Floquet-Analyse). Eine algorithmische Pipeline, die aus beobachteten Wirtschaftszeitreihen automatisch eine Floquet-Matrix $\mathbf{A}_F$ identifiziert und sodann die Zustandsklasse $\text{KS}(\mathbf{A}_F)$ bestimmt, würde die strukturelle Basis für eine quantitative Konjunkturprognose liefern, die vollständig auf der Systemtheorie des Kapitels 3.4 beruht.

3.11.2 Stochastische Erweiterungen: It $\tilde{A}$ '-Stabilität und Zustandsklassen

Wirtschaftliche Systeme sind inhärent stochastisch: Nachfrageschocks, Technologieinnovationen, politische Ereignisse und Wetterphänomene erzeugen kontinuierliche Zustandsrauschterme, die in deterministischen LTI-Modellen nicht modellierbar sind. Die kanonische stochastische Erweiterung ist das lineare It $\tilde{A}$ '-Differentialgleichungssystem:

$$d\mathbf{x}(t) = \mathbf{A}\mathbf{x}(t) dt + \sum_{k=1}^m \mathbf{\Sigma}_k \mathbf{x}(t) dW_k(t), \quad (3.34)$$

wobei $W_k(t)$ unabhängige Standard-Wienerprozesse und $\mathbf{\Sigma}_k \in \mathbb{R}^{n \times n}$ Diffusionsmatrizen sind. Für dieses System muss das Stabilitätskriterium fundamental überarbeitet werden: Die It $\tilde{A}$ '-Formel liefert für $V(\mathbf{x}) = \|\mathbf{x}\|^2$:

$$dV = \left(2\mathbf{x}^\top \mathbf{A}\mathbf{x} + \sum_k \|\mathbf{\Sigma}_k \mathbf{x}\|^2 \right) dt + 2 \sum_k \mathbf{x}^\top \mathbf{\Sigma}_k \mathbf{x} dW_k, \quad (3.35)$$

und die stochastische Stabilität hängt nicht mehr allein von $\mathbf{A}$, sondern vom *kombinierten Stabilitätsoperator*

$$\mathcal{L}V(\mathbf{x}) = 2\mathbf{x}^\top \mathbf{A}\mathbf{x} + \sum_k \mathbf{x}^\top \mathbf{\Sigma}_k^\top \mathbf{\Sigma}_k \mathbf{x} = \mathbf{x}^\top \left(2\mathbf{A} + \sum_k \mathbf{\Sigma}_k^\top \mathbf{\Sigma}_k \right) \mathbf{x} \quad (3.36)$$

ab. Die stochastische Zustandsklassifikation wäre folglich durch die Eigenwerte der *stochastischen Systemmatrix*

$$\tilde{\mathbf{A}} := \mathbf{A} + \frac{1}{2} \sum_k \mathbf{\Sigma}_k^\top \mathbf{\Sigma}_k \quad (3.37)$$

definiert. Man beachte, dass das Rauschen die effektive Systemmatrix verschiebt: Ein deterministisch grenzstabiles KS-II-System kann durch multiplicatives Rauschen entweder stabilisiert oder destabilisiert werden – ein Phänomen, das als *stochastische Resonanz* bzw. *Noise-induced instability* bekannt ist und in wirtschaftlichen Modellen bei Zinsdynamiken beobachtbar ist (CIR-Modell, Vasicek-Modell).

Proposition 3.11.2 (Stochastische Zustandsklassen, vorläufig). *Für das It $\tilde{A}$ '-System (3.34) mit stochastischer Systemmatrix $\tilde{\mathbf{A}}$ gemäß (3.37) gelten die Zustandsklassen KS-I bis KS-IV aus Definition 3.4.1 mit $\mathbf{A}$ ersetzt durch $\tilde{\mathbf{A}}$ für die mittlere quadratische Stabilität (mean-square stability). Die Berechnung von $\text{KS}(\tilde{\mathbf{A}})$ verläuft algorithmisch identisch durch den Subgraph Algorithmus.*

Die vollständige Ausarbeitung dieser Verallgemeinerung – insbesondere der Nachweis der Äquivalenz stochastischer Lyapunov-Bedingungen mit den Eigenwertkriterien für $\tilde{\mathbf{A}}$ – stellt ein eigenständiges Forschungsprogramm dar.

3.11.3 Nichtlineare Systeme: Globale Klassifikation und Bifurkationstheorie

Abschnitt 3.9 hat angemerkt, dass die Jacobi-Matrix $\mathbf{A}^*$ am Gleichgewicht $\mathbf{x}^*$ die *lokale* Zustandsklasse eines nichtlinearen Systems bestimmt (Satz von Hartman-Grobman). Diese lokale Sichtweise ist für viele wirtschaftliche Fragestellungen unzureichend, da

Märkte und Volkswirtschaften typischerweise *multiple Gleichgewichte* besitzen: stationäre Punkte, Grenzyklen, Attraktoren und chaotische Mengen koexistieren im gleichen Zustandsraum.

Eine weiterführende Forschungsfrage ist:

- A1. Globale KS-Karte:** Für ein nichtlineares System $\dot{\mathbf{x}} = f(\mathbf{x})$ mit mehreren Gleichgewichten $\mathbf{x}_1^*, \dots, \mathbf{x}_r^*$ definiert jede Jacobi-Matrix $\mathbf{A}_i^* = \partial f / \partial \mathbf{x}|_{\mathbf{x}_i^*}$ eine lokale Zustandsklasse $\text{KS}(\mathbf{A}_i^*)$. Die *globale KS-Karte* des Systems wäre die Abbildung $\mathbf{x} \mapsto \text{KS}(\mathbf{A}^*(\mathbf{x}))$, sofern $\mathbf{x}$ im Einzugsgebiet eines Gleichgewichts liegt. Diese Karte partitioniert den Zustandsraum nach lokalen Stabilitätseigenschaften und hat direkte Interpretation als “Risikokarte” für Wirtschaftssysteme.
- A2. Bifurkationen als Klassenwechsel:** Ein Parameterwechsel in einem nichtlinearen Wirtschaftsmodell (z. B. Erhöhung des Leitzinses) kann einen Eigenwert durch die imaginäre Achse bewegen und damit einen Klassenwechsel auslösen. Die Hopf-Bifurkation ($\mathbf{A}^*$ -Eigenwert überquert die imaginäre Achse als konjugiertes Paar) entspricht dem Übergang KS-I $\rightarrow$ KS-II, die Sattel-Knoten-Bifurkation (reeller Eigenwert durch Null) dem Übergang KS-I $\rightarrow$ KS-IV. Eine systematische Bifurkationsanalyse im Rahmen der Zustandsklassen würde eine quantitative Theorie wirtschaftlicher Phasenübergänge liefern.
- A3. Barrier-Funktionen als globale Lyapunov-Ersatz:** Für globale Stabilitätsaussagen nichtlinearer Systeme bieten Barrier-Zertifikatsmethoden (Prajna & Jadbabaie, 2004) eine Alternative zu lokalen Lyapunov-Funktionen. Die Verbindung zu den Zustandsklassen über Sum-of-Squares-(SOS-)Optimierung ermöglicht die automatische Synthese globaler Stabilitätszertifikate.

3.11.4 Datengetriebene Identifikation der Zustandsklasse

In der wirtschaftlichen Praxis ist die Systemmatrix $\mathbf{A}$ selten direkt bekannt. Stattdessen liegen Zeitreihendaten $\mathbf{x}(t_0), \mathbf{x}(t_1), \dots, \mathbf{x}(t_N)$ vor, aus denen sowohl $\mathbf{A}$ als auch $\text{KS}(\mathbf{A})$ inferiert werden müssen. Dies führt zum *System-Identifikationsproblem der Zustandsklassen*, das wir als eigenständiges Forschungsfeld skizzieren:

Koopman-Operator-Methoden

Der *Koopman-Operator* $\mathcal{K}$ eines nichtlinearen Systems $\dot{\mathbf{x}} = f(\mathbf{x})$ ist der lineare Operator auf dem Raum der Observablen $g : \mathbb{R}^n \rightarrow \mathbb{R}$:

$$(\mathcal{K}g)(\mathbf{x}) = \nabla g(\mathbf{x}) \cdot f(\mathbf{x}). \quad (3.38)$$

Obwohl f nichtlinear ist, ist $\mathcal{K}$ linear – allerdings auf einem unendlichdimensionalen Funktionenraum. Moderne Methoden wie die *Dynamic Mode Decomposition* (DMD) und ihre Erweiterungen (EDMD, DMDc) approximieren $\mathcal{K}$ durch eine endlichdimensionale Koopman-Matrix $\hat{\mathbf{K}} \in \mathbb{R}^{p \times p}$ aus Daten. Die Eigenwerte von $\hat{\mathbf{K}}$ (die *Koopman-Eigenwerte*) konvergieren unter geeigneten Annahmen gegen die Eigenwerte von $\mathcal{K}$, und ihr Spektrum enthält die dynamische Information des ursprünglichen Systems.

Bemerkung 3.11.3 (Zustandsklassen via Koopman-Eigenwerte). Die Zustandsklasse $\text{KS}(f)$ eines nichtlinearen Systems $\dot{\mathbf{x}} = f(\mathbf{x})$ im globalen Sinne könnte durch das

Spektrum des Koopman-Operators $\mathcal{K}$ definiert werden: Liegen alle Koopman-Eigenwerte mit negativem Realteil, so entspricht dies einem KS-I-Verhalten im Koopman-Bild. Diese Verallgemeinerung harmoniert mit der bekannten Tatsache, dass für LTI-Systeme Koopman-Eigenwerte und Systemmatrix-Eigenwerte identisch sind.

Sparse Identification of Nonlinear Dynamics (SINDy)

Das SINDy-Verfahren (Brunton et al., 2016) identifiziert aus Zeitreihendaten die spärlichste Darstellung $\dot{\mathbf{x}} \approx \Theta(\mathbf{x})\Xi$, wobei Θ eine Bibliothek von Basisfunktionen und Ξ eine Koeffizientenmatrix ist. Für lineare Systeme ergibt SINDy direkt die Systemmatrix $\mathbf{A} = \Xi^\top$, und damit $\text{KS}(\mathbf{A})$ durch direkten Eigenwertvergleich. Für nichtlineare Systeme liefert SINDy eine Approximation $f \approx \hat{f}$, deren Linearisierung als Näherung für KS dienen kann.

Maschinelles Lernen und spektrale Klassifikatoren

Eine dritte, rein datengetriebene Richtung ist das Training von Klassifikatoren (neuronale Netze, Support-Vector-Machines, Random Forests), die direkt aus Zeitreiheneigenschaften (Autokorrelationsfunktionen, Hurst-Exponenten, Leistungsspektren) auf die Zustandsklasse KS schließen. Erste Ergebnisse aus der Nichtlineare-Dynamik-Literatur zeigen, dass solche Klassifikatoren hohe Genauigkeit erreichen, sobald geeignete spektrale Merkmale als Features gewählt werden. Die formale Brücke zwischen diesen empirischen Klassifikatoren und den mathematisch exakten Definitionen aus Abschnitt 3.4 steht noch aus.

3.11.5 Netzwerke Gekoppelter Systeme und Multilevel-Subgraph

Makroökonomische Systeme bestehen nicht aus einer einzelnen Volkswirtschaft, sondern aus einem *Netzwerk* von Volkswirtschaften, die über Handelsströme, Kapitalflüsse und Währungskopplerbindungen interagieren. Formal ist ein solches System beschreibbar als *gekoppeltes LTI-Netz*:

$$\dot{\mathbf{x}}_i(t) = \mathbf{A}_i \mathbf{x}_i(t) + \sum_{j=1}^N \mathbf{C}_{ij} \mathbf{x}_j(t), \quad i = 1, \dots, N, \quad (3.39)$$

wobei $\mathbf{A}_i \in \mathbb{R}^{n_i \times n_i}$ die Systemmatrix der i -ten Volkswirtschaft, $\mathbf{C}_{ij} \in \mathbb{R}^{n_i \times n_j}$ die Kopplungsmatrix von j nach i und N die Anzahl der Volkswirtschaften bezeichnen. Das Gesamtsystem hat die Block-Systemmatrix

$$\mathbf{A}_{\text{net}} = \begin{pmatrix} \mathbf{A}_1 & \mathbf{C}_{12} & \cdots & \mathbf{C}_{1N} \\ \mathbf{C}_{21} & \mathbf{A}_2 & \cdots & \mathbf{C}_{2N} \\ \vdots & & \ddots & \vdots \\ \mathbf{C}_{N1} & \mathbf{C}_{N2} & \cdots & \mathbf{A}_N \end{pmatrix}. \quad (3.40)$$

Bemerkung 3.11.4 (Zustandsklasse des Gesamtnetzwerks versus Teilsystemen). Aus Proposition 3.5.6 folgt, dass das Gesamtnetzwerk nur dann KS-I ist, wenn alle Diagonalblöcke $\mathbf{A}_i$ zu KS-I gehören *und* die Kopplungen $\mathbf{C}_{ij}$ die Gesamtstabilität nicht zerstören. Die präzise Bedingung auf $\mathbf{C}_{ij}$ führt auf das Problem der *kompositionellen Stabilität*,

das in der Regelungstheorie als “small-gain theorem” bekannt ist. Im wirtschaftlichen Kontext fragt dieses Kriterium: Unter welchen Handelsbedingungen bleibt ein Netzwerk aus KS-I-Volkswirtschaften global stabil?

Multilevel-Subgraph Algorithmus

Für Systeme der Form (3.39) bietet der Subgraph Algorithmus eine natürliche *hierarchische Erweiterung*: Der *Multilevel-Subgraph* $\mathcal{S}_{\text{net}}$ besteht aus

- einem *Metagraphen* auf Ebene 2, dessen Knoten die Volkswirtschaften $1, \dots, N$ und dessen Kanten die nichtverschwindenden Kopplungsblöcke $\mathbf{C}_{ij} \neq \mathbf{0}$ sind,
- je einem Subgraph $\mathcal{S}(\mathbf{A}_i)$ als Knoten-Annotation auf Ebene 1.

Die SCC-Zerlegung des Metagraphen (Kosaraju auf Ebene 2) identifiziert *Systemcluster*: Volkswirtschaften, die zyklisch voneinander abhängen. Der Subgraph Algorithmus auf Ebene 1 liefert für jede Volkswirtschaft die Zustandsklasse. Die Kombination beider Informationen erlaubt Aussagen wie: “Cluster $\mathcal{C}$ bestehend aus KS-I- und KS-II-Volkswirtschaften hat durch seine interne Kopplungsstruktur ($\mathbf{C}_{ij}$ zu groß) eine instabile Rückkopplungsschleife – Gesamtsystem ist KS-IV.”

Die algorithmische Komplexität des Multilevel-Subgraph Algorithmus beläuft sich auf $O(N^2 n^3)$ für den Vollvergleich aller Kopplungen, wobei $n = \max_i n_i$. Für spärlich vernetzte Systeme (Anzahl nichtverschwindender Kopplungsblöcke $\ll N^2$) verbessert sich dies auf $O(|\mathcal{E}| \cdot n^3)$, wobei $|\mathcal{E}|$ die Anzahl der Kanten im Metagraphen bezeichnet.

3.11.6 Optimale Zustandsklassenübergänge und Polplatzierung

Aus dem Blickwinkel der Regelungstheorie ist die natürlichste wirtschaftspolitische Fragestellung nicht die Analyse des bestehenden Systems, sondern die *Synthese*: Wie muss eine wirtschaftspolitische Steuerung $\mathbf{u}(t)$ gewählt werden, um ein KS-III-System (Krise) in ein KS-I-System (Stabilität) zu überführen?

Polvorgabe und Spektralformung

Das *Polvorgabeproblem* (pole placement) fragt: Gesucht ist ein linearer Regler $\mathbf{u}(t) = -\mathbf{K}\mathbf{x}(t)$ (Zustandsrückführung), der die Systemmatrix des geschlossenen Regelkreises $\mathbf{A}_{\text{cl}} = \mathbf{A} - \mathbf{B}\mathbf{K}$ so gestaltet, dass $\text{KS}(\mathbf{A}_{\text{cl}}) = \text{KS-I}$ gilt. Ist das System $(\mathbf{A}, \mathbf{B})$ steuerbar (Theorem 3.6.11), so ist dieses Problem *immer* lösbar (Ackermann-Formel, allgemeiner: Bass-Gura-Methode). Der optimale Regler – der $\mathbf{K}$ unter minimaler Regelenergie $\int_0^\infty \mathbf{u}^\top \mathbf{u} dt$ bestimmt – ist der *Linear-Quadratic Regulator* (LQR), der die algebraische Riccati-Gleichung

$$\mathbf{A}^\top \mathbf{P} + \mathbf{P}\mathbf{A} - \mathbf{P}\mathbf{B}\mathbf{R}^{-1}\mathbf{B}^\top \mathbf{P} + \mathbf{Q} = \mathbf{0} \quad (3.41)$$

löst, mit $\mathbf{K}^* = \mathbf{R}^{-1}\mathbf{B}^\top \mathbf{P}$ und positiv definiten Gewichtsmatrizen $\mathbf{Q}, \mathbf{R}$. Das Wirtschaftsinterpretation von (3.41): $\mathbf{Q}$ gewichtet die “Kosten” von Zustandsabweichungen (BIP-Lücke, Inflationsabweichung), $\mathbf{R}$ die Kosten wirtschaftspolitischer Eingriffe (Zinssenkungskosten, fiskalische Schuldenaufnahme).

Minimale Perturbation für KS-III $\rightarrow$ KS-I

Eine verwandte, fundamental neue Fragestellung: Gegeben $\mathbf{A} \in \text{KS-III}$, gesucht ist die *kleinste Perturbation* $\Delta\mathbf{A}$ (im Sinne der Spektralnorm), so dass $\mathbf{A} + \Delta\mathbf{A} \in \text{KS-I}$:

$$\min_{\Delta\mathbf{A}} \|\Delta\mathbf{A}\|_2 \quad \text{s. d.} \quad \max_k \operatorname{Re}(\lambda_k(\mathbf{A} + \Delta\mathbf{A})) < 0. \quad (3.42)$$

Das Problem (3.42) ist das strukturelle Gegenstück zur Stabilitätsoptimierung. Seine Lösung – die *Distanz zum instabilen Rand* (distance to instability) – verallgemeinert den Stabilitätsabstand δ aus Proposition 3.9.1 und misst, wie viel Strukturveränderung benötigt wird, um ein Krisensystem zu stabilisieren. In wirtschaftspolitischer Sprache: Welches ist der kleinstmögliche Systemeingriff (Zinsänderung, Regulierung, fiskalisches Paket), der das System von KS-III nach KS-I transferiert?

Algorithmen zur Berechnung dieser Distanz (Guglielmi, Gürbüzbalaban, Overton, 2017) haben Komplexität $O(n^3)$ pro Iteration und sind für Wirtschaftssystemmatrizen bis $n \approx 500$ praktisch einsetzbar.

$\mathcal{H}_\infty$ -Synthese als robuste Klassensicherung

Über den LQR hinaus liefert die $\mathcal{H}_\infty$ -Synthese einen Regler, der die KS-I-Klassenzugehörigkeit auch unter Modellunsicherheiten $\|\Delta\mathbf{A}\|_2 < \varepsilon$ aufrechterhält (robuste Stabilität). Die zugehörige $\mathcal{H}_\infty$ -Norm

$$\|(I + \mathbf{G}\mathbf{K})^{-1}\mathbf{G}\|_\infty$$

quantifiziert, wie stark externe Störungen (wirtschaftliche Schocks) die Zustandsnorm beeinflussen. Systeme mit kleiner $\mathcal{H}_\infty$ -Norm sind durch Proposition 3.9.1 “tief” in der KS-I-Klasse verankert.

3.11.7 Erweiterungen des Subgraph Algorithmus

Der in Kapitel 3.7 vollständig analysierte Subgraph Algorithmus [Epp, 2026c] ist in seiner aktuellen Form auf quadratische $n \times n$ -Adjazenzmatrizen und zyklische Rotationen beschränkt. Mehrere Erweiterungsrichtungen sind von unmittelbarem theoretischem und praktischem Interesse:

Gewichtete Systemgraphen

In realen Wirtschaftssystemen tragen die Kanten von $\mathcal{G}(\mathbf{A})$ Gewichte (die Matrixeinträge $a_{ij} \in \mathbb{R}$), nicht nur Binärinformation. Die aktuelle Signaturfunktion (3.25) ignoriert diese Gewichte. Eine gewichtete Signatur könnte durch

$$\sigma_j^w(A) := \sum_{i=0}^{n-1} \lfloor A_{ij} \cdot 2^b \rfloor \cdot p_i + j \cdot P_n \quad (3.43)$$

definiert werden, wobei b die Quantisierungsgenauigkeit, p_i paarweise teilerfremde Primzahlen (Chinese Remainder Theorem) und $P_n = \prod_{i=0}^{n-1} p_i$ bezeichnen. Die Injektivität dieser gewichteten Signatur wäre unter geeigneten Ganzzahl-Quantisierungsannahmen beweisbar, und die Komplexität bliebe $O(n^3)$ mit einem Faktor $O(b)$ für die Ganzzahlarithmetik.

Nicht-quadratische und heterogene Systeme

Für Netzwerke aus Systemen verschiedener Dimension ($n_1 \neq n_2$) müssen die Adjazenzmatrizen $A \in \{0, 1\}^{n_1 \times n_1}$ und $B \in \{0, 1\}^{n_2 \times n_2}$ verglichen werden. Das *induced subgraph isomorphism problem* fragt ob $\mathcal{G}(\mathbf{B})$ einen Teilgraphen enthält, der isomorph zu $\mathcal{G}(\mathbf{A})$ ist – ein NP-vollständiges Problem im Allgemeinen. Für die systemtheoretisch relevante zyklische Subgraph-Relation könnte die Beschränkung auf zyklustreue Einbettungen (d. h. Einbettungen, die Zyklen auf Zyklen abbilden) wieder eine polynomielle Entscheidbarkeit ergeben. Dies ist eine offene Frage.

Dynamischer Subgraph-Vergleich

In zeitvarianten Kontexten variiert die Systemmatrix $\mathbf{A}(t)$, und damit auch der Systemgraph $\mathcal{G}(\mathbf{A}(t))$. Ein *dynamischer Subgraph-Vergleich* würde für zwei zeitvariante Systeme $\mathbf{A}(t)$ und $\mathbf{B}(t)$ fragen, ob die Subgraph-Relation $\mathcal{G}(\mathbf{A}(t)) \subseteq \mathcal{G}(\mathbf{B}(t))$ für alle $t \in [0, T]$ gilt. Dies ist äquivalent zur Frage, ob die *Unterstützung* (support) von $\mathbf{A}(t)$ stets in der Unterstützung von $\mathbf{B}(t)$ enthalten ist – eine Eigenschaft, die prüfbar ist, wenn Strukturwechselzeitpunkte bekannt sind.

Parallelisierung und verteilte Berechnung

Für sehr große Systemmatrizen ($n > 10^4$, wie sie etwa bei Eingabe-Output-Analysen von Volkswirtschaften mit mehreren tausend Sektoren auftreten) ist die sequentielle $\Theta(n^3)$ -Laufzeit des Subgraph Algorithmus zu langsam. Da die n LCS-Berechnungen für verschiedene Rotationen vollständig unabhängig sind (Beweis zu Theorem 3.7.12), ist der Algorithmus trivial parallelisierbar: Auf einem p -Prozessor-System ergibt sich eine parallele Laufzeit von $O(n^3/p + n^2)$, was für $p = O(n)$ Prozessoren eine Laufzeit $O(n^2)$ ergibt. Moderne GPU-Implementierungen erlauben in der Praxis $p \sim 10^4$, was Systemmatrizen der Dimension $n \sim 5000$ in Millisekunden analysierbar macht.

3.11.8 Verbindungen zu anderen Mathematischen Disziplinen

Die in dieser Arbeit entwickelten Konzepte berühren mehrere tiefe mathematische Forschungsfelder, die bislang noch keine systematische Verbindung zur Zustandsklassifikation hatten.

Algebraische Topologie: Persistente Homologie des Systemgraphen

Die *persistente Homologie* (Carlsson, 2009) extrahiert topologische Invarianten (Betti-Zahlen, Barcode) aus gefilterten Simplicialkomplexen. Angewendet auf den Systemgraphen $\mathcal{G}(\mathbf{A})$ – gefiltert nach dem Absolutwert der Kantengewichte $|a_{ij}|$ – liefert die persistente Homologie eine topologische Signatur des dynamischen Systems. Interessant ist die Frage: Korrelieren diese topologischen Signaturen mit der Zustandsklasse? Erste heuristische Befunde aus der Netzwerkwissenschaft deuten darauf hin, dass KS-I-Systeme charakteristisch einfachere Barcodes aufweisen als instabile Systeme.

Spektralgeometrie und Laplace-Spektrum

Der *Laplace-Operator* $L = D - A$ eines Graphen (mit Gradmatrix D und Adjazenzmatrix A) hat engen Bezug zur Systemmatrix $\mathbf{A}$: Für symmetrische $\mathbf{A}$ mit Zeilensumme

Null stimmt $-\mathbf{A}$ mit dem Laplace-Operator überein. Die Eigenwerte des Laplacians (Laplace-Spektrum) steuern Diffusions- und Synchronisationsprozesse auf Graphen. Die bereits bekannte Fiedler-Zahl $\lambda_2(L)$ (smallest nontrivial eigenvalue) quantifiziert die algebraische Konnektivität und damit die Resilienz des gekoppelten Netzwerks – eine direkte Verbindung zur Robustheit aus Proposition 3.9.1.

Kategorientheorie: Funktorialität der Zustandsklassenabbildung

Aus einem hohen Abstraktionsniveau betrachtet ist die Abbildung $\mathbf{A} \mapsto \text{KS}(\mathbf{A})$ ein Funktor von der Kategorie der reellen Matrizen (mit Konjugation als Morphismus) in eine Kategorie mit vier Objekten $\{\text{KS-I}, \text{KS-II}, \text{KS-III}, \text{KS-IV}\}$. Die Natürlichkeit dieser Abbildung – d. h. die Frage, ob strukturerhaltende Transformationen (Ähnlichkeitstransformationen $\mathbf{A} \mapsto \mathbf{S}\mathbf{A}\mathbf{S}^{-1}$) die Klasse erhalten – ist trivialerweise erfüllt, da Eigenwerte unter Ähnlichkeitstransformation invariant sind. Interessanter sind *strukturelle Morphismen*, etwa Netzwerkhomomorphismen $\mathcal{G}(\mathbf{A}) \rightarrow \mathcal{G}(\mathbf{B})$: Welche Eigenschaften der Zustandsklassen werden durch solche Morphismen bewahrt?

Informationstheorie: Maximale Entropie und Systemklassen

Das *Maximum-Entropie-Prinzip* (Jaynes, 1957) fragt nach der wahrscheinlichsten Systemmatrix $\mathbf{A}$ unter gegebenen Informationseinschränkungen. Für die Einschränkung $\alpha^* = \alpha_0$ (feste Spektralabszisse) ist die Verteilung über Systemmatrizen durch ein Gibbs-Maß mit dem Exponenten α^* als “inverse Temperatur” charakterisiert. Die Zustandsklassen entsprechen in diesem Bild thermodynamischen Phasen, und die Übergänge $\text{KS-I} \leftrightarrow \text{KS-II}$ etc. sind Phasenübergänge. Diese Analogie hat Konsequenzen für die statistische Schätzung von Systemmatrizen aus Daten: Die Maximum-Entropie-Schätzung unter der Nebenbedingung $\text{KS}(\hat{\mathbf{A}}) = \text{KS-I}$ liefert einen strukturell stabilen Schätzer.

3.11.9 Wirtschaftspolitische Implikationen: Regulierung und Systemdesign

Die Kernthese dieser Arbeit – dass Wirtschaftssysteme vollständig durch ihre Systemmatrix charakterisierbar sind – hat weitreichende Konsequenzen für Wirtschaftspolitik, Finanzregulierung und institutionelles Design.

Zustandsklassenbasierte Regulierungsarchitektur

Eine auf den Zustandsklassen basierende Regulierungsarchitektur würde Folgendes umfassen:

- R1. Pflichtklassifikation systemrelevanter Institute:** Jede systemrelevante Bank, jeder Versicherungskonzern und jeder Staatsfonds müsste vierteljährlich die Zustandsklasse seines internen Dynamikmodells $\text{KS}(\mathbf{A}_{\text{inst}})$ an die Regulierungsbehörde melden. Dies wäre der mathematisch präzise und nicht manipulierbare Ersatz für aktuelle qualitative Stressszenarien (DFAST, EBA-Stresstests).
- R2. Systemischer Risikopuffer als Funktion von δ :** Der Stabilitätsabstand $\delta = -\alpha^*(\mathbf{A}_{\text{inst}})$ liefert eine natürliche, quantitative Grundlage für Kapitalpuffer-Anforderungen: Je kleiner δ , desto näher das System am instabilen Rand, desto höher

der geforderte Kapitalpuffer. Eine Regulierungsformel der Form $\text{Puffer}(t) \propto \exp(-c \cdot \delta(t))$ hätte automatische antizyklische Eigenschaften.

R3. Netzwerkregulierung mittels Multilevel-Subgraph: Der Multilevel-Subgraph Algorithmus (Kapitel 3.11.5) erlaubt die Bestimmung, welche Kopplung C_{ij} (Interbanktransaktion, Kreditlinie, Derivatkontrakt) das Gesamtnetzwerk am stärksten destabilisiert. Regulierung kann dann gezielt diese Verbindungen unter Volumen- oder Konzentrationsschranken setzen.

R4. Geldpolitik als Polplatzierung: Die Zinspolitik einer Zentralbank wirkt auf die Systemmatrix durch Änderung bestimmter Einträge (Zinselastizitäten im IS-LM-Modell, vgl. Beispiel 3.6). Die optimale Geldpolitik ist dann formal identisch mit dem LQR-Problem (3.41): Minimiere den Abstand zur Gleichgewichtsbahn unter minimaler Kontrollanstrengung (Zinsschwankung).

Finanzmarktstabilität und KS-II als Zielklasse

Eine interessante normative Frage ist, ob Volkswirtschaften überhaupt KS-I oder vielmehr KS-II anstreben sollten. KS-I garantiert Konvergenz zum Gleichgewicht, eliminiert aber auch wirtschaftliche Wachstumsoszillationen. KS-II mit rein-imaginären Eigenwerten $\pm i\omega$ erzeugt nach Theorem 3.6.7 persistente Zyklen – was Innovation, schöpferische Zerstörung (Schumpeter) und Wachstumsdynamik modellieren kann. Eine “ideale” Volkswirtschaft könnte durch eine Systemmatrix A^{ideal} in KS-II mit kontrollierten Zyklusfrequenzen ω (Konjunkturperiode $T = 2\pi/\omega \approx 7$ Jahre) beschrieben werden. Das Regulierungsziel wäre dann nicht die Eliminierung aller Schwingungen, sondern die Sicherstellung der Semieinfachheit der rein-imaginären Eigenwerte – d. h. die Verhinderung resonanter Verstärkung durch Jordan-Blöcke.

Digitale Zentralbankwährungen und Echtzeit-Systemklassifikation

Digitale Zentralbankwährungen (CBDC) erzeugen Transaktionsdaten in nahezu Echtzeit. Dies ermöglicht erstmals die kontinuierliche Schätzung der Systemmatrix $\hat{A}(t)$ des monetären Sektors aus Transaktionszeitreihen (mit Methoden aus Kapitel 3.11.4). Eine CBDC-Infrastruktur könnte automatisch $\text{KS}(\hat{A}(t))$ in Echtzeit überwachen und bei Annäherung an KS-III (Auftreten von Eigenwerten mit positivem Realteil) automatische Gegenmaßnahmen (Liquiditätsinjektionen, Zinssenkungen) auslösen – ein *automatischer Stabilisator der mathematisch exakten Art*.

3.11.10 Implementierung, Software-Ökosystem und offene Standards

Die algorithmischen Beiträge dieser Arbeit – Subgraph Algorithmus und Subgraph Algorithmus – sind auf praktische Implementierungen angewiesen, um ihren wissenschaftlichen und wirtschaftlichen Wert voll zu entfalten.

Standardisierte Systemmatrix-Bibliothek

Eine kuratierte, öffentlich zugängliche Bibliothek von Systemmatrizen wirtschaftlicher Modelle (IS-LM, DSGE-Linearisierungen, Schuldendynamiken, Portfolio-Kovarianzmatrizen) würde es erlauben, die Zustandsklassen-Klassifikation

für bekannte Modelle zu standardisieren und vergleichbar zu machen. Analog zu den Matrix-Market-Benchmarks in der numerischen linearen Algebra wäre eine solche Bibliothek die Grundlage für reproduzierbare Experimente.

Interoperabilität mit bestehenden Werkzeugen

Die Zustandsklassenanalyse sollte nahtlos in bestehende wissenschaftliche Software-Ökosysteme integriert werden:

- **Python/SciPy:** Erweiterung von `scipy` um `state_class(A)` und `subgraph(A)`, basierend auf der QR-Iteration von LAPACK.
- **Julia/ControlSystems.jl:** Einbindung der Zustandsklassenanalyse in das Julia-Regelungspaket durch einen neuen Systemtyp `ClassifiedLTISystem`.
- **MATLAB/Simulink:** Block-Bibliothek für den Subgraph Algorithmus mit automatischer Visualisierung des Systemgraphen und Farbkodierung der Zustandsklassen (analog zu fig. 3.4).
- **R:** Paket `sysstate` für statistische Analysen von Systemmatrizen aus ökonometrischen Zeitreihenmodellen (VAR, VECM).

Offener Standard: KSML (Klassifikations-System-Markup-Language)

Für den Austausch von Systemmatrizen mitsamt ihrer Zustandsklassenannotation zwischen verschiedenen Werkzeugen und Institutionen wäre ein offener XML/JSON-basierter Standard wünschenswert:

```
{
  "system_matrix": [[...], ...],
  "state_class": "KS-I",
  "spectral_abscissa": -0.47,
  "stability_margin": 0.47,
  "subgraph": { "scc_count": 3, "eigenvalues": [...] }
}
```

Ein solcher Standard würde die Zustandsklassenanalyse zu einem reproduzierbaren, interoperablen Werkzeug für die wissenschaftliche Gemeinschaft machen.

3.11.11 Zusammenfassende Forschungsagenda

Die folgende Tabelle fasst die gesamte Forschungsagenda in drei Zeithorizonte zusammen:

Tabelle 3.4: Forschungsagenda: Kurzfristige, mittelfristige und langfristige Ziele

Horizont	Thema	Ziel
Kurzfristig	Stochastische Zustandsklassen	Beweis der mittleren quadratischen Äquivalenz via $\tilde{\mathbf{A}}$ (3.37)
	Gewichtete Subgraph-Signatur Open-Source-Implementierung	Injektivitätsbeweis für σ_j^w (3.43) Python-Paket <code>sysstate</code> mit Subgraph + Subgraph
Mittelfristig	Floquet-Analyse für Konjunktur Multilevel-Subgraph	Automatische Pipeline: Zeitreihe $\rightarrow \mathbf{A}_F \rightarrow \text{KS}(\mathbf{A}_F)$ Algorithmus und Komplexitätsanalyse für Netzwerke (3.39)
	Datengetriebene KS-Klassifikation Minimale Perturbation KS-III $\rightarrow$ I	Koopman-/SINDy-basierte Identifikation von KS Effizienter Algorithmus für (3.42)
Langfristig	Globale KS-Karte	Nichtlineare Dynamik: Partitionierung des Zustandsraums nach lokalen KS
	Topologische Invarianten	Persistente Homologie des Systemgraphen vs. KS
	CBDC-Echtzeit-Monitor	Kontinuierliche $\hat{\mathbf{A}}(t)$ -Schätzung und KS-Überwachung
	Regulierungsstandard	Integration in DFAST/EBA durch δ -basierten Puffer

Die Zustandsklassen KS-I bis KS-IV, der Subgraph Algorithmus und der Subgraph Algorithmus sind keine Endpunkte, sondern *Ausgangspunkte* einer umfassenden mathematischen Theorie dynamischer Systeme in Ingenieurwesen, Wirtschaft und Naturwissenschaften. Die nächste Entwicklungsstufe liegt in der Verschmelzung dieser algebraischen Theorie mit stochastischer Analysis, datengetriebenen Methoden, Netzwerktheorie und moderner Computational Science – mit dem Ziel, die mathematisch exakte Systemklassifikation zu einem universell einsetzbaren Werkzeug für Analyse, Regulierung und wirtschaftspolitisches Design zu machen.

Kapitel 4

Wirtschaftssysteme unter Unsicherheit

4.1 Einleitung und Problemstellung

4.1.1 Die Illusion der wirtschaftlichen Vorhersagbarkeit

Die Grundlage aller modernen betriebswirtschaftlichen Planung, Logistik und Finanzmodellierung ruht auf einer stillen Annahme: dass die Zukunft *vorhersagbar* ist oder zumindest *ausreichend* vorhersagbar, um operative Entscheidungen zu treffen.

Diese Annahme ist nicht falsch. Sie ist *graduell degradierend*.

Eine Nachfrage, die in zwei Tagen eintritt, ist mit hoher Sicherheit vorhersagbar. Ein Kunde, der morgen zum dritten Mal in Folge Produkt A kaufen wird, wird es mit großer Wahrscheinlichkeit auch übermorgen tun. Die Prognose ist *scharf*, die Fehlerquote gering, die operativen Puffer können klein sein.

Aber schon eine Vorhersage für die nächsten drei Monate verliert Schärfe. Der Kunde könnte sein Budget neuausrichten, ein neuer Konkurrent könnte erscheinen, eine Mode könnte sich ändern. Die Fehlerquote wächst. Die Konfidenzintervalle werden breiter. Eine Prognose mit einem geschätzten Fehler von $\pm 3\%$ wird zu $\pm 12\%$.

Und eine Prognose für ein Jahr? Für fünf Jahre? Hier ist die Vorhersage nicht falsch im strengen Sinne. Sie ist *unscharf geworden bis zur Unbrauchbarkeit*. Die Bandbreite ist so breit, dass die Prognose keine information mehr trägt als: “es könnte viel sein, oder viel weniger.”

Wer Unsicherheit in der Modellierung des Wirtschaftssystems und der Planung nicht nutzt, der handelt rechtswidrig, da er den Menschen in seiner Würde und Freiheit in seinem persönlichen Kaufverhalten *nicht will*.

4.1.2 Zentrale Aussage

Die zentrale Aussage dieser Arbeit lautet: Die Vorhersagbarkeit von Kundenbedarf ist eine *zeitabhängige degradierende Funktion*, nicht eine stabile Eigenschaft. Es existiert eine mathematisch charakterisierbare Degradationskurve $\delta(t)$, die die Zuverlässigkeit einer zum Zeitpunkt t_0 getroffenen Prognose als Funktion des Zeithorizonts $\tau = t - t_0$ beschreibt. Diese Degradation ist nicht Folge unzureichender Information, sondern Folge der *fundamentalen Unvorhersehbarkeit menschlichen Verhaltens*. Ein rationales Wirtschaftssystem muss diese Degradation explizit modellieren, nicht ignorieren.

Diese Aussage hat radikale Konsequenzen:

- (i) **Planung muss zeithorizontabhängig sein:** Zentrale Planung für 2 Wochen ist legitim und effizient. Zentrale Planung für 5 Jahre ist irrational.
- (ii) **Pufferung muss exponentiell wachsen:** Bestände, Kapazität und Redundanz müssen mit dem Zeithorizont exponentiell zunehmen, nicht linear.
- (iii) **Dezentralisierung ist eine Folge der Unsicherheit:** Je länger der Planungshorizont, desto dezentralisierter muss das System sein, weil der zentrale Planer blind wird.
- (iv) **Recht und Vertrag müssen neu formuliert werden:** Verträge über lange Zeiträume sind Umverteilungen von Unsicherheit, nicht Vereinbarungen über Realität. Das muss rechtlich reflektiert werden.

4.1.3 Aufbau der Arbeit

Kapitel 4.2 legt die mathematischen Grundlagen für stochastische Prozesse, Informationstheorie und die Messung von Vorhersagbarkeit fest. Kapitel 4.3 entwickelt die Degradationskurve $\delta(t)$ als mathematisches Primärobjekt und beweist ihre wesentlichen Eigenschaften: Monotonie, asymptotisches Verhalten, Zusammenhang mit Entropie und Kullback-Leibler-Divergenz.

Kapitel 4.4 modelliert den Kunden explizit als nicht-stationären stochastischen Prozess mit zeitabhängigen Präferenzen, zeigt, dass Stationarität empirisch nicht haltbar ist, und beweist, dass eine suffiziente Statistik über Kundenverhalten nicht für beliebig lange Zeiträume existieren kann.

Kapitel 4.5 überträgt diese mathematischen Erkenntnisse auf operative Unternehmensplanung: Lagerbestände, Produktionskapazität, Lieferketten. Es wird gezeigt, dass unter expliziter Berücksichtigung der Degradation optimale Puffergrößen nicht linear, sondern exponentiell mit dem Zeithorizont wachsen müssen.

Kapitel 4.6 beweist formal, dass jedes Wirtschaftssystem, das versucht, zentral über lange Zeithorizonte zu planen, entweder irrational große Puffer aufbaut oder systemische Fragilität akzeptiert. Dezentralisierung wird nicht als ideologisches Konzept, sondern als mathematische Notwendigkeit hergeleitet.

Kapitel 4.7 diskutiert die Implikationen für Wirtschaftsrecht, Vertragstheorie und institutionelles Design.

Kapitel 4.8 beschreibt die logarithmische Gewichtung von Kundenverhalten und die daraus resultierende Metaverteilung, die die zeitliche Degradation der Vorhersagbarkeit formalisiert.

Kapitel 4.9 präsentiert numerische Simulationen, die alle Hauptergebnisse visualisieren.

4.2 Mathematische Grundlagen

4.2.1 Informationstheoretische Rahmen

Sei X_t die stochastische Variable “Kundenverhalten zum Zeitpunkt t ”, etwa die gekaufte Menge eines Produkts, eine kategoriale Wahlentscheidung, oder eine kontinuierliche Nachfragefunktion. Der Zustandsraum von X_t sei $\mathcal{X} \subseteq \mathbb{R}^d$.

Definition 4.2.1 (Informationsgehalt eines Zeithorizonts). Gegeben ein Zeithorizont $\tau > 0$ (Tage, Wochen, etc.) und eine zum Zeitpunkt t_0 verfügbare Information $\mathcal{I}_{t_0}$, definieren wir die *Shannon-Entropie* der bedingten Verteilung von $X_{t_0+\tau}$ gegeben $\mathcal{I}_{t_0}$ als:

$$H_\tau := H(X_{t_0+\tau} | \mathcal{I}_{t_0}) = - \int_{\mathcal{X}} p(x | \mathcal{I}_{t_0}, \tau) \log p(x | \mathcal{I}_{t_0}, \tau) dx \quad (4.1)$$

wobei $p(x | \mathcal{I}_{t_0}, \tau)$ die bedingte Wahrscheinlichkeitsdichte ist.

Die Shannon-Entropie H_τ ist ein Maß für *Unsicherheit*. $H_\tau = 0$ bedeutet, dass $X_{t_0+\tau}$ mit Sicherheit bekannt ist; hohe H_τ bedeutet tiefe Unsicherheit.

Definition 4.2.2 (Prognosefehlervarianz). Gegeben eine Prognose $\hat{X}_{t_0+\tau}$ für $X_{t_0+\tau}$, definieren wir den *Prognosefehlervarianz* als:

$$\sigma_\tau^2 := \mathbb{E} \left[\left(X_{t_0+\tau} - \hat{X}_{t_0+\tau} \right)^2 | \mathcal{I}_{t_0} \right] \quad (4.2)$$

Dies ist die erwartete quadratische Abweichung zwischen tatsächlichem und prognostiziertem Wert.

Ein fundamentales Resultat der Informationstheorie verbindet Entropie mit Prognosefehlern:

Lemma 4.2.3 (Entropie-Prognose-Dualität). *Unter Annahme einer Gaußschen Verteilung von $X_{t_0+\tau} | \mathcal{I}_{t_0}$ mit Varianz σ_τ^2 gilt:*

$$H_\tau = \frac{1}{2} \log(2\pi e \sigma_\tau^2) \quad (4.3)$$

Damit ist die Entropie der bedingten Verteilung direkt proportional zum Logarithmus der Prognosefehlervarianz.

Beweis. Dies folgt direkt aus der Definition der Shannon-Entropie für eine Gaußsche Verteilung mit Varianz σ_τ^2 :

$$H_\tau = - \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi\sigma_\tau^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma_\tau^2}\right) \log \frac{1}{\sqrt{2\pi\sigma_\tau^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma_\tau^2}\right) dx \quad (4.4)$$

$$= - \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi\sigma_\tau^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma_\tau^2}\right) \left[-\frac{1}{2} \log(2\pi\sigma_\tau^2) - \frac{(x-\mu)^2}{2\sigma_\tau^2 \ln 2} \right] dx \quad (4.5)$$

$$= \frac{1}{2} \log(2\pi\sigma_\tau^2) + \frac{1}{2 \ln 2} \mathbb{E} \left[\frac{(X_{t_0+\tau} - \mu)^2}{\sigma_\tau^2} \right] \quad (4.6)$$

$$= \frac{1}{2} \log(2\pi\sigma_\tau^2) + \frac{1}{2 \ln 2} \cdot 1 \quad (4.7)$$

$$= \frac{1}{2} \log(2\pi e \sigma_\tau^2) \quad (4.8)$$

Das letzte Gleichheitszeichen folgt aus der Tatsache, dass für eine Normalverteilung $\mathbb{E}[(X - \mu)^2 / \sigma^2] = 1$ ist. $\square$

4.2.2 Kullback-Leibler-Divergenz und Prognosequalität

Ein präziseres Maß für Prognosequalität ist die Kullback-Leibler-Divergenz zwischen der tatsächlichen bedingten Verteilung und der prognostizierten Verteilung:

Definition 4.2.4 (KL-Divergenz als Prognosefehlermaß). Sei $p(x)$ die wahre bedingte Wahrscheinlichkeitsdichte von $X_{t_0+\tau} \mid \mathcal{I}_{t_0}$ und $q(x)$ die durch die Prognose implizierte Verteilung. Die Kullback-Leibler-Divergenz ist:

$$\text{KL}(p \parallel q) := \int_{\mathcal{X}} p(x) \log \frac{p(x)}{q(x)} dx \quad (4.9)$$

$\text{KL}(p \parallel q) = 0$ genau dann, wenn $p = q$ fast überall. Für $p \neq q$ ist $\text{KL}(p \parallel q) > 0$.

Bemerkung 4.2.5. Die KL-Divergenz ist nicht symmetrisch: $\text{KL}(p \parallel q) \neq \text{KL}(q \parallel p)$ im Allgemeinen. Sie ist auch keine Metrik (erfüllt die Dreiecksungleichung nicht). Sie ist aber ein fundamentales Maß dafür, wie sehr sich die prognostizierte Verteilung von der wahren unterscheidet.

4.3 Degradationskurve

4.3.1 Definition der Degradationsfunktion

Definition 4.3.1 (Prognosedegradation). Sei $\hat{X}_{t_0+\tau}(t_0)$ eine zum Zeitpunkt t_0 getroffene optimale Prognose (im Sinne von minimaler KL-Divergenz oder minimaler MSE) für $X_{t_0+\tau}$. Die *Degradationsfunktion* ist definiert als:

$$\delta(\tau) := \frac{\sigma_\tau^2}{\sigma_0^2} \quad (4.10)$$

wobei $\sigma_\tau^2 := \mathbb{E}[(X_{t_0+\tau} - \hat{X}_{t_0+\tau}(t_0))^2 \mid \mathcal{I}_{t_0}]$ und $\sigma_0^2 := \text{Var}(X_{t_0})$ ist. Alternativ, als normalisierte mittlere KL-Divergenz:

$$\delta_{\text{KL}}(\tau) := \frac{\text{KL}(p_\tau \parallel \hat{q}_\tau)}{\text{KL}(p_\infty \parallel \hat{q}_\infty)} \quad (4.11)$$

wobei p_τ die wahre und $\hat{q}_\tau$ die prognostizierte Verteilung sind, und $\tau \rightarrow \infty$ einer maximal uneingeweihten Prognose entspricht.

Die Degradationsfunktion $\delta(\tau)$ hat folgende Interpretation:

- $\delta(0) = 1$: Bei Zeithorizont $\tau = 0$ ist die Prognose exakt (bis auf Messfehler).
- $\delta(\tau) > 1$ für $\tau > 0$: Mit wachsendem Zeithorizont wird die Prognose ungenauer.
- $\delta(\tau) \rightarrow \delta_{\max}$ für $\tau \rightarrow \infty$: Irgendwann saturiert der Fehler, wenn die Prognose nur noch die marginale Verteilung kennt.

4.3.2 Charakterisierung der Degradation

Theorem 4.3.2 (Monotonität der Degradation). *Unter der Annahme, dass X_t ein stationärer, ergodischer stochastischer Prozess ist, gilt:*

$$\frac{d\delta(\tau)}{d\tau} \geq 0 \quad \text{für alle } \tau \geq 0 \quad (4.12)$$

Das heißt: Die Degradationsfunktion ist monoton nicht-fallend.

Beweis. Sei $\hat{X}_{t_0+\tau}(t_0) = \mathbb{E}[X_{t_0+\tau} \mid \mathcal{I}_{t_0}]$ die bedingte Erwartung (optimale Prognose im MSE-Sinne). Dann:

$$\sigma_\tau^2 = \mathbb{E} \left[\left(X_{t_0+\tau} - \hat{X}_{t_0+\tau}(t_0) \right)^2 \mid \mathcal{I}_{t_0} \right] \quad (4.13)$$

$$= \mathbb{E} \left[X_{t_0+\tau}^2 \mid \mathcal{I}_{t_0} \right] - (\mathbb{E}[X_{t_0+\tau} \mid \mathcal{I}_{t_0}])^2 \quad (4.14)$$

$$= \text{Var}(X_{t_0+\tau} \mid \mathcal{I}_{t_0}) \quad (4.15)$$

Für zwei Zeithorizonte $\tau_1 < \tau_2$ und die Information $\mathcal{I}_{t_0}$, die bei $t_0 + \tau_1$ verfügbar ist ($\mathcal{I}_{t_0+\tau_1} \supset \mathcal{I}_{t_0}$), gilt nach der Eigenschaft der bedingten Varianz (law of total variance):

$$\text{Var}(X_{t_0+\tau_2}) = \mathbb{E}[\text{Var}(X_{t_0+\tau_2} \mid \mathcal{I}_{t_0+\tau_1})] + \text{Var}(\mathbb{E}[X_{t_0+\tau_2} \mid \mathcal{I}_{t_0+\tau_1}]) \quad (4.16)$$

Da $\mathcal{I}_{t_0}$ weniger Information enthält als $\mathcal{I}_{t_0+\tau_1}$, gilt:

$$\text{Var}(X_{t_0+\tau_2} \mid \mathcal{I}_{t_0}) \geq \text{Var}(X_{t_0+\tau_2} \mid \mathcal{I}_{t_0+\tau_1}) \quad (4.17)$$

Dies impliziert $\sigma_{\tau_2}^2 \geq \sigma_{\tau_1}^2$ unter Unsicherheit, was zeigt, dass der Fehler mit wachsendem Zeithorizont nicht abnehmen kann.

Formaler: Die bedingte Varianz $\text{Var}(X_{t_0+\tau} \mid \mathcal{I}_{t_0})$ ist eine Funktion der verfügbaren Information. Mit zunehmendem τ gibt es weniger Abhängigkeit zwischen der bekannten Vergangenheit $\mathcal{I}_{t_0}$ und der fernen Zukunft $X_{t_0+\tau}$. Die Abhängigkeitsstärke ist charakterisiert durch die Autokorrelation des Prozesses oder durch die Mixing-Rate. Für einen exponentiell mixing Prozess mit Mixing-Rate $\rho < 1$ gilt:

$$\text{Var}(X_{t_0+\tau} \mid \mathcal{I}_{t_0}) \geq \text{Var}(X_{t_0+\tau}) \cdot (1 - O(\rho^\tau)) \quad (4.18)$$

Dies zeigt, dass die bedingte Varianz monoton gegen die unbedingte Varianz konvergiert, also σ_τ^2 ist monoton nicht-fallend. $\square$

Theorem 4.3.3 (Asymptotisches Verhalten). *Für einen stationären, ergodischen Prozess X_t ohne perfekte Periodizität gilt:*

$$\lim_{\tau \rightarrow \infty} \delta(\tau) = \frac{\text{Var}(X_t)}{\sigma_0^2} = 1 \quad (4.19)$$

Das heißt: Der Fehler einer unendlich langen Prognose konvergiert gegen die unbedingte Varianz des Prozesses. Das Prognose-Konfidenzintervall wird so breit wie die natürliche Schwankung des Prozesses selbst.

Beweis. Für großes τ ist $\mathcal{I}_{t_0}$ praktisch uninformativ über $X_{t_0+\tau}$. Die beste Prognose wird zur unbedingten Erwartung $\hat{X}_{t_0+\tau} = \mathbb{E}[X_t]$, und der Fehler wird:

$$\sigma_\infty^2 = \mathbb{E}[(X_{t_0+\tau} - \mathbb{E}[X_t])^2] = \text{Var}(X_t) \quad (4.20)$$

Normalisiert auf $\sigma_0^2 = \text{Var}(X_{t_0})$ und unter Stationarität ergibt sich $\delta(\infty) = 1$.

Präziser: Unter Annahme exponentiellen Decay der Autokovarianzen, d.h. $|\text{Cov}(X_t, X_{t+\tau})| \leq C\rho^\tau$ für $\rho < 1$, gilt die bedingte Varianz konvergiert exponentiell:

$$|\sigma_\tau^2 - \text{Var}(X_t)| \leq D\rho^\tau \quad (4.21)$$

für eine Konstante D . Dies beweist exponentiell schnelle Konvergenz gegen die unbedingte Varianz. $\square$

4.3.3 Funktionale Form der Degradation

Empirisch und theoretisch lässt sich zeigen, dass Degradationskurven häufig folgende funktionale Formen annehmen:

Definition 4.3.4 (Parametrische Degradationsmodelle). **Modell 1: Exponentielles Plateaumodell**

$$\delta_1(\tau) = 1 + (\delta_{\max} - 1)(1 - e^{-\lambda_1\tau}) \quad (4.22)$$

Hier konvergiert die Degradation exponentiell gegen ein Plateau bei $\delta_{\max}$.

Modell 2: Potenzgesetz

$$\delta_2(\tau) = 1 + \alpha\tau^\beta \quad (4.23)$$

mit $\alpha > 0$ und $\beta \in (0, 1)$. Dies hat keine obere Schranke und eignet sich für Szenarien ohne Sättigung.

Modell 3: Logarithmisches Modell

$$\delta_3(\tau) = 1 + \gamma \log(1 + \tau) \quad (4.24)$$

Dies ist ein Kompromiss zwischen exponentiellem und potenzgesetz-artigem Verhalten.

Modell 4: Doppelsexponentielles Modell (allgemeines Degradationsmodell)

$$\delta_4(\tau) = \frac{\delta_{\max}}{1 + e^{-\lambda_2(\tau - \tau_0)}} \quad (4.25)$$

Dies ist eine logistische Funktion mit Inflexionspunkt bei τ_0 .

Die Wahl des Modells hängt von der zugrundeliegenden Struktur des stochastischen Prozesses X_t ab. Für Kundennachfrage ist oft das exponentielle Plateaumodell (Eq. 4.22) oder das logistische Modell (Eq. 4.25) angemessen.

4.4 Der Kunde als stochastischer Prozess

4.4.1 Nicht-Stationarität von Kundenpräferenzen

Definition 4.4.1 (Kundenverhalten als stochastischer Prozess). Sei der Vektor $\mathbf{x}_t$ mit $\mathbf{x}_t = (X_t^{(1)}, X_t^{(2)}, \dots, X_t^{(m)}) \in \mathbb{R}^m$ ein Vektor von Kaufvariablen zum Zeitpunkt t , wobei

$X_t^{(j)}$ die Kaufmenge oder Häufigkeit von Produkt j angibt. Der Kunde wird modelliert als ein m -dimensionaler stochastischer Prozess mit bedingter Dichtefunktion:

$$p_t(\mathbf{x}) := p(\mathbf{x}_t = \mathbf{x} \mid \mathcal{I}_t) \quad (4.26)$$

Die Parameter dieser Dichtefunktion (Mittelwert $\boldsymbol{\mu}_t$, Kovarianzmatrix $\boldsymbol{\Sigma}_t$, etc.) sind selbst zeitabhängig.

Theorem 4.4.2 (Nichtstationarität ist empirisch unvermeidlich). *Es existiert kein Kunde und kein Kundenensemble, für das der Prozess $\mathbf{x}_t$ für ein Intervall $[t_0, t_0 + T]$ mit $T > T_{\min}$ stationär ist, wobei $T_{\min}$ eine kundenspezifische, typischerweise Monate bis Jahre betragende Zeitskala ist.*

Beweis. Dies ist keine streng mathematische These (da sie empirischer Natur ist), aber kann durch mehrere Mechanismen begründet werden:

Argument 1: Zeitliche Drift von Präferenzen

Der Kundenpräferenzvektor $\boldsymbol{\mu}_t$ folgt einem zeitabhängigen Prozess:

$$\boldsymbol{\mu}_t = \boldsymbol{\mu}_0 + \int_0^t \mathbf{g}(s) ds + \mathbf{w}_t \quad (4.27)$$

wobei $\mathbf{g}(t)$ einen deterministischen Trend (Mode, Lebenszyklus, kulturelle Veränderung) darstellt und $\mathbf{w}_t$ ein Zufallsschock ist. Ein Jahr ist lang genug, dass sich die Modetrends, Lebensumstände oder wirtschaftlichen Rahmenbedingungen merklich ändern.

Argument 2: Gewöhnung und Habituation

Menschliche Präferenzen folgen nicht nur äußeren Schocks, sondern auch interner psychologischer Dynamik. Der Marginalnutzen eines Gutes sinkt mit Gewöhnung, was zu einer zeitabhängigen Nachfragefunktion führt:

$$\mu_t^{(j)} = \mu_{t-1}^{(j)} - \alpha(X_{t-1}^{(j)} - \bar{X}^{(j)}) + \varepsilon_t \quad (4.28)$$

Dies ist ein intrinsisch nicht-stationärer Prozess.

Argument 3: Lebenszyklus und externe Ereignisse

Ein Kunde ändert seine Präferenzen, wenn er älter wird, seine Familie gründet, seinen Job wechselt, sich in ein anderes Land oder eine andere Stadt zieht, eine Krankheit hat, etc. Diese Ereignisse sind sporadisch, können aber nicht als rein stochastische Schocks auf einen stationären Prozess modelliert werden – sie verändern die *Natur* des Prozesses selbst.

Formal: Die Wahrscheinlichkeit für solch strukturelle Veränderungen ist positiv über jeden Zeitraum $T > T_{\min}$:

$$\Pr(\text{strukturelle Veränderung in } [t, t + T]) > 0 \quad \text{für } T > T_{\min} \quad (4.29)$$

Dies zeigt, dass Stationarität nur als lokale Approximation über kurze Zeiträume haltbar ist. $\square$

4.4.2 Temporal Dependencies und Gedächtniseffekte

Ein Kunde ist nicht gedächtnislos. Heutige Entscheidungen hängen von gestrigen, letztwöchigen oder letzten Kaufentscheidungen ab. Dies wird durch eine autoregressive Modell erfasst:

Definition 4.4.3 (Kundenautoregression). Die Kundennachfrage folge einem vektorautoregressiven Modell der Ordnung p :

$$\mathbf{x}_t = \boldsymbol{\mu}_t + \sum_{k=1}^p \mathbf{A}_k \mathbf{x}_{t-k} + \boldsymbol{\epsilon}_t \quad (4.30)$$

wobei $\mathbf{A}_k$ Koeffizientenmatrizen sind und $\boldsymbol{\epsilon}_t \sim \mathcal{N}(0, \boldsymbol{\Sigma})$ i.i.d. Rauschen ist.

Die Eigenschaftswerte der Matrizen $\mathbf{A}_k$ bestimmen die Erinnerungsdauer des Prozesses. Wenn alle Eigenschaftswerte innerhalb des Einheitskreises liegen, ist der Prozess stationär gegeben festen $\boldsymbol{\mu}_t$. Aber wenn $\boldsymbol{\mu}_t$ selbst zeitabhängig ist (was bewiesen wurde), wird der Prozess insgesamt nicht-stationär.

4.4.3 Theoretische Grenze für Vorhersagbarkeit

Theorem 4.4.4 (Maximale Vorhersageperiode). *Für einen Kunden mit Präferenzdrift $\boldsymbol{\mu}_t = \boldsymbol{\mu}_0 + \int_0^t \mathbf{g}(s) ds$ und intrinsischer Varianz $\boldsymbol{\Sigma}$ existiert eine maximale Vorhersageperiode $T_{\max}$, jenseits derer die Prognose-KL-Divergenz gegen $\text{KL}(\text{true} \parallel \text{stationary}) > \epsilon_0$ konvergiert, wobei $\epsilon_0 > 0$ eine systemspezifische Konstante ist.*

Beweis. Die KL-Divergenz zwischen einer zeitabhängigen wahren Verteilung und einer zum Zeitpunkt t_0 kalibrierten stationären Prognose wächst mit dem Zeithorizont. Sei die wahre Verteilung:

$$p_t(x) = \mathcal{N}(\boldsymbol{\mu}_0 + \int_0^t \mathbf{g}(s) ds, \boldsymbol{\Sigma}) \quad (4.31)$$

und die prognostizierte Verteilung (stationary):

$$q(x) = \mathcal{N}(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}) \quad (4.32)$$

Die KL-Divergenz ist:

$$\text{KL}(p_t \parallel q) = \frac{1}{2} \left\| \int_0^t \mathbf{g}(s) ds \right\|_{\boldsymbol{\Sigma}^{-1}}^2 \quad (4.33)$$

wobei $\|\cdot\|_{\boldsymbol{\Sigma}^{-1}}$ die Mahalanobis-Norm ist. Wenn die Drift-Rate $\|\mathbf{g}(s)\|$ positiv ist, wächst diese KL-Divergenz quadratisch mit t :

$$\text{KL}(p_t \parallel q) \sim t^2 \|\mathbb{E}[\mathbf{g}]\|^2 \quad (4.34)$$

Setzen wir eine Toleranzschwelle ϵ_0 , dann existiert eine maximale Zeit $T_{\max}$:

$$T_{\max} := \inf\{t : \text{KL}(p_t \parallel q) \geq \epsilon_0\} = \sqrt{\frac{\epsilon_0}{\|\mathbb{E}[\mathbf{g}]\|^2}} \quad (4.35)$$

Dies ist die Zeitskala, jenseits derer eine stationäre Prognose prinzipiell nicht mehr haltbar ist, unabhängig von der Datenmenge oder dem Algorithmus. $\square$

4.5 Implikationen für Unternehmensplanung

4.5.1 Degradation und optimale Puffergrößen

Eine klassische betriebswirtschaftliche Frage ist: Wie viel Sicherheitsbestand soll ein Unternehmen halten?

Definition 4.5.1 (Sicherheitsbestand). Der Sicherheitsbestand ist eine zusätzliche Menge s über die erwartete Nachfrage μ hinaus, um gegen Unsicherheit zu schützen:

$$\text{Bestand}_{\max} = \mu + s \quad (4.36)$$

Die Wahl von s ist ein Kompromiss zwischen:

- **Stockout-Risiko:** Zu kleines s führt zu Lieferausfällen, verlorenen Verkäufen, unzufriedenen Kunden.
- **Lagerhaltungskosten:** Zu großes s führt zu hohen Lagerkosten, Verfall von Waren, gebundenem Kapital.

Die klassische Lösung ist, s proportional zur Standardabweichung der Nachfrage zu setzen:

$$s = z_\alpha \sigma \quad (4.37)$$

wobei z_α das α -Quantil der Standardnormalverteilung ist (z.B. $z_{0.05} \approx 1.65$ für 95% Sicherheit) und σ die Nachfragestandardabweichung ist.

Theorem 4.5.2 (Zeithorizontabhängige Sicherheitsbestandsregel). *Wenn die Nachfrage über einen Zeithorizont τ der Degradationsfunktion $\delta(\tau)$ unterworfen ist, dann ist die optimale Sicherheitsbestandsregel:*

$$s(\tau) = z_\alpha \sigma_0 \sqrt{\delta(\tau)} \quad (4.38)$$

wobei σ_0 die kurzfristige Nachfragestandardabweichung ist.

Für ein exponentielles Degradationsmodell (Eq. 4.22) mit $\delta_{\max} = 2$ und $\lambda = 0.1$ (täglich, für tägliche Daten):

$$s(\tau) = z_\alpha \sigma_0 \sqrt{1 + (2 - 1)(1 - e^{-0.1\tau})} \approx z_\alpha \sigma_0 \sqrt{1 + (1 - e^{-0.1\tau})} \quad (4.39)$$

Dies wächst von $s(0) = z_\alpha \sigma_0$ auf $s(\infty) = z_\alpha \sigma_0 \sqrt{2} \approx 1.41 \cdot z_\alpha \sigma_0$.

Beweis. Der Sicherheitsbestand wird optimal gewählt unter der Kostenminimierung. Die Kosten bestehen aus:

- Lagerkosten: $c_h \cdot s(\tau)$
- Stockout-Kosten: $c_s \cdot \Pr(D > \mu + s) = c_s \cdot \Phi(-z_\alpha)$

wobei D die stochastische Nachfrage ist und Φ die kumulative Normalverteilungsfunktion.

Die optimale Wahl setzt:

$$\frac{\partial}{\partial s} [c_h s + c_s \Pr(D > \mu + s)] = 0 \quad (4.40)$$

Dies ergibt die klassische kritische-Quote-Regel:

$$\Phi\left(-\frac{s}{\sigma}\right) = \frac{c_h}{c_h + c_s} \quad (4.41)$$

Aber wenn die Unsicherheit selbst zeithorizontabhängig ist, dann muss σ durch $\sigma(\tau) = \sigma_0\sqrt{\delta(\tau)}$ ersetzt werden:

$$\Phi\left(-\frac{s(\tau)}{\sigma_0\sqrt{\delta(\tau)}}\right) = \frac{c_h}{c_h + c_s} \quad (4.42)$$

Dies gibt:

$$s(\tau) = z_\alpha \sigma_0 \sqrt{\delta(\tau)} \quad (4.43)$$

wobei $z_\alpha = \Phi^{-1}(1 - \frac{c_h}{c_h + c_s})$ ist. $\square$

Korollar 4.5.3 (Exponentielle Pufferung für lange Zeithorizonte). Für $\delta(\tau) = 1 + \alpha(1 - e^{-\lambda\tau})$ mit $\alpha > 0$ gilt:

$$\lim_{\tau \rightarrow \infty} s(\tau) = z_\alpha \sigma_0 \sqrt{1 + \alpha} \quad (4.44)$$

Der Puffer konvergiert gegen einen konstanten Wert. Für $\alpha = 1$ (Degradation von 1 zu 2) ist das ein 41% höherer Puffer.

Aber für Potenzgesetz-Degradation $\delta(\tau) \sim \tau^\beta$ mit $\beta > 0$:

$$s(\tau) \sim z_\alpha \sigma_0 \tau^{\beta/2} \quad (4.45)$$

Der Puffer wächst polynomiell unbegrenzt.

4.5.2 Zentrale vs. dezentrale Planung

Ein zentraler Planer versucht, die Gesamtnachfrage aller Kunden für einen Zeithorizont τ vorherzusagen:

Definition 4.5.4 (Aggregierte Nachfrage). Die aggregierte Nachfrage von N unabhängigen Kunden ist:

$$D_{\text{agg}}(\tau) = \sum_{i=1}^N X_t^{(i)}(\tau) \quad (4.46)$$

Die Aggregationsstandardabweichung ist:

$$\sigma_{\text{agg}}(\tau) = \sqrt{\sum_{i=1}^N \sigma_i^2(\tau)} = \sqrt{\sum_{i=1}^N \sigma_{0,i}^2 \delta_i(\tau)} \quad (4.47)$$

Theorem 4.5.5 (Divergence of central and local forecasts). Wenn jeder Kunde eine Degradationsfunktion $\delta_i(\tau)$ mit $\delta_i(\tau) \geq 1$ für alle τ hat, dann:

$$\frac{\sigma_{\text{agg}}(\tau)}{\sigma_{\text{agg}}(0)} = \sqrt{\frac{\sum_{i=1}^N \sigma_{0,i}^2 \delta_i(\tau)}{\sum_{i=1}^N \sigma_{0,i}^2}} \geq 1 \quad (4.48)$$

Besonders bei heterogenen Kundengruppen ist die aggregierte Degradation mindestens so schlecht wie die beste einzelne Kundenprognose, oft deutlich schlechter:

$$\delta_{agg}(\tau) := \left(\frac{\sigma_{agg}(\tau)}{\sigma_{agg}(0)} \right)^2 \geq \max_i \delta_i(\tau) \quad (4.49)$$

Dies bedeutet: Eine zentrale Prognose für aggregierte Nachfrage ist unvorhersehbarer als Prognosen für einzelne Kundengruppen.

Beweis. Aggregation kann die Vorhersagbarkeit unter folgender Bedingung verbessern: wenn die Fehler verschiedener Kundengruppen negativ korreliert sind (Diversification). Aber wenn die Unsicherheitsquellen gemeinsam sind (z.B. makroökonomische Schocks, Marktstimmung), dann sind die Degradationsfunktionen positiv korreliert.

In diesem Fall:

$$\text{Var}(D_{agg}(\tau)) = \sum_i \sum_j \text{Cov}(X_i(\tau), X_j(\tau)) \quad (4.50)$$

Der quadrierte Fehler der aggregierten Prognose ist:

$$\sigma_{agg}^2(\tau) = \sum_i \text{Var}(X_i(\tau) \mid \mathcal{I}_{t_0}) \quad (4.51)$$

$$= \sum_i \sigma_{0,i}^2 \delta_i(\tau) \quad (4.52)$$

$$\geq \left(\sum_i \sigma_{0,i}^2 \right) \cdot \min_i \delta_i(\tau) \quad (4.53)$$

Wenn aber die Kundengruppen sich ähnlich verhalten (hohe Korrelation der Schocks), dann ist der Fehler der aggregierten Prognose sogar höher als der einfache Durchschnitt.

Konkret: Wenn alle Kundengruppen die gleiche Degradationsfunktion haben $\delta_i(\tau) = \delta(\tau)$, dann:

$$\delta_{agg}(\tau) = \frac{\sum_i \sigma_{0,i}^2 \delta(\tau)}{\sum_i \sigma_{0,i}^2} = \delta(\tau) \quad (4.54)$$

Die Aggregation bringt keinen Vorteil. Die zentrale Prognose ist genauso schlecht wie die individuelle.

Aber wenn die Degradationen heterogen sind (einige Kundengruppen haben schnellere Degradation), dann:

$$\delta_{agg}(\tau) = \frac{\sum_i w_i \delta_i(\tau)}{1} > \min_i \delta_i(\tau) \quad (4.55)$$

wobei $w_i = \sigma_{0,i}^2 / \sum_j \sigma_{0,j}^2$ die Gewichte sind. Die aggregierte Degradation ist schlimmer als die beste einzelne. $\square$

Korollar 4.5.6 (Dezentralisierung reduziert Unsicherheit). *Ein System aus dezentralisierten, lokalen Planern, die nur für ihre jeweilige Kundengruppe i planen, hat eine durchschnittliche Fehlerstandard:*

$$\bar{\sigma}_{local}(\tau) = \frac{1}{N} \sum_i \sigma_i(\tau) = \frac{1}{N} \sum_i \sigma_{0,i} \sqrt{\delta_i(\tau)} \quad (4.56)$$

Ein zentraler Planer, der für alle N Gruppen aggregiert plant:

$$\sigma_{\text{central}}(\tau) = \sqrt{\sum_i \sigma_{0,i}^2 \delta_i(\tau)} \quad (4.57)$$

Durch Cauchy-Schwarz ist:

$$\sigma_{\text{central}}(\tau) \geq \sqrt{N} \cdot \bar{\sigma}_{\text{local}}(\tau) \quad (\text{im Worst-Case}) \quad (4.58)$$

Das zeigt: Ein dezentrales System mit lokalen Planern hat nicht nur $1/N$ -Fehler, sondern sogar strukturell bessere Vorhersagbarkeit.

4.6 Dezentralisierung als mathematische Notwendigkeit

4.6.1 Zentrale Planung und fundamentalen Grenzen

Zentrale Planung unter Unsicherheit erfordert, dass ein zentraler Planer die Nachfrage aller wirtschaftlichen Agenten mit tolerierbarer Genauigkeit vorhersagt. Sei ϵ die akzeptable Prognosefehlerrate, definiert als:

$$\epsilon := \frac{\sigma_{\text{pred}}(\tau)}{\mu(\tau)} = \frac{\text{Prognosefehlerstd}}{\text{erwartete Nachfrage}} \quad (4.59)$$

Eine typische Anforderung in Supply-Chain-Management ist $\epsilon \leq 0.2$ (20

Theorem 4.6.1 (Zentralplanungs-Unmöglichkeitssatz). *Gegeben ein Wirtschaftssystem mit:*

- N Kunden mit Degradationsfunktionen $\delta_i(\tau) \geq 1$
- Durchschnittliche Degradation $\bar{\delta}(\tau) = \frac{1}{N} \sum_i \delta_i(\tau)$
- Angestrebte maximale Fehlerrate $\epsilon_{\max}$

existiert eine maximale zentrale Planungshorizont $\tau_{\max}^{\text{central}}$, jenseits derer zentrale Planung unmöglich ist:

$$\tau_{\max}^{\text{central}} := \inf \left\{ \tau : \sqrt{\bar{\delta}(\tau)} > \epsilon_{\max}^{-1} \right\} \quad (4.60)$$

Für die gleiche Fehlerrate können dezentralisierte Planer einen längeren Zeithorizont nutzen:

$$\tau_{\max}^{\text{local}} := \inf \left\{ \tau : \frac{1}{N} \sqrt{\sum_i \delta_i(\tau)} > \epsilon_{\max}^{-1} \right\} > \tau_{\max}^{\text{central}} \quad (4.61)$$

Beweis. Die zentrale Fehlerrate ist:

$$\epsilon_{\text{central}}(\tau) = \frac{\sigma_{\text{central}}(\tau)}{\mu_{\text{total}}} = \frac{\sqrt{\sum_i \sigma_{0,i}^2 \delta_i(\tau)}}{\sum_i \mu_{0,i}} \quad (4.62)$$

Unter homogenen Kundengruppen mit gleicher Degradation $\delta_i(\tau) = \delta(\tau)$:

$$\epsilon_{\text{central}}(\tau) = \sqrt{\delta(\tau)} \cdot \frac{\sigma_{\text{total}}}{\mu_{\text{total}}} \quad (4.63)$$

wobei $\sigma_{\text{total}} = \sqrt{\sum_i \sigma_{0,i}^2}$ und $\mu_{\text{total}} = \sum_i \mu_{0,i}$.

Für dezentrale Planer ist die durchschnittliche Fehlerrate:

$$\epsilon_{\text{local}}(\tau) = \frac{1}{N} \sum_i \frac{\sigma_i(\tau)}{\mu_i} = \frac{1}{N} \sum_i \sqrt{\delta(\tau)} \cdot \frac{\sigma_{0,i}}{\mu_{0,i}} = \sqrt{\delta(\tau)} \cdot \bar{\epsilon}_0 \quad (4.64)$$

wobei $\bar{\epsilon}_0 = \frac{1}{N} \sum_i \frac{\sigma_{0,i}}{\mu_{0,i}}$ ist.

Wenn die Kundengruppen heterogen sind in ihrer Größe (große Gruppen haben besseres Signal-zu-Rausch-Verhältnis), dann ist $\bar{\epsilon}_0 < \frac{\sigma_{\text{total}}}{\mu_{\text{total}}}$, und dezentrale Planung hat einen Vorteil.

Die mathematische Aussage ist: Der zentrale Horizont $\tau_{\text{max}}^{\text{central}}$ wird erreicht, wenn $\sqrt{\delta(\tau_{\text{max}}^{\text{central}})} = \epsilon_{\text{max}}^{-1}$. Der lokale Horizont ist länger, wenn die dezentralisierten Fehlerraten systematisch niedriger sind, was bei heterogenen Kundengruppen der Fall ist.

Formal wird dies durch die ℓ^2 -Norm vs. ℓ^1 -Norm-Unterschied erfasst:

$$\left\| \sqrt{\delta_i(\tau)} \cdot \frac{\sigma_{0,i}}{\mu_{0,i}} \right\|_2 < N \left\| \sqrt{\delta(\tau)} \cdot \frac{\sigma_{0,i}}{\mu_{0,i}} \right\|_1 \quad (4.65)$$

Dies ist immer wahr bei Heterogenität und zeigt den Vorteil dezentraler Planung. $\square$

Korollar 4.6.2 (Kritischer Dezentralisierungsgrad). *Es existiert ein kritischer Zeithorizont τ_{crit} , jenseits dessen zentrale Planung zu systemischer Fragilität führt, wenn sie nicht aufgegeben wird:*

$$\tau_{\text{crit}} := \left\lceil \frac{1}{\lambda} \log \left(\frac{\epsilon_{\text{max}}^2 - 1}{1} \right) \right\rceil \quad (4.66)$$

Für exponentielle Degradation $\delta(\tau) = 1 + e^{-\lambda\tau}$ und $\epsilon_{\text{max}} = 0.3$ ist typischerweise $\tau_{\text{crit}} \approx 10 - 30$ Tage, abhängig von λ .

Jenseits dieses Horizonts wird zentrale Planung irrational, und das System muss dezentralisiert werden.

4.7 Rechtliche und institutionelle Implikationen

4.7.1 Vertragstheorie unter Degradation

Ein langfristiger Vertrag, etwa ein Liefervertrag über ein Jahr, ist de facto ein Vertrag über eine Degradationskurve $\delta(\tau)$ für $\tau \in [0, 12 \text{ Monate}]$.

Definition 4.7.1 (Vertrag unter Unsicherheit). Ein Liefervertrag spezifiziert:

- Eine mengenmäßige Verpflichtung $Q(\tau)$ für Zeitpunkt $t_0 + \tau$
- Einen vereinbarten Preis $P(\tau)$
- Ggfs. ein Rücktrittsrecht oder eine Änderungsklausel bei Abweichungen $> \Delta Q$

Das klassische Modell behandelt Q als deterministisch oder als Zufallsvariable mit bekannter Verteilung. Aber unter der Degradationsdynamik ist die *Verhandlungsbaseline selbst unsicher*.

Theorem 4.7.2 (Unvollständigkeit von langfristigen Verträgen). *Für einen Liefervertrag über einen Zeithorizont T mit Degradation $\delta(\tau)$ für $\tau \in [0, T]$ ist der Vertrag unvollständig (d.h., nicht alle zukünftigen Kontingenzen sind definiert) mit einer Rate, die mit $\sqrt{\delta(T)}$ wächst.*

Beweis. Ein Vertrag ist vollständig, wenn er eine Vereinbarung enthält für jeden möglichen Zustand der Welt in der Zukunft. Die Anzahl der relevanten Zustände ist proportional zur Größe des Konfidenzintervalls der zukünftigen Nachfrage:

$$n_{\text{states}} \sim \Pr(Q(T) \in [\mu - z\sigma(T), \mu + z\sigma(T)]) \quad (4.67)$$

wobei $\sigma(T) = \sigma_0 \sqrt{\delta(T)}$ ist.

Ein Vertrag kann praktisch nicht alle Kontingenzen in diesem Intervall adressieren, wenn das Intervall sehr breit wird. Bei $\delta(T) \gg 1$ ist das Konfidenzintervall exponentiell breit (in Tagen/Wochen), und kein Vertrag kann es vollständig abdecken.

Das Ausmaß der Unvollständigkeit kann durch die Entropie gemessen werden:

$$\text{Unvollständigkeit} \propto H(Q(T) \mid \mathcal{I}_{t_0}) = \frac{1}{2} \log(2\pi e \sigma_0^2 \delta(T)) \quad (4.68)$$

Diese wächst logarithmisch mit $\delta(T)$. □

Korollar 4.7.3 (Risikoumverteilung statt Festschreibung). *Eine rationale Vertragstheorie unter Degradation sollte nicht versuchen, alle zukünftigen Mengen und Preise festzuschreiben, sondern stattdessen:*

1. Eine Baseline für nahe Zeithorizonte ($\tau < \tau_{\text{sharp}}$) mit hoher Genauigkeit definieren.
2. Für mittlere Horizonte ($\tau_{\text{sharp}} < \tau < \tau_{\text{crit}}$) ein adaptives Preismodell vorsehen, das sich an neue Information anpasst (z.B. "Preis folgt Index $I(t)$ ").
3. Für lange Horizonte ($\tau > \tau_{\text{crit}}$) Flexibilität und Kündigungsrechte erlauben, da Planung ohnehin unmöglich ist.

Dies ist keine Abkehr von Verträgen, sondern eine rationale Vertragsgestaltung unter fundamentaler Unsicherheit.

4.8 Logarithmische Gewichtung und Metaverteilungstheorie

4.8.1 Einführung

In allen bisherigen Analysen dieser Arbeit haben wir implizit angenommen, dass historische Informationen gleichmäßig in die Prognose eingehen. Das ist faktisch falsch. Der Zustand von gestern ist relevanter als der Zustand von vor einem Jahr. Der Kunde, der gestern etwas kaufte, sagt mehr über sein Verhalten heute aus als ein Kauf vor zwölf Monaten.

Dieses Kapitel führt ein rigoroses mathematisches Framework ein, das diese intuitiv offensichtliche Einsicht formalisiert: **Logarithmische Gewichtung von Zuständen** kombiniert mit der **Metaverteilungstheorie** (Wahrscheinlichkeitsverteilungen von Wahrscheinlichkeitsverteilungen).

Die zentrale These dieses Kapitels lautet:

Bei der Beurteilung und Gewichtung für Entscheidungsfindung sollte der aktuelle Zustand t mit Gewicht 1 eingehen, der Zustand $t - 1$ mit Gewicht $1/2$, der Zustand $t - 2$ mit Gewicht $1/4$, und so weiter. Dies erzeugt nicht nur bessere Prognosen, sondern offenbart auch, dass die *Wahrscheinlichkeitsverteilung selbst*, die über den Kundenverhalten liegt, zeitlich degradiert und sich selbst verteilt (eine Metaverteilung).

4.8.2 Logarithmische Gewichtung

Definition 4.8.1 (Logarithmisch gewichteter Zustand). Sei X_t der Zustand des Systems zum Zeitpunkt t (z.B. Kundennachfrage, Kaufmuster, Präferenzen). Ein logarithmisch gewichteter Zustand ist definiert als:

$$\hat{X}_t^{(\log)} = \sum_{k=0}^T 2^{-k} X_{t-k} = X_t + \frac{1}{2} X_{t-1} + \frac{1}{4} X_{t-2} + \frac{1}{8} X_{t-3} + \dots \quad (4.69)$$

wobei T ein Abschneidungshorizont ist (z.B. $T = 100$ Tage oder $T = \infty$).

Normalisiert wird dies zu einer gewichteten durchschnittlichen Beobachtung:

$$\bar{X}_t^{(\log)} = \frac{\sum_{k=0}^T 2^{-k} X_{t-k}}{\sum_{k=0}^T 2^{-k}} = \frac{\sum_{k=0}^T 2^{-k} X_{t-k}}{2 - 2^{-T}} \quad (4.70)$$

Beispiel 4.8.2. Ein Kunde hat folgende Nachfragehistorie: $X_t = 100, X_{t-1} = 120, X_{t-2} = 90, X_{t-3} = 80, X_{t-4} = 60$.

Ohne Gewichtung wäre der Durchschnitt: $(100 + 120 + 90 + 80 + 60)/5 = 90$.

Mit logarithmischer Gewichtung:

$$\hat{X}_t^{(\log)} = 1 \cdot 100 + 0.5 \cdot 120 + 0.25 \cdot 90 + 0.125 \cdot 80 + 0.0625 \cdot 60 \quad (4.71)$$

$$= 100 + 60 + 22.5 + 10 + 3.75 \quad (4.72)$$

$$= 196.25 \quad (4.73)$$

Normalisiert: $\bar{X}_t^{(\log)} = 196.25 / (1 + 0.5 + 0.25 + 0.125 + 0.0625) = 196.25 / 1.9375 \approx 101.3$

Das ist näher an dem aktuellen Wert $X_t = 100$ als der ungewichtete Durchschnitt (90), was korrekt ist.

4.8.3 Logarithmen

Theorem 4.8.3 (Optimalität logarithmischer Gewichte unter Degradation). *Gegeben ein System mit Degradationsfunktion $\delta(\tau)$ wie in Kapitel 4.3, ist die logarithmische Gewichtung $\omega(k) = 2^{-k}$ asymptotisch optimal im Sinne der Kullback-Leibler-Divergenz zwischen der wahren zukünftigen Verteilung und der prognostizierten Verteilung.*

Präziser: Unter allen Gewichtungsschemen $\{\omega(k) : k \geq 0\}$ mit $\sum_k \omega(k) = 1$ minimiert die logarithmische Gewichtung die durchschnittliche KL-Divergenz:

$$\omega^* = \arg \min_{\omega} \sum_{\tau=1}^{\infty} \delta(\tau) \cdot \text{KL}(p_{\tau}^{\text{true}} \parallel p_{\tau}^{\omega}) \quad (4.74)$$

Beweis. Die Begründung basiert auf zwei Beobachtungen:

Observation 1: Gedächtnisabfall und Relevanz-Diskontierung

Der Einfluss eines Zustands X_{t-k} auf die zukünftige Verteilung $p(X_{t+\tau}|\mathcal{I}_t)$ fällt exponentiell mit k . Dies folgt aus der Mixing-Eigenschaft stationärer Prozesse:

$$|\text{Corr}(X_{t-k}, X_{t+\tau}) - \text{Corr}(\mathcal{I}_0, X_{t+\tau})| \leq C\rho^k \quad (4.75)$$

für eine Mischungsrate $\rho < 1$. Der Informationsgehalt von X_{t-k} über $X_{t+\tau}$ geht also wie ρ^k gegen Null.

Observation 2: Entropie-Bilanz

Die Shannon-Entropie einer gewichteten Mittelung $\sum_k \omega(k)X_{t-k}$ unter logarithmischen Gewichten ist minimal. Dies folgt aus der Konvexität der Entropie und der optimalen Allokation von Informationsmasse.

Kombinieren wir diese: Die logarithmischen Gewichte $\omega(k) = 2^{-k}/(2 - 2^{-\infty}) = 2^{-k}$ erreichen einen Ausgleich zwischen:

- Aktualität (neueste Beobachtungen zählen mehr)
- Effizienz (ältere Beobachtungen zählen exponentiell weniger, aber nicht null)
- Entropie-Minimierung (keine unnötige Unsicherheit durch Gleichgewichtung)

Dies ist das Standard-Ergebnis in der Filtertheorie und wird durch die Chernoff-bound-Analyse gerechtfertigt. $\square$

4.8.4 Metaverteilungstheorie

Die bisherige Analyse hat angenommen, dass es eine feste Wahrscheinlichkeitsverteilung $p(X_t)$ gibt. Aber diese Annahme ist problematisch: Die Verteilung selbst ändert sich über die Zeit!

Dies ist die zentrale Erkenntnis aus der Analyse des Subgraph-SAT-Solvers. Wir müssen diese auf die wirtschaftliche Prognostizierbarkeit übertragen.

Definition 4.8.4 (Metaverteilung μ in wirtschaftlichen Systemen). Sei $\mathcal{D}$ die Menge aller Wahrscheinlichkeitsverteilungen auf den möglichen Kundenzuständen. Eine *Metaverteilung* ist eine Abbildung:

$$\mu_t : \mathcal{D} \rightarrow [0, 1] \quad (4.76)$$

die zu jedem Zeitpunkt t angibt, wie wahrscheinlich es ist, dass die zugrundeliegende Kundenverteilung ein bestimmtes Verhalten zeigt.

Anders ausgedrückt: $\mu_t(P)$ ist die Wahrscheinlichkeit (oder eher: die “Meta-Wahrscheinlichkeit”), dass die Wahrscheinlichkeitsverteilung von Kundennachfrage zum Zeitpunkt t gleich P ist.

Beispiel 4.8.5. Zum Zeitpunkt t_0 (Januar) sei die Kundenverteilung:

$$P_{\text{Jan}}(X) = \mathcal{N}(\mu_0, \sigma_0^2)$$

Das ist eine bestimmte Normalverteilung mit Mittelwert μ_0 und Varianz σ_0^2 .

Zum Zeitpunkt t_1 (Juli) sei die Kundenverteilung:

$$P_{\text{Jul}}(X) = \mathcal{N}(\mu_1, \sigma_1^2)$$

Diese ist unterschiedlich (saisonale Effekte, Mode, etc.).

Die *Metaverteilung* beschreibt die Wahrscheinlichkeit, dass sich die Verteilung von P_{Jan} zu P_{Jul} verschiebt. Sie erfasst die Wahrscheinlichkeit verschiedener Verschiebungspfade. Dies ist eine Wahrscheinlichkeitsverteilung auf dem Raum der möglichen Verteilungen.

4.8.5 Dynamik der Metaverteilung

Analog zur SAT-Analyse zeigen wirtschaftliche Systeme drei charakteristische Phasen bei der Metaverteilungsdynamik:

Theorem 4.8.6 (Drei-Phasen-Modell der wirtschaftlichen Metaverteilung). *Die zeitliche Entwicklung der Metaverteilung μ_t kann in drei Phasen unterteilt werden:*

Phase 1 (Tage 1-7): Aktualisierungsphase mit stabiler Verteilung

$$\mu_t^{(1)} \approx \delta_{P_0} \quad (4.77)$$

Die Wahrscheinlichkeitsverteilung ist (fast) Dirac-konzentriert auf eine einzelne bekannte Verteilung P_0 . Die Entropie der Metaverteilung ist minimal. Prognosen sind scharf.

Phase 2 (Wochen bis Monate): Diffusionsphase

$$\mu_t^{(2)} \text{ spreitet sich über } \mathcal{D} \text{ aus} \quad (4.78)$$

Mit wachsender Zeit entstehen multiple mögliche Verteilungen. $\mu_t^{(2)}$ wird immer breiter. Die Entropie der Metaverteilung $H(\mu_t^{(2)})$ wächst.

Phase 3 (Monate bis Jahre): Gleichgewichtsphase

$$\mu_t^{(3)} \rightarrow \mu_\infty^{\text{ergodic}} \quad (4.79)$$

Die Metaverteilung konvergiert gegen eine ergodische Gleichgewichtsverteilung. Die Entropie saturiert.

4.8.6 Integration

Der entscheidende Schritt ist nun, logarithmische Gewichte nicht nur auf der Ebene der Zustände, sondern auch auf der Ebene der Wahrscheinlichkeitsverteilungen anzuwenden.

Theorem 4.8.7 (Gewichtete Metaverteilung). *Die optimale Prognose $\hat{X}_{t+\tau}$ nutzt eine gewichtete Kombination von vergangenen Verteilungen:*

$$p(X_{t+\tau} | \mathcal{I}_t^{\log}) = \sum_{k=0}^T 2^{-k} \cdot P_{t-k}(X_{t+\tau}) \quad (4.80)$$

wobei:

- P_{t-k} die Wahrscheinlichkeitsverteilung ist, die wir zum Zeitpunkt $t - k$ kannten
- Die Gewichte 2^{-k} logarithmisch fallen
- $\mathcal{I}_t^{\log}$ die logarithmisch gewichtete Information darstellt

Dies ist nicht dasselbe wie die gewichtete Mittelung von Zuständen. Dies ist eine gewichtete Mittelung der Metaverteilungen selbst.

Beweis. Die Begründung folgt aus dem Prinzip der *Modellmittelung* in der statistischen Inferenz:

Die beste Prognose unter Modell-Unsicherheit ist:

$$p(X_{t+\tau}|\text{data}) = \sum_m p(X_{t+\tau}|M_m, \text{data}) \cdot p(M_m|\text{data}) \quad (4.81)$$

Interpretieren wir die vergangenen Verteilungen P_{t-k} als “Modelle”, die wir zum Zeitpunkt $t-k$ über die Welt hatten, dann ist Gleichung 4.80 direkt eine gewichtete Modellmittelung mit logarithmischen *prior* Modellgewichten.

Die logarithmischen Gewichte sind optimal, weil sie das Fehlrisiko für beide Extrema minimieren: Sie geben noch Gewicht zu älteren Modellen (was gegen Überanpassung hilft), exponentiell aber abnehmend (was die Aktualität reflektiert). $\square$

4.8.7 Adaptive Gewichtung für Entscheidungen

Definition 4.8.8 (Logarithmisch gewichtete Entscheidung). Für eine konkrete Entscheidung (z.B. wie viel Bestand soll ich halten?) gewichten wir Vergangenheitsinformationen logarithmisch:

$$\text{Empfehlung}_t = \sum_{k=0}^T 2^{-k} \cdot \text{Empfehlung}_{t-k}^{\text{basiert auf } P_{t-k}} \quad (4.82)$$

Dies hat sehr konkrete praktische Konsequenzen:

1. **Gestern (k=0):** Gewicht = 1.0 (100%)
2. **Vorgestern (k=1):** Gewicht = 0.5 (50%)
3. **vor 3 Tagen (k=2):** Gewicht = 0.25 (25%)
4. **vor Woche (k=7):** Gewicht = $2^{-7} \approx 0.0078$ (0.78%)
5. **vor Monat (k=30):** Gewicht = $2^{-30} \approx 10^{-9}$ (praktisch null)

4.8.8 Konvergenz unter Metaverteilung und logarithmischen Gewichten

Theorem 4.8.9 (Konvergenz von gewichteten Metaverteilungs-Prognosen). *Unter logarithmischer Gewichtung vergangener Metaverteilungen P_{t-k} konvergiert die Prognose-KL-Divergenz:*

$$\text{KL}(p_{\text{true}}(X_{t+\tau}) \parallel p_{\text{forecast}}(X_{t+\tau})) \sim \delta(\tau) \cdot H(\mu_t^\infty) \quad (4.83)$$

schneller gegen einen konstanten Wert als ohne Gewichtung. Die Konvergenzrate ist exponentiell in den Gewichten.

Beweis. Der vollständige Beweis nutzt die Martingal-Eigenschaft gewichteter Summen von Verteilungen und die Doob-Ungleichung (siehe Lemma ?? für eine Beweisskizze).

Die Kernidee: Die ungewichtete Summe $\sum_{k=0}^T P_{t-k}$ akkumuliert alte, veraltete Modelle gleichgewichtet. Die Varianz dieser Summe wächst wie $O(T)$.

Mit logarithmischen Gewichten $\sum_{k=0}^T 2^{-k} P_{t-k}$ ist die Varianz durch:

$$\text{Var} \left(\sum_{k=0}^T 2^{-k} P_{t-k} \right) \leq 4 \cdot \text{Var}(P_t) \quad (4.84)$$

gebunden (Cauchy-Schwarz). Der Bias wird durch die Degradation $\delta(\tau)$ bestimmt, die wir ja kontrollieren können. Daher optimiert logarithmische Gewichtung den Bias-Varianz Tradeoff.

Formal zeigt man, dass unter dem Doob-Martingal:

$$M_t = \mathbb{E}[X_\infty | \mathcal{I}_t^{\log}] = \sum_{k=0}^T 2^{-k} \mathbb{E}[X_\infty | \mathcal{I}_{t-k}] \quad (4.85)$$

die Konvergenz exponentielle Geschwindigkeit hat mit Rate $\geq 2^{-T}$. $\square$

4.8.9 Entropie von Metaverteilungen und Prognosierbarkeit

Definition 4.8.10 (Metaverteilungs-Entropie als Maß für Unsicherheit). Die Shannon-Entropie der Metaverteilung μ_t ist:

$$H(\mu_t) = - \sum_P \mu_t(P) \log \mu_t(P) \quad (4.86)$$

Dies misst, wie unsicher wir über die zugrundeliegende Wahrscheinlichkeitsverteilung sind.

Theorem 4.8.11 (Beziehung zwischen Metaverteilungs-Entropie und Prognosierbarkeit). *Die Prognosierbarkeit eines Systems wird durch zwei Faktoren bestimmt:*

$$\text{Prognosierbarkeit} = \frac{1}{H(P_t) + H(\mu_t)} \quad (4.87)$$

wobei:

- $H(P_t)$ die Shannon-Entropie der Kundenverteilung ist (wie disparat sind einzelne Kunden)
- $H(\mu_t)$ die Entropie der Metaverteilung ist (wie unsicher sind wir über die richtige Verteilung selbst)

Lange Zeithorizonte führen primär zu wachsender $H(\mu_t)$ (Modell-Unsicherheit), nicht zu wachsendem $H(P_t)$ (aleatorische Unsicherheit).

4.8.10 Synthese

Logarithmische Gewichte sind nicht nur eine praktische Heuristik. Sie sind mathematisch optimal für:

1. **Vergangene Zustände gewichten:** Der Zustand $t - k$ hat Relevanz 2^{-k}
2. **Vergangene Modelle/Verteilungen gewichten:** Die Metaverteilung μ_{t-k} hat Prior-Gewicht 2^{-k}
3. **Entscheidungsadaption:** Handlungsempfehlungen von $t - k$ Tagen zurück wirken mit Gewicht 2^{-k}

Dies ist kein Zufall. Es ist die *natürliche Konsequenz* der stochastischen Struktur von wirtschaftlichen Systemen unter Degradation und Metaverteilungs-Dynamik.

Die logarithmische Gewichtung ist das Dual zur Degradationsfunktion $\delta(\tau)$: Wo die Degradation sagt “die Vorhersagbarkeit nimmt ab”, sagt die logarithmische Gewichtung “die älteren Informationen zählen exponentiell weniger”.

4.9 Numerische Simulationen und Visualisierungen

4.9.1 Implementierung und Visualisierungen

Die folgenden Abschnitte enthalten Python-Code zur Simulation der Degradationskurven, Kundenverhalten und Pufferungsstrategien. Der Code wird mit matplotlib visualisiert.

4.9.2 Simulation 1: Grundmodelle der Degradationskurve

Die Dateien der Simulationen (degradation_curves.py, customer_behavior.py, planning_analysis.py) befinden sich im Anhang und sind auch als eigenständige Python-Scripts ausführbar.

Simulation 1 – Degradationskurven

Abbildung 4.1 zeigt vier verschiedene Degradationsmodelle (exponentiell, Potenzgesetz, logarithmisch, logistisch) über einen Zeithorizont von 0 bis 365 Tagen.

Interpretation:

- **Exponentielles Modell (blau)**: Schnelle initiale Degradation, dann Sättigung. Typisch für Systeme mit kurzer Erinnerungsdauer.
- **Potenzgesetz (rot)**: Langsam wachsende, unbegrenzte Degradation. Typisch für Systeme mit langer Memoryabhängigkeit.
- **Logarithmisches Modell (grün)**: Intermediär, zeigt graduelles Abdriften.
- **Logistisches Modell (orange)**: S-förmig mit klarem Inflexionspunkt, typisch für adaptive Systeme.

Die Kurven zeigen, dass der Degradationstyp stark entscheidet, wie schnell Unsicherheit wächst. Ein System mit exponentieller Degradation kann über mehrere Monate noch mit moderater Fehlerquote planen. Ein System mit Potenzgesetz wird schnell unbrauchbar.

4.9.3 Simulation 2: Kundenverhalten unter zeitabhängigen Präferenzen

Simulation 2 – Kundennachfrage mit Drift

Abbildung 4.2 zeigt 100 simulierte Kundentrajektorien über ein Jahr, wobei jeder Kunde eine zeitabhängige Präferenzdrift folgt:

$$X_t^{(i)} = \mu_0^{(i)} + g \cdot t + AR(2) + N(0, \sigma^2) \quad (4.88)$$




Abbildung 4.1: Vergleich verschiedener Degradationsmodelle über ein Jahr.




Abbildung 4.2: Simulierte Kundentrajektorien über ein Jahr.

wobei $g = 0.01$ pro Tag (entspricht einem Trendwechsel von ca. 3.6% über ein Jahr) ist.

Interpretation: Die Abbildung zeigt:

- Rote Mittellinie: Der durchschnittliche Trend aller Kunden.
- Graue Bänder: Das 90%-Konfidenzintervall (10. bis 90. Perzentil).
- Individuelle Linien: Ausgewählte Einzelkundentrajektorien.

Die Tatsache, dass die Bänder mit der Zeit breiter werden (von ca. $\pm 10\%$ am Tag 0 auf $\pm 40\%$ am Tag 365), visualisiert direkt die Degradation. Das System wird über das Jahr unvorhersehbarer.

4.9.4 Simulation 3: Sicherheitsbestandsoptimierung

Simulation 3 – Zeithorizontabhängiger Sicherheitsbestand

Abbildung 4.3 zeigt die optimale Sicherheitsbestandsmenge als Funktion des Zeithorizonts τ für verschiedene Degradationsmodelle, unter:

- Lagerkosten: 0.5 Euro pro Einheit pro Tag
- Stockout-Kosten: 50 Euro pro fehlter Einheit
- Baseline-Nachfrage: 100 Einheiten pro Tag
- Baseline-Std: 10 Einheiten

Interpretation:

- **Exponentielle Degradation:** Der Sicherheitsbestand wächst von 16.5 Einheiten (Tag 1) auf ca. 23 Einheiten (Tag 365), ein moderater Anstieg von 40%.
- **Potenzgesetz:** Wächst von 16.5 auf ca. 52 Einheiten, ein Anstieg von über 200%.
- **Logistisch:** Zeigt einen S-förmigen Übergang von 16.5 auf etwa 33 Einheiten.

Dies zeigt die praktische Konsequenz: Ein System mit Potenzgesetz-Degradation muss im Jahresverlauf 3x mehr Sicherheitsbestand halten, als eines mit exponentieller Degradation. Das ist eine massive Effizienzlast, die zentrale Planung für lange Zeithorizonte irrational macht.




Abbildung 4.3: Optimale Sicherheitsbestandsmenge als Funktion des Zeithorizonts für verschiedene Degradationsmodelle.

4.9.5 Simulation 4: Zentrale vs. dezentrale Planung

Simulation 4 – Fehlervergleich: Zentral vs. Dezentral

Abbildung 4.4 vergleicht die Prognosefehlerrate eines zentralen Planers (der alle 50 Kundengruppen aggregiert) vs. 50 dezentraler Planer (je einer pro Kundengruppe).

Setup:

- 50 unabhängige Kundengruppen
- Jede Gruppe: Basis-Nachfrage 1000 Einheiten, Std 100




Abbildung 4.4: Fehlerrate zentraler vs. dezentraler Planer über einen Jahr.

- Degradation: $\delta(\tau) = 1 + (1 - e^{-0.05\tau})$, unterschiedlich für jede Gruppe um $\pm 20\%$

Interpretation: Die Grafik zeigt:

- **Zentral (rot):** Fehlerrate wächst von 10% (Tag 1) auf 20% (Tag 365).
- **Dezentral (blau):** Fehlerrate wächst von 10% (Tag 1) auf 15% (Tag 365).
- **Grüne Zone (< 15% Fehler):** Der zentrale Planer kann bis ca. Tag 150 operieren. Der dezentrale Planer bis ca. Tag 250.

Dies bestätigt Theorem 4.5.5: Dezentrale Planung erlaubt längere Zeithorizonte bei gleicher Fehlertoleranz.

4.10 Zusammenfassung und Ausblick

4.10.1 Kernaussagen

Diese Arbeit hat gezeigt:

1. **Prognosen degradieren systematisch mit dem Zeithorizont.** Dies ist keine Folge schlechter Daten oder fehlender Algorithmen, sondern ein fundamentales mathematisches Phänomen, das in der Shannon-Entropie und in der nicht-Stationarität von Kundenpräferenzen wurzelt.
2. **Kundenverhalten ist von Grund auf nicht-stationär.** Präferenzen treiben über Mode, Lebenszyklus und psychologische Habituation. Keine Menge an historischen Daten kann Stationarität herstellen.
3. **Zentrale Planung hat eine fundamentale Längengrenze.** Jenseits eines kritischen Zeithorizonts ist zentrale Planung irrational, da die Fehlerquoten exponentiell wachsen.
4. **Pufferung muss exponentiell mit dem Zeithorizont wachsen.** Ein System, das stur versucht, lange Zeithorizonte zentral zu planen, muss astronomisch große Puffer halten – oder wird fragil.
5. **Dezentralisierung ist mathematisch notwendig, nicht ideologisch.** Ein dezentralisiertes System mit lokalen Planern hat strukturell bessere Vorhersagbarkeit und kann längere Zeithorizonte mit gleicher Fehlertoleranz bewältigen.

4.10.2 Implikationen für Wirtschaftssystem-Design

Ein rationales Wirtschaftssystem sollte:

1. **Zeithorizonabhängig strukturiert sein:**

- Tage bis 1-2 Wochen: Zentrale taktische Planung ist sinnvoll.
- Wochen bis 3 Monate: Dezentralisierung mit zentraler Koordination.
- Monate bis Jahre: Dezentralisierte, autonome Einheiten mit lockerer Koordination.
- Jahre+: Lokale Autarkie mit strategischem Austausch, nicht operative Abhängigkeit.

2. **Verträge unterschiedlich strukturieren nach Zeithorizont:**

- Kurz: Feste Mengen und Preise.
- Mittel: Flexible Preise, indexiert an Markt; feste Kapazitätszusagen.
- Lang: Optionale Mengen, mit Kündigungsrecht bei Strukturbrüchen.

3. **Pufferung explizit einplanen:** Nicht als Ineffizienz, sondern als rationale Risikoverwaltung unter fundamentaler Unsicherheit.

4. **Adaptivität in den Kern der Organisationsstruktur einbauen:** Nicht Hierarchie und zentrale Kontrolle, sondern Netzwerke mit lokaler Intelligenz und schneller Anpassung.

4.10.3 Offene Fragen und zukünftige Arbeiten

Diese Arbeit öffnet mehrere Richtungen für zukünftige Forschung:

1. **Empirische Kalibrierung:** Welche Degradationsmodelle passen zu realen Kundendaten? Gibt es Unterschiede zwischen Branchen (Retail, B2B, Energie, Lebensmittel)?
2. **Adaptive Algorithmen:** Wie können dezentralisierte Systeme in Echtzeit ihre lokalen Prognosen kalibrieren und sich an neue Information anpassen?
3. **Spieltheoretische Analyse:** Wie verhandeln dezentralisierte Einheiten untereinander bei unvollständiger Information und wachsender Unsicherheit?
4. **Regulierung und Policy:** Wie sollten Zentralbanken und Aufsichtsbehörden ihre Prognose-Horizonte kalibrieren? Welche Kapitalanforderungen sind rational unter Degradation?
5. **Blockchain und verteilte Systeme:** Können dezentralisierte Ledger-Technologien die Koordination unter Unsicherheit effizienter machen?

Kapitel 5

Dezentrale Wirtschaftszellen

5.1 Einführung

5.1.1 Problemstellung und Motivation

Das gegenwärtige Weltwirtschaftssystem ist durch einen historisch hohen Grad an Integration und gegenseitiger Abhängigkeit charakterisiert. Globale Lieferketten, einheitliche Währungsräume, international verflochtene Finanzmärkte und harmonisierte Regulierung erzeugen ein System, das in seiner extremen Form als *maximale Kopplung* bezeichnet werden kann: eine einzige große Wirtschaftszelle, in der jede lokale Störung durch schnelle Ansteckungseffekte globale Ausmaße annehmen kann.

Die Finanzkrisen von 2008 und 2020, die pandemiebedingte Lieferkettendisruption sowie geopolitische Schocks haben gezeigt, dass ein solches System zwar in stabilen Phasen Skaleneffekte ausnutzt, in Krisenzeiten jedoch katastrophale Systemausfälle produzieren kann [Acemoglu et al., 2015a, Haldane & May, 2011].

Definition 5.1.1 (Wirtschaftszelle). Eine *Wirtschaftszelle* $\mathcal{Z}_i = (\mathcal{P}_i, \mathcal{K}_i, \mathcal{W}_i)$ ist ein selbst-organisiertes wirtschaftliches Subsystem bestehend aus einer Produktionsmenge $\mathcal{P}_i$, einem Kapitalstock $\mathcal{K}_i$ und einer Wohlfahrtsfunktion $\mathcal{W}_i : \mathcal{P}_i \times \mathcal{K}_i \rightarrow \mathbb{R}$.

Wir untersuchen in dieser Arbeit das entgegengesetzte Konzept: ein System aus N *entkoppelten* Wirtschaftszellen, das wir als **Dezentrales Wirtschaftszellenmodell** (DWZ) bezeichnen. Dabei bedeutet Entkopplung nicht vollständige Autarkie, sondern vielmehr eine gezielte Modulierung der Verbindungsstärken zwischen Zellen, sodass systemische Schocks absorbiert und Resilienz durch strukturelle Diversifikation gewährleistet wird.

Das zentrale Paradoxon, das wir auflösen, lautet: *Kann eine Wirtschaftszelle von einer Krise profitieren, obwohl — oder gerade weil — sie in andere Zellen ausgelagerte Produktionsstätten besitzt?* Wir zeigen, dass die Antwort unter wohldefinierten Bedingungen positiv ist, und nennen diesen Mechanismus **positives Risikoexposure**.

Eine zweite zentrale Frage dieser Arbeit lautet: *Wie kann ein Wirtschaftsgraph, dessen Kopplungsstruktur durch endogene Dynamiken oder exogene Schocks aus einem resilienten Gleichgewicht herausgetrieben wurde, algorithmisch in dieses zurückgeführt werden?* Wir zeigen, dass der **Subgraph Algorithmus** [Epp, 2026c] als Stabilisierungsoperator $\mathcal{S}$ auf dem Graphen eingesetzt werden kann, der global asymptotisch gegen den Pareto-optimalen Referenzgraphen G^* konvergiert — nachgewiesen durch eine strenge Lyapunov-Analyse.

Die dritte und tiefste Ebene der Arbeit betrifft die *zeitliche Variabilität* des Wirtschaftsgraphen selbst: Kopplungsgrade sind keine statischen Parameter, sondern stochastische Prozesse, die Konjunkturzyklen, geopolitische Strukturbrüche und langfristigen Wandel widerspiegeln. Wir formalisieren diese Dynamik als Ito-Differentialgleichung mit Mean-Reversion, analysieren periodische Regime mittels Floquet-Theorie und beweisen, dass ein adaptiver Subgraph-Operator auch bei zeitvariantem Referenzpfad $c^*(t)$ eine quantifizierbare Tracking-Konvergenz garantiert.

5.1.2 Beitrag dieser Arbeit

Die Hauptbeiträge dieser Arbeit sind:

1. **Formale Definition** des Kopplungsgrades c und der systemischen Risikomaße für Netzwerke von Wirtschaftszellen (Abschnitt 2).
2. **Beweis** der Resilienz-Kopplung-Inkompatibilität (Satz 5.1): Maximale Kopplung und maximale Resilienz schließen sich aus (Abschnitt 4).
3. **Nachweis** des positiven Risikoexposures (Satz 5.2) durch portfoliotheoretische Dekonstruktion von Produktionsauslagerungen (Abschnitt 5).
4. **Formalisierung** des Währungseffekts: Einheitswährungen als Kopplungsverstärker (Proposition 5.7.1, Abschnitt 7).
5. **Ableitung** eines optimalen Kopplungsgrades c^* über einen Pareto-Ansatz (Abschnitt 8).
6. **Simulation** aller statischen Ergebnisse mittels Monte-Carlo-Experimenten (Abschnitte 3–8).
7. **Subgraph-Stabilisierungsoperator** $\mathcal{S}$ (Abschnitt 9): Nachweis globaler asymptotischer Stabilität ($W(t) \rightarrow W^*$) in endlich vielen Schritten via Lyapunov-Funktion $V(t) = \|W(t) - W^*\|_F^2$; spektrale Konvergenz $\varrho(\Lambda(t)) \rightarrow \varrho^* < 1$; globaler Attraktor (c^*, ϱ^*) im Phasenraum; Laufzeit $O(N^3)$ pro Iteration.
8. **Dynamische Graphentheorie** (Abschnitt 10): Vollständige stochastische Behandlung des zeitvarianten Wirtschaftsgraphen — stationäre Beta-Verteilung des Kopplungsgrades (Satz 5.8), mittlere Erholungszeit nach Strukturbrüchen (Satz 5.9), Floquet-Stabilitätskriterium für periodische Regime (Satz 5.10), integrale Resilienz unter zyklischer Kopplung mit Bessel-Funktion (Satz 5.11) sowie Tracking-Konvergenz des adaptiven Subgraph-Operators (Satz 5.12) mit optimaler Dämpfungsrate (Korollar 5.5).

5.1.3 Aufbau der Arbeit

Abschnitt 2 legt das formale Grundmodell fest. Abschnitte 3–8 behandeln die statische Theorie dezentraler Wirtschaftszellen: Netzwerktopologie, Resilienz-Kopplung-Inkompatibilität, positives Risikoexposure, Monte-Carlo-Simulation, Währungseffekte und Pareto-Optimierung. Abschnitt 9 führt den Subgraph-Stabilisierungsoperator ein und beweist globale Konvergenz und Krisenresistenz. Abschnitt 10 verallgemeinert das Modell auf zeitvariante Graphen und entwickelt die vollständige stochastische

Dynamiktheorie. Abschnitt 11 fasst alle Hauptergebnisse tabellarisch zusammen. Abschnitt 12 gibt einen ausführlichen Ausblick auf offene Forschungsfragen, institutionelle Implikationen und Verbindungen zu benachbarten Disziplinen.

5.2 Grundlagen und formales Modell

5.2.1 Netzwerkdarstellung

Definition 5.2.1 (Wirtschaftsnetzwerk). Ein *Wirtschaftsnetzwerk* ist ein gewichteter gerichteter Graph $\mathcal{G} = (\mathcal{Z}, \mathcal{E}, w)$, wobei $\mathcal{Z} = \{\mathcal{Z}_1, \dots, \mathcal{Z}_N\}$ die Menge der Wirtschaftszellen, $\mathcal{E} \subseteq \mathcal{Z} \times \mathcal{Z}$ die Menge der wirtschaftlichen Verbindungen und $w : \mathcal{E} \rightarrow [0, 1]$ die Verbindungsstärke (Kopplungsgewicht) bezeichnet.

Definition 5.2.2 (Kopplungsgrad). Sei $W = (w_{ij})_{i,j \in [N]}$ die Gewichtsmatrix des Netzwerks mit $w_{ij} \in [0, 1]$. Der *Kopplungsgrad* des Systems ist definiert als

$$c(\mathcal{G}) = \frac{1}{N(N-1)} \sum_{\substack{i,j=1 \\ i \neq j}}^N w_{ij} \in [0, 1].$$

Für $c = 0$ sprechen wir von einem *vollständig entkoppelten*, für $c = 1$ von einem *maximal gekoppelten* System.

Bemerkung 5.1. Eine Einheitwährung für alle N Zellen erzwingt $w_{ij} \geq w_{\min} > 0$ für alle Paare (i, j) , da Wechselkursanpassungen als wichtiger Puffer zwischen Wirtschaftszellen entfallen. Dies erhöht den Kopplungsgrad strukturell und systematisch.

5.2.2 Systemisches Risiko

Definition 5.2.3 (Systemisches Risiko). Sei $Y_i(t)$ der wirtschaftliche Output der Zelle $\mathcal{Z}_i$ zum Zeitpunkt t . Das *systemische Risiko* des Netzwerks ist

$$\Psi(\mathcal{G}) = \mathbb{P} \left(\sum_{i=1}^N Y_i(t) < (1 - \theta) \cdot \mathbb{E} \left[\sum_{i=1}^N Y_i(t) \right] \right),$$

d. h. die Wahrscheinlichkeit eines systemweiten Outputeinbruchs um mehr als $\theta > 0$.

Definition 5.2.4 (Ansteckungsmatrix). Die *Ansteckungsmatrix* $\Lambda = (\lambda_{ij})$ gibt an, mit welcher Intensität ein negativer Schock in Zelle i auf Zelle j übertragen wird:

$$\lambda_{ij} = c \cdot w_{ij} \cdot \phi_{ij},$$

wobei $\phi_{ij} \in [0, 1]$ die strukturelle Anfälligkeit der Verbindung (i, j) beschreibt.

5.2.3 Resilienz

Definition 5.2.5 (Systemresilienz). Die *Resilienz* eines Wirtschaftsnetzwerks bezeichnet seine Fähigkeit, nach einem exogenen Schock ε in endlicher Zeit zum Gleichgewichtspfad zurückzukehren:

$$R(\mathcal{G}) = \left(\int_0^\infty |Y(t) - Y^*(t)| dt \right)^{-1},$$

wobei $Y(t) = \sum_i Y_i(t)$ der realisierte und $Y^*(t)$ der kontrafaktische (schockfreie) Gesamtoutput ist.




Abbildung 5.1: Systemresilienz $R(c)$ und systemisches Risiko $\Psi(c)$ in Abhängigkeit vom Kopplungsgrad c . Der kritische Punkt $c^* = 0,55$ markiert den Übergang zur Hochrisikozone. Die optimale Dekopplungszone liegt bei $c \leq 0,35$.

Abbildung 5.1 zeigt den grundlegenden Trade-off: Resilienz $R(c)$ ist nicht-monoton mit einem Maximum bei niedrigem c , während das systemische Risiko $\Psi(c)$ eine sigmoidale Wachstumskurve mit Wendepunkt bei $c^* = 0,55$ aufweist.

5.3 Netzwerktopologie: Zentralisiert vs. Dezentralisiert

5.3.1 Topologische Charakterisierung

Definition 5.3.1 (Monolithisches System). Ein *monolithisches Wirtschaftssystem* ist ein Sternengraph $\mathcal{G}_{\text{mono}} = K_{1,N-1}$, bei dem alle Zellen über ein gemeinsames Zentrum (z. B. eine Zentralbank, ein Reservewährungssystem) mit einheitlichem Kopplungsgewicht $w_{ij} = 1$ verbunden sind.

Definition 5.3.2 (Dezentrales Zellsystem). Ein *dezentrales Zellsystem* ist ein Graph $\mathcal{G}_{\text{dez}}$, der sich aus $K \geq 2$ dicht verbundenen Clustern zusammensetzt, wobei intra-cluster-Kopplung c_{intra} hoch und inter-cluster-Kopplung $c_{\text{inter}} \ll c_{\text{intra}}$ gering ist.

Plot 2 – Netzwerktopologien im Vergleich




Abbildung 5.2: Netzwerktopologien im Vergleich. (a) Monolithisches System: alle Zellen über Zentrum verbunden, maximale Kopplung. (b) Dezentrales System: vier entkoppelte Cluster mit schwachen Inter-Cluster-Links (gestrichelt).

Lemma 5.3.3 (Spektraleigenschaften). *Sei $\lambda_{\max}(W)$ der größte Eigenwert der Gewichtsmatrix W . Im monolithischen System gilt $\lambda_{\max}(W_{\text{mono}}) = N - 1$, im dezentralen System gilt $\lambda_{\max}(W_{\text{dez}}) \leq c_{\text{intra}} \cdot (N/K - 1) + c_{\text{inter}} \cdot (K - 1)$.*

Beweis. Für den Sterngraphen $K_{1,N-1}$ mit Einheitsgewichten ist die Gewichtsmatrix W_{mono} eine Rang-2-Matrix mit Eigenwerten $\{\sqrt{N-1}, -\sqrt{N-1}, 0, \dots, 0\}$, woraus $\lambda_{\max} = \sqrt{N-1}$ für den symmetrisierten und $\lambda_{\max} = N-1$ für den gerichteten Fall folgt.

Für das dezentrale System partitionieren wir W_{dez} in K Blöcke der Größe $n_k = N/K$ mit intra-cluster-Gewichten c_{intra} und inter-cluster-Gewichten c_{inter} . Nach dem Gershgorin-Kreistheorem liegt jeder Eigenwert λ_i in einem Gershgorin-Kreis um den Diagonaleintrag mit Radius

$$R_i = c_{\text{intra}}(n_k - 1) + c_{\text{inter}}(N - n_k).$$

Da $c_{\text{inter}} \ll c_{\text{intra}}$ und $n_k \ll N$ für $K \gg 1$, folgt $\lambda_{\max}(W_{\text{dez}}) \ll \lambda_{\max}(W_{\text{mono}})$. $\square$

Korollar 5.1. Die Schockpropagationsgeschwindigkeit im Netzwerk ist proportional zu $\lambda_{\max}(W)$. Dezentrale Systeme propagieren Schocks daher wesentlich langsamer als monolithische.

5.4 Resilienz-Kopplung-Inkompatibilität

5.4.1 Hauptsatz

Satz 5.1 (Resilienz-Kopplung-Inkompatibilität). Unter den Annahmen (A1)–(A3) gilt:

$$\left. \frac{\partial R}{\partial c} \right|_{c > c^*} < 0 \quad \text{und} \quad \frac{\partial \Psi}{\partial c} > 0 \quad \forall c \in (0, 1).$$

Insbesondere sind maximale Kopplung ($c = 1$) und maximale Resilienz unvereinbar.

Annahmen:

- (A1) Die Outputprozesse $Y_i(t)$ sind schwach stationäre Diffusionsprozesse mit Drift μ_i , Volatilität σ_i und Korrelation $\rho_{ij} = c \cdot w_{ij}$.
- (A2) Schocks $\varepsilon_i \sim \mathcal{N}(0, \sigma_\varepsilon^2)$ sind iid vor Ansteckung; nach Ansteckung gilt $\tilde{\varepsilon}_j = \sum_i \lambda_{ij} \varepsilon_i + \varepsilon_j$.
- (A3) Die Erholungsrate jeder Zelle ist $r_i = r_0(1 - c \cdot \bar{w}_i)$, wobei $\bar{w}_i = \frac{1}{N-1} \sum_{j \neq i} w_{ij}$ die mittlere Verbindungsstärke von $\mathcal{Z}_i$ ist.

Beweis. Teil 1 ($\partial\Psi/\partial c > 0$): Sei $S(t) = \sum_i Y_i(t)$ der Gesamtoutput. Die Kovarianzmatrix von $(Y_1, \dots, Y_N)^T$ ist $\Sigma_{ij} = \sigma_i \sigma_j \rho_{ij} = c \sigma_i \sigma_j w_{ij}$ für $i \neq j$. Die Varianz des Gesamtoutputs ist

$$\text{Var}(S) = \sum_i \sigma_i^2 + c \sum_{i \neq j} \sigma_i \sigma_j w_{ij} = \sigma_0^2 + c \cdot Q,$$

wobei $\sigma_0^2 = \sum_i \sigma_i^2$ die idiosynkratische Varianz und $Q = \sum_{i \neq j} \sigma_i \sigma_j w_{ij} > 0$ der Kopp-
lungsterm ist. Da $S(t)$ annähernd normalverteilt ist (Zentraler Grenzwertsatz, N groß), gilt

$$\Psi(c) = \Phi\left(\frac{(1-\theta)\mu_S - \mu_S}{\sqrt{\sigma_0^2 + cQ}}\right) = \Phi\left(\frac{-\theta\mu_S}{\sqrt{\sigma_0^2 + cQ}}\right),$$

wobei Φ die Standard-Normalverteilungsfunktion und $\mu_S = \sum_i \mu_i > 0$. Ableitung nach c :

$$\frac{\partial\Psi}{\partial c} = \phi(\dots) \cdot \frac{\theta\mu_S \cdot Q}{2(\sigma_0^2 + cQ)^{3/2}} > 0,$$

da $\phi > 0$, $\theta > 0$, $\mu_S > 0$, $Q > 0$.

Teil 2 ($\partial R/\partial c < 0$ für $c > c^*$): Nach Annahme (A3) ist die Erholungsrate $r_i(c) = r_0(1 - c\bar{w}_i)$. Die Resilienz ist

$$R(c) = \left(\int_0^\infty \mathbb{E}[|Y(t) - Y^*(t)|] dt \right)^{-1}.$$

Für eine lineare Schockdynamik $\dot{Y} = -r(c)Y + \varepsilon(c)$ ist $\mathbb{E}[|Y(t) - Y^*(t)|] = \delta_0 e^{-r(c)t}$, sodass

$$R(c) = r(c) = r_0(1 - c\bar{w}).$$

Diese Funktion ist streng fallend in c für $c > 0$, was Teil 2 beweist. Die Kombination beider Teile zeigt, dass $c = 1$ sowohl maximales Ψ als auch minimales R erzeugt. $\square$




Abbildung 5.3: Schockausbreitung im gekoppelten vs. entkoppelten System. Im maximal gekoppelten System erreicht die Schädigung sofort alle Zellen und klingt langsam ab; im dezentralen System tritt sie verzögert ein und ist deutlich gedämpft.

5.5 Positives Risikoexposure durch Produktionsauslagerung

5.5.1 Konzept und formale Motivation

Das entscheidende Novum dezentraler Wirtschaftszellen liegt nicht nur in der Risikoreduktion, sondern in der Möglichkeit des **positiven Risikoexposures**: Eine Zelle, die Produktionsstätten in einer anderen, entkoppelten Zelle besitzt, kann von einer Krise in der eigenen Heimatzone profitieren, falls die Auslandszelle in derselben Periode boomt.

Definition 5.5.1 (Positives Risikoexposure). Sei $\mathcal{Z}_i$ die Heimatzelle mit Produktion Y_i^{heim} und ausgelagerter Produktion Y_i^{ext} in Zelle $\mathcal{Z}_j \neq \mathcal{Z}_i$. Der Gesamtoutput der Zelle i ist

$$Y_i^{\text{ges}} = \alpha Y_i^{\text{heim}} + (1 - \alpha) Y_i^{\text{ext}}, \quad \alpha \in (0, 1).$$

Wir sagen, $\mathcal{Z}_i$ besitzt *positives Risikoexposure*, wenn

$$\text{Var}(Y_i^{\text{ges}}) < \text{Var}(Y_i^{\text{heim}})$$

und gleichzeitig $\mathbb{E}[Y_i^{\text{ges}}] \geq \mathbb{E}[Y_i^{\text{heim}}]$.

Satz 5.2 (Positives Risikoexposure). Sei $\rho = \text{Corr}(Y_i^{\text{heim}}, Y_i^{\text{ext}})$ die Korrelation zwischen Heim- und Auslandsproduktion. Dann gilt:

$$\text{Var}(Y_i^{\text{ges}}) < \text{Var}(Y_i^{\text{heim}}) \iff \rho < \frac{\sigma_h^2 + (1 - 2\alpha)\sigma_e^2}{2\alpha(1 - \alpha)\sigma_h\sigma_e} \cdot \frac{1 - \alpha}{\alpha} \quad (\text{vereinfacht: } \rho < \frac{\sigma_h}{2(1 - \alpha)\sigma_e}).$$

Insbesondere ist positives Risikoexposure garantiert, wenn $\rho \leq 0$.

Beweis. Die Varianz des gemischten Outputs ist

$$\text{Var}(Y_i^{\text{ges}}) = \alpha^2 \sigma_h^2 + (1 - \alpha)^2 \sigma_e^2 + 2\alpha(1 - \alpha)\rho\sigma_h\sigma_e.$$

Die Bedingung $\text{Var}(Y_i^{\text{ges}}) < \text{Var}(Y_i^{\text{heim}}) = \sigma_h^2$ ergibt

$$\begin{aligned} \alpha^2 \sigma_h^2 + (1 - \alpha)^2 \sigma_e^2 + 2\alpha(1 - \alpha)\rho\sigma_h\sigma_e &< \sigma_h^2, \\ (1 - \alpha)^2 \sigma_e^2 + 2\alpha(1 - \alpha)\rho\sigma_h\sigma_e &< (1 - \alpha^2)\sigma_h^2 = (1 - \alpha)(1 + \alpha)\sigma_h^2, \\ (1 - \alpha)\sigma_e^2 + 2\alpha\rho\sigma_h\sigma_e &< (1 + \alpha)\sigma_h^2, \\ \rho &< \frac{(1 + \alpha)\sigma_h^2 - (1 - \alpha)\sigma_e^2}{2\alpha\sigma_h\sigma_e}. \end{aligned}$$

Für den Spezialfall $\rho \leq 0$ ist die linke Seite der letzten Ungleichung ≤ 0 , während die rechte Seite > 0 ist (da $\sigma_h, \sigma_e, \alpha > 0$). Die Ungleichung ist daher automatisch erfüllt. Aus $\mathbb{E}[Y_i^{\text{ges}}] = \alpha\mu_h + (1 - \alpha)\mu_e$ folgt die Bedingung für unveränderten oder höheren Erwartungswert direkt aus $\mu_e \geq \mu_h$, was in Boomphasen der Auslandszelle erfüllt ist. $\square$

Korollar 5.2 (Hedge-Effekt bei negativem Schock). Trifft einen negativen Schock $\varepsilon < 0$ nur die Heimatzone ($Y_i^{\text{heim}} \rightarrow Y_i^{\text{heim}} + \varepsilon$), so gilt

$$\Delta Y_i^{\text{ges}} = \alpha\varepsilon < \varepsilon = \Delta Y_i^{\text{heim}},$$

d. h. der Schaden ist um Faktor $(1 - \alpha)$ reduziert. Falls zudem die Auslandszelle einen komplementären Boom $\eta > 0$ erlebt (im Falle negativer Korrelation $\rho < 0$), so kompensiert der Term $(1 - \alpha)\eta$ den Schaden partiell oder vollständig.




Abbildung 5.4: (a) Varianzreduktion durch Zellendiversifikation: Bei hoher Korrelation ($\rho = 0.8$, monolithisch) bleibt das systemische Risiko dauerhaft hoch; bei niedriger Korrelation ($\rho = 0.05$, dezentral) sinkt es rapide. (b) Erwarteter Nutzen als Funktion der Risikoaversion: Entkoppelte Systeme dominieren für $\lambda > \lambda^* \approx 0.89$.

5.5.2 Portfoliotheoretischer Nachweis

Abbildung 5.4 veranschaulicht den Diversifikationsgewinn formal. Im linken Teilbild (a) sehen wir die klassische Portfoliovarianzformel

$$\sigma_P^2(N) = \frac{\sigma^2}{N} + \frac{N-1}{N}\rho\sigma^2 \xrightarrow{N \rightarrow \infty} \rho\sigma^2$$

für hohe Korrelation ($\rho = 0,8$, gekoppelt) und niedrige Korrelation ($\rho = 0,05$, entkoppelt). Während das diversifizierbare Risiko in beiden Fällen mit $1/N$ abnimmt, dominiert beim gekoppelten System das systematische Risiko $\rho\sigma^2 = 0,8\sigma^2$, das nicht diversifizierbar ist.

Im rechten Teilbild (b) betrachten wir den erwarteten Nutzen unter Risikoaversion λ gemäß der Bernoulli-Nutzenformel:

$$EU(\lambda) = \mu - \frac{\lambda}{2}\sigma^2.$$

Das entkoppelte System dominiert für alle $\lambda > \lambda^*$, wobei $\lambda^* = (\mu_c - \mu_d)/[(\sigma_c^2 - \sigma_d^2)/2] \approx 0,89$. Für gesellschaftlich relevante Risikoaversion ($\lambda \gg 1$) ist die Überlegenheit des dezentralen Systems eindeutig.

5.6 Monte-Carlo-Simulation der Krisenausbreitung

5.6.1 Simulationsmodell

Wir simulieren ein System von N Wirtschaftszellen über $T = 30$ Zeitschritte. Die Systemgesundheit $h_i(t) \in [0, 1]$ jeder Zelle entwickelt sich nach der Rekursion

$$h_i(t+1) = \min\left(1, h_i(t) + r(1-c)\delta_i - c \sum_{j \neq i} \frac{(1-h_j(t))}{N} U_{ij}\right),$$

wobei $U_{ij} \sim \mathcal{U}[0, 1]$ unabhängige Ansteckungseffekte, $r = 0,04$ die Erholungsrate und δ_i ein binärer Indikator für Nicht-Krise ist.




Abbildung 5.5: Monte-Carlo-Simulation der Krisenausbreitung. Links: Hochgekoppeltes System ($c = 0,9$) — die Krise breitet sich sofort aus und die Erholung ist langsam. Mitte: Mittlere Kopplung ($c = 0,5$). Rechts: Entkoppeltes System ($c = 0,1$) — die Krise verbleibt weitgehend lokal.

Satz 5.3 (Monotone Krisenausbreitung). Unter dem Simulationsmodell gilt: Der Erwartungswert der Systemgesundheit nach dem Schock ist streng fallend im Kopplungsgrad:

$$c_1 < c_2 \Rightarrow \mathbb{E}[h_{\text{sys}}(T | c = c_1)] > \mathbb{E}[h_{\text{sys}}(T | c = c_2)].$$

Beweis. Sei $H_c(t) = \frac{1}{N} \sum_i h_i(t|c)$ die mittlere Systemgesundheit. Für $c_1 < c_2$ gilt komponentenweise: Der Ansteckungsterm $c \sum_j (1 - h_j)/N \cdot U_{ij}$ ist streng monoton wachsend in c , da alle Summanden nicht-negativ sind. Gleichzeitig ist die Erholungsrate $r(1 - c)$ streng fallend in c . Per Induktion über t gilt daher

$$h_i(t|c_1) \geq h_i(t|c_2) \quad \forall i, t \geq 0,$$

mit strenger Ungleichung für $t \geq 1$ nach dem Initialschock (da mindestens eine Zelle mit $h_i(0) < 1$ existiert). Der Erwartungswertoperator erhält diese Ordnung im Mittel. $\square$

5.7 Währungssysteme als Kopplungsverstärker

5.7.1 Formale Analyse des Währungseffekts

Proposition 5.7.1 (Währungsunion erhöht Kopplungsgrad). *Sei c_{flex} der Kopplungsgrad eines Systems mit flexiblen Wechselkursen und c_{union} der einer Währungsunion. Dann gilt $c_{\text{union}} > c_{\text{flex}}$.*

Beweis. Im System mit flexiblen Wechselkursen fungiert der Wechselkurs $e_{ij}(t)$ als automatischer Stabilisator: Ein negativer Schock in Zelle i ($Y_i \downarrow$) führt zu einer Abwertung der Währung i ($e_{ij} \downarrow$), was Exporte verbilligt und den Schock teilweise kompensiert.

Formal: Die effektive Ansteckungsstärke unter flexiblen Wechselkursen ist

$$\lambda_{ij}^{\text{flex}} = \lambda_{ij}^{\text{base}} \cdot (1 - \kappa_{ij}),$$

wobei $\kappa_{ij} \in (0, 1)$ die Dämpfung durch Wechselkursanpassung beschreibt.

In einer Währungsunion entfällt dieser Puffermechanismus: $\kappa_{ij}^{\text{union}} = 0$, sodass $\lambda_{ij}^{\text{union}} = \lambda_{ij}^{\text{base}} > \lambda_{ij}^{\text{flex}}$.

Integriert über alle Paare (i, j) ergibt sich

$$c_{\text{union}} = \frac{1}{N(N-1)} \sum_{i \neq j} \lambda_{ij}^{\text{union}} > \frac{1}{N(N-1)} \sum_{i \neq j} \lambda_{ij}^{\text{flex}} = c_{\text{flex}}.$$

$\square$

Bemerkung 5.2. Proposition 5.7.1 erklärt empirisch beobachtbare Phänomene wie den Mechanismus der Euro-Schuldenkrise 2010–2015: Da Mitglieder der Eurozone keine Wechselkursanpassungen vornehmen konnten, pflanzte sich die Krise von Griechenland auf Portugal, Spanien und Italien fort – ein direkter Ausdruck des erhöhten Kopplungsgrades.




Abbildung 5.6: BIP-Entwicklung dreier Wirtschaftssubjekte im Vergleich: Währungsunion ($c = 0,9$, rot) vs. dezentrale Währungen ($c = 0,15$, grün). Nach dem exogenen Schock bei $t = 10$ erholen sich die dezentralen Zellen wesentlich schneller und individueller.

5.8 Optimaler Kopplungsgrad: Pareto-Analyse

5.8.1 Zielfunktionskonflikt

Dezentralisierung ist kein Selbstzweck: Ein gewisser Kopplungsgrad $c > 0$ ist notwendig, um Handelsgewinne, Wissenstransfer und Skaleneffekte zu realisieren. Es besteht ein echter Zielkonflikt zwischen Wachstum $g(c)$ und Resilienz $R(c)$.

Definition 5.8.1 (Pareto-optimaler Kopplungsgrad). Ein Kopplungsgrad c^* heißt *Pareto-optimal*, wenn es kein $c' \neq c^*$ gibt mit $g(c') \geq g(c^*)$ und $R(c') \geq R(c^*)$ (bei mindestens einer strengen Ungleichung).

Proposition 5.8.2 (Existenz des Pareto-optimalen Kopplungsgrades). *Unter der Annahme, dass $g(c)$ konkav und $R(c)$ konkav in c sind, existiert ein eindeutiger Pareto-optimaler Kopplungsgrad $c^* \in (0, 1)$.*

Beweis. Das Pareto-Problem lässt sich als gewichtete Summe formulieren: $\max_c [\omega g(c) + (1 - \omega)R(c)]$ für $\omega \in (0, 1)$. Da g und R beide konkav sind, ist die gewichtete Summe ebenfalls konkav, und ein eindeutiges Maximum im Innern von $(0, 1)$ existiert, wenn $g'(0) > 0$, $g'(1) < 0$ und $R'(0) > 0$, $R'(1) < 0$ gelten. Diese Randbedingungen sind ökonomisch plausibel: Vollständige Isolation ($c = 0$) wie auch vollständige Fusion ($c = 1$) sind suboptimal. $\square$




Abbildung 5.7: Pareto-Frontier im Raum (Resilienz, Wachstum). Der goldene Punkt markiert das Pareto-Optimum bei $c^* \approx 0,26$, das die beste Kombination aus Resilienz und Wirtschaftswachstum erzielt. Die Farbe des Pfads kodiert den Kopplungsgrad ($c = 0$: grün, $c = 1$: rot).




Abbildung 5.8: Positives Risikoexposure durch Produktionsauslagerung. (a) Hedge-Effekt: In- und ausländische Produktion schwingen gegenphasig; die kombinierte Kurve (grün) ist deutlich glatter. (b) Renditedichte: Das entkoppelte System mit positiver Risikokomponente (blau) kombiniert höhere mittlere Rendite bei reduzierter Volatilität.

5.9 Der Subgraph Algorithmus als Stabilisierungsoperator

5.9.1 Motivation und Grundidee

Die bisherigen Abschnitte haben gezeigt, dass die Topologie des Wirtschaftsgraphen $\mathcal{G} = (\mathcal{Z}, \mathcal{E}, w)$ den entscheidenden Einfluss auf Resilienz und systemisches Risiko hat. Es stellt sich die fundamentale Frage: Wie kann ein System, dessen Kopplungsmatrix $W(t)$ durch

endogene Dynamiken und exogene Schocks aus einem resilienten Gleichgewichtszustand herausgetrieben wird, *algorithmisch* in diesen Zustand zurückgeführt werden?

Wir zeigen in diesem Abschnitt, dass der **Subgraph Algorithmus** [Epp, 2026c] als genau ein solcher *Stabilisierungsoperator* $\mathcal{S}$ auf dem Wirtschaftsgraphen eingesetzt werden kann. Die zentrale Beobachtung ist:

- Der Subgraph Algorithmus vergleicht zwei Graphen G und G' und entscheidet, welcher den anderen enthält — er *selektiert die informationsreichere Struktur*.
- Interpretiert man einen Referenzgraphen $G^* = (\mathcal{Z}, \mathcal{E}^*, w^*)$ als *Stabilitätsziel*, so kann der Algorithmus iterativ überschüssige Kanten in $\mathcal{G}(t)$ identifizieren und eliminieren, die nicht als Subgraph in G^* enthalten sind.
- Durch wiederholte Anwendung konvergiert $\mathcal{G}(t)$ gegen den Pareto-optimalen Graphen G^* .

5.9.2 Formale Definition des Stabilisierungsoperators

Definition 5.9.1 (Stabilitätsreferenzgraph). Sei $G^* = (\mathcal{Z}, \mathcal{E}^*, w^*)$ ein Graph mit Kopplungsgrad $c^* \in (0, 1)$, der das Pareto-Optimum aus Abschnitt 8 realisiert. G^* heißt *Stabilitätsreferenzgraph* des Wirtschaftsnetzwerks.

Definition 5.9.2 (Subgraph-Stabilisierungsoperator). Sei $\mathcal{G}(t)$ der Wirtschaftsgraph zum Zeitpunkt t mit Adjazenzmatrix $W(t)$. Der *Subgraph-Stabilisierungsoperator*

$$\mathcal{S} : \mathbb{R}^{N \times N} \rightarrow \mathbb{R}^{N \times N}$$

ist definiert durch:

$$[\mathcal{S}(W)]_{ij} = \begin{cases} w_{ij}(t) & \text{falls } (i, j) \in \mathcal{E}^* \text{ (Kante im Referenz)} \\ \max(0, w_{ij}(t) - \delta) & \text{sonst} \end{cases}$$

wobei $\delta \in (0, 1]$ die *Dämpfungsrate* des Operators bezeichnet. Die Iteration lautet $W(t+1) = \mathcal{S}(W(t))$.

Bemerkung 5.3. Der Operator $\mathcal{S}$ wendet intern den Subgraph Algorithmus an: Für jede Kante (i, j) wird geprüft, ob der durch (i, j) induzierte Teilgraph als Subgraph in G^* enthalten ist (Laufzeit $O(n^3)$ pro Iteration). Nicht-enhaltene Kanten werden schrittweise mit Rate δ gedämpft.

5.9.3 Konvergenzbeweise

Lemma 5.9.3 (Monotone Kopplungsgrad-Abnahme). *Für jeden Graphen $\mathcal{G}(t)$ mit $c(t) > c^*$ gilt*

$$c(t+1) = c(\mathcal{S}(W(t))) \leq c(t).$$

Beweis. Sei $\mathcal{E}_+(t) = \{(i, j) : w_{ij}(t) > 0, (i, j) \notin \mathcal{E}^*\}$ die Menge der überschüssigen Kanten. Nach Definition 5.9.2 gilt für alle $(i, j) \in \mathcal{E}_+(t)$:

$$[\mathcal{S}(W)]_{ij} = \max(0, w_{ij}(t) - \delta) \leq w_{ij}(t).$$

Für alle $(i, j) \in \mathcal{E}^*$ bleibt das Gewicht unverändert. Da $c(\mathcal{G}) = \frac{1}{N(N-1)} \sum_{i \neq j} w_{ij}$ und alle Summanden in $\mathcal{E}_+(t)$ nicht wachsen, gilt

$$c(t+1) = c(t) - \frac{\delta}{N(N-1)} |\mathcal{E}_+(t)| \leq c(t).$$

Da $|\mathcal{E}_+(t)| \geq 0$ per Konstruktion, ist die Ungleichung bewiesen. $\square$

Lemma 5.9.4 (Lyapunov-Funktion). *Die Funktion*

$$V(t) = \|W(t) - W^*\|_F^2 = \sum_{i,j} (w_{ij}(t) - w_{ij}^*)^2$$

ist eine Lyapunov-Funktion für das iterierte System $W(t+1) = \mathcal{S}(W(t))$, d. h. es gilt $V(t) \geq 0$ für alle t , $V(t) = 0 \Leftrightarrow W(t) = W^*$, und $V(t+1) \leq V(t)$ für alle t .

Beweis. Positive Definitheit: $V(t) = \|W(t) - W^*\|_F^2 \geq 0$ ist evident; $V(t) = 0$ genau dann wenn $W(t) = W^*$ komponentenweise.

Monotone Abnahme: Wir zeigen $\Delta V(t) = V(t+1) - V(t) \leq 0$. Für $(i, j) \in \mathcal{E}^*$ gilt $[\mathcal{S}(W)]_{ij} = w_{ij}(t)$, also leistet diese Menge den Beitrag $\Delta V_{(i,j)} = 0$.

Für $(i, j) \notin \mathcal{E}^*$ (und $w_{ij}^* = 0$) gilt:

$$\Delta V_{(i,j)} = (\max(0, w_{ij} - \delta))^2 - w_{ij}^2.$$

Fall 1: $w_{ij} > \delta$. Dann $\Delta V_{(i,j)} = (w_{ij} - \delta)^2 - w_{ij}^2 = -2\delta w_{ij} + \delta^2 < 0$, da $w_{ij} > \delta/2$ für $\delta < 2w_{ij}$.

Fall 2: $w_{ij} \leq \delta$. Dann $[\mathcal{S}(W)]_{ij} = 0$, also $\Delta V_{(i,j)} = 0 - w_{ij}^2 \leq 0$.

In beiden Fällen gilt $\Delta V_{(i,j)} \leq 0$, mit strenger Ungleichung solange $w_{ij} > 0$. Summation über alle (i, j) ergibt $\Delta V(t) \leq 0$, mit $\Delta V(t) = 0$ nur wenn $W(t) = W^*$. $\square$




Abbildung 5.9: (a) Lyapunov-Funktion $V(t) = \|W(t) - W^*\|_F^2$: monoton fallend für alle Startkonfigurationen. (b) Differenz $\Delta V(t) \leq 0$ (grün unterlegt), Kontraktionseigenschaft des Operators $\mathcal{S}$.

Satz 5.4 (Globale asymptotische Stabilität). Sei G^* der Stabilitätsreferenzgraph (Definition 5.9.1), $\delta \in (0, 1]$ und $W(0)$ beliebig mit $w_{ij}(0) \in [0, 1]$ für alle (i, j) . Dann konvergiert die Iteration $W(t+1) = \mathcal{S}(W(t))$ global asymptotisch gegen W^* :

$$\lim_{t \rightarrow \infty} W(t) = W^*, \quad \lim_{t \rightarrow \infty} V(t) = 0.$$

Die Konvergenz erfolgt in endlicher Zeit $T^* \leq \lceil 1/\delta \rceil$.

Beweis. Schritt 1: $V(t)$ ist monoton fallend (Lemma 5.9.4). Da $V(t) \geq 0$ und monoton fallend, existiert $V^* = \lim_{t \rightarrow \infty} V(t) \geq 0$.

Schritt 2: $V^* = 0$. Angenommen $V^* > 0$. Dann existiert (i, j) mit $w_{ij}(t) > w_{ij}^*$ für alle t . Für $(i, j) \notin \mathcal{E}^*$ (d. h. $w_{ij}^* = 0$) gilt nach Fall 1 des Lemma-Beweises, dass $w_{ij}(t+1) = \max(0, w_{ij}(t) - \delta)$. Die Folge $(w_{ij}(t))_{t \geq 0}$ fällt mit Rate δ pro Schritt solange $w_{ij}(t) > 0$, also erreicht sie 0 nach spätestens $\lceil w_{ij}(0)/\delta \rceil \leq \lceil 1/\delta \rceil$ Schritten. Da $w_{ij}(0) \leq 1$, ergibt sich $T^* \leq \lceil 1/\delta \rceil$.

Schritt 3: Endlichkeit. Sobald alle überschüssigen Kantengewichte 0 erreicht haben, ist $W(t) = W^*$ und $V(t) = 0$. Da es nur endlich viele Kanten gibt und jede in endlicher Zeit $\leq \lceil 1/\delta \rceil$ auf 0 fällt, ist die Gesamtkonvergenz in endlicher Zeit garantiert. $\square$




Abbildung 5.10: (a) Konvergenz des Kopplungsgrades $c(t) \rightarrow c^*$ für verschiedene Startkonfigurationen. (b) Logarithmische Darstellung der Abweichung $|c(t) - c^*|$: die lineare Abnahme auf der log-Skala bestätigt die geometrische Konvergenzrate.

5.9.4 Spektrale Stabilitätsanalyse

Definition 5.9.5 (Ansteckungsmatrix). Die Ansteckungsmatrix $\Lambda(t) = c(t) \cdot \phi \cdot W(t)/(N-1)$ beschreibt die Intensität der Schockpropagation im Netzwerk. Das System ist *spektral stabil*, wenn der Spektralradius $\varrho(\Lambda(t)) = \max_i |\lambda_i(\Lambda(t))| < 1$.

Satz 5.5 (Spektrale Konvergenz). Unter der Iteration $W(t+1) = \mathcal{S}(W(t))$ gilt:

$$\varrho(\Lambda(t)) \rightarrow \varrho(\Lambda^*) < 1$$

für $t \rightarrow \infty$, wobei $\Lambda^* = c^* \phi W^*/(N-1)$.

Beweis. Da $W(t) \rightarrow W^*$ komponentenweise (Satz 5.4), gilt für die Ansteckungsmatrix $\Lambda(t) = c(t) \phi W(t)/(N-1) \rightarrow c^* \phi W^*/(N-1) = \Lambda^*$ komponentenweise. Der Spektralradius $\varrho(\cdot)$ ist stetig (da Eigenwerte stetige Funktionen der Matrixeinträge sind, vgl. Weyl'sche Störungstheorie), also $\varrho(\Lambda(t)) \rightarrow \varrho(\Lambda^*)$. Der Referenzgraph G^* ist so gewählt, dass $c^* < c_{\text{krit}}^*$ (Pareto-Optimum liegt in der Stabilitätszone), woraus $\varrho(\Lambda^*) < 1$ folgt. $\square$




Abbildung 5.11: Spektralradius $\rho(\Lambda(t))$ der Ansteckungsmatrix unter Subgraph-Operator-Iteration. Alle Trajektorien fallen unter die Stabilitätsgrenze $\rho = 1$ und konvergieren gegen $\rho^* < 1$.

5.9.5 Phasenraumanalyse und Attraktor

Die Kombination aus Kopplungsgrad $c(t)$ und Spektralradius $\rho(t)$ definiert einen zweidimensionalen Zustandsraum, in dem die Trajektorie des Wirtschaftsgraphen unter $\mathcal{S}$ visualisiert werden kann.

Definition 5.9.6 (Stabilitätsattraktor). Der Punkt (c^*, ρ^*) im (c, ρ) -Phasenraum heißt *Stabilitätsattraktor* des Systems, wenn jede Trajektorie unter $\mathcal{S}$ gegen (c^*, ρ^*) konvergiert.

Satz 5.6 (Globaler Attraktor). Unter den Voraussetzungen von Satz 5.4 ist (c^*, ρ^*) ein *globaler Attraktor*: Für jeden Startzustand $W(0)$ mit $w_{ij}(0) \in [0, 1]$ gilt

$$(c(t), \rho(\Lambda(t))) \rightarrow (c^*, \rho^*) \quad \text{für } t \rightarrow \infty.$$

Beweis. Aus Satz 5.4 folgt $W(t) \rightarrow W^*$, also $c(t) \rightarrow c^*$. Aus Satz 5.5 folgt $\rho(\Lambda(t)) \rightarrow \rho^*$. Da beide Koordinaten konvergieren, konvergiert das Paar $(c(t), \rho(t)) \rightarrow (c^*, \rho^*)$. Die Globalität folgt daraus, dass keine Beschränkung an $W(0)$ gestellt wird außer $w_{ij}(0) \in [0, 1]$. $\square$




Abbildung 5.12: Phasendiagramm (c, ρ) : Trajektorien aus vier Startkonfigurationen (Punkte) konvergieren alle zum globalen Attraktor $\star$ im Stabilitätsbereich (grün). Die Stabilitätsgrenze $\rho_s(c)$ (gestrichelt) trennt stabile von instabilen Zuständen.

5.9.6 Wirkung auf die Graphstruktur und Krisenresistenz




Abbildung 5.13: Schrittweise Wirkung des Subgraph-Operators auf die Adjazenzmatrix: Der Kopplungsgrad fällt von $c = 0.702$ (überkoppelt) in zwei Iterationen auf $c = 0.393$ (annähernd Referenz $c^* = 0.357$). Helle Felder zeigen gelöschte Kanten.




Abbildung 5.14: Krisenresistenz im direkten Vergleich. (a) Ohne Subgraph-Operator: der exogene Schock bei $t = 8$ breitet sich systemweit aus, Erholung dauert über 20 Schritte. (b) Mit Subgraph-Operator (blaue Markierungen: aktive Iterationen): die Systemgesundheit stabilisiert sich rasch, da der Kopplungsgrad parallel zum Schock reduziert wird.

Korollar 5.3 (Krisenresistenz durch algorithmische Steuerung). Ein Wirtschaftsnetzwerk, auf dem der Subgraph-Stabilisierungsoperator $\mathcal{S}$ mit Periode τ angewendet wird, ist krisenresistenter als ein statisches Netzwerk gleicher Anfangskopplung. Formal: Sei $h_{\mathcal{S}}(t)$ die mittlere Systemgesundheit unter $\mathcal{S}$ und $h_0(t)$ ohne Operator. Dann gilt für alle $t \geq \tau$:

$$\mathbb{E}[h_{\mathcal{S}}(t)] \geq \mathbb{E}[h_0(t)].$$

Beweis. Nach Lemma 5.9.3 gilt $c_{\mathcal{S}}(t) \leq c_0 = c(0)$ für alle $t \geq \tau$. Aus Satz 5.3 folgt, dass niedrigerer Kopplungsgrad zu höherer mittlerer Systemgesundheit führt: $c_{\mathcal{S}}(t) \leq c_0$ impliziert $\mathbb{E}[h_{\mathcal{S}}(t)] \geq \mathbb{E}[h_0(t)]$. $\square$

5.9.7 Laufzeitkomplexität des Stabilisierungsoperators

Satz 5.7 (Komplexität einer Operatoriteration). Eine einzelne Anwendung von $\mathcal{S}$ auf einen Graphen mit N Knoten hat Laufzeit $O(N^3)$.

Beweis. Für jede der N^2 Kanten (i, j) führt $\mathcal{S}$ einen Subgraph-Check auf einem 2-Knoten-Teilgraphen gegen G^* durch. Dieser Check hat nach [Epp, 2026c] Laufzeit $O(n^3)$ für n -Knoten-Graphen; für den 2-Knoten-Teilgraphen ist $n = 2$, also $O(1)$. Die Gesamtlaufzeit für alle N^2 Kanten ist $O(N^2)$. Hinzu kommen die Signaturberechnungen für den vollständigen Referenzabgleich in $O(N^3)$ (gemäß Laufzeitsatz des Subgraph Algorithmus). Insgesamt ergibt sich $O(N^2) + O(N^3) = O(N^3)$. $\square$

Korollar 5.4. Das vollständige Stabilisierungsverfahren bis zur Konvergenz benötigt $O(N^3 \cdot \lceil 1/\delta \rceil)$ Gesamtoperationen. Für $\delta = \Theta(1)$ ergibt sich $O(N^3)$.

5.10 Dynamische Graphen: Zeitvariante Wirtschaftszellen

5.10.1 Motivation und Problemstellung

Die bisherige Behandlung des Wirtschaftsgraphen $\mathcal{G} = (\mathcal{Z}, \mathcal{E}, w)$ hat die Gewichtsmatrix W als zeitlich konstant betrachtet. In realen Wirtschaftssystemen ist diese Annahme jedoch eine grobe Vereinfachung: Handelsbeziehungen, Kapitalflüsse und institutionelle Kopplungen unterliegen einer kontinuierlichen zeitlichen Variation durch Konjunkturzyklen, geopolitische Ereignisse, technologische Disruption und endogene Anpassungsreaktionen der Akteure.

Definition 5.10.1 (Zeitvarianter Wirtschaftsgraph). Ein *zeitvarianter Wirtschaftsgraph* ist eine Familie $\{\mathcal{G}(t)\}_{t \geq 0}$ von gewichteten Graphen mit gemeinsamer Knotenmenge $\mathcal{Z}$ und zeitabhängiger Gewichtsmatrix $W : \mathbb{R}_{\geq 0} \rightarrow [0, 1]^{N \times N}$,

$$\mathcal{G}(t) = (\mathcal{Z}, \mathcal{E}(t), W(t)), \quad \mathcal{E}(t) = \{(i, j) : w_{ij}(t) > 0\}.$$

Der zeitvariante Kopplungsgrad ist $c(t) = \frac{1}{N(N-1)} \sum_{i \neq j} w_{ij}(t) \in [0, 1]$.

Wir unterscheiden drei grundlegende Klassen zeitlicher Dynamiken, die in Abbildung 5.15 illustriert sind:

- **Graduelle Kopplung** (Globalisierungsregime): $c(t)$ wächst monoton mit kleinen stochastischen Fluktuationen.
- **Schockdekopplung** (Krisendekopplung): $c(t)$ fällt nach einem exogenen Schock t^* schnell ab.
- **Zyklische Fluktuation**: $c(t)$ oszilliert periodisch, z. B. entlang von Konjunkturzyklen.




Abbildung 5.15: (a) Trajektorien des Kopplungsgrades unter drei Regime-Typen. (b) Phasenporträt $(c(t), \dot{c}(t))$: Das zyklische Regime bildet eine geschlossene Kurve (Grenzzyklus), während Globalisierung und Krisenregime offene Trajektorien aufweisen.

5.10.2 Kontinuierliche Dynamik: Differentialgleichungsmodell

Definition 5.10.2 (Kopplungsdynamik). Die zeitliche Entwicklung des Kopplungsgrades wird durch die Differentialgleichung

$$\dot{c}(t) = \mu_c(c(t), t) + \sigma_c(c(t)) \dot{W}(t) \quad (5.1)$$

beschrieben, wobei $\mu_c : [0, 1] \times \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}$ die *Driftfunktion*, $\sigma_c : [0, 1] \rightarrow \mathbb{R}_{\geq 0}$ die *Diffusionsfunktion* und $W(t)$ ein Standard-Wiener-Prozess ist.

Definition 5.10.3 (Mean-Reversion-Dynamik). Ein besonders wichtiger Spezialfall von (5.1) ist der *Ornstein-Uhlenbeck-Prozess* auf $[0, 1]$:

$$dc(t) = \kappa(c^* - c(t)) dt + \sigma \sqrt{c(t)(1 - c(t))} dW(t), \quad (5.2)$$

wobei $\kappa > 0$ die Mean-Reversion-Geschwindigkeit, $c^* \in (0, 1)$ der Gleichgewichtskopplungsgrad und $\sigma > 0$ die Volatilität des Prozesses bezeichnet.

Satz 5.8 (Stationäre Verteilung). Der Prozess (5.2) besitzt eine eindeutige stationäre Verteilung p_∞ auf $(0, 1)$, die durch eine Beta-Verteilung approximiert wird:

$$p_\infty(c) \approx \text{Beta}(\alpha, \beta), \quad \alpha = c^* \left(\frac{c^*(1 - c^*)}{\sigma^2} - 1 \right), \quad \beta = (1 - c^*) \left(\frac{c^*(1 - c^*)}{\sigma^2} - 1 \right).$$

Beweis. Für den Diffusionsprozess (5.2) auf $(0, 1)$ lautet die Fokker-Planck-Gleichung für die stationäre Dichte $p_\infty(c)$:

$$0 = -\frac{\partial}{\partial c} [\kappa(c^* - c) p_\infty] + \frac{1}{2} \frac{\partial^2}{\partial c^2} [\sigma^2 c(1 - c) p_\infty].$$

Dieser Operator stimmt mit dem Generator einer Beta-Verteilung überein, wenn die Koeffizientenabgleichung

$$\kappa(c^* - c) = \frac{\sigma^2}{2} [\alpha(1 - c) - \beta c]$$

erfüllt ist. Koeffizientenvergleich liefert $\alpha = 2\kappa c^*/\sigma^2$ und $\beta = 2\kappa(1 - c^*)/\sigma^2$, was mit den angegebenen Formeln für $\kappa \gg \sigma^2$ übereinstimmt. Die Eindeutigkeit der stationären Verteilung folgt aus der Irreduzibilität und positiven Rekurrenz des Prozesses auf dem kompakten Intervall $(0, 1)$ (Feller-Kriterium). $\square$

Plot D3 -- Stochastische Kopplung: Ito-SDE-Dynamik des Kopplungsgrades




Abbildung 5.16: (a) Ito-Pfade des Kopplungsgrades: fünf Realisierungen des Mean-Reversion-Prozesses mit verschiedenen Startwerten, alle konvergieren zur Umgebung von $c^* = 0,30$. (b) Stationäre Verteilung $p_\infty(c)$: empirisches Histogramm (blau) und Beta-Approximation (rot) stimmen gut überein.

5.10.3 Sprungprozesse und Strukturbrüche

Neben kontinuierlichen Fluktuationen treten in realen Wirtschaftsgraphen diskrete Strukturbrüche auf — abrupte Änderungen der Netzwerktopologie durch geopolitische Ereignisse, Finanzkrisen oder Pandemien.

Definition 5.10.4 (Sprung-Diffusions-Prozess). Sei $(J_k)_{k \geq 1}$ eine Folge unabhängiger Sprunggrößen mit $J_k \sim \mathcal{N}(\mu_J, \sigma_J^2)$ und $(N_t)_{t \geq 0}$ ein Poisson-Prozess mit Intensität $\lambda > 0$. Der *Sprung-Diffusions-Kopplungsgrad* ist

$$dc(t) = \kappa(c^* - c(t)) dt + \sigma_d dW(t) + d\left(\sum_{k=1}^{N_t} J_k\right). \quad (5.3)$$

Satz 5.9 (Mittlere Erholungszeit nach Strukturbruch). Nach einem einzelnen Sprung der Größe $J < 0$ (Dekopplung durch Krise) ist die erwartete Rückkehrzeit des Prozesses (5.3) zur ε -Umgebung von c^* :

$$\mathbb{E}[\tau_\varepsilon] \leq \frac{1}{\kappa} \ln\left(\frac{|J|}{\varepsilon}\right) + \frac{\sigma_d^2}{2\kappa^2 \varepsilon},$$

wobei $\tau_\varepsilon = \inf\{t > 0 : |c(t) - c^*| < \varepsilon\}$.

Beweis. Ohne Diffusion ($\sigma_d = 0$) löst die ODE $\dot{c} = \kappa(c^* - c)$ nach dem Sprung zum Zeitpunkt t_0 mit Anfangswert $c(t_0) = c^* + J$:

$$c(t) = c^* + J e^{-\kappa(t-t_0)}.$$

Die Abweichung $|c(t) - c^*| = |J|e^{-\kappa(t-t_0)}$ unterschreitet ε nach Zeit $\tau_\varepsilon^0 = \frac{1}{\kappa} \ln(|J|/\varepsilon)$.

Mit Diffusion ($\sigma_d > 0$) ergibt sich eine zusätzliche Streuung. Per Ito-Formel gilt für $V(c) = (c - c^*)^2$:

$$dV = [-2\kappa V + \sigma_d^2] dt + 2\sigma_d(c - c^*) dW.$$

Grönwall-Lemma angewandt auf $\mathbb{E}[V(t)]$ liefert $\mathbb{E}[V(t)] \leq J^2 e^{-2\kappa t} + \frac{\sigma_d^2}{2\kappa}$, woraus $\mathbb{E}[\tau_\varepsilon] \leq \tau_\varepsilon^0 + \frac{\sigma_d^2}{2\kappa^2 \varepsilon}$ folgt. $\square$




Abbildung 5.17: (a) Drei Realisierungen des Sprung-Diffusions-Prozesses: diskrete Sprünge (Krisen) überlagern die kontinuierliche Mean-Reversion. (b) Empirische Wartezeit-Verteilung zwischen Strukturbrüchen folgt einer Exponentialverteilung (rot), wie von der Poisson-Annahme vorhergesagt.

5.10.4 Floquet-Theorie für periodische Wirtschaftsgraphen

Konjunkturzyklen erzeugen periodisch zeitvariante Graphen. Die Stabilitätsanalyse solcher Systeme erfordert die Floquet-Theorie.

Definition 5.10.5 (Periodisches Wirtschaftssystem). Ein zeitvariantes Wirtschaftssystem heißt *T-periodisch*, wenn $W(t + T) = W(t)$ für alle $t \geq 0$. Das zugehörige linearisierte Systemdynamik ist

$$\dot{x}(t) = A(t)x(t), \quad A(t + T) = A(t), \quad (5.4)$$

wobei $A(t) = -\kappa \text{Id} + \mu W(t)$ die zeitvariante Systemmatrix ist.

Definition 5.10.6 (Monodromiematrix und Floquet-Multiplikatoren). Die *Monodromiematrix* des Systems (5.4) ist die Fundamentalmatrixlösung nach einer vollen Periode:

$$\Phi_T = \mathcal{T} \exp \left(\int_0^T A(s) ds \right),$$

wobei $\mathcal{T}$ den Zeitordnungsoperator bezeichnet. Die Eigenwerte $\mu_1, \dots, \mu_N$ von Φ_T heißen *Floquet-Multiplikatoren*.

Satz 5.10 (Floquet-Stabilitätskriterium). Das periodische System (5.4) ist genau dann asymptotisch stabil, wenn alle Floquet-Multiplikatoren innerhalb des Einheitskreises liegen:

$$|\mu_i| < 1 \quad \forall i \in \{1, \dots, N\}.$$

Beweis. Nach dem Floquet-Theorem existiert eine T -periodische Matrix $P(t)$ und eine konstante Matrix R mit $\Phi(t) = P(t)e^{Rt}$, wobei $e^{RT} = \Phi_T$. Eine Lösung $x(t) = \Phi(t)x_0$ wächst genau dann nicht exponentiell, wenn $\|e^{Rt}\|$ beschränkt bleibt, d. h. wenn alle Eigenwerte λ_i von R den Realteil $\text{Re}(\lambda_i) \leq 0$ haben. Da $e^{\lambda_i T} = \mu_i$, ist $\text{Re}(\lambda_i) < 0$ äquivalent zu $|\mu_i| = |e^{\lambda_i T}| = e^{T \text{Re}(\lambda_i)} < 1$. Asymptotische Stabilität erfordert strikte Ungleichung. $\square$




Abbildung 5.18: (a) Floquet-Multiplikatoren des periodischen Wirtschaftssystems: alle Punkte liegen innerhalb des Einheitskreises ($|\mu_i| < 1$), das System ist asymptotisch stabil. (b) Zeitvarianter Spektralradius $\varrho(\Lambda(t))$ über zwei Perioden: Phasen mit $\varrho > 1$ (instabile Phasen, rot) wechseln mit stabilen Phasen (grün).

5.10.5 Zeitvariante Resilienz

Definition 5.10.7 (Zeitvariante Resilienz). Die *zeitvariante Resilienz* eines dynamischen Wirtschaftsgraphen ist

$$R(t) = \exp\left(-\alpha(c(t) - c_0)^2\right) \cdot (1 - \beta c(t)), \quad \alpha, \beta, c_0 > 0,$$

wobei c_0 das Resilienzmaximum und β die lineare Dämpfung bezeichnet.

Definition 5.10.8 (Integrale Resilienz). Die *integrale Resilienz* über den Horizont $[0, T]$ ist

$$\bar{R}(T) = \frac{1}{T} \int_0^T R(t) dt.$$

Satz 5.11 (Resilienz unter zyklischer Kopplung). Sei $c(t) = c_0 + A \sin(\omega t)$ mit Amplitude $A < c_0$. Dann gilt für die integrale Resilienz im Grenzwert langer Beobachtungszeiten:

$$\lim_{T \rightarrow \infty} \bar{R}(T) = (1 - \beta c_0) e^{-\alpha A^2/2} \cdot I_0(\alpha A^2/2),$$

wobei I_0 die modifizierte Bessel-Funktion nullter Ordnung bezeichnet.

Beweis. Wir berechnen den Zeitmittelwert von $R(t) = e^{-\alpha(c(t)-c_0)^2} (1 - \beta c(t))$:

$$\lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T R(t) dt = \frac{1}{2\pi} \int_0^{2\pi} e^{-\alpha A^2 \sin^2 \theta} (1 - \beta c_0 - \beta A \sin \theta) d\theta.$$

Da $\int_0^{2\pi} \sin \theta g(\sin^2 \theta) d\theta = 0$ für jede gerade Funktion g , fällt der $\sin \theta$ -Term weg. Der verbleibende Integral ist

$$(1 - \beta c_0) \cdot \frac{1}{2\pi} \int_0^{2\pi} e^{-\alpha A^2 \sin^2 \theta} d\theta = (1 - \beta c_0) e^{-\alpha A^2/2} I_0(\alpha A^2/2),$$

wobei die letzte Gleichheit aus der Integraldarstellung der modifizierten Bessel-Funktion $I_0(z) = \frac{1}{2\pi} \int_0^{2\pi} e^{z \cos \theta} d\theta$ mit $z = \alpha A^2/2$ und der Substitution $\cos \theta \rightarrow -\sin^2 \theta + \text{const}$ folgt. $\square$




Abbildung 5.19: (a) Zeitvariante Resilienz $R(t)$ (durchgezogen) und Kopplungsgrad $c(t)$ (gepunktet) für drei Regime-Typen. Das Globalisierungsregime zeigt monoton fallende Resilienz; der Krisenzyklus kehrt nach dem Tief um. (b) Integrale Resilienz $\bar{R}(T)$: langfristig dominiert das stabile Regime.

5.10.6 Snapshot-Sequenz und zeitvariante Topologie

Ein zeitvarianter Graph kann als Sequenz von Snapshots $W(t_0), W(t_1), \dots, W(t_K)$ zu diskreten Zeitpunkten dargestellt werden.

Definition 5.10.9 (Snapshot-Folge). Die *Snapshot-Folge* $\mathbf{W} = (W^{(0)}, W^{(1)}, \dots, W^{(K)})$ ist eine endliche Approximation des zeitvarianten Graphen mit $W^{(k)} = W(k \cdot \Delta t)$ für ein Zeitinkrement $\Delta t > 0$.

Lemma 5.10.10 (Approximationsfehler der Snapshot-Folge). Sei $W(t)$ Lipschitz-stetig mit Konstante $L > 0$, d. h. $\|W(t) - W(s)\|_F \leq L|t - s|$ für alle $t, s \geq 0$. Dann gilt

$$\sup_{t \in [k\Delta t, (k+1)\Delta t]} \|W(t) - W^{(k)}\|_F \leq L \cdot \Delta t.$$

Beweis. Unmittelbar aus der Lipschitz-Bedingung: Für $t \in [k\Delta t, (k+1)\Delta t]$ gilt $|t - k\Delta t| \leq \Delta t$, also $\|W(t) - W^{(k)}\|_F = \|W(t) - W(k\Delta t)\|_F \leq L|t - k\Delta t| \leq L \cdot \Delta t$. $\square$




Abbildung 5.20: Snapshot-Sequenz der Gewichtsmatrix $W(t)$: Vier Zeitpunkte zeigen die Topologieänderung von $t = 0$ (dichtes Netz, $c = 0,55$) über den Schock bei $t = 20$ bis zur Erholung und neuem Gleichgewicht bei $t = 60$ (gelockerte Struktur, $c = 0,34$).

5.10.7 Adaptiver Subgraph-Operator auf dynamischen Graphen

Der in Abschnitt 5.9 eingeführte Subgraph-Stabilisierungsoperator $\mathcal{S}$ wurde für zeitkonstante Referenzgraphen G^* entwickelt. Im zeitvarianten Fall muss der Operator auf einen sich ebenfalls verändernden Referenzpfad $c^*(t)$ ausgerichtet werden.

Definition 5.10.11 (Adaptiver Subgraph-Operator). Sei $c^*(t)$ der zeitvariante Pareto-optimale Referenzpfad. Der *adaptive Subgraph-Stabilisierungsoperator* ist

$$[\mathcal{S}_t(W)]_{ij} = \begin{cases} w_{ij} & \text{falls } |w_{ij} - w_{ij}^*(t)| \leq \varepsilon \\ w_{ij} - \delta(t) \operatorname{sgn}(w_{ij} - w_{ij}^*(t)) & \text{sonst} \end{cases}$$

mit zeitvariantem Dämpfungsparameter $\delta(t) = \delta_0 |c(t) - c^*(t)|$.

Satz 5.12 (Tracking-Konvergenz des adaptiven Operators). Sei $e(t) = |c(t) - c^*(t)|$ der Tracking-Fehler. Unter der Annahme, dass $c^*(t)$ Lipschitz-stetig mit Konstante $L^* > 0$ ist und $\delta_0 > L^*/\kappa$, gilt

$$\limsup_{t \rightarrow \infty} e(t) \leq \frac{L^*}{\delta_0 \kappa - L^*}.$$

Beweis. Wir betrachten die Lyapunov-Funktion $V(t) = e(t)^2 = (c(t) - c^*(t))^2$. Ihre zeitliche Ableitung entlang der adaptierten Systemtrajektorie ist

$$\begin{aligned} \dot{V}(t) &= 2e(t) \left(\dot{c}(t) - \dot{c}^*(t) \right) \\ &= 2e(t) \left(-\delta(t) \kappa \operatorname{sgn}(e(t)) - \dot{c}^*(t) \right) \\ &= -2\delta_0 \kappa e(t)^2 + 2e(t) \left(-\dot{c}^*(t) \right). \end{aligned}$$

Da $|\dot{c}^*(t)| \leq L^*$ (Lipschitz), folgt mit Young'scher Ungleichung:

$$\dot{V}(t) \leq -2\delta_0 \kappa V(t) + 2L^* \sqrt{V(t)} \leq -(2\delta_0 \kappa - L^*/\sqrt{V}) V(t).$$

Für $V(t) > \left(\frac{L^*}{\delta_0 \kappa - L^*/2} \right)^2$ ist $\dot{V}(t) < 0$, d. h. $V(t)$ fällt. Der invariante Bereich ist daher $e(t) \leq \frac{L^*}{\delta_0 \kappa - L^*}$. $\square$

Plot D6 -- Adaptives Tracking des Pareto-Referenzpfades durch den Subgraph-Operator




Abbildung 5.21: (a) Tracking des zeitvarianten Referenzpfades $c^*(t)$ (grau gestrichelt): der adaptive Operator (grün) folgt dem Referenzpfad deutlich enger als das System ohne Operator (rot). (b) Tracking-Fehler $|c(t) - c^*(t)|$: die durch den Operator erzielte Verbesserung (blau) ist über alle Zeitschritte konsistent.

Korollar 5.5 (Optimale Dämpfungsrate). Der Tracking-Fehler wird minimiert für $\delta_0^* = \arg \min_{\delta_0 > L^*/\kappa} \frac{L^*}{\delta_0 \kappa - L^*} + \gamma \delta_0$, wobei $\gamma > 0$ einen Regularisierungsterm für Übersteuerung darstellt. Die Lösung ist $\delta_0^* = \frac{1}{\kappa} \left(L^* + \sqrt{L^* \gamma} \right)$.

Beweis. Die Zielfunktion $f(\delta_0) = \frac{L^*}{\delta_0 \kappa - L^*} + \gamma \delta_0$ ist konvex auf $(\frac{L^*}{\kappa}, \infty)$. Ableitung gleich null:

$$f'(\delta_0) = -\frac{L^* \kappa}{(\delta_0 \kappa - L^*)^2} + \gamma = 0 \Rightarrow (\delta_0 \kappa - L^*)^2 = \frac{L^* \kappa}{\gamma} \Rightarrow \delta_0^* = \frac{1}{\kappa} \left(L^* + \sqrt{\frac{L^* \kappa}{\gamma}} \right).$$

Da $f''(\delta_0^*) > 0$, ist dies ein globales Minimum. $\square$

5.11 Zusammenfassung der Beweise

Wir fassen die in dieser Arbeit formal nachgewiesenen Ergebnisse zusammen.

Tabelle 5.1: Übersicht der Hauptergebnisse

Nr.	Ergebnis	Kernaussage
Lemma 5.3.3	Spektraleigenschaften	$\lambda_{\max}(W_{\text{dez}}) \ll \lambda_{\max}(W_{\text{mono}})$
Satz 5.1	Resilienz-Kopplung-Inkompat.	$c = 1$ maximiert Risiko und minimiert Resilienz
Satz 5.2	Positives Risikoexposure	$\rho < \frac{\sigma_h}{2(1-\alpha)\sigma_e}$ garantiert Varianzreduktion
Korollar 1	Hedge-Effekt	Schaden reduziert um Faktor $(1 - \alpha)$
Satz 5.3	Krisenausbreitung	Systemgesundheit monoton fallend in c
Proposition 5.7.1	Währungseffekt	Währungsunion erhöht c strukturell
Lemma 5.9.3	Monotone c -Abnahme	$\mathcal{S}$ reduziert $c(t)$ in jedem Schritt
Lemma 5.9.4	Lyapunov-Funktion	$V(t) = \ W(t) - W^*\ _F^2$ streng fallend
Satz 5.4	Globale Stabilität	$W(t) \rightarrow W^*$ in $\leq \lceil 1/\delta \rceil$ Schritten
Satz 5.5	Spektrale Konvergenz	$\varrho(\Lambda(t)) \rightarrow \varrho^* < 1$
Satz 5.6	Globaler Attraktor	$(c(t), \varrho(t)) \rightarrow (c^*, \varrho^*)$ global
Korollar 5.3	Krisenresistenz	$\mathbb{E}[h_{\mathcal{S}}(t)] \geq \mathbb{E}[h_0(t)]$
Satz 5.7	Komplexität $\mathcal{S}$	$O(N^3)$ pro Iteration, $O(N^3)$ gesamt
Satz 5.8	Stationäre Verteilung	$p_{\infty}(c) \approx \text{Beta}(\alpha, \beta)$, eindeutig (Feller-Krit.)
Satz 5.9	Mittlere Erholungszeit	$\mathbb{E}[\tau_{\varepsilon}] \leq \frac{1}{\kappa} \ln \frac{ J }{\varepsilon} + \frac{\sigma_d^2}{2\kappa^2 \varepsilon}$
Satz 5.10	Floquet-Stabilität	$ \mu_i < 1 \forall i \Leftrightarrow$ asymptotische Stabilität
Satz 5.11	Integrale Resilienz	$\lim_{T \rightarrow \infty} \bar{R}(T) = (1 - \beta c_0) e^{-\alpha A^2/2} I_0(\alpha A^2/2)$
Lemma 5.10.10	Snapshot-Approximation	$\ W(t) - W^{(k)}\ _F \leq L \cdot \Delta t$
Satz 5.12	Tracking-Konvergenz	$\limsup_{t \rightarrow \infty} c(t) - c^*(t) \leq \frac{L^*}{\delta_0 \kappa - L^*}$
Korollar 5.5	Optimale Dämpfungsrate	$\delta_0^* = \frac{1}{\kappa} (L^* + \sqrt{L^* \gamma})$

5.12 Ausblick

5.12.1 Theoretische Erweiterungen

5.12.1.1 Dynamische Kopplungsanpassung

Das in dieser Arbeit entwickelte Modell behandelt den Kopplungsgrad c als exogen fixierten Parameter. Eine natürliche Erweiterung besteht in der Betrachtung *endogener Kopplung*: Wirtschaftsakteure passen ihre Inter-Zell-Verbindungen adaptiv an, um ihren Nutzen zu maximieren. Formal ließe sich dies als kontinuierliches Kontrollproblem

$$\max_{\{c(t)\}_{t \geq 0}} \int_0^\infty e^{-\delta t} \left[\omega g(c(t)) + (1 - \omega) R(c(t)) - \kappa \dot{c}(t)^2 \right] dt$$

modellieren, wobei κ die Anpassungskosten bezeichnet [Caballero & Simsek, 2009]. Die Hamilton-Jacobi-Bellman-Gleichung dieses Problems besitzt unter Regularitätsannahmen eine eindeutige Viskositätslösung, deren Charakterisierung ein offenes Forschungsproblem darstellt.

5.12.1.2 Stochastische Kopplungsmatrix und zeitvariante Prozesse höherer Ordnung

In der Realität sind die Verbindungsstärken w_{ij} nicht konstant, sondern unterliegen selbst stochastischen Prozessen – etwa durch Wechselkursschwankungen, geopolitische Ereignisse oder technologische Disruption. Kapitel 5.10 hat gezeigt, dass der Mean-Reversion-Prozess (5.2) eine Beta-stationäre Verteilung besitzt. Ein noch realistischeres Modell mit zufälliger Matrix $W(t) = \bar{W} + \sigma_W \cdot B(t)$ (matrixwertiger Brown'scher Störung) würde Ergebnisse aus der Theorie zufälliger Matrizen (Random Matrix Theory) [Mehta, 2004] zugänglich machen und erlaubt Aussagen über die Verteilung der systemischen Risikomaße. Von besonderem Interesse ist hierbei das Marčenko-Pastur-Gesetz, das die Eigenwertverteilung großer zufälliger Wishart-Matrizen beschreibt und unmittelbar auf die spektrale Stabilitätsanalyse (Satz 5.10) übertragbar ist. Eine offene Forschungsfrage lautet, ob der Floquet-Stabilitätssatz für den Fall einer stochastischen Monodromiematrix $\Phi_T(\omega)$ verallgemeinert werden kann — dies erfordert Methoden der zufälligen Spektraltheorie und der Lyapunov-Exponenten stochastischer Differentialgleichungen [?].

5.12.1.3 Mehrskalen-Dynamik und Zeitskalen-Separation

Reale Wirtschaftsgraphen weisen Dynamiken auf mehreren Zeitskalen gleichzeitig auf: schnelle Anpassungen auf Finanzmärkten (Millisekunden bis Tage), mittelfristige Konjunkturzyklen (Quartale bis Jahre) und langfristige Strukturwandlungen (Dekaden). Die in Kapitel 5.10 verwendete einzelne Zeitskala ist daher eine Vereinfachung. Eine Mehrskalenanalyse nach der Methode der singulären Störungstheorie [Kokotović et al., 1999] würde eine systematische Separation dieser Skalen erlauben: Für $\varepsilon \rightarrow 0$ kann das Schnell-Langsam-System

$$\dot{c}_{\text{langsam}} = f(c_{\text{langsam}}, c_{\text{schnell}}, t), \quad \varepsilon \dot{c}_{\text{schnell}} = g(c_{\text{langsam}}, c_{\text{schnell}}, t)$$

auf ein reduziertes System auf der Slow-Manifold approximiert werden. Der adaptive Subgraph-Operator $\mathcal{S}_t$ müsste dann auf jeder Zeitskala mit angepasster Dämpfungsrate δ_0 betrieben werden; Korollar 5.5 liefert dabei die skalenspezifischen Optimalwerte.

5.12.1.4 Lernende Referenzgraphen und Reinforcement Learning

Der zeitvariante Referenzpfad $c^*(t)$ in Definition 5.10.11 wurde als exogen gegeben angenommen. In der Praxis muss $c^*(t)$ selbst aus Beobachtungen des Systems gelernt werden. Dies führt auf ein *Reinforcement-Learning*-Problem, bei dem der adaptive Subgraph-Operator als Regelungsagent fungiert, der auf Basis von Belohnungssignalen (Resilienz, Wachstum) den optimalen Referenzpfad adaptiv schätzt [Sutton & Barto, 2018]. Der Zustandsraum ist die Menge aller Adjazenzmatrizen $W \in [0, 1]^{N \times N}$, der Aktionsraum die möglichen Operatoranwendungen $\mathcal{S}_t$, und die Belohnungsfunktion eine gewichtete Kombination aus $R(t)$ und $g(t)$ gemäß der Pareto-Zielfunktion aus Abschnitt 8. Die Konvergenzgarantien aus Satz 5.12 liefern dabei eine theoretische Grundlage für die Sample-Komplexität des Lernproblems.

5.12.1.5 Heterogene Zellengrößen und Gewichte

Das vorliegende Modell nimmt der Einfachheit halber homogene Zellen an ($\sigma_i = \sigma$, $\mu_i = \mu$). Eine Erweiterung auf heterogene Zellen – mit unterschiedlichen Größen, Entwicklungsniveaus und sektoralen Strukturen – erfordert eine verallgemeinerte Portfoliotheorie und eröffnet Fragen nach optimaler *Allokation* von Produktionskapazitäten zwischen Zellen [Markowitz, 1952].

5.12.1.6 Nicht-lineare Ansteckungsdynamiken

Die in Abschnitt 5 modellierte lineare Ansteckungsdynamik ist eine Vereinfachung. Empirische Evidenz deutet auf nicht-lineare Schwellenwerteffekte hin: Unterhalb einer kritischen Schockgröße ε^* ist die Ausbreitung begrenzt; oberhalb davon kann es zu kaskadierenden Ausfällen kommen (“tipping points”) [May et al., 2008]. Ein Modell mit bi-stabiler Dynamik

$$\dot{h}_i = r_i h_i (1 - h_i) - c \sum_j w_{ij} (1 - h_j)$$

würde diese Nichtlinearität erfassen und könnte mittels bifurkationstheoretischer Methoden analysiert werden.

5.12.1.7 Quantifizierung des positiven Risikoexposures

Die in Satz 5.2 abgeleitete Bedingung für positives Risikoexposure stellt eine hinreichende, aber nicht notwendige Bedingung dar. Eine vollständige Charakterisierung aller Situationen, in denen ausgelagerte Produktion den Gesamtnutzen steigert, erfordert die Lösung eines mehrstufigen stochastischen Optimierungsproblems. Methoden der Robust Optimization [Ben-Tal et al., 2009] könnten hier besonders geeignet sein, da sie keine vollständige Kenntnis der Wahrscheinlichkeitsverteilungen erfordern.

5.12.2 Institutionelles und politisches Design

5.12.2.1 Regulatorischer Rahmen für Dezentralisierung

Dezentrale Wirtschaftszellen erfordern neue regulatorische Konzepte. Der klassische Ansatz zentralisierter Regulierung (Einheitsnormen, harmonisierte Gesetzgebung) ist unter dem DWZ-Modell kontraproduktiv, da er Kopplung erzeugt, ohne die Resilienzvorteile

zu nutzen. Vielversprechender erscheint ein Modell der *regulatorischen Subsidiarität* kombiniert mit einem *Resilienzaudit*: Wirtschaftszellen erhalten volle regulatorische Autonomie, müssen jedoch periodisch nachweisen, dass ihr Kopplungsgrad $c < c_{\max}$ bleibt [Ostrom, 1990].

5.12.2.2 Gestaltung von Währungssystemen

Proposition 5.7.1 hat weitreichende Implikationen für das internationale Währungsdesign. An Stelle einer vollständigen Währungsunion könnte ein System *partiell konvertibler Gemeinschaftswährungen* treten, die einerseits Transaktionskostenvorteile bieten, andererseits limitierte Wechselkursflexibilität als automatischen Stabilisator erhalten. Konkret ließe sich ein Wechselkursband $[e_{\min}, e_{\max}]$ so kalibrieren, dass der resultierende Kopplungsgrad nahe am Pareto-optimalen c^* liegt.

Historische Präzedenzfälle wie das Bretton-Woods-System (1944–1971) oder das Europäische Währungssystem (1979–1999) können unter diesem Gesichtspunkt neu bewertet werden: Sie stellten Versuche dar, eine mittlere Kopplung durch verwaltete Wechselkurse zu realisieren, scheiterten jedoch an der fehlenden Kalibrierung auf den Pareto-Optimalpunkt [Eichengreen, 1998].

5.12.2.3 Produktionsauslagerung als Staatspolitik

Üblicherweise werden Entscheidungen über Produktionsauslagerung von privaten Unternehmen getroffen. Unter dem DWZ-Modell ergibt sich jedoch eine potenzielle Rolle des Staates: Gezielte staatliche Förderung von Auslandsproduktionen in komplementären Zellen (negativ korrelierte Konjunkturzyklen) kann positives Risikoexposure auf systemischer Ebene erzeugen. Dies entspricht einer verallgemeinerten Form der klassischen Industriepolitik, die nicht auf die Förderung nationaler Champions, sondern auf die Optimierung des Korrelationsmusters des nationalen Produktionsportfolios ausgerichtet ist [Rodrik, 2004].

5.12.2.4 Digitale Währungen und dezentrale Finanzsysteme

Die Entwicklung dezentraler Finanzsysteme (DeFi) und digitaler Zentralbankwährungen (CBDCs) eröffnet neue technische Möglichkeiten zur Implementierung des DWZ-Modells. Smart Contracts könnten automatisch den Kopplungsgrad zwischen Zellen messen und regulieren; algorithmische Währungsmechanismen könnten Wechselkurse präzise auf den Pareto-Optimalpunkt kalibrieren. Gleichzeitig birgt diese Digitalisierung neue Risiken: Systemische Abhängigkeiten durch gemeinsame technische Infrastruktur könnten die Kopplung auf anderer Ebene erhöhen und die Resilienzugewinne der monetären Dezentralisierung zunichte machen [Borio & Restoy, 2021].

5.12.3 Empirische Forschungsagenda

5.12.3.1 Messung des Kopplungsgrades

Eine zentrale empirische Herausforderung ist die Messung des Kopplungsgrades realer Wirtschaftsnetzwerke. Ansätze umfassen:

- Analyse internationaler Handelsmatrizen (UN Comtrade Datenbank)
- Auswertung von Kapitalflussmatrizen (BIS, IWF)

- Konjunkturkorrelationsanalyse (rolling-window cross-correlations der BIP-Zeitreihen)
- Netzwerkzentralitätsmaße (Pagerank, Betweenness) auf Handels- und Finanznetzwerken

Eine methodisch saubere Messung würde erstmals eine empirische Überprüfung von Satz 5.1 ermöglichen.

5.12.3.2 Natürliche Experimente

Die Geschichte bietet mehrere natürliche Experimente für den Vergleich gekoppelter und entkoppelter Systeme:

- Euro-Einführung 1999 (Erhöhung von c in der Eurozone)
- Brexit 2020 (Reduktion von c zwischen UK und EU)
- COVID-19-Lockdowns 2020/21 (erzwungene Entkopplung globaler Lieferketten)
- US-China Handelskrieg 2018–2020 (selektive Entkopplung)

Eine Difference-in-Differences-Analyse dieser Ereignisse könnte kausale Evidenz für die Theorie liefern [Callaway & Sant’Anna, 2021].

5.12.3.3 Agenten-basierte Modellierung

Die analytischen Modelle in dieser Arbeit abstrahieren von individuellen Entscheidungen wirtschaftlicher Akteure. Eine Agenten-basierte Simulation (ABM) würde es ermöglichen, emergente Kopplungsstrukturen aus individuellen Optimierungsentscheidungen abzuleiten und zu untersuchen, unter welchen Anreizbedingungen ein System spontan zum Pareto-optimalen Kopplungsgrad konvergiert [Tesfatsion & Judd, 2006].

5.12.4 Verbindung zu anderen Forschungsfeldern

Das DWZ-Modell berührt und verbindet mehrere klassische Forschungsfelder:

- **Komplexe Systeme und kritische Phänomene:** Der Phasenübergang bei c^* ist analog zum Perkolationsschwellenwert in zufälligen Graphen [Erdős & Rényi, 1960]. Eine Verbindung zur statistischen Mechanik (Ising-Modell, Spin-Glas-Theorie) erscheint fruchtbar.
- **Informatik und Netzwerkdesign:** Die Optimierung dezentraler Netzwerkarchitekturen (P2P-Netze, Content-Delivery-Networks) folgt ähnlichen Prinzipien. Algorithmen zur optimalen Clusterung [von Luxburg, 2007] könnten direkt auf das Zelldesignproblem angewendet werden.
- **Evolutionäre Spieltheorie:** Welche Kopplungsstrategien setzen sich in evolutionären Gleichgewichten durch? Eine Analyse mittels evolutionärer stabiler Strategien (ESS) könnte zeigen, ob c^* evolutionär stabil ist oder ob es Anreize zu individueller Über- oder Unterkopplung gibt [Maynard Smith, 1982].

- **Kontrolltheorie:** Die Systemdynamik entkoppelter Wirtschaftszellen lässt sich als Regelkreisproblem formulieren. Methoden der robusten Regelung (H_∞ -Regelung) könnten zur Bestimmung stabilitätsoptimaler Kopplungsmatrizen eingesetzt werden [?]. Der adaptive Subgraph-Operator $\mathcal{S}_t$ aus Kapitel 5.10 ist formal ein zeitvarianter Feedback-Regler auf dem Graphzustandsraum; seine Analyse im Rahmen der nichtlinearen Regelungstheorie (Lyapunov-basierte Stabilitätsaussagen) wurde in den Sätzen 5.4 und 5.12 bereits begonnen und sollte auf den Fall unstetiger Referenzpfade und stochastischer Störungen ausgedehnt werden.
- **Dynamische Graphentheorie und temporale Netzwerke:** Temporale Netzwerke [Holme & Saramäki, 2012] erweitern die klassische Graphentheorie auf zeitabhängige Strukturen. Konzepte wie zeitlicher Zusammenhang, temporale Erreichbarkeit und zeitvariante Zentralitätsmaße liefern natürliche Werkzeuge zur Analyse der Snapshot-Folgen aus Definition 5.10.9. Insbesondere erlaubt das Konzept der *zeitlichen Pfade* eine Verfeinerung der Schockausbreitungsanalyse aus Abschnitt 6: Ein Schock kann nur entlang zeitlich geordneter Kanten propagieren, was die effektive Ansteckungsrate im dynamischen System gegenüber dem statischen Modell systematisch reduziert.
- **Stochastische Prozesse und Ergodizität:** Satz 5.8 hat die stationäre Verteilung des Kopplungsgrades als Beta-Verteilung charakterisiert. Die Ergodizität des Prozesses — d. h. die Übereinstimmung von Zeit- und Ensemblemittelwerten — ist für die Interpretation empirischer Zeitreihendaten entscheidend: Sie erlaubt es, aus einer einzigen langen Trajektorie $c(t)$ auf die stationäre Verteilung $p_\infty(c)$ zu schließen. Die Ergodizitätsbedingungen für den Sprung-Diffusions-Prozess aus Definition 5.10.4 sind bislang nicht vollständig charakterisiert und stellen ein offenes Problem dar.

5.12.5 Schlussbetrachtung

Diese Arbeit hat gezeigt, dass dezentrale Wirtschaftszellen keine rückwärtsgewandte Utopie sind, sondern ein formal begründbares, mathematisch präzises Organisationsprinzip für robuste wirtschaftliche Systeme. Die zentralen Einsichten — Resilienz-Kopplung-Inkompatibilität, positives Risikoexposure durch Auslagerung, der kopplungsverstärkende Effekt von Währungsunionen, die globale Konvergenzeigenschaft des Subgraph-Operators und die Stabilitätsgarantien für zeitvariante Graphen — ergeben sich zwingend aus den mathematischen Eigenschaften vernetzter stochastischer Systeme.

Kapitel 5.10 hat die statische Sichtweise auf Wirtschaftsgraphen in eine vollständige dynamische Theorie überführt: Der Kopplungsgrad $c(t)$ ist selbst ein stochastischer Prozess mit wohldefinierter stationärer Verteilung, die Systemstabilität lässt sich über Floquet-Multiplikatoren periodischer Regimes exakt charakterisieren, und der adaptive Subgraph-Operator $\mathcal{S}_t$ gewährleistet auch dann Tracking-Konvergenz, wenn sich das Stabilitätsziel $c^*(t)$ zeitlich verändert. Diese Erweiterung ist nicht nur theoretisch bedeutsam — sie ist praktisch notwendig, denn kein reales Wirtschaftsnetzwerk ist statisch.

Der optimale Kopplungsgrad c^* — und in seiner dynamischen Verallgemeinerung $c^*(t)$ — ist kein ideologisches Konzept, sondern eine berechenbare, zeitveränderliche Steuergröße, die empirisch geschätzt, durch den Subgraph Algorithmus verfolgt und algorithmisch durchgesetzt werden kann. Die Zukunft liegt nicht im Rückzug von

internationaler Zusammenarbeit, sondern in ihrer *intelligenten, adaptiven Modularisierung*: Kopplung dort, wo Synergien entstehen; Entkopplung dort, wo systemische Risiken akkumulieren; und algorithmische Neukalibrierung immer dann, wenn sich die Bedingungen ändern.

Das in dieser Arbeit entwickelte formale Fundament — von der statischen Graphentheorie über den Subgraph-Stabilisierungsoperator bis zur stochastischen Differentialgleichung des zeitvarianten Kopplungsgrades — bildet ein kohärentes theoretisches Gerüst, auf dem zukünftige Arbeiten aufbauen können. Die unmittelbar offenen Forschungsfragen betreffen die empirische Kalibrierung von $c^*(t)$ aus realen Handelsdaten, die RL-basierte Implementierung des adaptiven Operators in digitalen Finanzsystemen sowie die vollständige spektraltheoretische Analyse stochastischer Monodromiematrizen.

Kapitel 6

Agrarwirtschaftliches KI-Ökosystem

6.1 Einleitung und Motivation

6.1.1 Ausgangssituation

Die vorliegende Arbeit präsentiert das wissenschaftliche Fundament und die experimentellen Ergebnisse der Arbeitspakete AP5.3 und AP5.4 des AGRI-GAIA Verbundvorhabens. Im Mittelpunkt steht die Entwicklung eines KI-gestützten Klassifikationssystems zur Früherkennung von Kartoffelqualitätsparametern entlang der gesamten Wertschöpfungskette von der Lagerung beim Landwirt bis zur Anlieferung an das Verarbeitungsunternehmen Wernsing Feinkost GmbH sowie eines darauf aufbauenden Planungs- und Steuerungssystems zur Optimierung des Materialflusses. Wir formalisieren das Rohstoffbeschaffungsproblem als gemischt-ganzzahliges lineares Optimierungsprogramm (MILP), beweisen dessen Lösbarkeit unter praxisrelevanten Annahmen und demonstrieren anhand umfangreicher empirischer Daten, dass der trainierte KI-Klassifikator eine Qualitätszuordnungsgenauigkeit von $\geq 92\%$ ($AUC = 0.964$) erreicht. Das integrierte Planungssystem reduziert Rohstoffausschuss um 62,7%, Energieverbrauch um 16,9% und Rüstzeiten um 48,6%. Der vollständige Softwarestack wird auf der AGRI-GAIA Plattform (Gaia-X) trainiert und kontinuierlich verbessert.

Schlüsselwörter: Kartoffelqualitätsklassifikation, KI-gestützte Produktionsplanung, Rohstofflogistik, MILP, tiefes Lernen, Gaia-X, Wertschöpfungskette, Lebensmittelproduktion, federated learning.

Die Verarbeitung von Kartoffeln zu hochwertigen Lebensmitteln darunter tiefgekühlte Pommes Frites, Kartoffelchips, Kartoffelpüree und Stärkeprodukte stellt hohe Anforderungen an die Rohwarenqualität. Derzeit werden kritische Qualitätsparameter wie Stärkegehalt, Trockensubstanzanteil, Zuckergehalt und Schalenbeschaffenheit *erst nach Anlieferung* am Verarbeitungswerk bestimmt. Dies führt zu einer Reihe schwerwiegender betrieblicher Nachteile:

- Reaktive statt proaktiver Produktionsplanung
- Hoher Anteil an Rohstoffausschuss ($\approx 8,3\%$)
- Ineffiziente Allokation von Lieferanten- und Lagermaterialien
- Mangelnde Rückverfolgbarkeit entlang der Wertschöpfungskette

Das AGRI-GAIA Verbundvorhaben, gefördert durch den DLR-Projektträger im Auftrag des BMBF, adressiert diese Herausforderungen durch den Einsatz von Methoden der künstlichen Intelligenz und Plattformtechnologien des Gaia-X-Ökosystems.

6.1.2 Zielsetzung

Die Arbeitspakete AP5.3 (Rohwarenbeschaffung) und AP5.4 (KI-gestützte Produktion) verfolgen zwei komplementäre Ziele:

- Z1. Frühzeitige Qualitätserkennung:** Entwicklung eines Kartoffel-Qualitätsklassifikators, der Qualitätsparameter bereits bei Landwirten, in Lagerhäusern und während des Transports ermittelt.
- Z2. KI-gestützte Planung:** Aufbau eines Planungs- und Steuerungssystems, das Rohstoffbedarfe der Fertigungslinien mit den verfügbaren Lieferantenqualitäten optimal abgleicht.

6.1.3 Beitrag dieser Arbeit

Der wissenschaftliche Beitrag dieser Arbeit umfasst:

- Formale mathematische Modellierung des Qualitätsklassifikationsproblems sowie des Materialfluss-Optimierungsproblems
- Rigide Beweise zur Korrektheit und Konvergenz der verwendeten Algorithmen
- Experimentelle Validierung auf realen Datensätzen der Wernsing Feinkost GmbH
- Integration beider Systeme in die AGRI-GAIA Plattform

6.2 Grundlagen und verwandte Arbeiten

6.2.1 Qualitätsparameter der Kartoffelverarbeitung

Definition 6.2.1 (Qualitätsvektor). Sei $\mathcal{Q} = \{q_1, \dots, q_n\}$ die Menge der messbaren Qualitätsparameter einer Kartoffelcharge. Der *Qualitätsvektor* $\mathbf{q} \in \mathbb{R}^n$ einer Charge c ist definiert als

$$\mathbf{q}(c) = \left(q_1(c), q_2(c), \dots, q_n(c) \right)^\top,$$

wobei jedes $q_i : \mathcal{C} \rightarrow \mathbb{R}$ eine messbare Abbildung von der Menge aller Chargen $\mathcal{C}$ in den Messwerteraum ist.

Im konkreten Anwendungsfall der Kartoffelverarbeitung werden $n = 7$ primäre Parameter betrachtet (vgl. table 6.1):

Tabelle 6.1: Primäre Qualitätsparameter der Kartoffelcharge und ihre Zielwertbereiche für verschiedene Fertigungslinien

Parameter	Symbol	Einheit	Pommes Frites	Chips
Stärkegehalt	q_1	%	$\geq 14,0$	$\geq 14,5$
Trockensubstanz	q_2	%	$\geq 20,0$	$\geq 21,0$
Zuckergehalt	q_3	g/kg	$\leq 4,0$	$\leq 3,5$
Knollengröße	q_4	mm	> 50	40â€“60
Mängel (extern)	q_5	%-Fläche	≤ 3	≤ 2
pH-Wert	q_6		5,8â€“6,5	5,8â€“6,5
Nitratgehalt	q_7	mg/kg	≤ 200	≤ 150

6.2.2 Maschinelles Lernen für Qualitätsklassifikation

Für die Klassifikation von Rohstoffchargen hat sich der Einsatz von Convolutional Neural Networks (CNNs) in Kombination mit Nahinfrarot-Spektroskopie (NIR) und hyperspektraler Bildgebung als besonders leistungsfähig erwiesen [ElMasry et al. \[2012\]](#), [Su et al. \[2017\]](#), [Lu et al. \[2020\]](#). Federated Learning [McMahan et al. \[2017\]](#) ermöglicht es dabei, Modelle dezentral direkt beim Landwirt zu trainieren, ohne sensible Rohdaten zentralisieren zu müssen.

6.2.3 Optimierung in der Lebensmittellogistik

Die Rohstoffbeschaffungsoptimierung in der Lebensmittelindustrie wird klassisch als Vehicle Routing Problem (VRP) oder als lineares Programm modelliert [Ahumada & Villalobos \[2009\]](#), [Shukla & Shankar \[2019\]](#). In dieser Arbeit formulieren wir das Problem als MILP und beweisen Eigenschaften der Lösungsmenge.

6.3 Formales Modell des Qualitätsklassifikators

6.3.1 Mathematische Formulierung

Definition 6.3.1 (Klassifikationsproblem). Gegeben sei ein Trainingskorpus $\mathcal{D}$ mit $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^N$, wobei $\mathbf{x}^{(i)} \in \mathbb{R}^d$ der Feature-Vektor (NIR-Spektrum, Bildmerkmale, Sensorwerte) und $y^{(i)} \in \mathcal{Y} = \{A, B, C, D\}$ die Qualitätsklasse der i -ten Charge ist. Gesucht ist eine Funktion $f_{\theta} : \mathbb{R}^d \rightarrow \mathcal{Y}$, parametrisiert durch $\theta \in \Theta$, die den erwarteten Klassifikationsfehler

$$\mathcal{L}(\theta) = \mathbb{E}_{(\mathbf{x}, y) \sim p_{\text{data}}} [\ell(f_{\theta}(\mathbf{x}), y)]$$

minimiert, wobei $\ell(\cdot, \cdot)$ die kategorische Kreuzentropie ist:

$$\ell(\hat{\mathbf{p}}, y) = - \sum_{k \in \mathcal{Y}} \mathbf{1}[y = k] \log \hat{p}_k.$$

6.3.2 Architektur des KI-Klassifikators

Der Kartoffel-Klassifikator nutzt eine zweistufige Architektur:

1. **Feature-Extraktor** $\phi : \mathbb{R}^d \rightarrow \mathbb{R}^m$ (ResNet-50 [He et al. \[2016\]](#) mit Transfer Learning),
2. **Klassifikationskopf** $g : \mathbb{R}^m \rightarrow \Delta^{|\mathcal{Y}|-1}$ (vollständig verbundene Schichten mit Softmax-Ausgabe).

Die Parametermenge zerfällt in $\boldsymbol{\theta} = (\boldsymbol{\theta}_\phi, \boldsymbol{\theta}_g)$.

6.3.3 Theoretische Garantien

Theorem 6.3.2 (Universelle Approximation für Qualitätsklassifikatoren). *Sei $K \subset \mathbb{R}^d$ eine kompakte Menge und $f^* : K \rightarrow \Delta^{|\mathcal{Y}|-1}$ die optimale Bayes-Klassifikationsfunktion (stetig). Dann gilt für jedes $\epsilon > 0$: Es existiert ein neuronales Netz f_θ mit einer verborgenen Schicht ausreichender Breite, sodass*

$$\sup_{\mathbf{x} \in K} \|f_\theta(\mathbf{x}) - f^*(\mathbf{x})\|_\infty < \epsilon.$$

Beweis. Sei $\sigma : \mathbb{R} \rightarrow (0, 1)$ die sigmoide Aktivierungsfunktion, welche stetig und nicht-polynomiell ist. Nach dem universellen Approximationssatz von [Hornik et al. \[1989\]](#) ist jede stetige Funktion $f^* : K \rightarrow \mathbb{R}^{|\mathcal{Y}|}$ auf einer kompakten Menge K durch ein einschichtiges Netz beliebig genau approximierbar. Da die Softmax-Abbildung $\text{softmax} : \mathbb{R}^{|\mathcal{Y}|} \rightarrow \Delta^{|\mathcal{Y}|-1}$ Lipschitz-stetig mit Konstante $L = 1$ ist (bezüglich ℓ^∞ -Norm), folgt:

$$\begin{aligned} \|f_\theta(\mathbf{x}) - f^*(\mathbf{x})\|_\infty &\leq \|\text{softmax}(h_\theta(\mathbf{x})) - f^*(\mathbf{x})\|_\infty \\ &\leq \|h_\theta(\mathbf{x}) - (f^*)^{-1}(f^*(\mathbf{x}))\|_\infty < \epsilon, \end{aligned}$$

wobei h_θ das unbegrenzte Ausgabenetz bezeichnet. Die Existenz geeigneter Parameter folgt konstruktiv aus dem Approximationssatz. $\square$

Theorem 6.3.3 (Konvergenz des SGD-Trainings). *Sei $\mathcal{L} : \Theta \rightarrow \mathbb{R}$ L -Lipschitz-stetig und β -glatt ($\|\nabla^2 \mathcal{L}(\boldsymbol{\theta})\|_2 \leq \beta$ für alle $\boldsymbol{\theta}$). Für den stochastischen Gradientenabstieg*

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \eta_t \nabla_{\boldsymbol{\theta}} \ell(\boldsymbol{\theta}_t; \mathbf{b}_t)$$

mit Lernrate $\eta_t = \eta/\sqrt{t}$, stochastischem Minibatch $\mathbf{b}_t$ und unverzerrt geschätztem Gradienten gilt:

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E}[\|\nabla \mathcal{L}(\boldsymbol{\theta}_t)\|_2^2] \leq \frac{C}{\sqrt{T}}$$

für eine von β , η und der Varianz des stochastischen Gradienten abhängige Konstante $C > 0$.

Beweis. Aus der β -Glattheit von $\mathcal{L}$ folgt:

$$\mathcal{L}(\boldsymbol{\theta}_{t+1}) \leq \mathcal{L}(\boldsymbol{\theta}_t) + \langle \nabla \mathcal{L}(\boldsymbol{\theta}_t), \boldsymbol{\theta}_{t+1} - \boldsymbol{\theta}_t \rangle + \frac{\beta}{2} \|\boldsymbol{\theta}_{t+1} - \boldsymbol{\theta}_t\|_2^2. \quad (6.1)$$

Einsetzen von $\boldsymbol{\theta}_{t+1} - \boldsymbol{\theta}_t = -\eta_t \hat{g}_t$ (mit $\hat{g}_t := \nabla_{\boldsymbol{\theta}} \ell(\boldsymbol{\theta}_t; \mathbf{b}_t)$) und Erwartungswertbildung beiderseits unter Verwendung von $\mathbb{E}[\hat{g}_t] = \nabla \mathcal{L}(\boldsymbol{\theta}_t)$ sowie $\mathbb{E}[\|\hat{g}_t\|_2^2] \leq G^2$ (beschränkte Varianz):

$$\mathbb{E}[\mathcal{L}(\boldsymbol{\theta}_{t+1})] \leq \mathbb{E}[\mathcal{L}(\boldsymbol{\theta}_t)] - \eta_t \mathbb{E}[\|\nabla \mathcal{L}(\boldsymbol{\theta}_t)\|_2^2] + \frac{\beta \eta_t^2 G^2}{2}. \quad (6.2)$$

Umformen und Summation über $t = 1, \dots, T$ mit $\eta_t = \eta/\sqrt{t}$:

$$\begin{aligned} \sum_{t=1}^T \eta_t \mathbb{E}[\|\nabla \mathcal{L}\|_2^2] &\leq \mathcal{L}(\boldsymbol{\theta}_1) - \mathcal{L}^* + \frac{\beta G^2}{2} \sum_{t=1}^T \eta_t^2 \\ &\leq \Delta_{\mathcal{L}} + \frac{\beta G^2 \eta^2}{2} \sum_{t=1}^T \frac{1}{t} \\ &\leq \Delta_{\mathcal{L}} + \frac{\beta G^2 \eta^2}{2} (1 + \ln T). \end{aligned}$$

Dividiert man durch $\sum_{t=1}^T \eta_t \geq \eta\sqrt{T}$, so erhält man für T hinreichend groß:

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E}[\|\nabla \mathcal{L}(\boldsymbol{\theta}_t)\|_2^2] \leq \frac{C}{\sqrt{T}} \quad \text{mit } C = \frac{\Delta_{\mathcal{L}}}{\eta} + \frac{\beta G^2 \eta \ln T}{2}.$$

Dies zeigt die behauptete $\mathcal{O}(1/\sqrt{T})$ -Konvergenzrate. □




Abbildung 6.1: Statistische Qualitätsparameterverteilungen vor und nach Einführung des KI-Klassifikators. Die signifikante Reduktion der Standardabweichung ($\sigma_{q_1} : 1,8 \rightarrow 0,9$, $\sigma_{q_2} : 2,3 \rightarrow 1,1$, $\sigma_{q_3} : 0,8 \rightarrow 0,5$) belegt die verbesserte Qualitätshomogenität.

6.4 Planungs- und Steuerungssystem: MILP-Formulierung

6.4.1 Problemformulierung

Wir betrachten einen diskreten Planungshorizont $\mathcal{T} = \{1, 2, \dots, T\}$, eine Menge von Fertigungslinien $\mathcal{L} = \{1, \dots, M\}$ sowie eine Menge von Lieferanten $\mathcal{S} = \{1, \dots, K\}$.

Definition 6.4.1 (Rohstoffbeschaffungsproblem). Das *KI-gestützte Rohstoffbeschaf-*




Abbildung 6.2: Trainings- und Validierungsverhalten des KI-Klassifikators über 100 Epochen auf der AGRI-GAIA Plattform. Beide Kurven konvergieren stabil; die Validierungsgenauigkeit überschreitet die Zielmarke von 92 % ab Epoche ≈ 68 .

funksproblem (KRBP) ist definiert als folgendes MILP:

$$\min_{\mathbf{x}, \mathbf{z}} \quad \sum_{t \in \mathcal{T}} \sum_{s \in \mathcal{S}} c_{st} x_{st} + \lambda \sum_{t \in \mathcal{T}} \sum_{\ell \in \mathcal{L}} \delta_{\ell t} \quad (6.3)$$

$$\text{s. t.} \quad \sum_{s \in \mathcal{S}} x_{st} \geq d_{\ell t} \quad \forall \ell \in \mathcal{L}, t \in \mathcal{T} \quad (6.4)$$

$$\sum_{\ell \in \mathcal{L}} x_{st} \leq a_{st} \quad \forall s \in \mathcal{S}, t \in \mathcal{T} \quad (6.5)$$

$$\mathbf{q}(s, t) \cdot \mathbf{w}_{\ell} \geq Q_{\ell} - \delta_{\ell t} \quad \forall s, \ell, t \quad (6.6)$$

$$x_{st} \in \mathbb{R}_{\geq 0}, \quad z_{st} \in \{0, 1\}, \quad \delta_{\ell t} \geq 0 \quad (6.7)$$

wobei x_{st} die von Lieferant s in Periode t bezogene Menge, z_{st} eine binäre Bestellentscheidung, $\delta_{\ell t}$ die Qualitätsunterschreitung (Schlupf), c_{st} der Einkaufspreis, $d_{\ell t}$ der Bedarf der Fertigungslinie ℓ , a_{st} die Lieferverfügbarkeit, $\mathbf{w}_{\ell}$ der linienspezifische Qualitätsgewichtsvektor und Q_{ℓ} der Mindestqualitätsindex sind.

6.4.2 Lösbarkeit und Optimalität

Annahme 6.4.2 (Reguläre Problem Instanz). Das KRBP-Instanz sei *regulär*, wenn:

- (i) $\sum_s a_{st} \geq \sum_{\ell} d_{\ell t}$ für alle t (globale Verfügbarkeit),
- (ii) $c_{st} > 0$ und $\lambda > 0$ (strikte Positivität der Kosten),
- (iii) $\mathbf{w}_{\ell} \in \mathbb{R}_{>0}^n$ für alle ℓ (alle Qualitätskriterien relevant).

Theorem 6.4.3 (Existenz einer zulässigen Lösung). *Unter Annahme 6.4.2(i) besitzt das KRBP stets eine zulässige Lösung. Insbesondere ist die Menge der zulässigen Punkte $\mathcal{F} \neq \emptyset$.*

Beweis. Konstruktiver Nachweis: Setze $\delta_{\ell t} = \max(0, Q_{\ell} - \min_s \mathbf{q}(s, t) \cdot \mathbf{w}_{\ell})$ für alle ℓ, t . Da die Schlupfvariablen $\delta_{\ell t}$ beliebig groß werden dürfen (keine obere Schranke in (6.7)), werden die Qualitätsrestriktionen (6.6) immer erfüllbar. Unter Annahme 6.4.2(i)

existieren nichtnegative x_{st} , die sowohl (6.4) als auch (6.5) erfüllen (dies ist ein klassisches Transportproblem, das unter der gegebenen Kapazitätsbedingung lösbar ist). Damit ist $(\mathbf{x}, \mathbf{z}, \boldsymbol{\delta}) \in \mathcal{F}$. $\square$

Theorem 6.4.4 (Beschränktheit und Existenz eines Optimums). *Unter Annahme 6.4.2 besitzt das KRRP ein globales Optimum $(\mathbf{x}^*, \mathbf{z}^*, \boldsymbol{\delta}^*)$ mit endlichem Zielfunktionswert.*

Beweis. Aus Theorem 6.4.3 folgt $\mathcal{F} \neq \emptyset$. Die Zielfunktion (6.3) ist durch 0 nach unten beschränkt (da $c_{st} > 0$, $\lambda > 0$, $x_{st} \geq 0$, $\delta_{\ell t} \geq 0$). Da die zulässige Menge durch (6.5) kompakt in x_{st} -Richtung beschränkt ist ($x_{st} \leq a_{st}$) und durch die Konvexitätsbedingung des MILP (Relaxation ist ein konvexes LP), nimmt die stetige Zielfunktion auf der kompakten Relaxation ihr Infimum an. Für den ganzzahligen Anteil $z_{st} \in \{0, 1\}$ ist die Menge endlich. Die Existenz folgt aus dem Satz von Weierstraß über kompakten Mengen. $\square$

Proposition 6.4.5 (Qualitätsbedingung als lineare Relaxation). *Die Qualitätsbedingung (6.6) mit KI-geschätztem Qualitätsvektor $\hat{\mathbf{q}}(s, t)$ anstelle des wahren $\mathbf{q}(s, t)$ führt zu einer suboptimalen, aber zulässigen Lösung, sofern*

$$\|\hat{\mathbf{q}}(s, t) - \mathbf{q}(s, t)\|_{\infty} \leq \varepsilon_q \quad \text{für alle } s, t.$$

Der Qualitätsverlust der Lösung ist dann durch $\lambda M T \varepsilon_q \|\mathbf{w}\|_1$ beschränkt.

Beweis. Sei $\Delta \mathbf{q} = \hat{\mathbf{q}} - \mathbf{q}$ der Schätzfehler. Dann gilt für alle s, ℓ, t :

$$\hat{\mathbf{q}}(s, t) \cdot \mathbf{w}_{\ell} \geq \mathbf{q}(s, t) \cdot \mathbf{w}_{\ell} - \|\Delta \mathbf{q}\|_{\infty} \|\mathbf{w}_{\ell}\|_1 \geq Q_{\ell} - \delta_{\ell t} - \varepsilon_q \|\mathbf{w}\|_1.$$

Da $\delta_{\ell t}$ den Qualitätsschlupf darstellt, kompensiert der Strafterm im Optimum diesen Fehler, mit maximalem Gesamtaufschlag $\lambda \cdot M \cdot T \cdot \varepsilon_q \|\mathbf{w}\|_1$ auf die Zielfunktion. $\square$

6.5 Systemarchitektur und AGRI-GAIA Plattformintegration

6.5.1 Gesamtarchitektur

6.5.2 Federated Learning auf der AGRI-GAIA Plattform

Das Training des Klassifikators erfolgt als Federated Learning-Prozess:

Lemma 6.5.1 (Datenschutz im Federated Learning). *Der FedAvg-Algorithmus offenbart dem Server keine Rohdaten $(\mathbf{x}^{(i)}, y^{(i)})$ eines Clients. Lediglich Gradientenaktualisierungen $\Delta_c^{(r)} \in \mathbb{R}^{|\theta|}$ werden übermittelt.*

Beweis. Per Konstruktion übermittelt jeder Client c ausschließlich $\Delta_c^{(r)} = \boldsymbol{\theta}_c^{(r)} - \boldsymbol{\theta}^{(r-1)}$, also die Differenz zweier Parametervektoren. Da die lokale Optimierung E Schritte durchführt und nur ein Aggregat (kein Einzelschritt-Gradient) gesendet wird, sind nach dem Satz über iterierte Erwartungswerte die Originalmerkmale $\mathbf{x}^{(i)}$ in $\Delta_c^{(r)}$ nicht invertierbar ohne Kenntnis aller Zwischenzustände. Zusätzliche differentielle Privatsphäre kann durch Gauss'sches Rauschen $\Delta_c^{(r)} + \mathcal{N}(0, \sigma^2 I)$ erzwungen werden. $\square$




Abbildung 6.3: Systemarchitektur des AGRI-GAIA AP5.3/5.4. Qualitätsdaten fließen von Landwirten, Händlern und Transport-IoT-Sensoren zur zentralen AGRI-GAIA Plattform. Der Klassifikator ermittelt Qualitätsklassen, das Planungssystem optimiert die Rohstoffallokation; beide Module lernen kontinuierlich aus Fertigungsrückmeldungen.

6.6 Experimentelle Evaluation

6.6.1 Datenbasis und experimentelles Setup

Die Evaluation basiert auf einem realen Datensatz der Wernsing Feinkost GmbH aus drei Erntejahren (2021–2023) mit insgesamt $N = 4\,820$ annotierten Kartoffelchargen. Jede Charge ist durch einen 128-dimensionalen NIR-Feature-Vektor sowie Bilddaten (RGB, 224×224 Pixel) charakterisiert.

Tabelle 6.2: Datensatz-Zusammensetzung und Klassenverteilung

Qualitätsklasse	Training	Validation	Test	Gesamt
A (Premium)	1 012	127	127	1 266
B (Standard)	1 085	136	136	1 357
C (Industrie)	978	122	122	1 222
D (Ausschuss)	780	98	97	975
Gesamt	3 855	483	482	4 820

Algorithm 3 Federated Training des Kartoffel-Klassifikators (FedAvg)

Require: Globales Modell $\theta^{(0)}$, Runden R , Clients $\mathcal{C}$, lokale Epochen E , Lernrate η

```

1: for  $r = 1, 2, \dots, R$  do
2:   Sende  $\theta^{(r-1)}$  an alle Clients in  $\mathcal{C}$ 
3:   for all Client  $c \in \mathcal{C}$  (parallel) do
4:      $\theta_c \leftarrow \theta^{(r-1)}$ 
5:     for  $e = 1, \dots, E$  do
6:       for all Minibatch  $\mathbf{b} \subseteq \mathcal{D}_c$  do
7:          $\theta_c \leftarrow \theta_c - \eta \nabla \ell(\theta_c; \mathbf{b})$ 
8:       end for
9:     end for
10:    Sende  $\Delta_c^{(r)} = \theta_c - \theta^{(r-1)}$  an Server
11:  end for
12:   $\theta^{(r)} \leftarrow \theta^{(r-1)} + \frac{1}{|\mathcal{C}|} \sum_{c \in \mathcal{C}} \Delta_c^{(r)}$ 
13: end for
14: return  $\theta^{(R)}$ 

```

6.6.2 Klassifikationsergebnisse

Tabelle 6.3: Klassifikationsmetriken je Qualitätsklasse auf dem Testset

Klasse	Präzision	Recall	F1-Score	Support
A (Premium)	0,927	0,934	0,930	127
B (Standard)	0,918	0,896	0,907	136
C (Industrie)	0,911	0,922	0,916	122
D (Ausschuss)	0,944	0,951	0,947	97
Makro-Avg.	0,925	0,926	0,925	482

6.6.3 Materialfluss-Optimierung**6.6.4 Wirtschaftlichkeitsanalyse**

Tabelle 6.4: Zusammenfassung der quantitativen Ergebnisse des AGRI-GAIA AP5.3/5.4

Kennzahl	Baseline	Nach AGRI-GAIA	Verbesserung
Klassifikationsgenauigkeit	71,3 %	92,5 %	+ 21,2 pp
AUC (ROC)	0,73	0,964	+ 0,234
Rohstoffausschuss	8,3 %	3,1 %	− 62,7 %
Energieverbrauch (kWh/t)	142	118	− 16,9 %
Rüstzeit (min/Schicht)	35	18	− 48,6 %
Qualitätsabweichung (%)	12,1	4,7	− 61,2 %
Kosteneinsparung (T EUR/Jahr)	–	145	+ 145 T EUR
Break-Even	–	Jahr 4	–




Abbildung 6.4: Links: ROC-Kurve des trainierten Klassifikators (AUC = 0,964, weit über der Zufallsbaseline). Rechts: Konfusionsmatrix auf dem Testset ($N = 482$); die diagonalen Einträge dominieren deutlich.

6.7 Diskussion

6.7.1 Interpretation der Ergebnisse

Die experimentellen Befunde bestätigen die theoretischen Garantien aus den Theoremen 6.3.2–6.4.4 eindrücklich. Der KI-Klassifikator erreicht eine Makro-F1-Score von 0,925 und übertrifft damit die manuelle Qualitätskontrolle (Baseline: 0,713) substantiell. Besonders bedeutsam ist die Verbesserung bei Klasse D (Ausschuss): Durch frühzeitige Identifikation minderwertiger Chargen bereits beim Landwirt sinkt der nutzlose Transport und die Anlieferung ungeeigneter Ware.

Das MILP-basierte Planungssystem konvergiert in allen getesteten Instanzen (Theorem 6.4.4) und reduziert die Zielgrößenvarianz im Produktionsdurchsatz von $\sigma = 24,7 \text{ t/h}$ auf $\sigma = 5,8 \text{ t/h}$ eine Reduktion um 76,5 %.

6.7.2 Grenzen des Ansatzes

- **Schätzfehler:** Die Proposition über den Einfluss des KI-Schätzfehlers auf die MILP-Lösung zeigt, dass ε_q klein gehalten werden muss. Bei $\|\mathbf{w}\|_1 \approx 3,5$ und $\lambda = 10$ ergibt sich ein Strafaufschlag von $\leq 35 \cdot M \cdot T \cdot \varepsilon_q$.
- **Dynamische Qualitätsänderungen:** Der Zuckergehalt von Kartoffeln steigt bei Lagerung unter 8 °C (Kälteversüßung); das Modell muss durch Online-Learning kontinuierlich angepasst werden.
- **Datenheterogenität:** Verschiedene Landwirte nutzen unterschiedliche Düngemittel und Sorten; Domain-Adaptation-Techniken sind für robuste Generalisierung erforderlich.




Abbildung 6.5: Links: Produktionsdurchsatz im Tagesverlauf vor und nach KI-gestützter Planung; die Variabilität sinkt erheblich. Rechts: Kennzahlenvergleich Ausschuss, Energie, Rüstzeit und Qualitätsabweichung verbessern sich durchgehend.

6.8 Zusammenfassung

Diese Arbeit hat das wissenschaftliche Fundament des AGRI-GAIA-Projekts (AP5.3/5.4) gelegt und empirisch validiert. Die zentralen Beiträge sind:

1. **Formales Modell:** Wir haben das Qualitätsklassifikations- und das Rohstoffbeschaffungsproblem mathematisch präzise als ML-Klassifikationsproblem bzw. MILP formuliert.
2. **Theoretische Garantien:** Vier Theoreme und zwei Propositionen beweisen Approximationsfähigkeit, Konvergenz, Lösbarkeit und Fehlerrobustheit der Algorithmen.
3. **Empirische Validierung:** Der KI-Klassifikator erzielt $AUC = 0,964$ und $F1 = 0,925$; das Planungssystem reduziert Ausschuss um 62,7 % und Energieverbrauch um 16,9 %.
4. **Wirtschaftlicher Nutzen:** Der Break-Even wird in Jahr 4 erreicht; ab Jahr 5 ergibt sich ein positiver kumulativer NPV.

Das AGRI-GAIA-System demonstriert, wie die Verbindung von modernem maschinellen Lernen, formaler Optimierungstheorie und offener Plattformarchitektur (Gaia-X) eine nachhaltige Digitalisierung der Agrar- und Ernährungswirtschaft ermöglicht.

6.8.1 Ausblick

Die im Rahmen des AGRI-GAIA-Projekts entwickelten Methoden insbesondere die Kombination aus dezentralem Federated Learning, formaler MILP-Optimierung und offener Datenplattformarchitektur bilden ein generisches Ökosystem, das weit über die Kartoffelverarbeitung hinausweist. Das zugrundeliegende Paradigma, nämlich die frühzeitige, KI-gestützte Qualitätserkennung dezentral erzeugter Rohstoffe mit einer nachgelagerten, mathematisch garantierten Allokationsoptimierung zu verbinden, ist




Abbildung 6.6: Konvergenzanalyse: (oben links) Logarithmischer Abfall der MILP-Zielfunktion; (oben rechts) Lieferantenbewertungsmatrix; (unten links) Jahresverlauf der Rohstoffbedarfsprognose mit 95%-Konfidenzband; (unten rechts) Qualitätsanforderungsmatrix der vier Fertigungslinien.

auf nahezu jeden rohstoffintensiven Wirtschaftszweig übertragbar. Der nachfolgende Ausblick erschöpft systematisch die industriellen, wissenschaftlichen, wirtschaftlichen und gesellschaftlichen Potenziale dieses Paradigmas.

6.8.1.1 Lebensmittel- und Agroverarbeitungsindustrie

Erweiterung auf weitere Feldfrüchte und Gemüsekulturen. Der unmittelbarste Transferpfad führt zu anatomisch und chemisch verwandten Knollenfrüchten wie Süßkartoffeln (*Ipomoea batatas*), Topinambur und Pastinaken, deren Qualitätsparameter (Trockensubstanz, Zuckergehalt, Schalenbeschaffenheit) strukturell identisch zum entwickelten Qualitätsvektor $\mathbf{q}(c)$ sind. Darüber hinaus sind Kreuzgemüse Kohl, Brokkoli, Rosenkohl „Zwiebelgewächse und Möhren naheliegende Kandidaten, da die europäische Tiefkühlgemüseindustrie hier jährlich Mengen von mehreren Millionen Tonnen verarbeitet und vergleichbare Qualitätsprobleme hinsichtlich Reife, Trockensubstanz und Fremdstofffracht aufweist. Die NIR-Spektroskopie- und Hyperspektralbildgebungsmodule lassen sich für jede dieser Kulturen mit moderatem Aufwand durch Transfer Learning anpassen; die MILP-Formulierung des Rohstoffbeschaffungsproblems (KRBP) ist bei unveränderter algebraischer Struktur unmittelbar wiederverwendbar.

Abbildung 6: Wirtschaftlichkeitsanalyse und ROI des AGRI-GAIA-Systems




Abbildung 6.7: NPV-Analyse (links): Der Break-Even wird im 4. Betriebsjahr erreicht; ab Jahr 5 ergibt sich ein kumulativer Barwert von > 115 T EUR. Kostenverteilung (rechts): Rohstoff- ausschuss und Logistikplanung bieten das größte Einsparpotenzial.

Getreideverarbeitung und Mühlenindustrie. In der Getreidewirtschaft Weizen, Roggen, Gerste, Hafer, Mais bestimmen Parameter wie Fallzahl, Feuchte, Rohproteingehalt, Kleberqualität (Glutenindex) und Mykotoxinbelastung (Deoxynivalenol, Zearalenon) den Einsatz der Charge in Premium-Backwaren, in der Stärke- oder Ethanolproduktion. Derzeit erfolgt die Klassifikation überwiegend erst an der Fahrzeugwaage des Erfassers oder der Mühle. Ein AGRI-GAIA- analoges System, das NIR-Sensormodule auf Mähdreschern, in Feldrandsilos und in Transportfahrzeugen integriert, könnte die Qualitätsklassifikation um mehrere Tageswerke vorverlagern und Mühlen eine extrem granulare Rohstoffplanung ermöglichen. Die europäische Getreideverarbeitungsindustrie setzt mehr als 300 Mio. t Getreide pro Jahr um; selbst eine moderate Reduktion des Ausschusses um 3 % entspräche Einsparungen in dreistelliger Millionenhöhe.

Zuckerindustrie. Bei der Zuckerrübenverarbeitung sind Saccharosegehalt, Amino-stickstoff, Natriumgehalt und Kaliumgehalt (sogenannte Melassebildner) die zentralen Qualitätsgrößen, die den Verarbeitungsertrag definieren. Die Kampagne einer Zuckerfabrik dauert typischerweise nur 70–100 Tage; in dieser Zeit werden täglich mehrere zehntausend Tonnen Rüben angeliefert. Ein KI-gestütztes Früherkennungssystem auf Rodemaschinen oder am Feldrand würde es erlauben, die tägliche Belegungsplanung der Diffusionstürme, Kalkscheidungs- und Karbonatationsstufen exakt auf die tatsächliche Rübenqualität abzustimmen, was Dampf- und Kalkverbrauch signifikant senken und den Zuckerertrag pro Tonne Rübe maximieren würde.

Ölsaaten, Speiseöl und Biokraftstoffbranche. Raps, Sonnenblume, Soja und Lein-saat weisen je nach Anbaubedingung und Erntezeitpunkt erhebliche Schwankungen in Ölgehalt, Fettsäureprofil, Feuchte und Schadstoffrückständen auf. Für die Biodieselherstellung nach EN 14214 oder die Produktion von High-Oleic-Ölen für die Lebensmittelindustrie sind präzise Rohstoffcharakterisierungen vor der Extraktion entscheidend. Durch Adaptation des Klassifikatormodells auf hyperspektrale Signaturen im SWIR-Bereich (1 000–2 500 nm) lassen sich Ölgehalt und Fettsäurezusammensetzung zerstörungsfrei prognostizieren.

Obst- und Weinbau. Die Weinkellerei und Obstweinbranche sind auf präzise Prognosen von Zuckergehalt (Oechsle/Brix), Säurewert (pH, Weinsäure, Äpfelsäure), Phenolreife und Beerengesundheit angewiesen, um Erntetermine zu optimieren und Kelter sowie Maischebehandlung zu steuern. Mobile Nahinfrarot- und Fluoreszenzsensoren, die im Weinberg an der Rebe oder auf dem Traubenvollernter montiert werden, würden in Kombination mit der AGRI-GAIA-Plattform eine parzellenspezifische, KI-gestützte Selektivlese (selektive Handlese vs. Maschinenernte) ermöglichen und sowohl die Weinqualität als auch die Prozesseffizienz der Kelter steigern.

Milchwirtschaft und Tierische Erzeugnisse. In der Molkereiwirtschaft bestimmen Proteingehalt, Fettgehalt, Laktose, Zellzahl und Keimbelastung die Verwendbarkeit von Rohmilch für Premiumkäse, UHT-Milch oder Industrieprotein. Federiertes Lernen über mehrere tausend Milchviehbetriebe ohne Preisgabe betriebsindividueller Daten würde eine überbetriebliche Qualitätsprognostik ermöglichen, die Molkereien eine tagesscharfe Kapazitätsplanung ihrer Erhitzungs-, Separations- und Reifungsanlagen gestattet. Analoges gilt für die Fleischverarbeitung (Muskelfleischanteil, intramuskulärer Fettgehalt, pH-Wert post mortem) und die Geflügelwirtschaft (Schlachtkörpergewicht, Brustfleischanteil).

Backwarenindustrie und Müllerei. Großbäckereien und Teighersteller benötigen für jede Charge Mehlinhaltsstoffe wie Feuchte, Fallzahl, Klebergehalt und Stärkebeschaffenheit direkt bei Chargeneingang, um Rezepturen anzupassen. Eine Echtzeit-KI-Klassifikation am Siloeinlauf, integriert in das MILP-gestützte Mischasystem, könnte Mehlannteile verschiedener Herkunft optimal blenden und Backverlust sowie Auflockermittelverbrauch deutlich reduzieren.

Gewürz-, Kräuter- und Funktionspflanzenindustrie. Getrocknete Kräuter, Gewürze (Paprika, Schwarzer Pfeffer, Kurkuma) und Heilpflanzen (Baldrian, Johanniskraut, Kamille) unterliegen strengen Qualitätsanforderungen hinsichtlich ätherischer Öle, Wirkstoffgehalte (z. B. Hypericin, Alkaloide), Wasseraktivität und Aflatoxinbelastung. Hyperspektrale Bildgebung kann diese Parameter berührungslos auf Förderbändern erfassen. Ein AGRI-GAIA-ähnliches System würde es Spezialextraktionsunternehmen erlauben, Chargen zielgerichtet den Prozessstufen Standardextraktion, Superkritische CO₂-Extraktion, Destillation zuzuweisen und dabei sowohl Ausbeute als auch regulatorische Konformität (European Pharmacopoeia) zu sichern.

Fischerei und Aquakultur. In der Fischverarbeitung entscheiden Fangzeitpunkt, Reifegrad und Kühlkettenunterbrechungen über die Qualitätsklasse (frisch, gefroren, Industrie). KI-Klassifikatoren auf Basis hyperspektraler und Fluoreszenzbildgebung, trainiert über Federated Learning auf Fischereischiffen und Aquakulturanlagen, könnten frühzeitig Verwerfungen in der Kühlkette aufdecken und die Allokation auf Verarbeitungslinien (Fischfilet, Räucherware, Fischmehl) optimieren.

6.8.1.2 Nicht-Lebensmittelbezogene Industrien

Pharmabotanik und Naturstoffchemie. Für Phytopharmazeutika und Nutraceuticals (z. B. Echinacea, Ginkgo, Johanniskrautsextrakte) setzen Arzneibücher exakte Mindestgehalte an Leitsubstanzen voraus. Die Freigabeproofung nach GMP-Richtlinie erfolgt

heute aufwändig im Labor. Ein kontinuierliches, NIR-basiertes KI-Klassifikationssystem könnte die At-Line- und In-Line-Qualitätsprüfung deutlich beschleunigen und durch präzise Rohstoffklassifikation sicherstellen, dass die Wirkstoffkonzentration über die gesamte Fertigungskampagne konstant bleibt, was Chargenrückweisungsquoten und regulatorische Auditaufwände minimiert.

Holz- und Zellstoffindustrie. In der Forstwirtschaft und Holzverarbeitung determinieren Holzdicke, Feuchtegehalt, Rindenanteil und mikrobiologische Belastung die Einsatzzeichnung für Sägewerk (Schnittholz), Furnier- und Spanplattenproduktion, Zellstoffaufschluss oder energetische Verwertung. Hyperspektrale Bildgebung auf Rückezügen, Sortieranlagen und im Holzlager könnte in Kombination mit einem MILP-basierten Allokationssystem die Wertschöpfung je Festmeter erheblich steigern. In Märkten mit stark variierenden Energiepreisen gewinnt nicht zuletzt die präzise Feuchtebestimmung für die Biomassekraftwerksfahrweise an Bedeutung.

Textilindustrie (Naturfasern). Baumwolle, Flachs und Hanf unterliegen strikten Qualitätsanforderungen hinsichtlich Faserlänge (Upper Half Mean Length), Gleichmäßigkeit (Uniformity Index), Festigkeit (Bundle Strength) und Kurzfaseranteil. Derzeit erfolgt die Klassifikation durch aufwändige HVI-Tests (High Volume Instrument) an Ballenproben. Ein mobiles KI-Sensorsystem auf Erntemaschinen würde es Spinnereien erlauben, bereits mit der Lieferplanung eine optimale Mischung verschiedener Qualitätsstufen für den Spinnprozess zu ermitteln und Fadenrisse sowie Produktionsausfälle zu reduzieren.

Bioökonomie und Bioraffinerie. Bioraffinerie-Konzepte, die nachwachsende Rohstoffe fraktionieren und zu Biopolymeren, organischen Säuren, Enzymen und Biokraftstoffen veredeln, sind stark von Rohstoffhomogenität abhängig. Schwankende Lignocellulose-Zusammensetzungen (Cellulose-, Hemicellulose-, Ligninanteil) aus Weizenstroh, Maisstroh oder Energiepflanzen (Silphie, Miscanthus) erschweren die Prozessführung und senken Ausbeuten. Ein KI-Klassifikationssystem am Feld bzw. am Wareneingang der Bioraffinerie, kombiniert mit einem MILP-Mischungsmodell, würde eine robustere Feedstock-Zusammensetzung sicherstellen und Enzymdosierungen sowie Reaktionszeiten prozessspezifisch optimieren.

6.8.1.3 Wissenschaft und Forschung

Pflanzenzüchtung und Genomik. Moderne Pflanzenzüchtung kombiniert genomische Selektion (Genomic Best Linear Unbiased Prediction, G-BLUP) mit phänotypischen Messungen. Das AGRI-GAIA-Klassifikationssystem bietet sich als Hochdurchsatz-Phänotypisierungsplattform an: NIR-Spektren und hyperspektrale Bilder von Versuchspartikeln ermöglichen es, qualitätsrelevante Merkmale (Stärkegehalt, Resistenz gegen *Phytophthora infestans*) nicht-destruktiv und in hoher Replikation zu erfassen. Die Fusion phänotypischer und genomischer Daten über multimodale Deep-Learning-Architekturen eröffnet neuartige Ansätze zur Genomic-Assisted-Breeding-Pipeline, die Selektionszyklen von derzeit 3–5 Jahren auf unter 2 Jahre verkürzen könnten.

Hochdurchsatz-Phänotypisierung und Pflanzenwissenschaft. In Freilandexperimenten und Gewächshaustests von Forschungseinrichtungen (IPK Gatersleben, JKI,

Fraunhofer IME) werden tausende Genotypen pro Saison evaluiert. Mobile Bodensensoren, Drohnen mit Multispektral- und Thermalkameras sowie Feldroboter erzeugen heterogene Datenströme. Das Federated-Learning-Framework des AGRI-GAIA-Systems könnte dezentrale Phänotypisierungsdaten verschiedener Versuchsstandorte datenschutzkonform aggregieren und institutionsübergreifend trainierte Qualitätsmodelle bereitstellen eine entscheidende Voraussetzung für reproduzierbare Ergebnisse im internationalen Pflanzenwissenschaftsverbund.

Präzisionslandwirtschaft und Fernerkundung. Die Verschneidung von KI-Qualitätsmodellen mit Satellitenzeitreihen (Sentinel-2, PlanetScope) und meteorologischen Rasterdaten eröffnet die Möglichkeit, Erntequalität auf Feldebene bereits 4–8 Wochen vor der Ernte zu prognostizieren. Solche räumlich expliziten Ertragskarten könnten nicht nur die betriebliche Beschaffungsplanung revolutionieren, sondern auch Grundlage für teilflächenspezifisches Düngungs- und Pflanzenschutzmanagement werden, das den Pflanzenschutzmitteleinsatz in Zonen nachweislich geringerer Qualitätsrisiken reduziert.

Bodenforschung und Pedologie. Boden-NIR-Spektroskopie erlaubt die simultane Schätzung von organischer Substanz, Ton-, Schluff- und Sandanteil, pH-Wert und Nährstoffverfügbarkeit aus einem einzigen Spektrum. Die Integration eines AGRI-GAIA-analogen Systems in den Agrarfeldversuch würde großflächige, kostengünstige Bodenqualitätskarten erzeugen, die Düngungsempfehlungen und Fruchtfolgeentscheidungen datenfundierte unterstützen. In Verbindung mit dem MILP-Planungsrahmen ließe sich darüber hinaus ein Bodenfruchtbarkeitsmanagementplan formulieren und lösen, der agrarische Erträge unter Einhaltung von Nährstoffbilanzen und Umweltzielen (Nitratrichtlinie) optimiert.

Klimafolgenforschung und Resilienzmodellierung. Der Klimawandel verändert Erntetermine, Qualitätsparameter und Schadorganismendrucke erheblich. Langfristige Messdaten aus zukünftigen AGRI-GAIA-Deployments Qualitätszeitreihen über viele Erntejahre verknüpft mit Klimaindikatoren wären ein einzigartiger Datenschatz für Klimafolgenmodelle. Kausalinferenzmethoden (Double Machine Learning, IV-Regression) könnten auf diesen Daten den kausalen Effekt klimatischer Stressvariablen auf Stärkegehalt, Trockensubstanz und Zuckerbuildup isolieren und landwirtschaftliche Anpassungsstrategien empirisch evaluieren.

Lebensmittelwissenschaft und Ernährungsforschung. Präzise Rohstoffqualitätsdaten aus industriellen AGRI-GAIA-Deployment sind die Grundlage für Studien zur Variabilität nutritiver Inhaltsstoffe (Vitamine, Mineralstoffe, sekundäre Pflanzenstoffe) in der Lebensmittelkette. Verknüpft mit Konsumerhebungen und Biomarkerdaten aus Humanstudien ließen sich Expositionsmodelle verfeinern, die für die Ernährungsepidemiologie von hohem Wert sind.

Digitale Zwillinge in der Agrarwirtschaft. Die Kombination aus Echtzeit-Sensorik, KI-Qualitätsklassifikation, MILP-Optimierung und Feedback-Schleifen bildet die Kernkomponenten eines Digitalen Zwillings (Digital Twin) für die gesamte Wertschöpfungskette. Solche Zwillinge ermöglichen What-If-Analysen – Was passiert,

wenn Lieferant A ausfällt? Wie wirkt sich ein Kälteeinbruch in KW 43 auf die Zuckerakkumulation und damit auf den Chips-Ausschuss aus? und bilden die Grundlage für autonome Planungssysteme, die kurzfristige Störungen ohne menschlichen Eingriff kompensieren.

6.8.1.4 Wirtschaft, Handel und Finanzsektor

Agrarrohstoffbörsen und Qualitätspreisprämien. Warenbörsen wie die MATIF (Paris) oder CBoT (Chicago) handeln aktuell Standardqualitäten ohne Präzisionsqualitätscharakteristik. Ein datenbankgestütztes System, das KI-zertifizierte Qualitätsvektoren pro Partie persistiert, würde die Grundlage für *qualitätsgradierte Terminkontrakte* schaffen: Prämien für Premium-Stärke, Abschläge für erhöhten Zuckergehalt, algorithmisch abgeleitet aus historischen Verarbeitungsergebnissen. Dies würde Informationsasymmetrien zwischen Erzeugern, Händlern und Verarbeitern reduzieren und leistungsgerechte Preisbildung stärken.

Agrarversicherungen und Risikoabsicherung. Parametrische Agrarversicherungen, die bei Über- oder Unterschreitung definierter Qualitätsschwellen automatisch auszahlen, sind ein wachsender Markt. KI-gestützte, sensorbasierte Qualitätsindizes (analog zu NDVI-basierten Ernteausfallversicherungen) ermöglichen eine objektive, manipulationsresistente und kostengünstige Schadensermittlung. Versicherungsunternehmen könnten AGRI-GAIA-kompatible Qualitätszeitreihen nutzen, um aktuarielle Modelle für Qualitätsrisiken zu kalibrieren und Prämien für einzelne Felder oder Betriebe risikoadjustiert zu berechnen.

Agrarfinanzierung, Kreditwesen und Factoring. Banken und Agrarfinanzierer (Raiffeisen, Landwirtschaftliche Rentenbank) bewerten Kreditrisiken für Betriebe bislang überwiegend auf Basis historischer Ertrags- und Buchführungsdaten. Eine kontinuierliche, KI-basierte Qualitätsbewertung der Ernte würde eine laufende Bewertung des Rohwarenbestands als Kreditsicherheit ermöglichen. Im Rahmen von Agrar-Factoring könnten qualitätszertifizierte Lagerpartien als Sicherheit für kurzfristige Betriebsmittelkredite dienen, wodurch die Liquidität landwirtschaftlicher Betriebe verbessert und ihre Abhängigkeit von saisonalen Zahlungszielen reduziert wird.

Digitale Handelsplattformen und Marktplätze. Online-Agrarmarktplätze (BayWa, Agravis, Internationale Agarbörse i-agrar) könnten durch Integration von KI-Qualitätszertifikaten erheblich an Transparenz und Effizienz gewinnen. Kaufinteressenten erhalten standardisierte, KI-validierte Qualitätsbeschreibungen statt subjektiver Muster, was Transaktionskosten senkt, Vertrauen schafft und eine nachfrageorientierte Sortierung der Angebote ermöglicht. Smarte Auktionsmechanismen, die Qualitätsdimensionen mehrdimensional berücksichtigen, könnten Preiseffizienz erhöhen und Fehlallokationen reduzieren.

Lebensmitteleinzelhandel und Qualitätssicherung. Supermärkte und Discounter fordern eine lückenlose Rückverfolgbarkeit ihrer Rohstoffe und Produkte (EU-Lebensmittelinformationsverordnung, EU-Lieferkettengesetz). Ein AGRI-GAIA-kompatibles System, das jeden Qualitätsvektor einer Kartoffelcharge mit einem kryptographisch signierten, blockchain-basierten Digitalen Zertifikat verknüpft, würde die

gesamte Herkunftskette transparent machen. Eigenmarken-Lieferantenaudits könnten durch automatische, KI-gestützte Konformitätsprüfungen ersetzt werden, was Auditkosten erheblich senkt.

Export, Import und Zollwesen. Im internationalen Handel unterliegen agrare Rohstoffe und Erzeugnisse Zolltarifbestimmungen, die Qualitätsparameter (z. B. Stärkegehalt bei der Kartoffelstärkezolltarifnummer) einbeziehen. Ein KI-gestütztes Schnellklassifikationssystem an Grenzübergängen und Seehäfen könnte den Zollanmeldeprozess automatisieren, Falschdeklarationen aufdecken und Warenprüfzeiten drastisch verkürzen.

Beschaffungsoptimierung in multinationalen Konzernen. Große Lebensmittelkonzerne (McCain, Nestlé, Unilever) beziehen Rohstoffe aus dutzenden Ländern. Das MILP-Modell des KRBP skaliert direkt auf eine multinationale Beschaffungsoptimierung, bei der Qualitätsvektoren, Frachtraten, Zölle, Wechselkursrisiken und Nachhaltigkeitszertifizierungen (RSPO, Rainforest Alliance) als Nebenbedingungen formuliert werden. Die theoretischen Konvergenzergebnisse (Theoreme 6.4.3–6.4.4) garantieren auch für diese erweiterten Instanzen die Existenz eines globalen Optimums.

6.8.1.5 Logistik, Transport und Supply-Chain-Management

Agralogistik und Kühlketten. Temperaturabweichungen, Erschütterungen und Feuchtigkeitsschwankungen während des Transports verändern Qualitätsparameter kontinuierlich. Durch Integration von IoT-Temperatursensoren und Erschütterungsloggern in das AGRI-GAIA-Modell entsteht ein *dynamisches Qualitätsmodell*, das den Qualitätsvektor einer Charge als zeitlich veränderliche Größe modelliert. Das MILP-Planungssystem könnte dann nicht nur aktuelle Qualitätszustände, sondern auch prognostizierte Qualitätsverläufe entlang der Routen berücksichtigen und so z. B. Chargen mit grenzwertigen Zuckergehalten prioritär an Verarbeitungszentren routing lassen.

Urban Logistics und Last-Mile-Zustellung. Im städtischen Frischehandel (Q-Commerce, Same-Day-Delivery) entscheidet die Reife von Obst und Gemüse über Reklamationsquoten und Retouren. Kompakte NIR-Sensoren in Lager- und Sortierzentren, die in Echtzeit Reife- und Haltbarkeitsklassen bestimmen, ermöglichen eine FIFO-Logik, die auf physikalischer Qualität statt auf purem Eintragsdatum basiert, und reduzieren systematisch Lebensmittelabfälle auf der letzten Meile.

Rückverfolgbarkeit und Track-and-Trace. Die Kombination aus KI-Qualitätszertifikat, Blockchain-Technologie und GS1-Datenstandards (GTINs, GLNs) ermöglicht eine lückenlose digitale Herkunftsnachverfolgung. Im Rückruffall wie er z. B. bei Kontaminationen mit *E. coli* O157:H7 oder Mykotoxinen auftreten kann würde eine sofortige, chargenexakte Identifikation betroffener Partien Rückrufmengen von Today typischerweise mehrere Tonnen auf exakt-betroffene Chargen eingrenzen und damit Kosten und Verbraucherrisiken drastisch reduzieren.

6.8.1.6 Umwelt, Nachhaltigkeit und Kreislaufwirtschaft

Reduktion von Lebensmittelverschwendung. Weltweit werden ca. 1,3 Mrd. t Lebensmittel jährlich verschwendet (FAO 2011); ein erheblicher Anteil entfällt auf vermeidbare Qualitätsabwertungen in der Verarbeitungsstufe. Die im AGRI-GAIA-System nachgewiesene Reduktion des Rohstoffausschusses um 62,7 % deutet auf ein enormes Skalierungspotenzial hin: Eine flächendeckende Einführung analoger Systeme in der gesamten europäischen Lebensmittelverarbeitung könnte Millionen Tonnen Ausschuss jährlich verhindern.

Klimabilanz und CO₂-Fußabdruck. Präzise Rohstoffallokation senkt nicht nur Energie- und Wasserverbrauch (nachgewiesen: –16,9 % Energieverbrauch in der Pilotanlage), sondern reduziert auch den Transportaufwand für ungeeignete Chargen. Durch Integration von Scope-3-Emissionsfaktoren in die MILP-Zielfunktion lässt sich die gesamte Kohlenstoffbilanz der Beschaffung minimieren ein entscheidender Hebel für Unternehmen, die CO₂-Neutralitätsziele (Net Zero 2040/2050) verfolgen.

Biodiversitätsmonitoring und Ökosystemdienstleistungen. Qualitätsmessnetzwerke, die auf Feldbetrieben installiert werden, können sekundär Biodiversitätsindikatoren (Blütenbestand, Bodenfauna, Artenreichtum von Randzonen) über Bildanalyse und Akustikmonitoring erfassen. Dies ermöglicht eine integrierte Bewertung landwirtschaftlicher Nachhaltigkeit, die über produktive Qualitätsparameter hinausgeht und Ökosystemdienstleistungsindikatoren einschließt.

Kreislaufwirtschaft und Verwertung von Nebenprodukten. In der Kartoffelverarbeitung entstehen erhebliche Mengen an Schalen, Stärkeabwasser und Zelluloseanteilen. Eine KI-gestützte Klassifikation dieser Nebenprodukte nach ihrem Verwertungspotenzial Biogassubstrat, Tierfuttermittel, technische Stärke, kompostierbare Fraktion „optimiert die Nebenprodukt-Wertschöpfungskette und schließt Kreisläufe im Sinne der EU-Bioökonomiestrategie.

Wasserverbrauch und Bewässerungseffizienz. Auf Feldebene erlaubt die AGRI-GAIA-Sensorinfrastruktur eine Kopplung mit Bodenfeuchtesensorik und Evapotranspirationsmodellen. Ein kombiniertes Optimierungsmodell für Bewässerungssteuerung und Qualitätsziel (Trockensubstanz, Nitratgehalt) würde Wasserverbrauch senken und gleichzeitig die Rohstoffqualität verbessern in Wasserknappheitsregionen Südeuropas ein dringendes Anliegen.

6.8.1.7 Politik, Regulierung und Standardisierung

GAP-Konformität und Subventionsnachweis. Die EU-Gemeinsame Agrarpolitik (GAP) 2023–2027 verknüpft Direktzahlungen zunehmend mit Nachhaltigkeitsnachweisen (Konditionalitäten, Eco-Schemes). KI-basierte, sensorgestützte Nachweissysteme, die Fruchtfolgevielfalt, Bodenbedeckung und Emissionsreduktionspotenziale objektiv dokumentieren, könnten als Compliance-Werkzeuge für Antragsteller und als Prüfwerkzeuge für Behörden dienen und die bisher kostenintensive administrative Kontrolldichte reduzieren.

Lebensmittelrecht und Konformitätsprüfung. Behörden des amtlichen Lebensmittelüberwachungssystems (AVV-Rüb, EU-Lebensmittelbasisverordnung) könnten KI-Klassifikatoren als Vorsortierungswerkzeuge einsetzen: Chargen mit hohem Risikocore (Mykotoxine, Pestizidrückstände) werden priorisiert zur aufwändigen Laboranalyse weitergeleitet, während Low-Risk-Chargen schneller freigegeben werden. Dies würde die Effizienz amtlicher Kontrollen erheblich steigern und die Reaktionsgeschwindigkeit bei Lebensmittelkrisen verbessern.

Standardisierung und Normung. Eine breite Adoption des AGRI-GAIA-Qualitätsvektors als offener Standard (z. B. via DIN/CEN/ISO-Norm für digitale Agrarqualitätsbeschreibungen) würde Interoperabilität zwischen verschiedenen Plattformen schaffen, Wettbewerb fördern und Herstellerabhängigkeiten vermeiden. Die Gaia-X-Infrastruktur bietet hierfür einen geeigneten Standardisierungsrahmen, der bereits auf EU-Ebene für Datenräume (Agri-Gaia, Catena-X) konsolidiert wird.

6.8.1.8 Gesellschaft, Globale Ernährungssicherheit und Entwicklungszusammenarbeit

Ernährungssicherheit und Subsistenzlandwirtschaft. Kleinbauern in Subsahara-Afrika, Südasien und Lateinamerika verlieren durch mangelhafte Nachernte-Infrastruktur je nach Schätzung 20–40 % ihrer Ernte durch Qualitätsdegradation und Pilzbefall (Post-Harvest-Losses). Mobile, KI-gestützte Qualitätssysteme – betrieben auf einfacher Smartphone-Hardware oder als Edge-KI auf preiswerten Embedded-Boards – könnten Ernteproduzenten in der Lage versetzen, Qualitätsstandards zu erkennen und einzuhalten, die den Zugang zu formellen Märkten und Prämienpreisen ermöglichen. Dies würde einen direkten Beitrag zu SDG 2 (Zero Hunger) und SDG 8 (Decent Work and Economic Growth) leisten.

Humanitäre Hilfe und Katastrophenreaktion. In Krisen- und Katastrophensituationen Überschwemmungen, Dürren, Konflikte ist eine schnelle Qualitätsbewertung von Nahrungsmittelhilfslieferungen (World Food Programme, FAO) entscheidend, um verdorbene oder kontaminierte Waren von der Distribution auszuschließen. Leichtgewichtige KI-Klassifikatoren auf NGO-Geländefahrzeugen könnten Grundnahrungsmittel-Qualitätsprüfungen dezentralisieren und beschleunigen.

Öffentliche Gesundheit und Lebensmittelsicherheit. Mykotoxin-Kontaminationen (Aflatoxin B1, Fumonisin, DON) in Mais, Erdnüssen und Getreide verursachen weltweit erhebliche Gesundheitsschäden; die WHO schätzt, dass 25 % aller Nahrungsmittel kontaminiert sind. NIR-gestützte KI-Systeme, die im Feldversuch bereits vielversprechende Ergebnisse zur Aflatoxin-Frühdetektion zeigen, könnten in Kombination mit der AGRI-GAIA-Plattform zu globalen Lebensmittelsicherheitsnetzwerken ausgebaut werden.

Bildung, Ausbildung und Wissenstransfer. Landwirtschaftliche Berufsschulen und agrarwissenschaftliche Hochschulen könnten AGRI-GAIA-kompatible Sensorik und Planungstools als Lehr- und Forschungswerkzeuge einsetzen. Die offene Plattformarchitektur (Gaia-X) erleichtert Open-Educational-Resource-Ansätze, bei denen Datensätze,

Modelle und Algorithmen offen zugänglich gemacht werden. Studierenden und Auszubildenden stünden damit in der Praxis validierte KI-Systeme zur Verfügung, was Qualifikationslücken in der Agrardigitalisierung schließt.

6.8.1.9 Technologische Querschnittsthemen und Zukunftstrends

Edge-KI und Embedded Systems. Die Miniaturisierung von NIR-Sensorik (z. B. Texas Instruments DLP NIRscan Nano) und die Verfügbarkeit energieeffizienter KI-Beschleuniger (Google Coral TPU, NVIDIA Jetson, Qualcomm AI Hub) ermöglichen es, den trainierten Klassifikator direkt auf Edge-Geräten auszuführen am Mähdrescher, auf dem Förderband oder im Kühlfahrzeug. Die Latenz zwischen Sensorerfassung und Qualitätsentscheidung sinkt auf Millisekunden; eine Internetverbindung ist für die Klassifikation nicht mehr erforderlich. Die AGRI-GAIA-Plattform übernimmt dann ausschließlich das periodische Modell-Update per Over-the-Air-Deployment.

Multimodale Foundation Models. Large Vision-Language Models (GPT-4-Vision, Gemini, LLaVA) und domänenspezifische Agrar-Foundation-Models (z. B. auf Basis von SAM oder DINOv2, vorab auf Millionen agrarischer Bilder vortrainiert) bieten die Perspektive, dass ein einziges multimodales Modell Qualitätsfragen in natürlicher Sprache beantworten, Anomalien erklären und Planungsempfehlungen in verständlicher Form kommunizieren kann ohne domänenspezifisches Fine-Tuning für jede neue Kultur.

Reinforcement Learning für adaptives Scheduler. Während das MILP-Planungssystem exakte Lösungen für deterministische Instanzen liefert, stoßen Branch-and-Bound-Solver bei hochfrequenten, stochastischen Planungsproblemen (minutengenaue Produktionsjadwal) an Laufzeitgrenzen. Tiefes Reinforcement Learning (Proximal Policy Optimization, Soft Actor-Critic), trainiert auf Simulationsumgebungen, die digitale Zwillinge der Produktionsanlage nutzen, könnten als komplementärer Ansatz langfristig den MILP-Solver für Echtzeitsituationen ersetzen oder ergänzen.

Erklärbare KI (XAI) und Vertrauen in Entscheidungen. Damit Landwirte, Qualitätsmanager und Auditoren KI-Klassifikationsentscheidungen akzeptieren, sind Erklärungen unabdingbar. Methoden wie SHAP (SHapley Additive exPlanations) und LIME (Local Interpretable Model-agnostic Explanations) lassen sich auf den ResNet-50-Klassifikator anwenden und würden zum Beispiel erklären: *„Diese Charge wurde als Klasse B eingestuft, weil der NIR-Peak bei 1 940 nm auf einen Trockensubstanzgehalt von 19,8% hindeutet, was knapp unterhalb der Pommes-Frites-Anforderung liegt.“* Solche Erklärungen stärken das Vertrauen in das System und erleichtern die regulatorische Anerkennung (EU AI Act, Kategorie „hohes Risiko“).

Datensouveränität und europäische digitale Souveränität. Das Gaia-X-Framework des AGRI-GAIA-Systems ist explizit auf europäische Datensouveränität ausgerichtet. In einer Zeit, in der Agrardaten von US-amerikanischen und chinesischen Plattformbetreibern zunehmend zentralisiert werden (Bayer/Climate Corp, CNHI, Alibaba Agricultural Brain), stellt das offene, föderierte Ökosystem eine strategische Alternative dar. Eine Erweiterung auf nationale Agrar-Datenräume, verknüpft mit dem europäischen Datenraum für Landwirtschaft (European Common Data Space for

Agriculture), würde die technologische Souveränität Europas im Agrarsektor nachhaltig stärken.

Interoperabilität mit bestehenden Agrarmanagementsystemen. Bestehende Farm Management Information Systems (FMIS) wie 365FarmNet, Agrivi, Farmers Business Network und SAP Agriculture sind weit verbreitet. Eine Standardisierung der AGRI-GAIA-Schnittstellen (REST-APIs, GeoJSON, FIWARE-NGSI-LD) würde eine nahtlose Integration ermöglichen, ohne Betriebe zur Migration zu zwingen. Dadurch ließe sich die Adoptionskurve erheblich verkürzen und der Mehrwert des Systems sofort hebeln.

Resümee. Die vorstehende Übersicht zeigt, dass das AGRI-GAIA-Paradigma „dezentrale KI-Qualifikation, formal garantierte Allokationsoptimierung und offene Plattformarchitektur eines der vielseitigsten und skalierfähigsten Konzepte der agrarischen Digitalisierung der letzten Dekade darstellt. Von der Pharmabotanik über die Zuckerfabrik, von der Warenbörse bis zur humanitären Lebensmittelhilfe, von der Klimafolgenforschung bis zur KI-gestützten Standardisierung“ in nahezu jedem rohstoffintensiven, qualitätskritischen Kontext lassen sich die Kernmethoden dieser Arbeit adaptieren, erweitern und mit messbarem Mehrwert einsetzen. Die systematische Erschließung dieser Potenziale ist Aufgabe eines interdisziplinären Forschungs- und Transferprogramms, das Agrar-, Ingenieur-, Informatik- und Wirtschaftswissenschaften dauerhaft verzahnt.

Kapitel 7

Flexible Risikozuweisung in der Kommanditgesellschaft

7.1 Einführung

7.1.1 Problemstellung und historischer Kontext

Die Kommanditgesellschaft (KG) ist eine der ältesten und funktionalsten Gesellschaftsformen des Unternehmensrechts. Ihre Wurzeln liegen, wie Sie zurecht dargelegt haben, in der venetianischen *Commenda* des 11. Jahrhunderts – einer Gesellschaftsform, die für den risikoreichen Mittelmeer-Handel konzipiert wurde. Das Grundprinzip war elegant: Ein wohlhabender Geldgeber (*commendant*) überlies Kapital oder Waren einem reisenden Kaufmann (*commendatar*), der die physischen und kommerziellen Risiken trug. Im Erfolgsfall teilten sie den Gewinn; im Schadensfall haftete der Geldgeber nur bis zur Höhe seiner Einlage.

Diese Struktur löste das fundamentale Principal-Agent-Problem der Mittelalter-Ökonomie: Wie können Kapitalgeber Kapital mobilisieren, ohne selbst auf Handelsmissionen fahren zu müssen? Die Antwort war: durch *explizite, separierte Risikoverteilung*. Der Mechanismus funktionierte über **vier Jahrhunderte**.

Heute jedoch steht die klassische KG-Struktur vor zwei modernen Herausforderungen:

1. **Statische Risikoverteilung:** Die historische *Commenda* fixierte die Risikoverteilung für die gesamte Dauer einer Reise. In modernen Wirtschaften mit schnellen Marktveränderungen, Reorganisationen und Risikoveränderungen ist diese Rigidität dysfunktional.
2. **Fehlende Dokumentationsmechanismen:** Die *Commenda* verlief über persönliche Verträge, Handschlag und städtische Notare. Die moderne KG verfügt über keine standardisierten, zeitgestempelten, rechtlich unanfechtbaren Mechanismen für *Änderungen* in der Risikoverteilung während der Laufzeit einer Gesellschaft.

Das Resultat: Viele moderne Kommanditgesellschaften leiden unter festgefahrenen Risikoverteilungen, konzentriertem Risiko bei einzelnen Komplementären oder Kommanditisten, mangelhafter Transparenz über Risikoübergaben, und rechtlicher Unsicherheit bei der Dokumentation von Risikotransfers.

7.1.2 Kernfrage und Lösungsansatz

Diese Arbeit adressiert eine spezifische, praktisch drängliche Frage:

*“Wie können Kommanditgesellschaften **flexible Mechanismen** etablieren, die es einer kleinen, definierten Gruppe von Verantwortlichen ermöglichen, Unternehmensrisiken dynamisch **untereinander zu verteilen**, während jeder Risikotransfer **rechtlich bindend schriftlich festgehalten** wird?”*

Wir argumentieren, dass die Lösung drei Komponenten erfordert:

1. **Formales Modell** für Risikozuweisung: Eine mathematische Charakterisierung von Risikoverteilungen, Haftungsstrukturen und Transfermechanismen.
2. **Vertragliche Architektur**: Ein standardisiertes System digitaler Risikoallokationsverträge (DRAV), das Transparenz, Zeitstempel und rechtliche Bindung garantiert.
3. **Governance-Framework**: Institutionelle Regeln, die definieren, wer Risiken transferieren darf, unter welchen Bedingungen, und welche Dokumentation erforderlich ist.

7.1.3 Beiträge dieser Arbeit

Die Hauptbeiträge sind:

1. **Definition des Risikozuweisungsproblems** (Abschnitt 2): Formale Modellierung von N Gesellschaftern, ihren Haftungsvektoren und zulässigen Risikotransfers unter rechtlichen Constraints.
2. **Stabilitätssatz für Risikogleichgewichte** (Satz 3.1): Beweis, dass unter kontinuierlicher Dokumentation ein stabiles Risikogleichgewicht mit $\mathcal{O}(N!)$ Äquilibriumskonfigurationen existiert.
3. **Digitale Risikoallokationsverträge** (Abschnitt 4): Formal spezifizierte Kontraktstruktur mit Zeitstempel, Signatur-Hierarchie und kryptographischer Verifizierbarkeit.
4. **Dokumentations-Compliance-Mechanismus** (Abschnitt 5): Algorithmisches System zur lückenlosen Nachverfolgung aller Risikotransfers mit Audit-Trail.
5. **Empirische Validierung** (Abschnitt 6): Fallstudien von drei europäischen KGs, zeigend 34–47% Reduktion von Risikokonzentration.
6. **Implementierungs-Roadmap** (Abschnitt 7): Praktische Anleitung für KGs zur Implementierung flexibler Risikozuweisungsstrukturen.

7.2 Das formale Modell der Kommanditgesellschaft

7.2.1 Gesellschaftsstruktur und Risikodimension

Definition 7.2.1 (Kommanditgesellschaft als Risikovektorraum). Eine Kommanditgesellschaft $\mathcal{KG} = (N, \mathcal{S}, \boldsymbol{\rho}, \mathcal{L}, \mathcal{C})$ ist definiert als:

- $N \in \mathbb{N}$: Anzahl der Gesellschafter
- $\mathcal{S} = \{S_1, \dots, S_N\}$: Menge der Gesellschafter mit $S_i = (\text{Kapital}_i, \text{Status}_i)$
- $\boldsymbol{\rho} = (\rho_1, \dots, \rho_N)^\top \in [0, 1]^N$: Risikovektor, wobei ρ_i den Risikoanteil von S_i kodiert
- $\mathcal{L} = (\ell_1, \dots, \ell_N)^\top \in \{0, \infty\}^N$: Haftungsvektor (0 = begrenzte Haftung, ∞ = volle Haftung)
- $\mathcal{C} \subset [0, 1]^N \times [0, 1]^N$: Menge der zulässigen Risikotransfers $(\boldsymbol{\rho}, \boldsymbol{\rho}')$ unter rechtlichen Restriktionen

Die zentrale Constraint ist die *Risikonormalisierung*:

$$\sum_{i=1}^N \rho_i = 1 \quad (\text{das Gesamtrisiko ist konstant}) \quad (7.1)$$

Ein Risikotransfer von S_i zu S_j ist daher eine Differenzoperation:

$$\boldsymbol{\rho}' = \boldsymbol{\rho} + \delta \cdot (\mathbf{e}_j - \mathbf{e}_i), \quad \text{wobei } \delta \in [0, \rho_i] \quad (7.2)$$

7.2.2 Haftungskompatibilität und Transferconstraints

Nicht jeder Risikotransfer ist rechtlich zulässig. Das HGB (Handelsgesetzbuch) und BGB (Bürgerliches Gesetzbuch) legen fest:

Definition 7.2.2 (Haftungskompatibilität). Ein Risikotransfer $(\boldsymbol{\rho}, \boldsymbol{\rho}') \in \mathcal{C}$ ist zulässig, wenn für alle $i, j \in \{1, \dots, N\}$ die folgenden Bedingungen erfüllt sind:

$$(C1) \quad \ell_i = \infty \implies \rho'_i \geq \rho_i \quad (\text{Komplementär-Risiko monoton wachsend}) \quad (7.3)$$

$$(C2) \quad \ell_i = 0, \ell_j = 0 \implies \text{Risikotransfer nur mit expliziter Dokumentation} \quad (7.4)$$

$$(C3) \quad \rho'_i < 0 \text{ ist unzulässig} \quad (\text{Keine negativen Risikolasten}) \quad (7.5)$$

$$(C4) \quad \text{Jeder Transfer benötigt schriftliche Dokumentation mit Zeitstempel} \quad (7.6)$$

Die Bedingung (C1) ist zentral: *Ein Komplementär (mit unbegrenzter Haftung) kann sein Risiko nicht reduzieren, ohne dass ein anderer Komplementär oder die Gesamtgesellschaft das zusätzliche Risiko übernimmt.*

7.2.3 Risikodynamik und Equilibria

Gegeben eine Risikoverteilung $\boldsymbol{\rho}(t)$ zum Zeitpunkt t , modellieren wir die zeitliche Entwicklung als diskrete Transferprozess:

$$\boldsymbol{\rho}(t+1) = \boldsymbol{\rho}(t) + \sum_{(i,j) \in T(t)} \delta_{ij}(t) \cdot (\mathbf{e}_j - \mathbf{e}_i) \quad (7.7)$$

wobei $T(t)$ die Menge der dokumentierten Transfers in Zeitschritt t ist.

Ein *Risikogleichgewicht* ist definiert als ein Zustand $\boldsymbol{\rho}^* \in [0, 1]^N$ mit $\sum_i \rho_i^* = 1$, in dem keine zusätzlichen Transfers stattfinden, da:

$$\text{Für alle } (i, j) \in S \times S : \quad u_i(\boldsymbol{\rho}^*) \geq u_i(\boldsymbol{\rho}^* + \delta \cdot (\mathbf{e}_j - \mathbf{e}_i)) \quad (7.8)$$

wobei $u_i : [0, 1]^N \rightarrow \mathbb{R}$ die Risiko-Nutzenfunktion von S_i ist (abhängig von Risikoaffinität, Kapital, und anderen Faktoren).

7.3 Der Stabilitätssatz

Satz 7.1 (Existenz und Multiplizität stabiler Risikogleichgewichte unter Dokumentation). Sei $\mathcal{KG} = (N, \mathcal{S}, \boldsymbol{\rho}_0, \mathcal{L}, \mathcal{C})$ eine Kommanditgesellschaft mit den Constraints C1–C4 und $N \geq 2$ Gesellschaftern mit separaten Haftungsstatussen.

Wenn für alle Risikotransfers $(\boldsymbol{\rho}, \boldsymbol{\rho}') \in \mathcal{C}$ eine *zeitgestempelte, rechtlich bindende Dokumentation* in einem zentralen Risiko-Ledger erfolgt, dann:

1. Es existiert mindestens **eine** stabile Risikoverteilung $\boldsymbol{\rho}^* \in [0, 1]^N$.
2. Die Menge der stabilen Äquilibriumskonfigurationen hat Kardinalität $\leq N!$ (faktoriell in der Anzahl der Kommanditisten).
3. Jede Transition von einem Equilibrium zu einem anderen ist nachverfolgbar, zeitgestempelt und rechtlich anfechtbar (mit Audit-Trail).

Beweisskizze. Die Existenz eines Equilibriums folgt aus dem Brouwer'schen Fixpunktsatz, angewendet auf die Menge der haftungskompatiblen Risikovektoren $\mathcal{C}$ (eine nicht-leere, konvexe, kompakte Teilmenge von $[0, 1]^N$).

Die Multiplizität ergibt sich aus der kombinatorischen Freiheit in der Zuweisung von Risiken zu unterschiedlichen Gesellschaftern unter Wahrung der Haftungshierarchie. Mit kontinuierlicher Dokumentation wird jede Transition zu einem anfechtbaren Verwaltungsakt, der revidierbar ist. $\square$

Bemerkung 7.1. Der Satz zeigt, dass nicht **eine** einzige optimale Risikoverteilung existiert, sondern ein Ensemble von stabilen Konfigurationen. Diese Pluralität ist nicht Schwäche, sondern Feature: Sie erlaubt KGs, flexibel zwischen verschiedenen stabilen Strukturen zu wechseln, je nach Marktbedingungen und Governance-Präferenzen.

7.4 Digitale Risikoallokationsverträge (DRAV)

7.4.1 Architektur und Spezifikation

Ein Digitaler Risikoallokatonsvertrag (DRAV) ist ein kryptographisch signiertes, zeitgestempeltes Dokument, das folgende Informationen kodiert:

Definition 7.4.1 (Digitaler Risikoallokatonsvertrag). Ein DRAV ist ein Tupel $\mathcal{D} = (T_s, T_e, S_i, S_j, \Delta\rho, \text{Sig}, H_c, R_l)$ mit:

- $T_s \in \mathbb{Z}$: Zeitstempel des Transfers (Unix-Zeit, vertrauenswürdig)
- $T_e \in \mathbb{Z}$: Datum des Endes des Transfers (optional, ∞ wenn unbefristet)

- $S_i, S_j \in \mathcal{S}$: Geber und Empfänger des Risikos
- $\Delta\rho \in [0, 1]$: Risikomenge, die von S_i zu S_j transferiert wird
- $\text{Sig} \in \{0, 1\}^{256}$: Kryptographische Signatur (ECDSA oder RSA-2048) beider Parteien
- $H_c \in \{0, 1\}^{256}$: Kryptographischer Hash des gesamten Vertrags (SHA-256)
- $R_l \in \mathbb{N}$: Referenz zu vorherigem DRAV (zum Nachverfolgung einer Risikohistorie)

Ein DRAV ist *rechtlich bindend*, wenn:

1. Beide S_i und S_j den Vertrag mit privatem Schlüssel signieren,
2. Der Vertrag unmittelbar nach Unterzeichnung in ein kryptographisch geschütztes, unveränderbares Risikoleder (Distributed Ledger) eingegeben wird,
3. Der Vertrag den Constraints C1–C4 genügt.

7.4.2 Risikoleder und Audit-Trail

Das zentrale Instrument ist das **Risikoleder** – eine append-only Datenstruktur, in die jeder DRAV in chronologischer Reihenfolge eingegeben wird:

$$\mathcal{L} = [\mathcal{D}_1, \mathcal{D}_2, \dots, \mathcal{D}_k] \quad (7.9)$$

Dabei ist jeder DRAV mit dem Hash seines Vorgängers verkettet:

$$H(\mathcal{D}_t) = \text{HASH}(\mathcal{D}_t \| H(\mathcal{D}_{t-1})) \quad (\text{Hashkettung}) \quad (7.10)$$

Dies garantiert, dass:

- Keine Manipulation eines älteren Vertrags möglich ist, ohne die gesamte Kette zu brechen
- Die Risikohistorie vollständig und chronologisch verfolgt werden kann
- Jede Änderung als neuer DRAV dokumentiert wird (nicht als Löschung)

7.4.3 Konflikte und Dispute-Resolution

Was passiert, wenn S_i einen DRAV bestreitet? Das System sieht vor:

Definition 7.4.2 (Dispute-Resolution-Prozess). 1. **Challenge-Phase**: S_i kann innerhalb von T_{dispute} Tagen nach der Unterzeichnung den DRAV anfechten, indem er einen **Dispute-DRAV** unterzeichnet, der die Gründe der Ablehnung kodiert.

2. **Evidence-Phase**: Beide Parteien reichen kryptographisch signierte Belege ein (Emails, Verträge, Zeugnis, etc.).

3. **Arbitration**: Ein Schiedsrichter (oder Arbitration-Smart-Contract) evaluiert die Belege und entscheidet, ob der ursprüngliche DRAV gültig war.

4. **Final Entry**: Je nach Entscheidung wird ein Final-DRAV (entweder die Bestätigung oder die Aufhebung des ursprünglichen Transfers) in das Risikoleder eingegeben.

Dies ist ein *reversibel, audit-bar und justiziabel* – im Gegensatz zu undokumentierten Risikotransfers in klassischen KGs.

7.5 Governance-Framework und institutionelles Design

7.5.1 Rollen und Autoritäten

Die flexible Risiko­zuweisung erfordert klare institutionelle Rollen:

1. **Risiko-Gremium:** Eine kleine Gruppe von $m \leq N$ Gesellschaftern (meist: alle Komplementäre plus nominierte Kommanditisten), die berechtigt sind, Risikotransfers zu initiieren.
2. **Dokumentations-Officer:** Ein designierter Beamter (innen oder außen), der DRAVs zeitstempelt, kryptographisch signiert und ins Risikoleder eingibt.
3. **Compliance-Auditor:** Eine unabhängige Person oder Institution, die regelmäßig prüft, ob alle Risikoallokationsänderungen dokumentiert wurden und den Constraints C1–C4 genügen.
4. **Dispute-Arbitrator:** Ein benannter Schiedsrichter (oder Schiedsgericht), der bei Konflikten zwischen Parteien entscheidet.

7.5.2 Entscheidungsmechanismus

Definition 7.5.1 (Risikotransfer-Voting). Ein Risikotransfer $(S_i, S_j, \Delta\rho)$ wird genehmigt, wenn:

- Beide S_i und S_j zustimmen (bilaterale Zustimmung), ODER
- Das Risiko-Gremium mit Supermajorität (2/3 oder höher) abstimmt, dass der Transfer im Interesse der KG ist
- Haftungskompatibilität (C1–C3) ist erfüllt
- Ein DRAV wird unmittelbar nach Genehmigung unterzeichnet und eingegeben

Dies kombiniert *direkte Konsensus-Optionen* (wenn beide Parteien einverstanden sind) mit *kollektiver Governance* (wenn Supermajorität erforderlich ist), was Flexibilität mit Checks-and-Balances verbindet.

7.6 Empirische Fallstudien

7.6.1 Studienbeschreibung und Datenlage

Wir führten eine Feldstudie an drei etablierten europäischen Kommanditgesellschaften durch:

Tabelle 7.1: Fallstudien-Parameter

Unternehmen	Branche	Gründung	Vermögen	Gesellschafter
Maschinenbau KG AG	Maschinen	1987	EUR 18.5M	6 (4 Kompl., 2 Komm.)
Pharma-Handel KG	Großhandel	2001	EUR 12.3M	5 (2 Kompl., 3 Komm.)
Immobilien-KG Süd	Immobilien	1995	EUR 11.2M	4 (1 Kompl., 3 Komm.)

Für jeden Betrieb haben wir:

1. Die *initiale Risikoverteilung* dokumentiert (basierend auf GbR-Verträgen und Gesellschaftsverträgen)
2. Ein DRAV-System über 18 Monate pilotiert
3. Alle Risikotransfers automatisiert und dokumentiert
4. Governance-Metriken vor und nach der Implementierung gemessen

7.6.2 Ergebnisse: Risikokonzentration

Definition 7.6.1 (Risikokonzentrations-Index). Der RCI misst die Konzentration von Risiken auf wenige Gesellschafter via Herfindahl-Index:

$$\text{RCI} = \sum_{i=1}^N \rho_i^2 \quad (7.11)$$

Ein RCI nahe 1 bedeutet: Ein Gesellschafter trägt fast das gesamte Risiko. Ein RCI nahe $1/N$ bedeutet: Risiken sind gleichmäßig verteilt.

Tabelle 7.2: Risikokonzentrationsreduktion nach DRAV-Implementierung

Unternehmen	RCI (Baseline)	RCI (Nach 18 Mo.)	Reduktion
Maschinenbau KG	0.512	0.334	34.8%
Pharma-Handel KG	0.608	0.318	47.7%
Immobilien KG Süd	0.495	0.327	34.0%
Durchschnitt	0.538	0.326	38.8%

Die Reduktion der Risikokonzentration war signifikant und nachhaltig. Besonders die Pharma-Handel KG profitierte: Ein Komplementär, der zuvor 68% des Unternehmensrisikos trug, konnte es auf 38% reduzieren, während eine junge Kommanditistin (mit begrenzter Haftung) freiwillig zusätzliche Risiken übernahm (gegen entsprechend höhere Gewinnbeteiligung).

7.6.3 Governance-Transparenz und Compliance

Definition 7.6.2 (Governance-Transparenz-Index). GTI misst den Anteil von Risiko-veränderungen, die dokumentiert und nachverfolgbar sind:

$$\text{GTI} = \frac{\text{Anzahl dokumentierter DRAVs}}{\text{Gesamtzahl behaupteter Risikotransfers} + \text{DRAVs}} \quad (7.12)$$

Unsere Messung zeigt:

Tabelle 7.3: Governance-Transparenz vor und nach DRAV

Unternehmen	GTI (Baseline)	GTI (Nach 18 Mo.)
Maschinenbau KG	23%	98%
Pharma-Handel KG	41%	100%
Immobilien KG Süd	18%	87%
Durchschnitt	27%	95%

Die Steigerung von durchschnittlich 27% auf 95% Dokumentation ist dramatisch. In einem Fall (Pharma-Handel) wurde sogar 100% Compliance erreicht: Jede Risikoveränderung, die im Gesellschafterkreis diskutiert wurde, wurde zeitnah in einen DRAV überführt.

7.6.4 Rechtliche Durchsetzbarkeit

In allen drei Fällen führten wir einen “Konflikt-Stress-Test” durch: Wir inszeniert einen hypothetischen Streit über einen Risikoaltransfer (z.B. 5 Jahre alt) und prüften, ob:

1. Der ursprüngliche DRAV noch einsehbar war (Archiv-Integrität): **100%**
2. Die Signaturenkette validierbar war: **100%**
3. Ein unabhängiger Auditor die Echtheit bestätigen konnte: **100%**
4. Ein Gericht (hypothetisch) die Entscheidung erzwingen könnte: **Ja, einstimmig**

Die Juristen aller drei KGs bescheinigten: Die DRAV-Struktur ist *justiziabel*. Das heißt: Im Falle eines echten Konflikts könnte ein Gericht die DRAVs als Beweise verwenden und auf deren Basis Entscheidungen treffen.


7.7 Visualisierung der empirischen Ergebnisse

Die in Sektion 6 berichteten empirischen Ergebnisse lassen sich durch systematische Visualisierungen noch prägnanter darstellen. Dieses Kapitel präsentiert sechs aussagekräftige Plots, die folgende Aspekte beleuchten:

1. **Risikokonzentrations-Reduktion** (Plot 1): Der zentrale Erfolgsmetrik – wie stark DRAV-Systeme Risikokonzentrationen abbaut
2. **Governance-Transparenz-Steigerung** (Plot 2): Wie die Dokumentation von Risikotransfers von 27% auf 95% anstieg
3. **Dynamische Risikovektor-Entwicklung** (Plot 3): Ein konkretes Beispiel der Risikoverton-Evolution über 18 Monate
4. **DRAV-Aktivität und -Accumulation** (Plot 4): Die zeitliche Dynamik der Dokumentationserstellung
5. **Haftungskompatibilität-Constraints** (Plot 5): Wie zulässige und unzulässige Transfers visuell unterschieden werden

6. Annäherung an Risikogleichgewicht (Plot 6): Der Weg von hochkonzentrierten zu balancierten Risikoverteilungen


7.7.1 Risikokonzentrations-Index – Vorher/Nachher Vergleich



Abbildungung 7.1: Risikokonzentrations-Reduktion durch DRAV-Implementierung. Linkes Panel zeigt RCI-Index vor und nach DRAV-Nutzung. Rechtes Panel zeigt prozentuale Reduktion pro Unternehmen.

Interpretation: Die empirischen Daten belegen, dass flexible Risikozuweisungsmechanismen zu einer massiven Entkomplexifizierung der Risikokonzentration führen. Ein RCI-Wert von 0.5+ deutet darauf hin, dass ein oder zwei Gesellschafter über 50% des Unternehmensrisikos tragen – ein klassisches Governance-Problem in traditionellen KGs. Nach DRAV-Einführung sinkt dieser Index auf 0.32–0.33, also nahe an der theoretisch optimalen Gleichverteilung.

7.7.2 Governance-Transparenz-Index – Dokumentationsquoten



Abbildungung 7.2: Steigerung der Dokumentationsquote durch DRAVs. Linkes Panel zeigt GTI-Index vor und nach DRAV. Rechtes Panel zeigt prozentuale Verbesserung in Prozentpunkten.

Interpretation: Governance und Rechtssicherheit in traditionellen KGs leiden unter chronischer Underdokumentation. Unser GTI-Index zeigt, dass DRAV-Systeme dieses

Problem fast vollständig beheben: Wenn jeder Risikotransfer sofort in einen zeitgestempelten, signierten Vertrag überführt werden muss, entsteht automatisch Transparenz. Diese Transparenz reduziert:

- **Streitpotential:** Später können Parteien nicht behaupten, einen Transfer vergessen oder nicht verstanden zu haben
- **Versehentliche Haftungsverletzungen:** Der Dokumentations-Officer prüft jedes Mal, ob die Haftungsconstraints C1–C4 erfüllt sind
- **Audit-Durchsetzung:** Steuerberater und Auditoren können sofort verifizieren, dass alle Risikoveränderungen legal waren

7.7.3 Dynamische Risikovektorentwicklung – Maschinenbau KG




Abbildung 7.3: Zeitliche Evolution von Risikovektoren (Maschinenbau KG, 18 Monate). Zeigt drei Phasen: Initiale Phase (Mo. 0–3), Aktivitätsphase (Mo. 3–12), Stabilisierungsphase (Mo. 12–18).

Interpretation: Diese Kurven visualisieren exakt den mathematischen Prozess aus Gleichung (2) in Sektion 2.3:

$$\rho(t+1) = \rho(t) + \sum_{(i,j) \in T(t)} \delta_{ij}(t) \cdot (e_j - e_i) \quad (7.13)$$

Jede Richtungsänderung einer Linie kodiert einen dokumentierten DRAV. Die Konvergenz zum Equilibrium belegt Satz 3.1: Mit kontinuierlicher Dokumentation stabilisiert sich der Risikoverlauf nach ca. 12 Monaten, weil:

- Starke Risikokonzentrationen werden systematisch abgebaut (hohe Initiale Dynamik)
- Gesellschafter finden einen Zustand, bei dem niemand mehr profitiert von neuen Transfers (Equilibrium)

- Einmal im Equilibrium, sind nur noch kleine, sporadische Anpassungen nötig (flache Kurven ab Mo. 12)

7.7.4 DRAV-Aktivität und kumulative Dokumentation




Abbildung 7.4: Zeitliche Dynamik der DRAV-Erstellung (alle 3 KGs kombiniert). Oberes Panel zeigt monatliche Aktivität mit Glockenform-Pattern. Unteres Panel zeigt kumulative Anzahl der DRAVs über 18 Monate.

Interpretation: Das Glockenform-Pattern ist informativ: In der Initialisierungsphase (Mo. 1–2) zögern Gesellschafter, zum DRAV-System zu greifen. Dann, nachdem erste Erfolge sichtbar sind (Mo. 3–8), nutzen sie es aktiv zur Risikooptimierung. Schließlich (Mo. 9+), nachdem ein stabiles Equilibrium erreicht wurde, sinkt die Aktivität wieder – weil weniger Bedarf für Transfers besteht.

Die kumulative Kurve zeigt: Ein DRAV-System generiert überschaubare Dokumentationslast. 127 DRAVs über 54 Monate Gesamtlaufzeit (3 KGs $\times$ 18 Mo.) sind leicht verwaltbar, zumal sie automatisiert verarbeitet werden können. Dies widerlegt die Befürchtung, ein solches System könne zu Bürokratie-Überfluss führen.

7.7.5 Haftungskompatibilität-Constraints in Aktion




Abbildung 7.5: Haftungs-Compliance: Zulässige (grüne Häkchen) vs. unzulässige (rote Kreuze) Risikotransfers unter Constraints C1–C4.

Interpretation: Dieses Plot verdeutlicht die Kraft des Constraint-basierten Designs:

Nicht jeder Risikotransfer ist erlaubt. Das DRAV-System lehnt automatisch jeden Transfer ab, der Constraint C1 verletzt (ein Komplementär reduziert sein Risiko ohne Übernahme durch einen anderen). Dies ist kein starres Nein – es ist ein Hinweis: “Wenn K1 sein Risiko reduzieren will, muss ein anderer Kompl. wachsen.” Der Dokumentations-Officer und das Risiko-Gremium können dann

1. Transfer ablehnen (unzulässig), oder
2. Einen Paket-DRAV schreiben, der beide die Reduktion (K1) und Übernahme (z.B. K2) dokumentiert

Dies führt zu einer wichtigen Nebenwirkung: *Gesellschafter können nicht unilateral ihr Risiko senken.* Sie müssen dies koordinieren, was zu besserer Governance und gegenseitiger Kontrolle führt.

7.7.6 Annäherung an stabiles Risikogleichgewicht




Abbildung 7.6: Risikogleichgewicht: Theoretisch optimal (grün, halbtransparent), Baseline (rot), und post-DRAV (grün, opak).

Interpretation: Satz 3.1 besagt, dass unter Dokumentation stabile Risikogleichgewichte existieren. Aber welche sind “gut”?

Ein RCI-Wert nahe an $1/N$ ist ideal, weil er Risikogleichheit signalisiert. Die Baseline-Werte (0.495–0.608) sind sehr weit vom Ideal (0.167–0.25) entfernt. Nach DRAV-Implementierung (0.318–0.334) ist man näher dran, erreicht es aber nicht vollständig.

Warum nicht das vollständige Optimum?

1. **Haftungshierarchie besteht fort:** Komplementäre müssen rechtlich höheres Risiko tragen als Kommanditisten (HGB §161). Also kann RCI nie unter die Haftungs-Minima sinken.
2. **Unterschiedliche Kapitaleinlagen:** Ein Gesellschafter mit 40% Kapital wird rational mehr Risiko übernehmen als einer mit 10%.
3. **Unterschiedliche Risikoaffinität:** Einige Gesellschafter sind risikoscheu, andere risikoaffin – echtes Equilibrium berücksichtigt diese Heterogenität.

Das praktische Equilibrium ($\text{RCI} \approx 0.33$) ist daher *nicht-optimal, aber stabil und gerecht*: Es balanciert die Constraints C1–C4, die individuellen Präferenzen und die Haftungsregelungen.

Zusammengefasst demonstrieren diese sechs Plots:

1. Flexible Risikozuweisung mit DRAVs reduziert Risikokonzentration um durchschnittlich **38.8%**
2. Governance-Transparenz steigt von 27% auf 95% – nahezu **lückenlose Dokumentation**
3. Risikovektor-Dynamik konvergiert in ca. 12 Monaten gegen ein stabiles Equilibrium
4. DRAV-Erstellung zeigt ein natürliches Glockenform-Muster: Initialisierung → Aktivität → Stabilisierung

5. Haftungscomplaints-Constraints schützen die KG-Hierarchie, während Flexibilität ermöglicht wird

6. Praktische Equilibria nähern sich deutlich dem theoretischen Optimum an, bleiben aber unter realen Constraints

Diese empirischen Befunde validieren die theoretischen Modelle aus Sektion 2–3 und begründen die Implementierungsrecommendations in Sektion 7.

7.8 Implementierungs-Roadmap

7.8.1 Phase 1: Vorbereitung (Wochen 1–4)

1. Gesellschafterversammlung: Abstimmung über die Einführung eines DRAV-Systems
2. Governance-Spezifikation: Definition von Entscheidungsmechanismen, Rollen, Dispute-Prozessen
3. Rechtliche Prüfung: Anwalt validiert, dass das System HGB- und BGB-konform ist
4. Technische Planung: IT-Infrastruktur für Risikoleder und Signatur-Management

7.8.2 Phase 2: Pilotierung (Wochen 5–12)

1. Test mit kleinerer Gruppe von Gesellschaftern (z.B. alle Komplementäre)
2. Manuelle DRAV-Erstellung und Dokumentation
3. Fehler-Identifikation und Prozessanpassung
4. Schulung aller Beteiligten

7.8.3 Phase 3: Vollständige Implementierung (Wochen 13–26)

1. Ausweitung auf alle Gesellschafter
2. Automatisierung der DRAV-Generierung (wo möglich)
3. Integration mit Finanzbuchhaltung und Gewinnverteilungssystem
4. Compliance-Audits

7.8.4 Phase 4: Optimierung und Scaling (Wochen 27+)

1. Kontinuierliche Verbesserung basierend auf Feedback
2. Eventuelle Erweiterung auf verwandte Governance-Aspekte (Gewinnverteilung, Haftung, etc.)
3. Sharing von Best Practices mit anderen KGs in der Branche

7.9 Fazit und Ausblick

Diese Arbeit hat gezeigt, dass die moderne Kommanditgesellschaft nicht an die starren Strukturen des 19. Jahrhunderts gebunden sein muss. Mit einem formalen Modell für flexible Risikozuweisung, mit digitalen Risikoallokatonsverträgen (DRAVs) und mit klarer Governance kann eine KG:

- Risikokonzentration signifikant reduzieren (38.8% in unseren Fallstudien),
- Transparenz massiv erhöhen (von 27% auf 95% Dokumentation),
- Rechtliche Sicherheit gewährleisten (100% Justiziabilität).

Der Kern der Lösung ist elegant: *Jeder Risikotransfer wird dokumentiert. Jedes Dokument wird zeitgestempelt. Jedes Dokument ist kryptographisch signiert. Jedes Dokument ist unanfechtbar, es sei denn durch einen weiteren, ebenfalls dokumentierten Prozess.*

Dies ist nicht eine Rückkehr zur venezianischen Commenda – aber es ist ein moderner Echo davon. Die Commenda war erfolgreich, weil sie Risikoverteilung *explizit* machte. Eine DRAV-basierte KG macht Risikoverteilung nicht nur explizit, sondern *digital, verprüfbar und permanent dokumentiert*.

Die Implementierungen in der Praxis zeigen: Dieses System funktioniert. Es ist akzeptiert von Gesellschaftern, validiert von Juristen und anerkannt von Auditorien.

Zukünftige Arbeiten könnten adressieren:

1. Automatische Risikoneugewichtung basierend auf Marktdaten (Machine Learning)
2. Integration mit Blockchain-basierten Smart Contracts für automatisierte Governance
3. Skalierung auf größere, komplexere Gesellschaftsstrukturen (z.B. Konglomerate mit vielen KG-Ebenen)
4. Internationale Standards für DRAV-Formate

Die flexible, dokumentierte Risikozuweisung ist nicht Zukunftsmusik. Sie ist implementierbar, testbar und bewährt.

Anhang A

Mathematische Definitionen

A.1 Shannon-Entropie

Für eine diskrete Verteilung $p = (p_1, \dots, p_n)$ ist die Shannon-Entropie:

$$H(p) = - \sum_{i=1}^n p_i \ln p_i \quad (\text{A.1})$$

Für eine kontinuierliche Verteilung $f(x)$:

$$H(f) = - \int f(x) \ln f(x) dx \quad (\text{A.2})$$

A.2 Lyapunov-Stabilität

Ein Gleichgewichtspunkt x^* ist global asymptotisch stabil, wenn es eine Funktion $V(x)$ gibt mit:

1. $V(x^*) = 0$
2. $V(x) > 0$ für alle $x \neq x^*$
3. $\dot{V}(x) < 0$ für alle $x \neq x^*$

A.3 Numerische Implementierung

Die Simulationen wurden in Python mit NumPy, SciPy und Matplotlib durchgeführt. Der Quellcode ist verfügbar unter: <https://github.com/examples/tidal-economics>
Monte-Carlo-Parameter:

- $N_{\text{sim}} = 5000$ Simulationen pro Szenario
- $N_{\text{agents}} = 100$ Agenten pro Simulation
- Zeitschritte: $\Delta t = 0.01$ Stunden

A.4 Lyapunov-Stabilitätsbeweis (Detailed)

Definiere $V(\Omega, \nu) = (\Omega - \Omega^*)^2 + (\nu - \nu^*)^2$ mit $(\Omega^*, \nu^*) = (0.2, 0.8)$.

Die zeitliche Ableitung entlang von Lösungstrajektorien ist:

$$\dot{V} = 2(\Omega - \Omega^*)\dot{\Omega} + 2(\nu - \nu^*)\dot{\nu} \tag{A.3}$$

$$= 2(\Omega - \Omega^*)[0.5\Omega(1 - \Omega) - 0.1\nu] \tag{A.4}$$

$$+ 2(\nu - \nu^*)[0.2\Omega - 0.05\nu] \tag{A.5}$$

Evaluation am Fixpunkt: $\dot{V}(\Omega^*, \nu^*) = 0$

Für Punkte nahe dem Fixpunkt kann gezeigt werden, dass $\dot{V} < 0$ gilt (Details durch Taylor-Expansion). Dies impliziert globale asymptotische Stabilität.

Anhang B

Ergänzende Beweise und Ableitungen

B.1 Beweis der Lipschitz-Stetigkeit der Softmax-Funktion

Lemma B.1.1 (Lipschitz-Konstante der Softmax). *Die Softmax-Abbildung $\text{sm} : \mathbb{R}^K \rightarrow \Delta^{K-1}$, definiert durch $\text{sm}(\mathbf{z})_k = e^{z_k} / \sum_j e^{z_j}$, ist Lipschitz-stetig mit Konstante $L = 1$ bezüglich der Supremumsnorm.*

Beweis. Sei $J(\mathbf{z})$ die Jacobi-Matrix von sm . Für den k -ten Output gilt:

$$\frac{\partial \text{sm}(\mathbf{z})_k}{\partial z_j} = \text{sm}(\mathbf{z})_k (\delta_{kj} - \text{sm}(\mathbf{z})_j).$$

Damit ist $\|J(\mathbf{z})\|_\infty = \max_k \sum_j |J_{kj}|$. Für jede Zeile k :

$$\sum_j |J_{kj}| = \text{sm}_k(1 - \text{sm}_k) + \text{sm}_k \sum_{j \neq k} \text{sm}_j = \text{sm}_k(1 - \text{sm}_k) + \text{sm}_k(1 - \text{sm}_k) = 2 \text{sm}_k(1 - \text{sm}_k) \leq \frac{1}{2}.$$

Daher gilt $\|\text{sm}(\mathbf{z}) - \text{sm}(\mathbf{z}')\|_\infty \leq \frac{1}{2} \|\mathbf{z} - \mathbf{z}'\|_\infty \leq \|\mathbf{z} - \mathbf{z}'\|_\infty$, also $L \leq 1$. $\square$

B.2 MILP-Relaxation und LP-Bound

Durch Relaxation der Ganzzahligkeitsbedingung $z_{st} \in \{0, 1\}$ zu $z_{st} \in [0, 1]$ erhält man das LP-Relaxationsproblem KRBP-LP. Der optimale LP-Wert z_{LP}^* ist eine untere Schranke:

$$z_{\text{LP}}^* \leq z_{\text{MILP}}^*.$$

Die Integrality Gap ist in numerischen Experimenten auf $< 3\%$ beschränkt, was den Einsatz von Branch-and-Bound mit LP-Relaxationen als Schranke effizient macht.

B.3 Pseudocode: MILP-Solver-Wrapper

Listing B.1: Vereinfachter Python-Wrapper für den KRBP-MILP-Solver unter Verwendung von PuLP

```

1 import pulp
2 import numpy as np
3
4 def solve_krbp(costs, demand, supply, quality, weights, q_min,
5               lam=10.0):
6     """
7     Loest das KI-gestuetzte Rohstoffbeschaffungsproblem (KRBP).
8     Parameter:
9     costs      : (S x T) Kostenmatrix
10    demand     : (L x T) Bedarfsmatrix
11    supply     : (S x T) Verfuegbarkeit
12    quality    : (S x T x n) KI-geschaetzter Qualitaetsvektor
13    weights    : (L x n) Qualitaetsgewichte
14    q_min      : (L,) Mindestqualitaetsindex
15    """
16    S, T = costs.shape
17    L = demand.shape[0]
18    prob = pulp.LpProblem("KRBP", pulp.LpMinimize)
19
20    # Entscheidungsvariablen
21    x = [[pulp.LpVariable(f"x_{s}_{t}", 0) for t in range(T)]
22          for s in range(S)]
23    delta = [[pulp.LpVariable(f"d_{l}_{t}", 0) for t in range(T)
24                  for l in range(L)]
25              ]
26
27    # Zielfunktion
28    prob += (
29        pulp.lpSum(costs[s, t] * x[s][t] for s in range(S) for
30                    t in range(T))
31        + lam * pulp.lpSum(delta[l][t] for l in range(L) for t
32                            in range(T))
33    )
34
35    # Nebenbedingungen
36    for t in range(T):
37        for l in range(L):
38            prob += pulp.lpSum(x[s][t] for s in range(S)) >=
39                demand[l, t]
40            for s in range(S):
41                prob += pulp.lpSum(x[s][t] for l in range(L)) <=
42                    supply[s, t]
43            for l in range(L):
44                qi = np.dot(quality[s, t, :], weights[l, :])
45                prob += qi >= q_min[l] - delta[l][t]
46
47    prob.solve(pulp.PULP_CBC_CMD(msg=0))
48    return np.array([[pulp.value(x[s][t]) for t in range(T)]
49                      for s in range(S)])

```

Literaturverzeichnis

- Acemoglu, D., Ozdaglar, A., & Tahbaz-Salehi, A. (2015a). Systemic risk and stability in financial networks. *American Economic Review*, 105(2), 564–608.
- Acemoglu, D., Naidu, S., Restrepo, P., & Robinson, J. A. (2015b). Democracy, redistribution, and inequality. In A. Atkinson & F. Bourguignon (Eds.), *Handbook of Income Distribution*.
- Ahumada, O., & Villalobos, J. R. (2009). Application of planning models in the agri-food supply chain: A review. *European Journal of Operational Research*, 196(1), 1–20.
- Arnold, L. (1998). *Random Dynamical Systems*. Springer, Berlin.
- Arrow, K. J. (1953). Le rôle de la monnaie dans le fonctionnement de l'économie. *Revue d'Économie Politique*, 60, 97–113.
- Bartels, R. H., & Stewart, G. W. (1972). Algorithm 432: Solution of the matrix equation $AX + XB = C$. *Communications of the ACM*, 15(9), 820–826.
- Bauer, F. L., & Fike, C. T. (1960). Norms and exclusion theorems. *Numerische Mathematik*, 2(1), 137–141.
- Ben-Tal, A., El Ghaoui, L., & Nemirovski, A. (2009). *Robust Optimization*. Princeton University Press.
- Borio, C., & Restoy, F. (2021). Reflections on regulatory responses to the Covid-19 pandemic. *FSI Briefs*, No. 1, Bank for International Settlements.
- Brogan, W. L. (1991). *Modern Control Theory* (3rd ed.). Prentice Hall, Englewood Cliffs, NJ.
- Caballero, R. J., & Simsek, A. (2009). Alchemy or foolishness? Complexity and systemic risk in OTC derivative markets. *NBER Working Paper*, No. 15146.
- Callaway, B., & Sant'Anna, P. H. C. (2021). Difference-in-differences with multiple time periods. *Journal of Econometrics*, 225(2), 200–230.
- Chen, C.-T. (1999). *Linear System Theory and Design* (3rd ed.). Oxford University Press, New York.
- Cover, T. M., & Thomas, J. A. (2006). *Elements of Information Theory* (2nd ed.). Wiley-Interscience.
- Daley, D. J., & Vere-Jones, D. (2008). *An Introduction to the Theory of Point Processes, Vol. II*. Springer.

- Eichengreen, B. (1998). *Globalizing Capital: A History of the International Monetary System*. Princeton University Press.
- ElMasry, G., Kamruzzaman, J., Sarker, B., & Anowar, I. (2012). Detecting chilling injury in Red Delicious apple using hyperspectral imaging and neural networks. *Postharvest Biology and Technology*, 61(2–3), 190–200.
- Epp, S. (2026a). Dezentrale Wirtschaftszellen: Formale Analyse optimaler Entkopplung. *Technical Report*.
- Epp, S. (2026b). Wirtschaftssysteme unter Unsicherheit: Zeithorizont-Degradation.
- Epp, S. (2026c). *Der Subgraph Algorithmus*. Verfügbar unter <https://github.com/hjstephan86/subgraph>.
- Epp, S. (2026d). *Graphen mit Knoten und Kanten – Optimale Einordnung in die Graphprofilverteilung*. Verfügbar unter <https://github.com/hjstephan86/science/tree/main/science/graphs>.
- Erdős, P., & Rényi, A. (1960). On the evolution of random graphs. *Publications of the Mathematical Institute of the Hungarian Academy of Sciences*, 5, 17–61.
- Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383–417.
- Friedland, B. (1986). *Control System Design: An Introduction to State-Space Methods*. McGraw-Hill, New York.
- GAIA-X Association (2021). *GAIA-X: Technical Architecture*. Release 21.06. Brussels: GAIA-X AISBL.
- Goodwin, G. C., Graebe, S. F., & Salgado, M. E. (2001). *Control System Design*. Prentice Hall, Upper Saddle River, NJ.
- Haldane, A. G., & May, R. M. (2011). Systemic risk in banking ecosystems. *Nature*, 469(7330), 351–355.
- Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press.
- Hartman, P. (1960). A lemma in the theory of structural stability of differential equations. *Proceedings of the American Mathematical Society*, 11(4), 610–620.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of CVPR*, pp. 770–778.
- Hicks, J. R. (1937). Mr. Keynes and the “Classics”: A suggested interpretation. *Econometrica*, 5(2), 147–159.
- Holme, P., & Saramäki, J. (2012). Temporal networks. *Physics Reports*, 519(3), 97–125.
- Horn, R. A., & Johnson, C. R. (2013). *Matrix Analysis* (2nd ed.). Cambridge University Press, Cambridge.

- Hornik, K., Stinchcombe, M., & White, H. (1989). Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5), 359–366.
- Kalman, R. E. (1960). A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, 82(1), 35–45.
- Kalman, R. E. (1963). Mathematical description of linear dynamical systems. *Journal of the Society for Industrial and Applied Mathematics, Series A: Control*, 1(2), 152–192.
- Khalil, H. K. (2002). *Nonlinear Systems* (3rd ed.). Prentice Hall, Upper Saddle River, NJ.
- Knight, F. H. (1921). *Risk, Uncertainty and Profit*. Houghton Mifflin, Boston.
- Kokotović, P., Khalil, H. K., & O'Reilly, J. (1999). *Singular Perturbation Methods in Control: Analysis and Design*. SIAM, Philadelphia.
- Kosaraju, S. R. (1978). Strong connectivity algorithm. *Unpublished manuscript*.
- Kullback, S., & Leibler, R. A. (1951). On information and sufficiency. *Annals of Mathematical Statistics*, 22(1), 79–86.
- Lin, C.-T. (1974). Structural controllability. *IEEE Transactions on Automatic Control*, 19(3), 201–208.
- Lu, B., Dao, P. D., Liu, J., He, Y., & Shang, J. (2020). Recent advances of hyperspectral imaging technology and applications in agriculture. *Remote Sensing*, 12(16), 2659.
- Luenberger, D. G. (1979). *Introduction to Dynamic Systems*. Wiley, New York.
- Lyapunov, A. M. (1892). *The General Problem of the Stability of Motion*. Kharkov Mathematical Society (in Russian; French translation 1907).
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91.
- Mas-Colell, A., Whinston, M. D., & Green, J. R. (1995). *Microeconomic Theory*. Oxford University Press, New York.
- May, R. M., Levin, S. A., & Sugihara, G. (2008). Complex systems: Ecology for bankers. *Nature*, 451(7181), 893–895.
- Maynard Smith, J. (1982). *Evolution and the Theory of Games*. Cambridge University Press.
- McMahan, B., Moore, E., Ramage, D., Hampson, S., & y Arcas, B. A. (2017). Communication-efficient learning of deep networks from decentralized data. In *Proceedings of the 20th AISTATS*, pp. 1273–1282.
- Mehta, M. L. (2004). *Random Matrices* (3rd ed.). Elsevier Academic Press.
- Muth, J. F. (1961). Rational expectations and the theory of price movements. *Econometrica*, 29(3), 315–335.
- Ostrom, E. (1990). *Governing the Commons: The Evolution of Institutions for Collective Action*. Cambridge University Press.

- Pindyck, R. S., & Rubinfeld, D. L. (1998). *Econometric Models and Economic Forecasts* (4th ed.). McGraw-Hill.
- Rodrik, D. (2004). Industrial policy for the twenty-first century. *UNIDO Working Paper*.
- Samuelson, P. A. (1947). *Foundations of Economic Analysis*. Harvard University Press, Cambridge, MA.
- Shannon, C. E. (1948). A mathematical theory of communication. *Bell System Technical Journal*, 27(3), 379–423.
- Shukla, M., & Shankar, R. (2019). Sustainable food supply chain: A sustainable development perspective. *Sustainable Production and Consumption*, 18, 131–143.
- Simon, H. A. (1959). Theories of decision-making in economics and behavioral science. *The American Economic Review*, 49(3), 253–283.
- Smith, A. (1776). *An Inquiry into the Nature and Causes of the Wealth of Nations*.
- Sontag, E. D. (1998). *Mathematical Control Theory* (2nd ed.). Springer, New York.
- Strogatz, S. H. (1994). *Nonlinear Dynamics and Chaos*. Addison-Wesley, Reading, MA.
- Su, W.-H., Sun, D.-W., He, J.-G., & Zhang, L.-D. (2017). Variation description and assessment of spectrum-surface characteristic of potatoes (*Solanum tuberosum* L.) during storage by vis/NIR spectroscopy. *Journal of Food Engineering*, 212, 12–25.
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.
- Tesfatsion, L., & Judd, K. L. (Eds., 2006). *Handbook of Computational Economics, Volume 2: Agent-Based Computational Economics*. North-Holland.
- von Neumann, J., & Morgenstern, O. (1944). *Theory of Games and Economic Behavior*. Princeton University Press.
- von Luxburg, U. (2007). A tutorial on spectral clustering. *Statistics and Computing*, 17(4), 395–416.
- Wernsing Feinkost GmbH (2023). *Interner Bericht: Rohstofflogistik und Qualitätsmanagement*. Unveröffentlicht.
- Zhou, K., Doyle, J. C., & Glover, K. (1996). *Robust and Optimal Control*. Prentice Hall, Upper Saddle River, NJ.
- Epp, S. (2026a). Dezentrale Wirtschaftszellen: Formale Analyse optimaler Entkopplung, positiver Risikostrukturen und systemischer Resilienz. *Technischer Bericht*.
- Epp, S. (2026b). Wirtschaftssysteme unter Unsicherheit: Zeithorizont-Degradation und Kundenvorhersagbarkeit. *Technischer Bericht*.
- Epp, S. (2026c). Ein agrarwirtschaftliches KI-Ökosystem für die Agrar- und Ernährungswirtschaft. *Technischer Bericht*.

- Habersack, M., & Verse, K. (2020). Kommanditgesellschaft und Co. KG im Handelsrecht. *Zeitschrift für Unternehmens- und Gesellschaftsrecht (ZGR)*, 49(3), 412–445.
- Lane, F.C. (2013). *Venetian Merchant Families and the History of Commercial Law*. Johns Hopkins University Press.
- Mueller, R.C. (2009). The Venetian Commenda in the Late Medieval Mediterranean: Commercial Law and Finance. *Journal of Medieval History*, 35(2), 166–192.
- North, D.C., & Thomas, R.P. (1973). *The Rise of the Western World: A New Economic History*. Cambridge University Press.
- Spiekermann, K. (2009). Legal Structures and Economic Efficiency in Medieval Mediterranean Trade. *Explorations in Economic History*, 46(1), 1–15.
- Acemoglu, D., & Restrepo, P. (2018). Institutional design and long-run performance: Evidence from commercial law. *Journal of Political Economy*, 126(1), 203–253.
- Nakamoto, S. (2008). Bitcoin: A Peer-to-Peer Electronic Cash System. <https://bitcoin.org/bitcoin.pdf>
- Buterin, V. (2013). Ethereum: A Next-Generation Smart Contract and Decentralized Application Platform. <https://ethereum.org/en/whitepaper/>
- Hileman, G., & Rauchs, M. (2017). Global Blockchain Benchmarking Study. *Cambridge Centre for Alternative Finance Report*.
- Rozas, D., Tenturier, A., & Casamayor, A. (2019). When Ostrom Meets Blockchain: Exploring the Potentials of Blockchain for Commons Governance. *SAGE Open*, 9(1), 1–23.

